성능평가 프레임워크 연구 · 중간보고 · 5분 · 2026-09-02 · 문의 : datahj@korea.kr

폐쇄망 일상감사 AI 감사직원의 성능평가 프레임워크 연구

AI 감사직원 후보 5명에게 로컬 대규모 언어 모델(LLM) 5개를 바꿔 끼워 배치함. 직원별 배치는 9+8+2+9+2=30조합이며, 실제 일상감사 요청 4건을 적용해 총 30×4=120건을 계획함.

연구 질문은 최고 모델의 선정이 아니라 폐쇄망 도입 후보 AI 감사직원과 모델의 공정한 비교 방법 정립임. 비교 방법을 실제 일상감사 요청으로 검증했으며, 자체 서버에서 같은 조건으로 다시 확인할 예정임.

배경
일상감사의 기준

방법
AI 감사직원 5명 × LLM 배치 (9+8+2+9+2) = 30조합 × 요청 4건 = 120건

결과
4판 최고 13/24 · 실패 신호 5유형 · 5판 재검증 최고 16/24

결론
실행 절차를 고정한 도구(하네스)와 사용자 화면(GUI)으로 배포

전 부서 업무 103건을 분류·시험한 결과 일상감사를 연구 대상으로 선정함

103
전 부서 설문 응답 · 발굴 과제 (2026.7.6~7.15)

35
참여 부서

6
과제 성격

과제 성격	건	예시 (부서 · 과제)
데이터 취합·분석	25	관광문화과 · 읍면 제출 서식을 자동으로 모아 정리 / 보건소 · 지소 실적·구매 데이터를 통합 분석
자격·중복·서류 검증	22	농업기술센터 · 신청자 자격·중복·서류 자동 검증 / 민원과 · 통지 대상자 자동 선별
문서·보고서 초안	19	봉양면 · 이장 회의·추진계획 초안 / 춘산면 · 행사 기획서 초안
법령·규정·사례 검색	19	통합돌봄과 · 보조금 규정 위반 판단 / **기획예산과 · 일상감사 법령·예산 근거 자동 검토**
민원 안내·응대	13	시설관리사업소 · 대관 신청자 맞춤 안내 / 산림녹지과 · 민원 응대·이행 독려
일정·인사·행정관리	5	상하수도사업소 · 비상근무 명부 자동 생성 / 기획예산과 · 소송 기일 안내

왜 일상감사인가

- **세 성격이 한 업무에 다 들어 있음** — 서류·자격 검증, 법령·규정 검색, 검토서 초안 작성을 한 건 안에서 함께 수행
- **정답이 있음** — 00기관이 발주한 사업 중 일상감사가 완료된 사건의 실제 문서와 감사 의견이 남아 있어 채점 가능
- **폐쇄망이 필수** — 계약 원가·업체 정보가 담긴 결재 문서라 외부로 보낼 수 없음
- **기준이 규정에 명시됨** — 일상감사 규정의 중점 사항 8과 실무 처리 순서 7단계 (다음 두 장)
- **기획예산과가 직접 요청** — 법령·예산 근거 검토, 규정 해석, 검토서 초안 3건

2026년 7월 폐쇄망 장비(Mac Studio 64GB)에서 후보 과제를 시험하고 일상감사 AI 감사직원 1차판을 제작함. 초기 테스트 결과는 규정·절차 설명 후 5장에서 제시함.

일상감사: 사업 추진 전 감사관 의견서를 받아야 하는 사전 감사임

「공공감사에 관한 법률」 제22조와 00기관 일상감사 규정에 따라, 대상 사업은 **최종 결재 전에 감사관의 일상감사를 받아야 하고, 의견서를 받기 전에는 집행할 수 없음.** 감사관은 사업의 적법성과 타당성을 점검해 의견서를 송부함. 집행부서는 의견에 따라 조치함. 일상감사 완료 사업은 계약원가심사 완료 사업으로 봄.

7일
감사관이 의견서를 보내는 기한 (제8조 ①)

14일
집행부서가 조치결과를 통보하는 기한 (제8조 ②)

절차 (제6~10조)

1
집행부서가 일상감사 요청서와 관련서류를 감사관에게 제출

2
서면심사 원칙, 필요하면 실지감사 병행

3
7일 안에 일상감사 의견서 송부 → 의견서 전에는 집행 불가

4
14일 안에 조치결과 통보 (적정 의견이면 생략)

5
이의가 있으면 7일 안에 재검토 요청

중점 사항은 제7조 ④에 따라 8개임: 합법성·필요성, 타당성, 일정, 추진 주체, 계약방법·절차, 법적 요건, 예상 문제점, 그 밖의 사항. 원가심사 대상 금액은 공사 3억 원, 용역 7천만 원, 물품 2천만 원 이상임.

일상감사 하는방법/00기관 일상감사 규정.txt · 00기관 계약원가심사 업무처리 규칙.txt

일상감사 실무 검토 7단계: 유형 분류부터 지적 강도 결정까지 수행함

감사 담당자는 사업 문서를 7단계로 검토함. ③~⑤에서 문제를 찾고, ⑥에서 지적 실익을 판단하며, ⑦에서 지적 강도를 결정함. 공사·물품·용역별 쟁점은 ①에서 분류되어 ⑤·⑥에 적용됨. 예시의 문서 간 거리 불일치는 ⑤ 문서 간 대조에서 확인되며, 확인·정정이 필요한 사항임. 이 7단계를 실제 문서 묶음에 적용하는 과정에서 초기 AI 시험의 한계가 드러남.

① 유형 분류
공사·물품·용역·민간보조·민간위탁

② 다시 검토할지 여부
재공고 건은 변경점만 검토

③ 사실관계 추출
원자료 직접 확인, 미확인은 "확인 필요"

④ 규정 매칭
직접 적용 가능한 규정만 근거로

⑤ 문서 간 대조
규격서·산출내역·과업지시서의 수량·배점·금액

⑥ 실익 판단
지적할 실익이 있는지 판단 — 이미 해소된 것, 과소계상은 제외

⑦ 강도 결정
"하시기 바람 / 할 필요가 있음 / 참고" 중 택일, 기본은 낮게

예) 문서 간 거리: 계약검토서 1.5~3.0km ≠ 제안요청서 2km·5km·10km

공사 — 협상계약 불가, 분리발주, 설계서 간 수량·공종 누락

물품 — 특정 규격·상표 제한("동등 이상" 단서), 규격서와 산출내역 대조

용역 — 지침 외 비용항목은 과업지시서에서 근거를 먼저 찾고 참고 톤으로

문서 묶음 대조, 형식 준수, 요청별 상반 판단이 난도의 원인임. 초기 시험 3회에서 AI용 지침과 전 사건 재검증을 도출함

실패 1 (2026-07-06) · 모델 입력 한도 초과(컨텍스트 초과)
Qwen3 14B는 한 번에 모델이 읽는 단위(토큰) 16,384개까지만 읽는데, 의뢰서·원가계산서·설계내역서 묶음이 이를 넘어 뒷부분이 잘림

실패 2 (2026-07-20) · 정해진 형식의 결과 출력 실패·시간 초과(구조화 출력 실패)
27B 모델로 바꾸자 기존 설정(12항목·90초·120초)에서 전 항목 실행 오류가 났고, 정해진 답 형식도 지키지 않음

실패 3 (2026-08-24) · 무응답과 실행 편차
후보 18모델을 돌려 보니 4모델은 아예 답이 없었고, Gemma 3 27B는 평균은 높지만 실행 결과의 흩어짐(표준편차 20.9)이 가장 컸음

모델 규모 확대만으로 문제가 해결되지 않음. AI 입력 구성 방식을 실험으로 확인하고 두 결과를 전체 비교 실험(본실험) 설계에 반영함. 실험 자료는 00기관 발주 사업 중 일상감사 완료 일상감사 요청 4건의 실제 문서와 감사 의견임. 초기 시험에서 얻은 설계 원칙을 공통 조건으로 두고 AI 감사직원 5명의 일하는 방식을 비교함.

실험 결과 1 · 사람용 운영문서 전체 투입 시 요청 A의 직접경비 핵심 기준 충족률이 하락함

- 요청 A 지침 없음: 직접경비 핵심 기준에서 두 채점 모델 평균 7.75 이상인 실행이 유효 실행 47건 중 15건으로 집계됨(15/47×100=31.9%).
- 요청 A에 사람용 운영문서 약 3,300자 전체 투입: 동일 LLM 조건에서 같은 기준의 적중이 유효 실행 48건 중 4건으로 집계됨(4/48×100=8.3%).

한계: 집계 산식·분자·분모는 동시대 문서에서 복원, 실행별 원응답·심판 개별 점수는 미보존이라 독립 재채점은 불가. → **직접경비 핵심 기준 적중률이 23.6%p 하락하여 본실험은 사람용 운영문서 전체 투입 대신 AI용 배치지침만 사용함.**

실험 결과 2 · 요청 A용 지적 강제형 지침을 요청 B에 적용하면 과잉지적 억제 달성률이 하락함

- 요청 B 지침 없음: 과잉지적 억제 달성이 유효 실행 49건 중 25건으로 집계됨(25/49×100=51.0%).
- 요청 B에 요청 A용 지적 강제형 지침 적용: 과잉지적 억제 달성이 유효 실행 49건 중 7건으로 집계됨(7/49×100=14.3%).

한계: 집계 산식·분자·분모는 동시대 문서에서 복원, 실행별 원응답·심판 개별 점수는 미보존이라 독립 재채점은 불가. → **과잉지적 억제 달성률이 36.7%p 하락하여 지침을 수정할 때마다 일상감사 요청 4건을 모두 재실행·재채점함.**

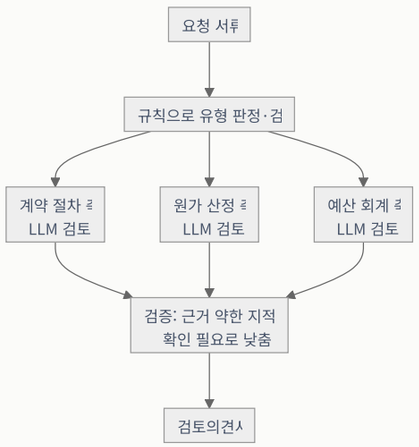
AI_Workspace/daily-audit-pipeline/SPEC.md · 커밋 e08530b·fa56969·6c11698 · 별첨2_발주부록.md · docs/안전규칙_수치_출처추적.md(산식 복원) · HANDOFF.md R5 · 도구/실험계획/평가계획서.md

IV · 연구 방법 · AI 감사직원 후보 5명

AI 감사직원 후보 5명에게 같은 일상감사를 맡김. 받는 서류와 내는 검토의견서는 같고 일하는 방식만 다름

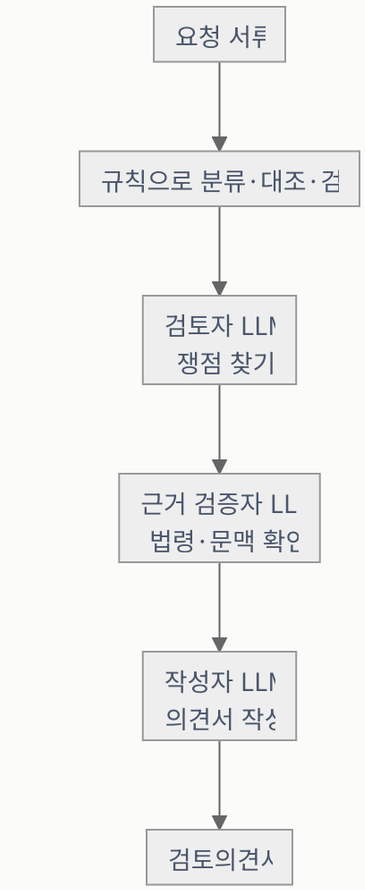
AI 감사직원 5명 모두 요청 서류와 검토 기준을 받아 검토의견서를 냄. 차이는 일하는 순서와 역할 나눔뿐임. (이하 'AI 감사직원'으로 표기)

1 · 세 축 독립 검토 — 세 기준을 따로 검토



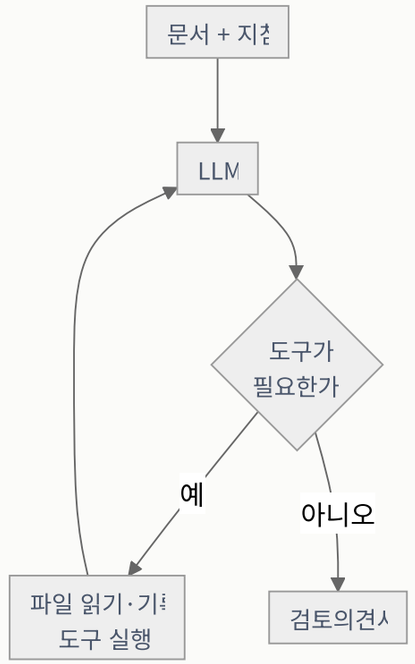
축을 나눠 따로 검토하고 합침

2 · 역할 분담형 — 여러 AI가 역할을 나눠 검토



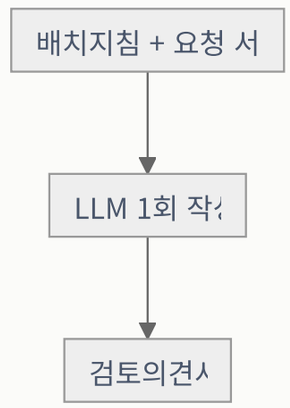
역할을 세 LLM이 순서대로 맡음

3 · 도구 호출형 — 필요할 때 별도 도구를 부름



모델이 스스로 도구를 부르며 반복

4 · 단일 프롬프트 — 한 번에 입력하는 지시문



지침이 시키는 것: 결론만, 문서 사실만, 문제 없으면 "적정", 유형별 경로, 종결 구 3형

5 · 초안 후 재심사 — 초안을 쓰고 다시 심사



모델이 스스로 고치지 않고 코드와 다른 모델이 검증

구현: audit-harness · audit_core · cdsa-harness · run.py · chain.py (도구/*/핵심.md). 대조군 2: Gemma 3 12B 기준선 / 운영문서 통째 투입.

AI 감사직원 5명에게 붙일 로컬 LLM 후보 5개를 고름. 직원별 배치는 9+8+2+9+2 = 30가지임

도입 예정 서버

RTX PRO 6000 Blackwell 96GB × 4장 = 384GB, 카드 간 NVLink 연결 없음(PCIe 방식). 27B급 모델은 한 장에 여유 있게 올라가고, 120B급(MoE)은 한 장, 235B급은 4비트로 두 장이 필요함. 예상 배치는 작성용 27B × 3장 + 검증용 120B × 1장(서버 도착 후 시험해 확정).

후보 선정 기준은 서버 적재 가능성, 한국어 문서 처리 실적, 작성·검증 역할 적합성임. 서버 도착 전에는 OpenRouter에서 동일 모델을 불러 실험함.

AI 감사직원	붙여 본 LLM	조합
세 축 독립 검토	5모델 전부 (추론 켬·끔)	9
역할 분담	작성 Qwen 3.8 고정, 검증 자리만 3모델 교체 · 전 역할 Qwen 3.6	8
도구 호출형	Qwen 3.8 · gpt-oss-120b	2
단일 프롬프트	5모델 전부 (추론 켬·끔)	9
초안 후 재심사	초안 Qwen 3.8, 재심사 gpt-oss-120b / Qwen3 235B	2
합계	× 일상감사 요청 4건 = 검토의견서 120건	**30**

조합은 LLM 종류와 추론 켬·끔을 함께 셈. 예: 세 축 독립 검토는 4개 모델 × 켬·끔 8가지 + 추론 조절이 없는 Llama 70B 1가지 = 9가지. 역할 분담은 앞뒤를 Qwen 3.8로 고정하고 가운데 검증 자리만 3가지 × 켬·끔 6가지 + 세 자리 모두 Qwen 3.6 2가지 = 8가지.

Qwen 3.8 27B · 작성 주력 1순위 추론 켬·끔 가능

알리바바 공개 모델, 일반형(dense) 270억. 4비트 약 18GB로 한 장에 여유. 입력 한도(컨텍스트)가 100만 토큰이라 사업계획서를 자르지 않고 넣을 수 있음. 한국어 토큰 효율 가장 좋음.

Qwen 3.6 27B · 작성 대체재 추론 켬·끔 가능

같은 계열 한 세대 전, dense 270억, 컨텍스트 26만. 기존 도구의 기본 모델. 정해진 데이터 형식(JSON) 강제에는 불안정해 단일 프롬프트에 적합.

gpt-oss-120b · 검증 후보 추론 항상 켬(끄기 불가)

OpenAI 공개 모델(Apache 2.0), 여러 모델 부분을 선택해 처리하는 구조(MoE) 총 1,170억·활성 51억. 4비트 약 65GB로 한 장. 답할 때마다 추론 기능을 사용하며(끄기 불가) 활성이 작아 27B보다 빠름.

Qwen3 235B-A22B · 상급 검증 예비 추론 켬·끔 가능

MoE 총 2,350억·활성 220억. 4비트 약 129GB로 두 장 필요. 27B보다 실제로 나은지 확인용. 추론을 끄면 형식이 무너지는 실측.

Llama 3.3 70B · 대형 dense 비교용 추론 조절 없음

메타 공개 모델, dense 700억, 4비트 약 47GB. 후보 중 가장 느리고 사실 창작이 가장 많아 서버 후보가 아닌 비교용.

AI 감사직원 5명과 후보 로컬 LLM 5개의 배치로 30조합을 구성함. 요청 4건을 적용해 120건을 계획하고 답변서가 있는 평가 자료(골든 데이터셋)와 실제 쟁점으로 만든 평가 자료(실버 데이터셋) 기준으로 채점함.

데이터셋 — 일상감사 요청 4건 (일상감사 요청서 + 답변서)

구분	사건	기준의 출처
골든	A 생성형 AI 플랫폼 구축(용역) B GPU 서버 구매 (물품) C 한컴 SDK 구매 (물품)	일상감사가 완료된 사건. 실제 감사관 답변서(검토의견서)에서 평가할 항목을 추출
실버	D 스카이런 행사 운영(용역)	진행 중이라 답변서 없음. 요청서·계약검토서·제안요청서에 실재하는 쟁점(거리 불일치, 상금 합산 오류, 산출근거 공란)으로 기준 작성

요청별 채점 항목은 6개이며 중요도는 1~3임. 요청 4건×6항목=24개임. 서로 다른 회사의 채점 모델(심판) 2개가 항목마다 1~10점을 부여하고 평균 7.75점 이상을 충족으로 판정함. 점수 차이가 3점 이상이면 사람 재검토 대기열로 분리함.

채점 규칙

- 요청마다 채점 항목 6개(중요도 1~3), 요청 4건 × 6 = **24개** — 항목 목록은 다음 장
- AI가 쓴 의견서 117건(계획 120건 중 3건은 출력 한도로 막힘)을 각 사건의 기준과 대조해 **Claude와 GPT 두 심판**이 기준마다 1~10점 (gpt-oss가 쓴 의견서는 GPT 대신 Gemini)
- 두 심판 평균 **7.75점 이상이면 적중**, 3점 이상 갈리면 사람 재검토 대기열로 분리
- 실행 설정은 온도 0.2, 난수 시작값(seed) 42, 동일 지침으로 고정함.
- 요청별 채점 항목 24개의 구성은 다음 장에서 제시함.

의견서 1건의 채점은 7단계로 수행함.



IV · 연구 방법 · 평가 기준 24개

일상감사 요청 4건에 주요 평가 기준을 6개씩 마련함. 4건 × 6개 = 24개임

평가 기준은 두 종류임. 반드시 짚어야 할 것과 짚지 말아야 할 것임. 앞의 숫자는 중요도 1~3임. 사실 정확성, 창작 금지, 형식은 요청 4건 공통임. A와 D는 핵심 쟁점 발견을, B와 C는 과잉 지적 억제를 봄. A~C는 감사관 답변서에서, D는 문서에 실재하는 쟁점에서 뽑음. 기준별 점수는 Claude Sonnet 5와 GPT-5가 매기며, gpt-oss가 쓴 의견서는 Gemini 2.5 Pro가 GPT-5를 대신함. 두 채점 모델 점수의 평균이 7.75점 이상이면 충족으로 판정함.

일상감사 요청	평가 기준 6개 (앞 숫자 = 중요도 1~3)	
A 플랫폼 구축 골든	3 직접경비 산출근거 첨부 요구	2 사실 정확성: 사업명·계약방법·개발비 3.1억
	3 없는 수치·규정 창작 금지	1 근거 규정 인용: 일상감사규정 제6조
	1 조치 어조 3형	1 핵심 쟁점 집중
B GPU 서버 구매 골든	3 과잉 지적 억제: 4항목 적정 판단	2 조달 논리: 원가 조정 실익 없음 인식
	2 사실 정확성: 1.4억·150일·GPU 4개	3 창작 금지
	1 금액 표기 불일치 발견: 140,000,000원 ≠ 금일억구천만원	1 항목별 판정 형식
C 한컴 SDK 구매 골든	3 수의계약 요건·증빙 확인 제기	2 어조 조절: "참고" 수준
	2 과잉 지적 억제: 3항목 적정	2 사실 정확성: 3,080만원·150일·영구 라이선스
	3 창작 금지	1 항목별 판정 형식
D 스카이런 실버	3 문서 간 거리 대조: 1.5~3km vs 2·5·10km	2 상금 합산 검산: 2,030만 ≠ 2,000만
	2 산출근거 공란 항목 특정: 의전도우미·안전진단·기록영상	2 확인된 일치사항 과잉 지적 금지: 2.9억·1,000명
	3 창작 금지	1 항목별 판정 형식

사건/A~D/골든.md 채점 기준 · 평가/judge.py

사전 설계한 30조합을 동일 요청·동일 규칙에서 비교함. 최고 조합도 24개 중 13개를 충족함

질문

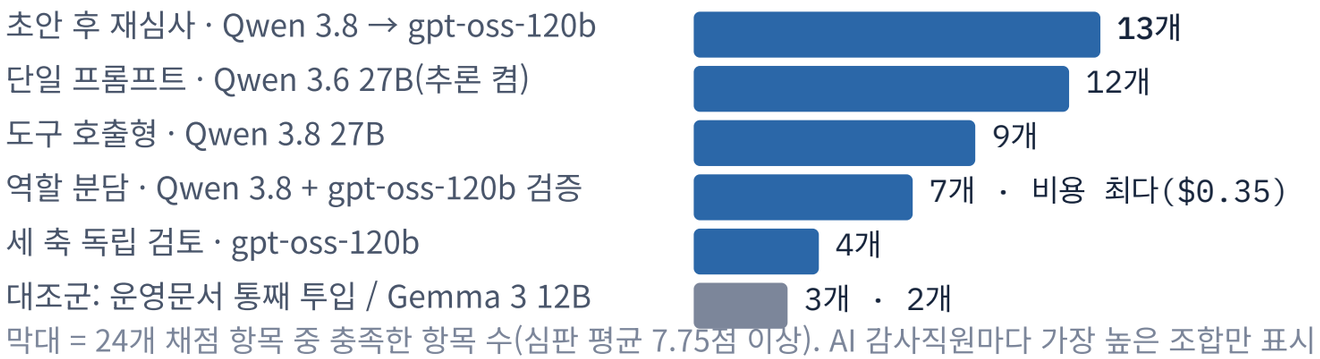
사전 설계한 30개 조합의 충족 항목 수를 비교함.
모든 조합에 동일한 일상감사 요청 4건을 적용함.
모든 조합에 동일한 판정 규칙을 적용함.

답

1위는 Qwen 3.8 27B 초안과 gpt-oss-120b 재심사 조합임(지침 4판 본실험).
이 조합은 요청 4건×6항목=24개 중 13개를 충족함.
Qwen 3.6 27B 한 번에 입력하는 지시문(프롬프트) 방식은 12개를 충족함.
도구 호출형은 9개를 충족함.
역할 분담형은 7개를 충족함.
세 축 독립 검토는 4개를 충족함.
비교 기준으로 둔 구성(대조군)은 각각 3개와 2개를 충족함.

뜻

1위의 적중 수는 24개 항목 중 13개임.
현재 결과는 업무 적용 단계가 아님.
방식별 충족 항목 수는 4~13개임.
이 격차가 개선 대상을 정하는 비교 기준이 됨.
지침을 5판으로 고친 뒤에는 1위가 단일 프롬프트로 바뀜(결론 장 참조).



막대 = 24개 채점 항목 중 충족한 항목 수(심판 평균 7.75점 이상). AI 감사직원마다 가장 높은 조합만 표시

실험 규모와 판정 기준

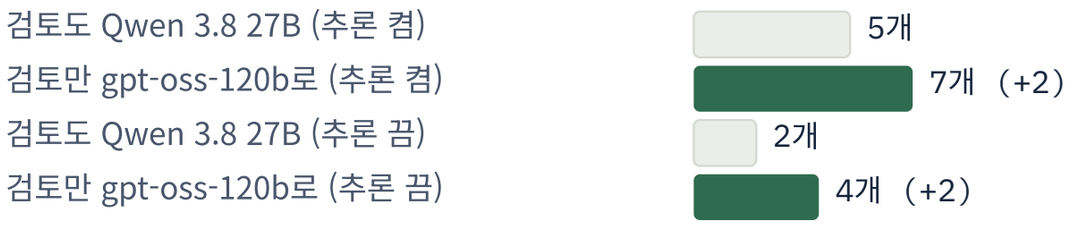
30가지 조합에 요청 4건씩 = 120번 검토를 계획함.
실제로 나온 검토의견서 117건을 채점했고 3건은 답이 길어 중간에 끊김.
AI 호출 584회, 비용 $3.62, 기계 처리 시간 440분임.
Claude Sonnet 5와 GPT-5가 채점함.
gpt-oss 산출물은 GPT-5 대신 Gemini 2.5 Pro가 채점함.
두 심판의 평균이 7.75점 이상이면 충족으로 판정함.
`docs/연구결과서_초안.md 3.1절 · 결과/도구비교/_취합/비교표.md · 비용.md · 전체 순위는 부록 A`

큰 LLM을 근거 검증 자리에 배치할 때 적중 수가 증가함. 모델 규모보다 모델 종류의 영향이 확인됨.

질문 검토·작성은 동일 27B로 유지하고 근거 검증 자리만 큰 LLM으로 교체할 때 성능이 향상되는지 확인함.

답 **추론 기능을 사용할 때 3개 역할 모두 Qwen 3.8 27B이면 5개이고, 검증만 gpt-oss-120b 또는 Qwen3 235B로 교체하면 각각 7개임. 추론 기능을 사용하지 않을 때 gpt-oss-120b 검증 구성은 2개에서 4개로 증가하고 Qwen3 235B 구성은 2개로 유지됨. 초안 작성 후 다시 심사하는 연속 방식은 gpt-oss-120b 13개, Qwen3 235B 5개임.**

뜻 큰 LLM을 모든 자리에 배치할 필요는 없음. 근거 검증 자리에 선택적으로 배치하는 방향이 유망함. 작성용 27B의 충분성 및 GPU별 수량은 서버 도착 후 시험할 사항으로 미확정임. 첫 운영 후보는 Qwen 3.6 27B 단일 프롬프트이며 gpt-oss-120b는 선택적 검증 후보임.
운영 후보를 확정하기 전에 실패 유형과 심판 계열별 채점 성향을 점검함.



단서

재심사 모델을 Qwen3 235B로 교체하면 13개에서 5개로 감소함. 모델 규모보다 검증 모델의 종류가 중요함. 역할 분담 도구는 호출·비용이 많고 최고 적중 수가 7개이므로 구조 개선이 우선임. 서버 GPU별 모델 수량은 미확정임.

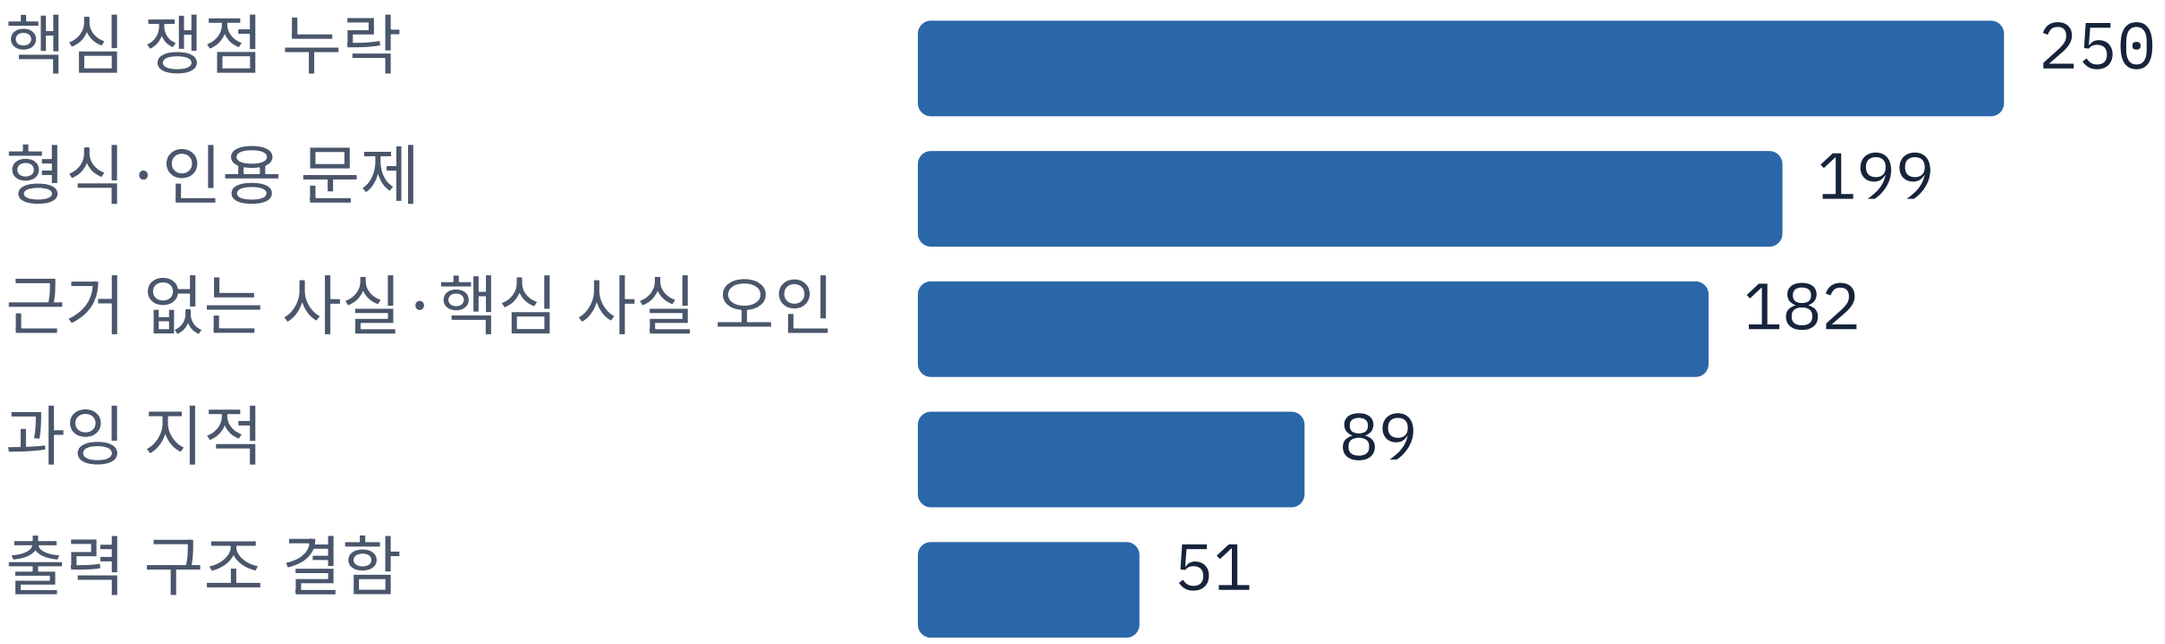
docs/연구결과서_초안.md 3.4·3.6절 · 결과/도구비교/_취합/비교표.md

연구 결과 ③ · 실패 유형

질문 이번 실험에서 AI 검토의견서의 주요 실패 유형을 확인함.

답 **전체 비교 실험(본실험) 117건과 비교 기준 구성(대조군) 8건을 합한 125건에서 실패 신호를 5유형으로 분류함. 핵심 쟁점 누락 250건, 형식·인용 문제 199건, 근거 없는 사실·핵심 사실 오인 182건, 과잉 지적 89건, 출력 구조 결함 51건임. 한 의견서가 여러 유형에 중복 계수됨.**

뜻 핵심 누락 신호가 가장 많았음. 긴 용역 문서에서 문서 간 대조·계산 누락이 발생했고 스카이런 관련 건수는 104건임. 조달 물품에서는 불필요한 지적이 48건 발생함. 대조·검산 절차를 보강하고 다른 기준의 악화 여부를 사람 확인 후 재실행함.



실패 신호 건수(중복 계수). 누락은 스카이런 104건, 과잉은 GPU 서버 48건에 집중

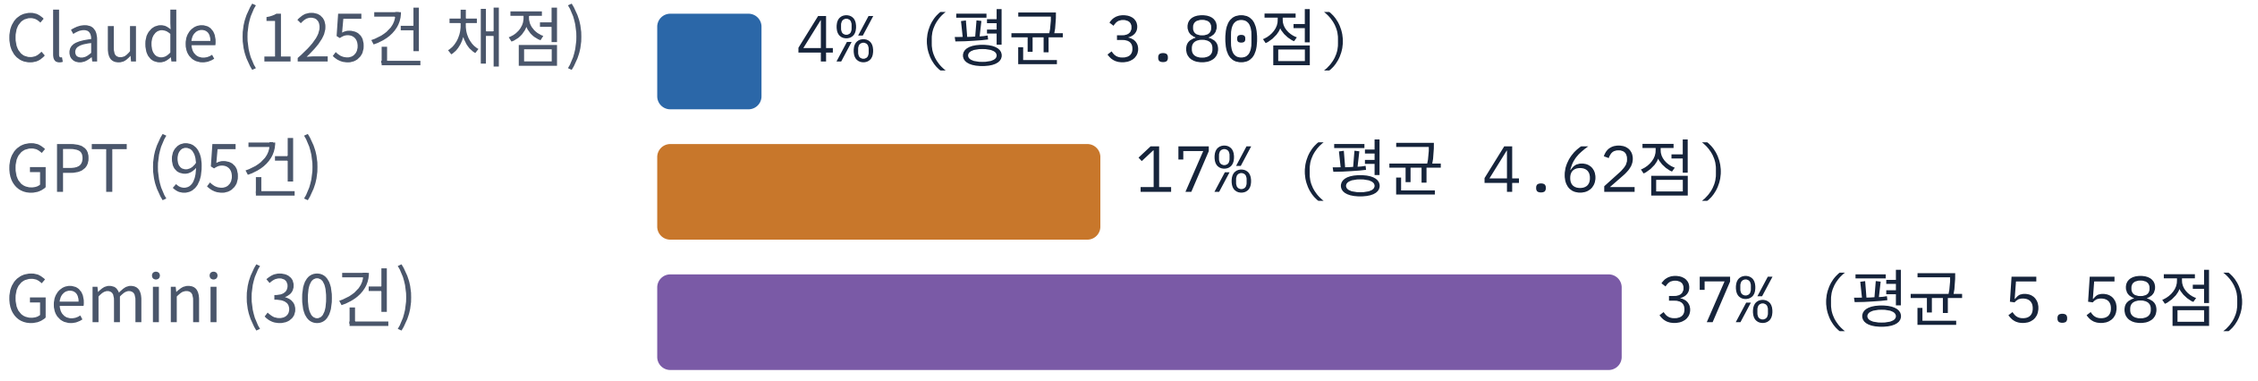
연구 결과 ④ · 채점 AI의 계열별 성향

질문 AI 채점 모델의 회사·모델 계통별 점수 부여 성향을 비교함.

답 **125건 모두 Claude Sonnet 5가 채점하고 둘째 심판은 GPT-5 95건과 Gemini 2.5 Pro 30건으로 구성함. 10점 부여 비율은 Claude 4%(평균 3.80), GPT 17%(4.62), Gemini 37%(5.58)로 차이가 확인됨.**

뜻 단일 계열 심판 사용 시 계열 성향이 결과에 반영될 수 있음. 서로 다른 계열의 심판 모델 2개를 사용하며 125건×6채점 항목=750개 점수 중 3점 이상 차이 난 165개를 사람이 다시 확인할 목록으로 분리

함. 재검토 범위는 미정임.



막대 = 10점 부여 비율. 750개 점수 중 165개가 3점 이상 불일치

결과/도구비교/_취합/약점목록.md · 불일치.md · 비교표.md 심판 분포

V · 연구 결과 ⑤·⑥ · 고치면 나아지나, 실험은 어떻게 돌렸나

지침 수정 후 총점은 증가했으나 일부 판단은 악화됨. 120건 실행 마감까지 12시간 39분 소요됨.

질문 실패 유형에 맞춘 지침 수정이 성능 향상으로 이어졌는지 확인함.

답 **한 번에 입력하는 지시문 방식 6조합과 다시 심사하는 방식 2조합을 합한 8조합에 요청 4건을 적용해 8×4=32건을 다시 실행하고 29건을 채점함. 전후 비교 가능한 28건의 6개 채점 항목 적중 합계는 59에서 65로 6개 증가함. 금액 표기 불일치와 규정 인용은 각각 +2.57, +2.36 개선됐으나 조달 발주 원가 조정 판단 −2.21, 직접경비 산출근거 −1.14, 사실 정확성 −1.00은 악화됨.**

뜻 지침 수정이 다른 판단을 악화시킬 수 있음. 개선안 5건은 사람이 확정했으며 총점만으로 자동 적용하지 않고 개선·악화 기준을 함께 검토함.

59 → 65

전후 비교 가능한 28개 실행의 여섯 채점 항목 적중 합계(+6). 좋아진 기준: 금액 표기 불일치 +2.57, 규정 인용 +2.36

−2.21

조달 발주 원가 조정 판단 평균. 나빠진 기준: 직접경비 산출근거 −1.14, 사실 정확성 −1.00

질문 여러 AI 세션의 실험 분담과 중단 후 재개 방식을 확인함.

답 **관리자 1명이 게시판 파일로 역할·순서를 정하고 Claude·Codex 작업 단위가 실행·채점·결과 정리를 분담함. 첫 실행 통과부터 120건 마감까지 12시간 39분이 소요됐으며 117건 채점·3건 중단으로 구성됨. 지침 5판 32건 재실행·29건 재채점은 약 50분 소요됨.**

뜻 파일과 게시판으로 장시간 반복 실행과 채점 진행을 관리함. 터미널 중단 후에도 산출 파일이 보존되어 새 세션이 잔여 20건 실행을 이어감.

12h 39m

120개 실행 마감(117개 채점·3개 막힘)

50분

지침 5판 32건 재실행·29건 재채점

결과/도구비교/_취합/개선안/검증결과_v5.md · HANDOFF_도구통합.md 상태 보고 · 상세는 부록

지침 4판→5판 추가 예시 · 실패 유형별 개선안 5건은 전부 채택하되 명령형 제안을 권고 어조로 완화해 사람이 확정함(9월 2일). 삭제한 문장은 없음

실패 유형	5판에 추가한 지침(요지)	재실행 전후 변화
③ 핵심 누락	공통 절차에 **내역 검산**(항목을 직접 합산해 총액과 대조, 예: "합산 20,300,000원 ≠ 계상액 20,000,000원")과 **문서 간 동일 속성 대조**(계약검토서 코스 거리 vs 제안요청서 코스 거리) 2개 절차 신설. 지적 시 "산출근거 없는 항목 있음" 대신 항목명을 그대로 열거하도록 권고	금액 표기 불일치 +2.57 · 직접경비 산출근거 −1.14
⑤ 형식·인용	공문에 명시된 근거 규정(00기관 일상감사 규정 등)을 문서 전체에서 1회 이상 인용 권고. 요청 항목을 공문의 순서·이름 그대로 번호를 붙여 "적정" 또는 "감사의견 제n항 참조"로 판정하는 **작성 실례 1건**을 출력 형식에 고정	규정 인용 +2.36

② 과잉 지적	절대 규칙 5 신설: "판단 불가·확인 필요"의 나열은 지적이 아니며 서너 건 이상 나열하지 않도록 권고. 조달·물품 경로에서 산출근거·단가 자료 보완 요구도 원가 지적에 해당하므로 하지 않도록 권고	과잉 지적 +2.07 · 조달 발주 원가 조정 판단 −2.21
① 사실 창작	수치는 원문 표기를 그대로 옮기고 직접 계산한 값은 계산식을 병기. 문서에 없는 조문은 번호를 지어내지 말고 "확인 필요: 관련 근거 규정 확인"으로 쓰도록 권고	사실 정확성 −1.00

지침/00기관_배치지침_v4_유형조건부.md → v5_유형조건부_권고.md · 결과/도구비교/_취합/개선안/README.md · ④ 구조 결함은 지침이 아닌 실행 설정(max_tokens 8000)으로 처리

지침 5판 최고 조합은 단일 프롬프트와 Qwen 3.6 27B(추론 켬)임. 충족 항목은 16/24이며 운영 적용은 보류함.

AI 감사직원	가장 좋았던 모델 조합	처음 지침 충족 (30조합 전부)	고친 지침 충족 (8조합만)	비용/요청 4건 (처음 지침)	시간 (처음 지침)	판정
4 단일 프롬프트	**Qwen 3.6 27B, 추론 켬**	12/24	**16/24**	$0.0532	497초	운영 후보 지침 5판 기준 1위
5 초안 후 재심사	초안 Qwen 3.8 27B → 코드 검산 → 재심사 gpt-oss-120b(낮음)	**13/24**	11/24	$0.0246	112초	보류 4판 1위였으나 5판에서 하락
3 도구 호출형	Qwen 3.8 27B, 추론 켬	9/24	–	$0.0445	250초	도구 연동이 필요할 때만
2 역할 분담 멀티에이전트	검토·작성 Qwen 3.8 27B + 검증 gpt-oss-120b, 추론 켬	7/24	–	$0.3504	2,140초	비용·시간 과다, 구조 개선 후 재평가
1 세 축 독립 검토	gpt-oss-120b, 추론 낮음	4/24	–	$0.0040	41초	핵심 누락 최다, 부적합
대조군	Gemma 3 12B 기준선 / 운영문서 통째 투입	2/24 · 3/24	–	–	–	기준선 재확인

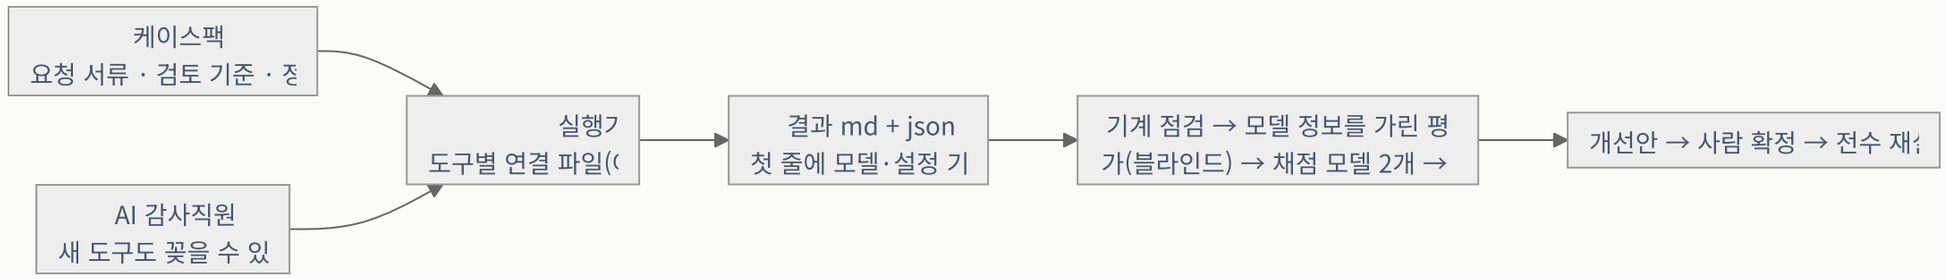
현재 후보와 후속 가설: 1차 운영 후보는 Qwen 3.6 27B 단일 프롬프트. gpt-oss-120b는 검증 자리에 선택적으로 둘 후속 실험 후보(검증 자리 교체 시 +2). 연속 방식 기본 경로는 기존 기능이 다시 나빠지는 문제(회귀)를 고쳐 같은 조건으로 다시 확인할 때까지 보류함. 호출이 많은 역할 분담형은 비용 대부분을 쓰고도 7/24.

단서: 24개 채점 항목 중 16개가 최고이므로 운영 인증이 아니라 개선 기준선임. 지침 5판은 지침을 쓰는 8조합만 재검증했고(28건 전후 비교), 나머지 3도구는 5판 점수가 없어 30조합 전체의 새 순위는 아님. 비용·시간은 4판 실행값. 운영 보류 대상은 AI 감사직원의 업무 적용이며, 다음 장의 배포 대상은 성능평가 절차임.

성능평가 절차를 개발자용 실행 절차 고정 도구(하네스)로 배포함

방법론은 동일 요청·동일 규칙 적용, 서로 다른 회사 심판, 사람 확정, 전수 재검증의 순서로 구성됨. 하네스는 폴더·파일 규약으로 절차를 고정하며 AI 감사직원별 어댑터 1파일을 연결해 동일 절차로 평가함.

구조: 사건 자료 묶음(케이스팩)과 도구를 입력하면 채점·개선안·다시 실행까지 수행함.



Python 표준 라이브러리만 사용함. cases는 사건 자료 묶음, workflows는 도구 연결 파일, 실행 절차 고정 도구는 실행 프로그램·평가 프로그램·상태 확인 프로그램으로 구성됨.

도구 등록 검사(온보딩) — 아무 도구나 넣으면 무엇이 부족한지 사람 말로 알려줌 (전)

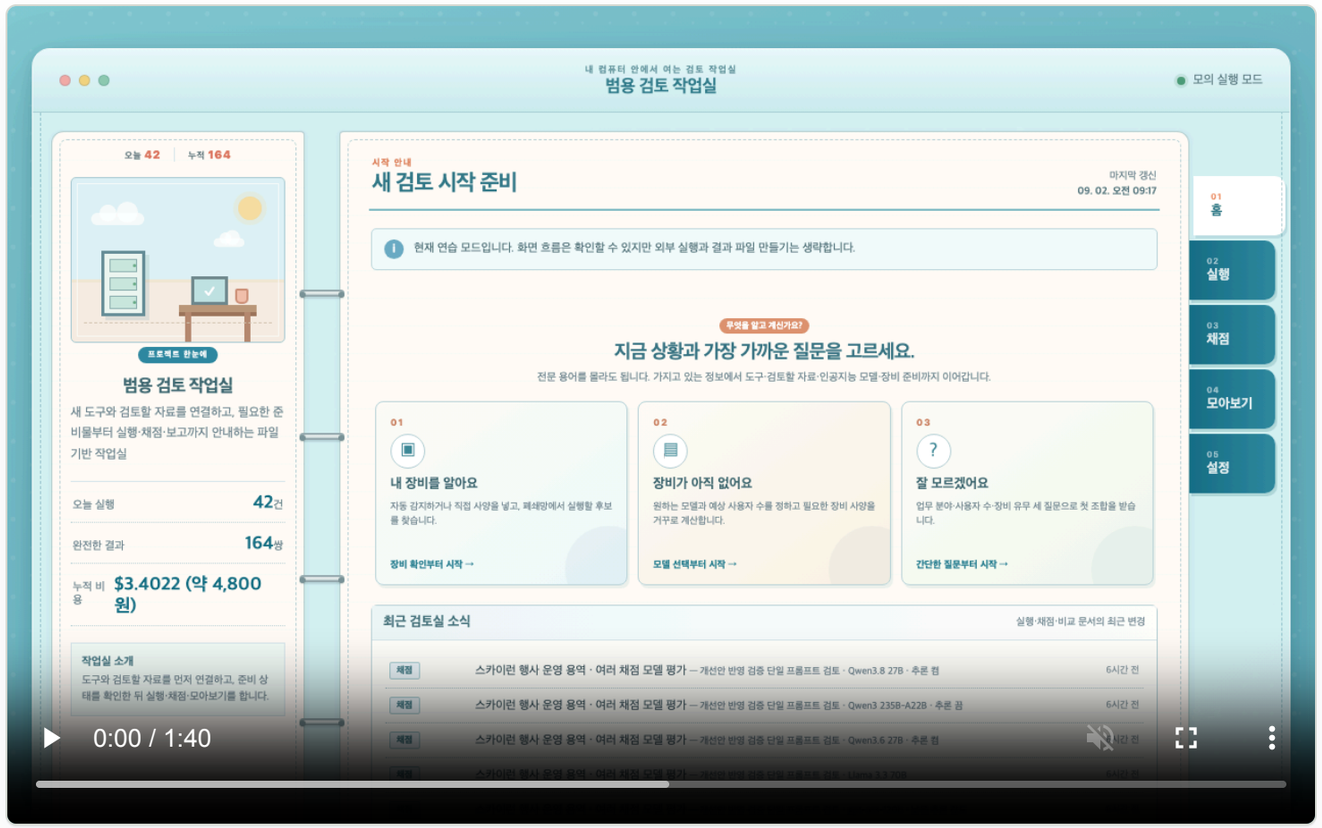
```
도구 온보딩 검사 — 결과: 보완 필요
[통과] 도구 폴더를 찾았습니다 — 파일 2개를 읽기 전용으로 검사, 원본 수정 없음
[부족] 실행 연결 정보 파일(워크플로우.json)이 필요합니다 — "넣어 주신 설명 글
(README.md)은 확인했습니다. 다만 도구를 연결하려면 '워크플로우.json'이라는 정해진 형식의
설명 파일이 따로 필요합니다."
[부족] 실행 어댑터를 확인할 수 없습니다 — "원래 도구는 고치지 말고, 예시 실행 어댑터를 복사
해 내 도구를 호출하는 부분과 결과 저장 부분만 내 도구에 맞게 바꾸면 됩니다."
[부족] 검토할 자료 안내 · [부족] 검토 기준 안내
요약: 통과 1 · 안내 1 · 부족 4
```

안내대로 설명 파일과 어댑터를 채운 뒤 (후)

```
도구 온보딩 검사 — 결과: 실행 준비 완료
[통과] 실행 연결 정보 파일(워크플로우.json)을 읽었습니다 (계약 버전 1.0)
[통과] 실행 어댑터를 확인했습니다 — 코드는 실행하지 않고 정적으로만 검사
[통과] 공통 러너 인자 · 검토할 자료 · 검토 기준 · 정답 분리 · 산출 계약
[통과] 도구와 케이스팩 형식이 맞습니다
요약: 통과 14 · 안내 0 · 부족 0
```

발표자료/하네스형 검토도구/README.md·설계서.md · harness/도구_온보딩_검사기.py 실행 결과(원본 run.py 폴더 / workflows/예시_파일접수 + cases/예시_문서일치)

동일 평가 절차를 비개발자용 사용자 화면(GUI) 5개로 제공함



시연 영상(2026-09-02 17:57 빌드, 실제 실행 포함): 홈 3질문, 도구·자료 폴더 입력, 준비 검사, 한컴 SDK 사건의 gpt-oss-120b·Qwen3 235B 비교 실행(36초), 검토의견서 열람, 채점, 색 등급 결과보고서 확인 순서임. 추가 컷(두 번째 도메인 10초)은 '자격·중복·서류 검증 × 중복 수급 의심 신청 건'을 실행→채점→모아보기로 처리하는 장면이며, 등록한 새 업무도 같은 채점 절차로 처리함. 실행 구간은 실측 16초를 컷 편집함. 기존 영상 뒤에 연결해 총 1분 40초로 구성함.

- **홈**: "내 장비를 알아요 / 장비가 아직 없어요 / 잘 모르겠어요" 중 하나를 선택함. 홈에서 장비를 자동 감지하고 서버 메모리별 모델을 추천함. 도구 폴더와 검토 자료를 입력하면 도구 등록 검사가 부족 항목을 안내함.
- **실행**: 사건·검토 방법·모델(여러 모델 동시 비교)·지침을 확인한 후 실행함. 등록한 새 업무(두 번째 업무 분야: 자격·중복·서류 검증)도 같은 화면에서 도구 등록→실행→채점을 완결함.
- **채점**: 기계 점검 → 블라인드 → 다른 회사 심판을 한 번에
- **모아보기**: 비교표·비용·불일치·약점·개선안, 색 등급 결과보고서
- **설정**: 실행 채널 준비 상태·업무 분야 묶음·프로그램 정보를 제공함.

새 도구 연결 실측 (두 번째 도메인)

연결 파일 1개(135행급) 제작 → 도구 등록 검사 12항목 통과 → 실행 16.2초·$0.002 → 기계 채점 6/6 → Claude+GPT 두 채점 모델 6/6 일치(함정 판정 포함).
`docs/두번째도메인_실증.md 1·2절 · 결과/도구비교/등록된_검토/…/두번째도메인_실증_0902_221924.judge.json`

macOS 앱 더블클릭으로 실행함. Python 표준 라이브러리만 사용하며 127.0.0.1에서만 동작함. 키 값은 화면·로그에 표시하지 않음.

운영 후보(지침 5판 기준): Qwen 3.6 27B 단일 프롬프트 추론 켬 16/24. **확정 조건:** 회귀(조달 논리·직접경비·사실 정확성)를 고친 뒤 도구·LLM 30조합 전체 재검증, 자체 서버(RTX PRO 6000 × 4)에서 30조합 × 요청 4건 = 120건 재실행.
`발표자료/gui형 검토도구/README.md · 하네스형 검토도구/모델추천.md · docs/연구결과서_초안.md 3.7절`

부록 상세 · 연구 질문 및 이론적 배경 (II·III)

본 연구는 검토 구조·입력 보존·외부 근거 검증·절차 자동화와 재사용성의 네 연구 질문을 검증하는 것을 목적으로 한다

연구 질문 1(Research Question 1, RQ1)

역할별 LLM 배치

검토·검증·작성에 동일한 LLM을 배치한 조건과 검증 역할만 강화한 조건의 정확도·비용·시간을 비교한다.

연구 질문 2(Research Question 2, RQ2)

입력 정보 보존

긴 입력을 검토축별로 분할하거나 축약할 때 금액·산식·계약조건이 보존되는지를 분석한다.

연구 질문 3(Research Question 3, RQ3)

근거 검증

별도 검증과 재심사가 사실 창작과 과잉 지적을 억제하면서 핵심 기준의 적중을 유지하는지를 평가한다.

연구 질문 4(Research Question 4, RQ4)

절차 자동화

여러 에이전트가 실행·채점·취합·개선 절차를 완주할 수 있는지와 동일 절차를 다른 검토 업무에 재사용할 수 있는지를 검증한다.
출처: docs/연구결과서_초안.md 1.2절, 도구/실험계획/평가파이프라인.md 0절.

부록 상세 · 본편 2장 · 연구 대상 선정

본 연구는 동일 문서의 한 줄에 금액 1억 4천만원과 1억 9천만원이 병기된 불일치 사례를 포함하여 판단 방향이 상이한 실제 일상감사 사건을 평가 대상으로 선정하였다

방법: 전 부서 인공지능 과제 전수조사(2026.7.6~7.15)

103
응답·발굴 과제

35
부서

60
검증·검색·초안 과제

업무 유형은 자료·문서 59건, 민원 20건, 대상자 검토 16건, 시스템 8건으로 분류하였다(59+20+16+8=103). 과제 성격은 데이터 취합·분석 25건, 자격·중복·서류 검증 22건, 문서·보고서 초안 19건, 법령·규정·사례 검색 19건, 민원 안내 13건, 일정·인사 5건으로 분류하였다(25+22+19+19+13+5=103). 이 가운데 검증·검색·초안 과제는 60건이었다(22+19+19=60).

방법: 판단 방향이 상이한 일상감사 요청 4건을 구성하였다

사건	길이	참조 판단 방향
생성형 AI 플랫폼 구축(용역)	18,114자	지적형 · 직접경비 산출근거
스카이런 행사 운영(용역)	16,333자	지적형 · 거리·상금·빈 산출근거
GPU 서버 구매(물품)	6,759자	절제형 · 표기 불일치만
한컴 SDK 구매(물품)	305자	조건부 참고형 · 수의계약 요건

결과 및 고찰: 일상감사를 연구 대상으로 선정한 근거

- 기획예산과는 법령·예산 근거 검토, 규정 해석, 검토서 초안의 세 과제를 직접 제안하였다.
- 일상감사 요청 4건 중 A·B·C는 실제 감사 의견을 참조답안으로 사용하는 골든 데이터셋(golden dataset)으로 구성하였다. 진행 중인 D는 원문에 실재하는 쟁점을 기준으로 사용하는 실버 데이터셋(silver dataset)으로 구성하였다.
- 계약 원가와 업체 정보가 포함된 문서의 특성을 고려하여 폐쇄망 실행을 전제로 하였다.
- 일상감사는 실재 오류를 탐지하는 동시에 근거 없는 문제 제기를 억제해야 한다. 이에 따라 과잉 지적을 판별하는 절제형 사건을 포함하였다.

출처: 사건/B_GPU서버_물품/입력.md 35행, 발표자료/00기관_AI과제_업무유형별_정리.html DATA, docs/연구결과서_초안.md 1.1·1.3절.

초기 중단 3회를 분석하여 LLM용 지침 사용, 입력 분할, 구조 검증, 전 사건 재검증을 설계 원칙으로 도출하였다.

결과: 초기 실패 연대기

07-06	Qwen3 14B의 컨텍스트 길이 16,384토큰에서 의뢰서·원가계산서·설계내역서 묶음이 입력 한도를 초과하였다. 이에 따라 문서 분할 단계를 신설하였다.
07-15	72,310자 제안요청서를 7개 구간으로 분할하여 검토한 결과, 검토축 1개에 216초가 소요되었다. 약 23,000자의 단일 호출은 3회 연속 시간 초과가 발생하였다. 8,000~14,000자 단위의 분할 호출은 완료되었다.
07-20	27B 프로파일은 12개 항목과 90초·120초 제한 조건에서 전 항목 실행 오류가 발생하였다. 구조화 출력 무시, 항목 식별자 누락, 환각이 관찰되었다. gpt-oss-120b는 당시 메모리 한계로 후보에서 제외하였다.
08-24~25	발주용 후보 LLM 18개를 평가한 결과, 14개가 응답하였고 4개가 빈 응답을 반환하였다(14+4=18). Gemma 3 27B의 절사평균은 50.0, 표준편차는 20.9였으며 후보 중 변동성이 가장 컸다.

고찰: 실패 사례에서 도출한 설계 조치

- 출력 절단을 정상 결과로 처리하지 않고 실패 상태로 격리하였다. 입력 분할과 재시도를 복구 절차로 채택하였다.
- 구조화 출력 형식을 요청에 포함하였다. 허용 식별자를 대조하고 누락 항목을 재요청하도록 하였다.
- 단일 실행 순위 대신 반복 결과, 분산, 실행 실패를 함께 보고하도록 하였다.
- 지침은 단일 사건 결과만으로 수정하지 않는다. 지침을 수정한 경우 일상감사 요청 4건을 전부 재실행한다.

구조와 모델을 함께 비교하면 실행 조합 수가 증가한다. 지침을 수정할 때마다 전 사건 재실행이 필요하므로 표준화된 자동 실행 절차가 요구된다.

출처: AI_Workspace/daily-audit-pipeline/SPEC.md 개정 이력, 커밋 e08530b·fa56969·6c11698, docs/adr/ADR-001 35행, 별첨2_발주부록.md, HANDOFF.md R5.

연구 질문 4개에 대응하여 선행연구로부터 고정 절차·외부 검증·근거 식별자 대조·원문 보존과 심판 계열 분리 원칙을 도출하였다.

다중 에이전트(multi-agent) 실패는 설계 결함, 비정렬, 검증 실패로 구분된다. 이에 따라 자율 협의 대신 고정 절차를 채택하였다(Cemri et al., 2025, MAST; Hong et al., 2023, MetaGPT; Zhang et al., 2024, AFlow).

외부 피드백이 없는 자기 수정은 성능을 악화시킬 수 있다. 이에 따라 자기 수정 대신 외부 검증기를 배치하였다(Huang et al., 2023).

법률 환각은 58~88%, 상용 검색 증강 생성(retrieval-augmented generation, RAG)에서도 17~33%로 보고되었다. 이에 따라 근거 식별자와 조문의 실존 여부를 대조하였다(Dahl et al., 2024; Magesh et al., 2024).

멀티턴 반복 검토에서 요약 압축에 따른 정보 손실이 보고되었다. 원문 입력을 유지하고 요약 압축을 적용하지 않았다(LLMLingua; SCBench).

본 연구는 동일 요청·동일 평가 규칙에서 구조와 모델 배치를 비교하는 것을 목적으로 한다. 실패 분석에서 개선안을 도출하고, 사람이 확정한 개선안만 일상감사 요청 4건에서 재검증하는 순환 절차를 제안한다.

방법: 선행연구에 근거한 설계 선택

- **자율 협의 배제, 고정 절차** — 멀티에이전트 실패는 설계 결함·비정렬·검증 실패로 나뉨. Cemri et al. 2025 MAST · Hong et al. 2023 MetaGPT · Zhang et al. 2024 AFlow
- **자기 수정 대신 외부 검증기** — 외부 피드백 없는 자기 수정은 성능 악화. Huang et al. 2023
- **근거 식별자·조문 실존 대조** — 법률 환각 58~88%, 상용 RAG도 17~33%. Dahl et al. 2024 · Magesh et al. 2024
- **요약 압축 불채택** — 멀티턴 반복 검토에서 손실. LLMLingua · SCBench

방법: 평가 편향 통제

- 기계 판정이 가능한 형식·구조 항목은 자동 검사로 분리하였다. LLM 심판은 내용 평가에 한정하였다(IFEval; JudgeBench).
- 참조답안(reference answer), 블라인드 평가(blind evaluation), 서로 다른 계열의 심판 2인을 결합하였다(Zheng et al., 2023; Verga et al., 2024, PoLL; Panickssery et al., 2024).
- 동일 기준에서 두 심판의 점수 차가 3점 이상인 경우 사람 재검토 대기열로 분리하였다(Thakur et al., 2024).
- IntelliAudit(2026)에서는 사람이 27건 중 15건의 관대한 AI 판정을 교정하였다. 이에 따라 최종 확정 단계에 사람 확정 게이트를 배치하였다.

연구 공백·목적 및 고찰

- 국내 최인접 연구는 임경태(2025)의 종결 감사사례 질의응답 연구이다. 조사 범위에서는 계약 집행 전 일상감사의 근거 강제와 폐쇄망 구조를 함께 다룬 국내 연구를 확인하지 못하였다.
- 공개 벤치마크 하네스는 비공개 실사건, 과잉 지적의 비대칭 비용, 비개발자 운영을 동시에 지원하지 않는다.
- **목적:** 같은 요청·같은 규칙에서 구조와 모델 배치를 비교하고, 실패에서 개선안을 도출하되 사람이 확정한 후 일상감사 요청 4건 전체로 재검증하는 순환 절차를 구축한다.

출처: docs/연구결과서_초안.md 1.2절, AI_Workspace/docs/research/논문흐름지도.md, AI_Workspace/docs/research/연구계획서.md, 도구/실험계획/평가파이프라인.md 0절.
관련 표: 부록 E.

본 연구는 AI 감사직원 5명별 LLM 배치 9+8+2+9+2=30조합과 일상감사 요청 4건을 결합한 30×4=120건을 동일 통제조건에서 실행하고 7단계로 평가하였다

목적 및 비교 대상: 검토 워크플로우 5종과 대조군 2종

세 축 독립 검토 하네스	9구성
역할 분담형 멀티에이전트	8구성
도구 호출형 하네스	2구성
단일 프롬프트	9구성
초안 작성 후 재심사 연쇄	2구성

후보 로컬 LLM은 Qwen 3.8 27B, Qwen 3.6 27B, OpenAI gpt-oss-120b, Qwen3 235B-A22B, Llama 3.3 70B로 구성하였다. 추론 설정은 모델 특성에 따라 켬·끔 또는 낮음·높음으로 구분하였다. 서버 도착 전 단계에서는 OpenRouter의 동일 모델을 사용하여 사전 비교하였다.

방법: 공통 통제 조건

- 온도는 0.2, seed는 42로 고정하였다. 기본 최대 출력은 4,000토큰, 의견서 작성 단계는 8,000토큰으로 설정하였다.
- 입력 원문을 유지하고 요약 압축을 적용하지 않았다. 실측 입력의 최댓값은 13,194토큰이었다.
- 단일 프롬프트에는 지침 4판을 적용하였다. 재심사 연쇄에는 지침 3판과 심사 강도 보정을 적용하였으므로 구조 간 직접 비교에는 지침 차이가 포함된다.
- 각 실행은 Markdown 문서와 JSON(JavaScript Object Notation) 기록의 한 쌍으로 저장하였다. 재실행 결과는 이력 폴더에 보존하였다.
- 가장 짧은 사건 1건으로 첫 구성을 검수한 뒤 전체 실행으로 확장하였다.

방법: 판정 및 개선 규칙

- gpt-oss 계열이 산출에 참여한 경우 GPT 심판을 제외하고 Gemini 심판을 투입하여 계열을 분리하였다.
- 동일 기준에서 두 심판의 점수 차가 3점 이상이면 사람 재검토 대기열로 분리하였다.
- 기계 점검은 수치 실재, 조문 실존, 출력 구조, 어조, 기록 유효성을 대상으로 하였다.
- 실패는 사실 창작·오류, 과잉 지적, 핵심 누락, 구조 결함, 형식·인용의 5개 유형으로 분류하였다.
- 개선안은 자동 적용하지 않았다. 사람이 확정한 개선안만 일상감사 요청 4건에서 재실행하였다.

출처: 도구/실험계획/모델실험계획서.md, 도구/실험계획/평가파이프라인.md, 도구/실험계획/입력크기_압축검토.md, 평가/*.py.

부록 상세 · 본편 6장 · 다중 에이전트 협업 운영

사람 관리자 1명과 AI 에이전트 5개가 파일 기반 협업 절차에 따라 실험 운영을 분담하였다

상태는 완료·진행·막힘으로 구분하고 산출물·수치·변경 파일을 한 줄로 기록하였다.

점호 요청 2회는 모두 전달되었으며(2/2), 약 10초가 소요되었다.

AI 에이전트 3개가 동시에 기록한 결과, 충돌과 유실은 0건이었다.

편집 범위 준수 여부는 3건 모두 충족하였다(3/3).

첫 전송의 미제출은 빈 줄 재전송으로 우회하였다.

방법: 협업 채널 3종

세션 메시지	Claude 간 세션 메시지를 즉시 전달하였다.
터미널 입력	Claude가 Codex 터미널에 입력하였으며, 제출에는 빈 줄 재전송이 필요하였다.
게시판 파일	모든 참여자가 게시판 파일을 유일한 영구 기록 채널로 사용하였다.

방법: 파일 기반 운영 규약

1. 새 세션은 게시판과 지침을 읽은 후 점호에 응답하였다.
2. 작업별로 담당자와 전용 파일을 지정하였다. 담당 범위 밖의 파일은 수정하지 않았다.
3. 가장 짧은 사건 1건에서 첫 구성을 검수한 후 전체 실행으로 확장하였다.
4. 상태는 완료/진행/막힘 — 산출물·수치·변경 파일 한 줄
5. 비밀 값은 기록하지 않았다. 개선안의 채택 권한은 사람에게만 부여하였다.

결과: 사전 협업 실측(2026-08-27)

- "손 들어" 2회 `2/2 · 약 10초`
- 세 에이전트 동시 기록(가위바위보) `충돌·유실 0`
- 편집 범위 준수 `3/3`
- 첫 전송 미제출 `빈 줄 재전송으로 우회`

본 실측에는 전달 확인, 자동 재시도, 권한 강제가 포함되지 않았다. 따라서 결과는 운영 수준의 자동화 체계가 아닌 파일 기반 협업 절차의 관찰 결과로 한정한다.

출처: HANDOFF_도구통합.md 2·3-4절, 협업로그/0827_사이클1_교신기록.md, ~/New Communication with AI Agents/README.md.

지침 4판 본실험의 최고 구성은 일상감사 요청 4건과 평가 기준 6개를 결합한 24개 기준 중 13개를 충족하였다(4×6=24). 대형 LLM은 검증 역할에서만 적중 수가 각각 5→7, 2→4로 증가하였다.

결과 1: 실행 완결성과 자원 사용

97.5%

계획 120건 중 117건을 채점하여 97.5%를 완료하였고(117/120), 3건이 막힘으로 남았다.

584

산출 단계에서 LLM을 584회 호출하였다.

$3.62

심판 비용을 제외한 산출 비용은 $3.62였다.

막힘 3건은 모두 단일 프롬프트의 출력 길이 초과에서 발생하였다. 역할 분담형 Qwen 3.6 27B 추론 켬 구성은 자동 분할과 재시도로 복구하였으나, 해당 구성에 146회 호출과 14,675초가 소요되었다.

결과 2: 상위 5개 구성과 대조군의 성적

재심사 연쇄: Qwen 3.8 27B → gpt-oss-120b	13/24	$0.0246	112초
단일 프롬프트: Qwen 3.6 27B, 추론 켬	12/24	$0.0532	497초
도구 호출형: Qwen 3.8 27B, 추론 켬	9/24	$0.0445	250초
단일 프롬프트: Qwen 3.8 27B, 추론 끔	9/24	$0.0154	21초
역할 분담형: Qwen 3.8 27B + gpt-oss-120b 검증, 추론 켬	7/24	$0.3504	2,140초
세 축 독립 검토의 최고 구성	4/24	$0.0040	41초
대조군: 기준선 / 운영문서 전체 투입	2/24 · 3/24	–	–

고찰 및 한계

- Qwen 3.8 27B 추론 켬 단일 프롬프트는 18개 기준 중 10개를 충족하였다(10/18). 다만 스카이런 요청 1건이 막혀 전체 24개 기준의 순위를 확정하지 않았다.
- 호출 단계의 증가는 품질 향상과 일치하지 않았다. 역할 분담형은 전체 산출 비용 $3.62 중 $3.17을 사용하였다. 해당 유형의 최고 적중은 24개 기준 중 7개였다(7/24).
- 재심사 LLM을 Qwen3 235B-A22B로 교체한 구성은 24개 기준 중 5개를 충족하였다(5/24). 이 결과는 재심사 LLM 선택의 중요성을 시사한다. 다만 두 경로에 적용한 지침 판본이 다르므로 모델의 순수 효과로 단정하지 않는다.
- 최고 재심사 연쇄형도 요청 B와 C의 창작 방지 평균이 각각 7.0과 6.0으로 적중선 7.75에 미달하였다.

출처: docs/연구결과서_초안.md 3.1~3.6절, 결과/도구비교/_취합/비교표.md, 결과/도구비교/_취합/비용.md.
관련 표: 부록 A·B.

실패 신호를 중복 허용 5개 유형으로 분류하였다. 심판 계열별 점수 분포의 차이도 확인하였다

결과 1: 중복 허용 실패 신호와 조치

핵심 누락 250건	핵심 적중 49·상금 검산 30·거리 대조 29	내역 검산·문서 간 대조
형식·인용 199건	항목별 형식 87·기계 어조 77	출력 실례·형식 계약
사실 창작·오류 182건	창작 방지 100·사실 정확성 82	수치·조문 검증 게이트
과잉 지적 89건	과잉 억제 53·조달 논리 25	조달 실익 판단 규칙
구조 결함 51건	구조 43·스키마 8	출력 한도·종료 사유 검사

고찰 1: 연구 질문 2의 입력 분할 관찰과 인과 추론의 한계

- 세 축 독립 검토의 최고 적중은 24개 기준 중 4개였다(4/24). GPU 서버 구매 사건은 9개 구성 모두 6개 기준 중 적중이 없었다(0/6).
- 골든 쟁점이 있는 실행 27건에서 기계 점검의 핵심 적중 판정은 모두 미적중이었다.
- 입력 길이가 305자인 사건에서도 최고 적중은 6개 기준 중 1개였다(1/6). 따라서 핵심 누락을 입력 길이만으로 설명할 수 없다.
- 원문 전체, 구조 보존 분할, 요약 입력을 동일 조건에서 비교한 대조군이 없으므로 입력 분할의 인과 효과를 확정할 수 없다. 해당 관계는 후속 연구 가설로 남긴다.

결과 2: 심판 불일치 165/750 기준쌍

- 요청별 불일치는 32건, 40건, 43건, 50건으로 총 165건이었다(32+40+43+50=165). 평가 기준별로는 창작 방지가 55건으로 가장 많았다.
- 본실험 117건과 대조군 8건을 합한 125건(117+8=125)에서 Claude 심판의 평균은 3.80, 표준편차는 2.84였다. 계열 분리 규칙에 따라 GPT 심판은 95건에서 평균 4.62와 표준편차 3.49를 기록하였다. Gemini 심판은 30건에서 평균 5.58과 표준편차 3.99를 기록하였다(95+30=125).
- Gemini는 계열 충돌을 회피하기 위한 대체 심판이므로 해당 구성의 절대점수에는 심판 계열의 관대화가 혼재할 수 있다. 심판 불일치 사례는 사람 재검토 대기열로 분리하였다.

출처: 결과/도구비교/_취합/약점목록.md, 결과/도구비교/_취합/불일치.md, 결과/도구비교/_취합/비교표.md, docs/연구결과서_초안.md 3.2~3.5절.

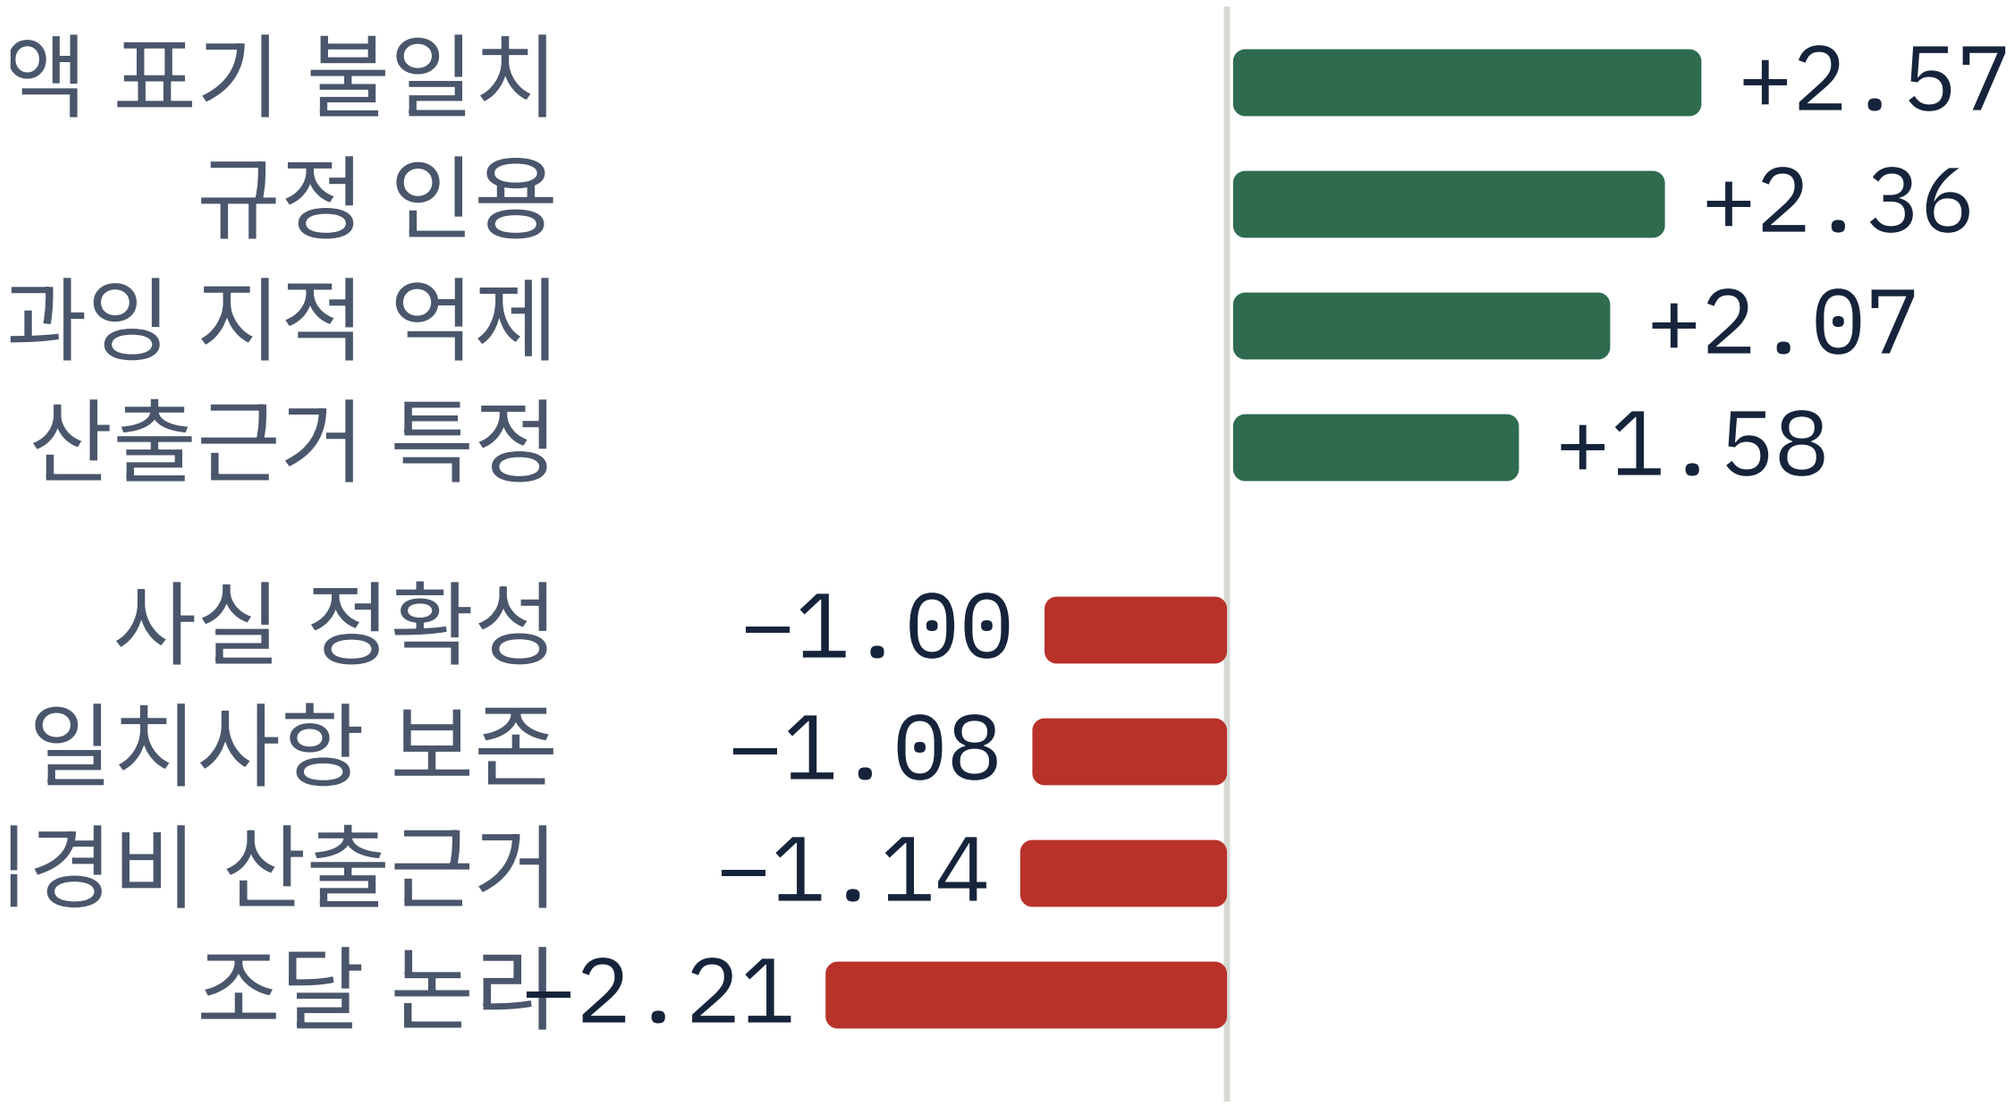
부록 상세 · 본편 9장 · 지침 5판 부분 재검증: 지침을 적용한 8개 구성과 일상감사 요청 4건을 결합한 32건 중 짝 비교가 가능한 28건(8×4=32)

사람이 권고 어조로 확정한 지침 5판을 재검증한 결과, 일부 적중은 증가하였다. 조달 논리 평균은 2.21점 감소하였다

결과 1: 기존 지침과 지침 5판의 전후 비교

스카이런 요청의 짝 비교 가능 실행 6건	12	17
Qwen 3.6 27B 단일, 추론 켬	12/24	16/24
Llama 3.3 70B 단일	2/24	7/24
지침 4판 본실험 최고 재심사 연쇄형	13/24	11/24
Qwen 3.8 27B 추론 켬 × 스카이런 요청	막힘	6/6 회복

결과 2: 평가 기준별 평균 변화량



고찰 및 한계

- 적중 합계 59→65는 30개 구성 전체의 결과가 아니다. 지침을 소비하는 8개 구성과 일상감사 요청 4건을 결합한 32건 중 재채점 29건을 확보하였고, 이 가운데 전후 점수가 모두 있는 28건의 비교 결과이다 (8×4=32).
- 막혔던 스카이런 요청은 6개 기준을 모두 충족하여 6/6으로 회복하였다. 그러나 동일 구성의 나머지 사건 3건에서는 적중이 10→6으로 감소하였으므로 함께 해석해야 한다.
- 핵심 대조 절차가 조달 사건의 원가성 지적으로 확장된 회귀를 보완하기 전에는 운영에 적용하지 않는다.
- 개선안을 확정한 후 32건을 재실행하고 29건을 재채점하기까지 약 50분이 소요되었다.

출처: 결과/도구비교/_취합/개선안/검증결과_v5.md, 결과/도구비교/_취합/개선안/README.md, docs/연구결과서_초안.md 5절.
관련 표: 부록 C.

부록 상세 · 본편 9장 · 실험 수행 방법: 실험 수행 연대기(12시간 39분)

첫 구성 검수부터 전체 실행·채점 확정까지 12시간 39분이 소요되었다. 터미널 중단 이후 파일 기록을 근거로 실험을 재개하였다

기록

09-01 13:21	첫 구성을 검수한 후 본실험 전체로 확장하였다.
09-01 19:14	터미널 전체 중단으로 대화 맥락이 소실되었으나 산출 파일과 게시판은 보존되었다. 새 세션은 파일 기록을 근거로 남은 실행을 재개하였다.
09-02 02:00	계획 120건을 실행하고 117건을 채점하였으며, 막힘 3건을 포함한 취합 확정판을 작성하였다(117+3=120).
09-02 02:10~03:00	개선안을 확정한 후 지침 5판으로 32건을 재실행하고 29건을 재채점하였다.

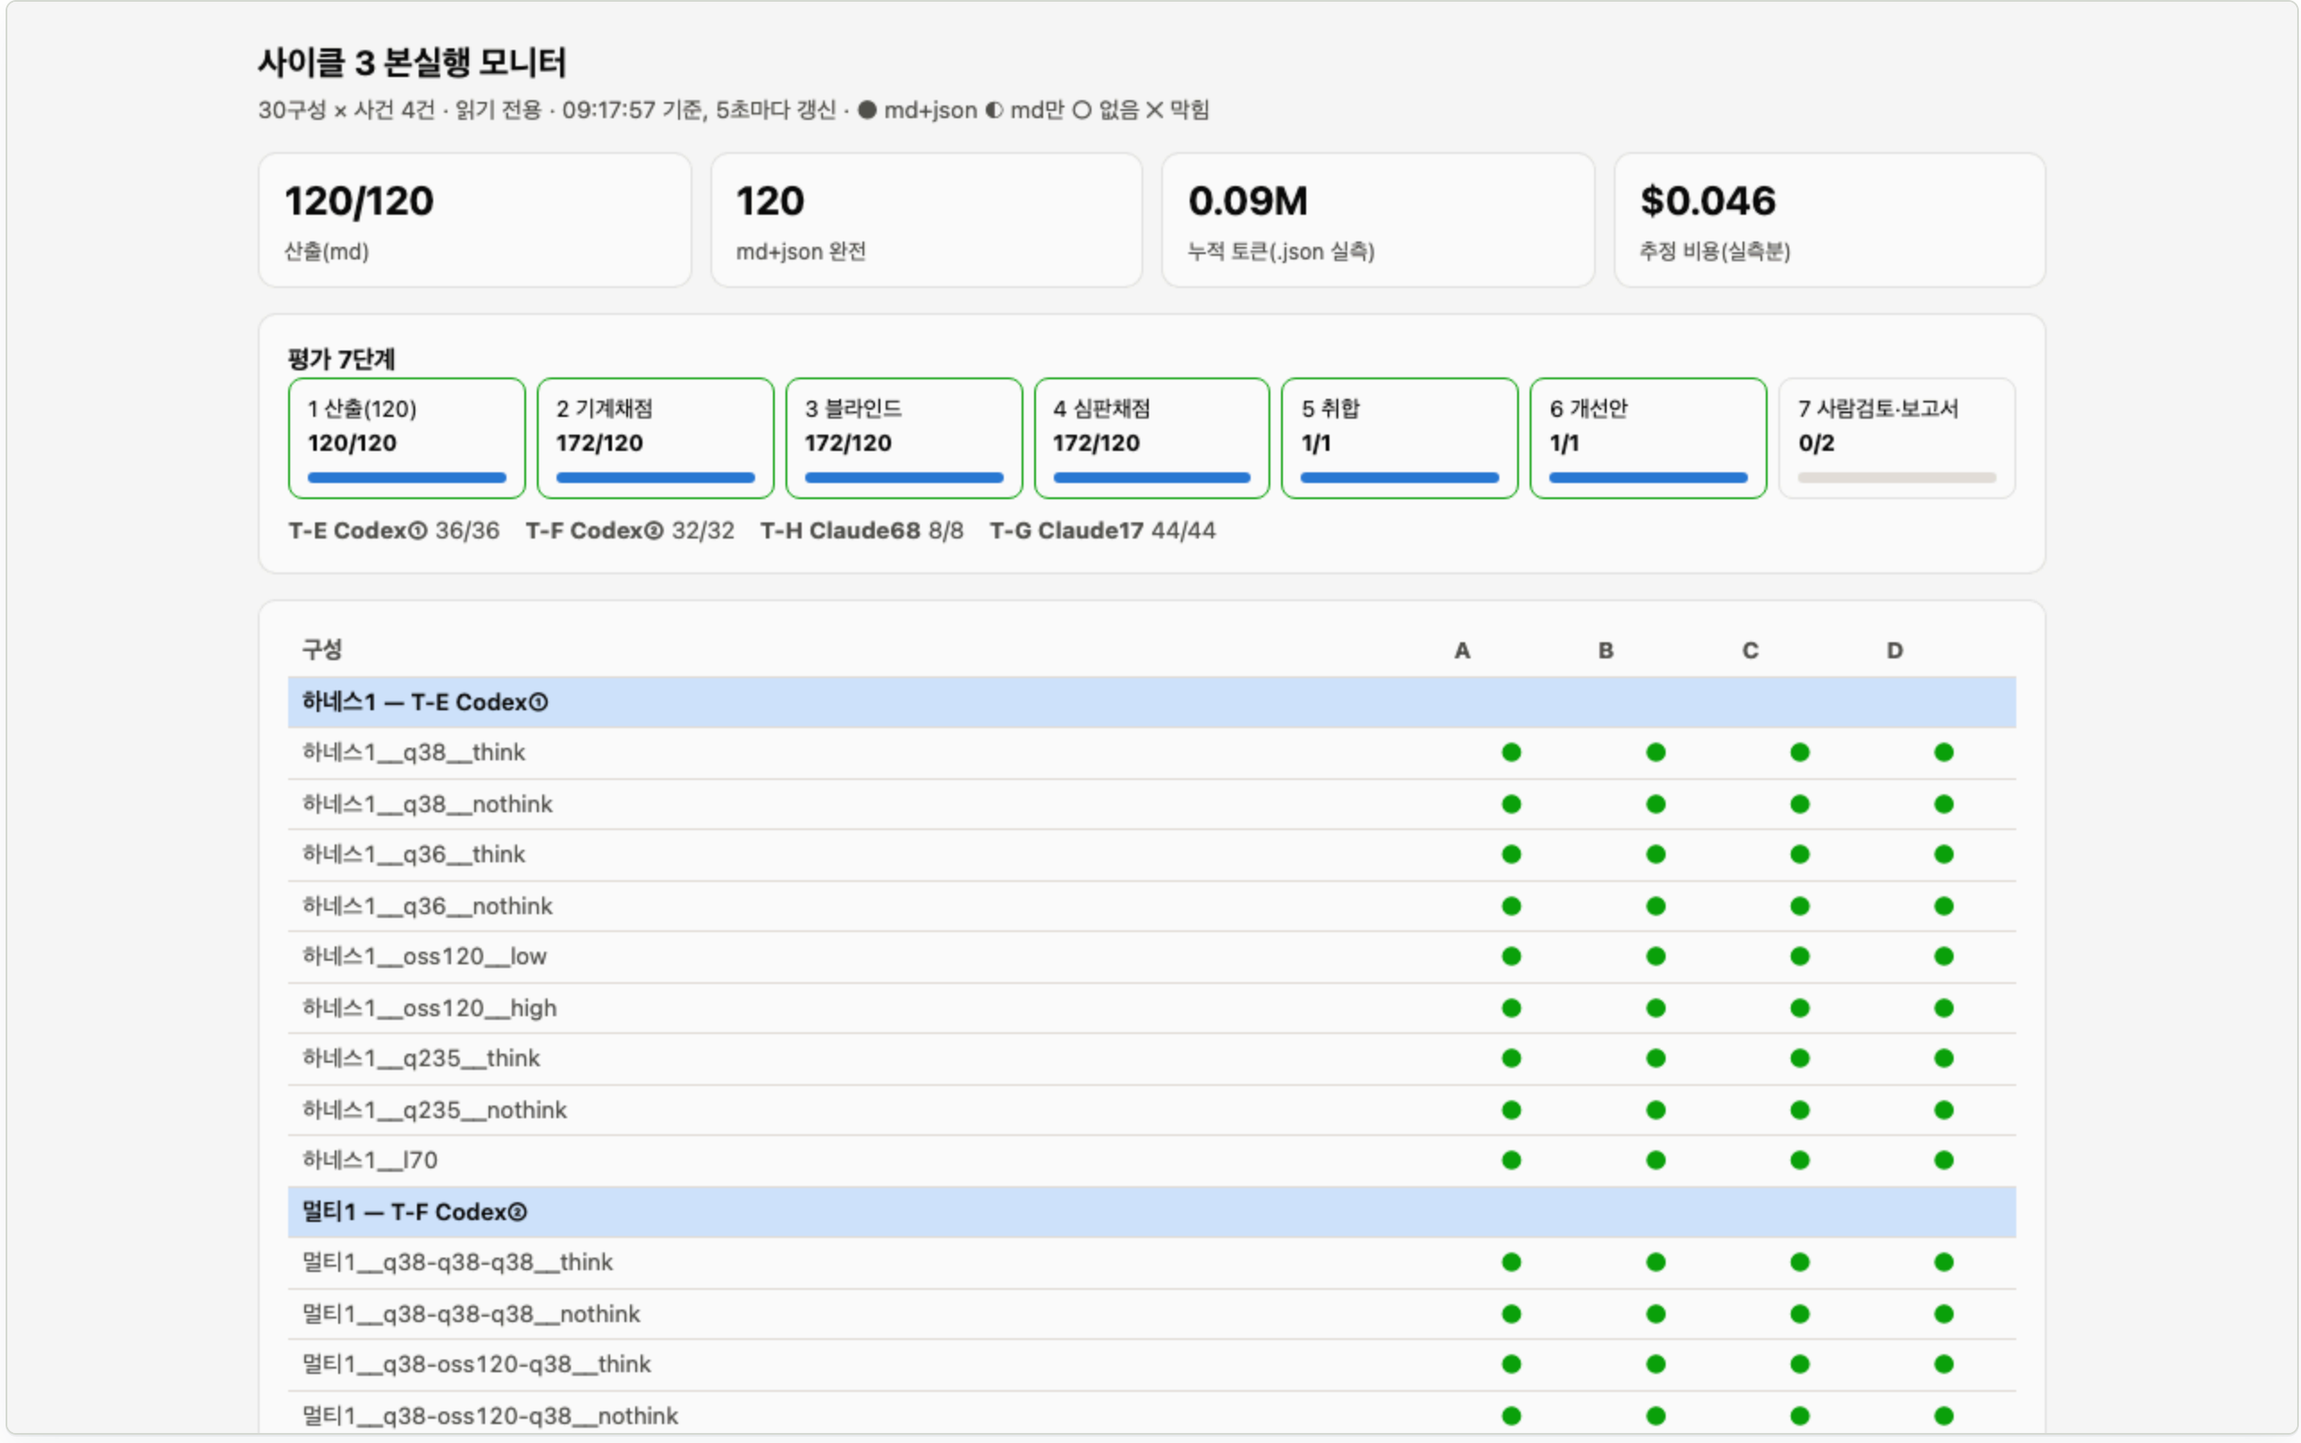


그림 1. 실험 모니터(monitor, 127.0.0.1:8912)는 30개 조합과 일상감사 요청 4건을 결합한 120건(30×4=120) 및 평가 7단계의 진행 상태를 읽기 전용으로 갱신하였다.

결과: 실행·평가·재검증 규모

- 실행 산출물은 Markdown 문서와 JSON 기록 120쌍이었다. 기계 점검은 111건, 블라인드 평가는 123건이었다. 심판 호출은 Claude 125건, GPT 95건, Gemini 30건으로 총 250건이었다(125+95+30=250).
- 취합 문서 4개, 실패 유형 5개, 개선안 5개를 산출하였으며 32건을 재검증하였다.
- 결제 오류와 API 키 노출은 각각 0건이었다. 입력 원본은 수정하지 않았다.

본 협업 절차에는 전달 확인, 실행 순서 제어, 자동 재시도가 없었다. 편집 범위도 기술적으로 강제되지 않았으므로 운영 수준의 자동화 체계로 일반화하는 데 한계가 있다.

출처: HANDOFF_도구통합.md 상태 보고, 도구/모니터/serve.py, 협업로그/.

수작업 협업 절차를 평가 실행틀(harness)의 구성요소와 입·출력 계약으로 정식화하였다

방법: 협업 절차와 평가 실행틀(harness) 구성요소의 대응 명세

게시판·한 줄 상태 기록	BOARD.md 계약 + 모니터(monitor)
점호와 검사 후 수용	도구 온보딩(onboarding) 검사기와 정적 검사 후 수용
도구별 실행 스크립트(script)	어댑터(adapter) 계약
Markdown·JSON 쌍과 메타데이터(metadata) 주석	러너(runner) 산출 계약
평가 5종	harness/eval 노드(node)
사용자 확정 게이트(gate)	게이트(gate) 3종
절대 규칙	헌법 7조

결과: 사용자 요구 4개에 대한 구현 명세

- 입력 안내는 케이스 팩(case pack) 스키마(schema)와 온보딩(onboarding) 검사기로 구현하였다. 자급형 도구는 14개 항목을 모두 통과하였고(14/14), 미포장 도구에는 부족한 4개 항목을 안내하였다.
- 서버 성능별 추천과 사용자 지정 모델은 메모리 계층(memory tier) 표(8GB~96GB×4), 용량 산정, 직접 입력 기능으로 명세하였다(부록 D).
- 비개발자 조작은 홈 화면의 도구·자료 끌어놓기(drag-and-drop)와 클릭 선택으로 명세하였다.
- 보고서는 첫 화면 요약, 등급 색상, 접기, 원문 링크(link)를 포함하는 템플릿(template)으로 명세하였다.

고찰: 자동화 범위와 인간 의사결정의 경계

- 파일과 종료 사유 점검, 블라인드 평가, 계열 분리 채점·취합, 실패 분류, 개선안 초안, 전체 재실행을 자동화 대상으로 정의하였다.
- 막힘의 재실행 여부, 불일치의 최종 판정, 운영 후보의 채택·보류, 개선안 문구 확정, 개선과 회귀의 수용은 사람의 의사결정으로 남겼다.
- 후속 도메인 팩(domain pack) 후보는 자격·중복·서류 검증 22건과 법령·규정·사례 검색 19건이다.

출처: 발표자료/하네스형 검토도구/설계서.md, 발표자료/하네스형 검토도구/README.md, 발표자료/하네스형 검토도구/CONSTITUTION.md, 발표자료/하네스형 검토도구/모델추천.md, 발표자료/gui형 검토도구/README.md.

운영 후보를 제한적으로 도출하였다. 회귀를 보완한 후 자체 서버 재검증과 사람의 최종 확정이 필요하다

조건부 채택: 회귀 보완 후 우선 재검증

유지: 선택적 검증 역할

보류: 기본 경로 채택을 보류하였다.

연구 질문 1: 대형 LLM은 검증 역할에 선택적으로 배치할 때 적중이 각각 5→7, 2→4로 증가하였다. 유지·강등·제외 집계와 자체 서버 재실행이 필요하다.

연구 질문 2: 축 분할에서 핵심 누락을 관찰하였으나 인과는 확정하지 못하였다. 원문 전체, 구조 보존 분할, 요약 입력의 직접 대조가 필요하다.

연구 질문 3: 재심사 연쇄는 단일 Qwen 3.8 27B 추론 끔의 9/24에서 13/24로 4개 기준이 증가하였다. 다만 지침 판본 차이가 혼재하고 창작 방지 기준은 미달하므로 동일 지침에서 재심사 켬·끔을 비교해야 한다.

연구 질문 4: 전체 실행과 복구는 12시간 39분에 완료되었고, 지침 5판의 32건 재실행과 29건 재채점은 약 50분이 소요되었다. 두 번째 도메인 팩(domain pack), 역방향 통신, 동시 저장 충돌을 추가 검증해야 한다.

결과: 운영 후보 판단

기본 후보	Qwen 3.6 27B 단일 프롬프트, 추론 켬 12→16/24	조건부 채택 회귀 보완 뒤 우선 재검증
검증 역할	gpt-oss-120b 검증 배치에서 +2/+2	유지 선택적 검증 역할
재심사 연쇄	13/24→11/24	보류 기본 경로 확정 보류
대형 검증 예비	Qwen3 235B-A22B 추론 켬 7/24, 추론 끔 2/24	조건부 예비안

고찰: 연구 질문별 중간 결론

- **1** 대형 모델은 검증 역할 선택 배치가 유리 → 유지·강등·제외 집계와 서버 재실행 필요
- **2** 축 분할에서 핵심 누락 관찰, 인과 미확정 → 원문·분할·요약 직접 대조
- **3** 재심사로 +4이나 지침 차이 혼재, 창작 방지 미완 → 같은 지침에서 켬·끔 비교
- **4** 12시간 39분 완주·복구·50분 재검증 → 두 번째 팩, 역방향 통신, 동시 저장 충돌 검증

한계 및 후속 검증

- 일상감사 요청 4건은 전체 일상감사 유형을 대표하지 않는다.
- OpenRouter를 통한 대리 실행이므로 관찰된 처리 시간을 자체 서버 처리량으로 환산할 수 없다.
- 재심사 연쇄의 지침 3판과 단일 프롬프트의 지침 4판 차이가 구조 효과에 혼재한다.
- 지침 5판은 8개 구성만 재검증하였다. 13/24와 16/24는 운영 인증이 아니라 후속 검증을 위한 기준선이다.
- 협업 워크플로우에는 전달 보장과 권한 강제 기능이 없다.

출처: docs/연구결과서_초안.md 0.2·1.7·3.7·5.4절, 결과/도구비교/_취합/개선안/검증결과_v5.md.

본 연구는 검토 워크플로우와 모델 조합별 적중·비용·소요 시간을 비교하였다.

표 1의 지침 4판 본실험에서 최고 적중은 재심사 연쇄의 13/24였으며, 가중평균은 6.62, 비용은 $0.0246, 소요 시간은 112초였다. 단일 프롬프트 Qwen 3.6 27B 추론 켬은 12/24를 기록하였고, Qwen 3.8 27B 추론 켬은 스카이런 막힘을 포함하여 10/18을 기록하였다. 나머지 조합의 적중·가중평균·비용·시간은 원자료의 결측값을 포함하여 그대로 제시한다. 대조군은 Gemma 3 12B 기준선과 운영문서 통째 투입으로 구분하였다.

사건별 최고 구성은 A 플랫폼 구축 6/6, B 서버 구매 4/6, C 개발 도구 구매 4/6, D 스카이런 4/6으로 나타났다.

검토·작성 모델을 Qwen 3.8 27B로 고정한 역할별 비교에서는 검증 역할에 배치한 모델의 적중·가중평균·비용·시간을 분리하여 산출하였다. 작성 모델을 동일하게 둔 재심사 비교에서는 Qwen 3.8 27B 단일 추론 끔의 9/24가 검산과 gpt-oss-120b 재심사 추가 후 13/24로 변하였다.

표 1은 확인 가능한 조합을 적중 수, 가중평균, 비용 및 소요 시간으로 정렬하여 제시한다.

구성	적중	가중평균	비용	시간
재심사 연쇄: Qwen 3.8 27B → 검산 → gpt-oss-120b(낮음)	13/24	6.62	$0.0246	112초
단일 프롬프트: Qwen 3.6 27B, 켬	12/24	6.50	$0.0532	497초
단일 프롬프트: Qwen 3.8 27B, 켬 (스카이런 막힘)	10/18	7.16	–	–
도구 호출형: Qwen 3.8 27B, 켬	9/24	6.30	$0.0445	250초
단일 프롬프트: Qwen 3.8 27B, 끔	9/24	5.52	$0.0154	21초
단일 프롬프트: gpt-oss-120b 낮음 · Qwen3 235B 끔	9/24	–	–	–
역할 분담형 최고: Qwen 3.8 + gpt-oss-120b 검증, 켬	7/24	5.41	$0.3504	2,140초
세 축 독립 검토 최고: gpt-oss-120b 낮음	4/24	4.87	$0.0040	41초
대조군: Gemma 3 12B 기준선 / 운영문서 통째	2/24 · 3/24	2.49 · 3.51	–	–

사건별 최고 구성

A 플랫폼 구축	재심사 연쇄 Qwen 3.8 → gpt-oss-120b	6/6
B 서버 구매	단일 Qwen 3.6 27B 켬	4/6
C 개발 도구 구매	단일 Qwen 3.8 27B 켬	4/6
D 스카이런	재심사 연쇄 Qwen 3.8 → gpt-oss-120b	4/6

역할별 배치 (검토·작성 = Qwen 3.8 27B 고정)

검증 역할	추론	적중	가중평균	비용	시간
Qwen 3.8 27B	켬	5/24	4.71	$0.3209	2,077초
gpt-oss-120b	켬	7/24	5.41	$0.3504	2,140초
Qwen3 235B-A22B	켬	7/24	5.02	$0.3025	1,947초
Qwen 3.8 27B	끔	2/24	3.84	$0.1150	543초
gpt-oss-120b	끔	4/24	4.15	$0.0975	451초
Qwen3 235B-A22B	끔	2/24	3.86	$0.1135	482초

재심사 효과 (작성 모델 동일)

Qwen 3.8 27B 단일, 끔 (지침 4판)	9/24	$0.0154	21초
+ 검산 + gpt-oss-120b 재심사 (3판+보정)	13/24	$0.0246	112초
+ 검산 + Qwen3 235B 재심사	5/24	–	–

출처: docs/연구결과서_초안.md 3.1·3.4·3.6절, 결과/도구비교/_취합/비교표.md.

본 표의 비용은 산출물 생성 실행분으로 한정하며, LLM 심판 비용은 포함하지 않았다.

표 2는 검토 워크플로우별 호출 수, 입력·출력 토큰 수, 비용, 소요 시간, 막힘 수 및 구조 내 최고 적중을 보고한다.

다섯 검토 워크플로우의 합계는 584회 호출, 입력 토큰 2,988,849개, 출력 토큰 1,049,708개, 비용 $3.62, 소요 시간 440분, 막힘 3건이었다. 구조 내 최고 적중은 세 축 독립 검토 하네스 4/24, 역할 분담형 멀티에이전트 7/24, 도구 호출형 하네스 9/24, 단일 프롬프트 12/24, 초안 작성 후 재심사 연쇄 13/24였다.

역할 분담형 Qwen 3.6 27B 추론 켬에서는 스키마 오류 30건과 시간 초과 2건을 자동 분할·재시도로 복구하였으며, 146회 호출, 출력 토큰 570,187개, 14,675초, $1.7498이 기록되었다. 가장 빠른 완주는 Qwen 3.8 27B 단일 프롬프트 추론 끔으로, 네 사건에 21초가 소요되었다. OpenRouter 처리 시간은 자체 서버 처리량으로 환산하지 않았다. 심판 채점은 Claude 125회, GPT 95회, Gemini 30회로 총 250회였으며(125+95+30=250), 사전 견적은 약 $10 내외였다.

검토 워크플로우	호출	입력 토큰	출력 토큰	비용	시간	막힘	구조 내 최고
세 축 독립 검토 하네스	90	513,099	50,529	$0.1969	1,219초	0	4/24
역할 분담형 멀티에이전트	425	2,063,844	903,925	$3.1660	23,126초	0	7/24
도구 호출형 하네스	9	77,362	13,270	$0.0464	297초	0	9/24
단일 프롬프트	36	268,613	67,369	$0.1614	1,404초	3	12/24
초안 작성 후 재심사 연쇄	24	65,931	14,615	$0.0486	372초	0	13/24
합계	**584**	**2,988,849**	**1,049,708**	**$3.62**	**440분**	**3**	

적중 1건당 비용은 통계적 효율성 지표가 아니라, 각 조합의 총비용을 적중 수와 함께 제시한 기술 통계로 해석한다.

비고			
재심사 연쇄 Qwen 3.8 → gpt-oss-120b	13	$0.0246	$0.0019
단일 Qwen 3.6 27B 켬	12	$0.0532	$0.0044
단일 Qwen 3.8 27B 끔	9	$0.0154	$0.0017
도구 호출형 Qwen 3.8	9	$0.0445	$0.0049
역할 분담 Qwen 3.8 + gpt-oss 검증	7	$0.3504	$0.0501

- 역할 분담형 Qwen 3.6 27B 켬: 스키마 오류 30·시간 초과 2를 자동 분할·재시도로 복구, 146회 호출·570,187 출력 토큰·14,675초·$1.7498.
- 가장 빠른 완주: Qwen 3.8 27B 단일 끔, 4사건 21초. OpenRouter 처리 시간은 자체 서버 처리량으로 환산하지 않음.
- 심판 채점 규모: 250회 호출, 사전 견적 약 $10 내외.

출처: 결과/도구비교/_취합/비용.md, docs/연구결과서_초안.md 4절.

기존 지침과 지침 5판의 변화는 전후 채점이 모두 존재하는 실행 28건을 기준으로 평가하였다. 사건별 적중(짝 비교 가능 실행 28건)

기준별 변화는 셀 수와 평균 변화량으로 구분하여 보고하며, 개선된 기준과 악화된 기준을 별도로 제시한다.

개선된 기준 중 평균 변화량은 금액 표기 불일치 +2.57, 규정 인용 +2.36, 과잉 지적 억제 +2.07 순이었다. 악화된 기준 중 평균 변화량은 핵심 초점 −0.21, 사실 정확성 −1.00, 확인된 일치사항 보존 −1.08, 직접경비 산출근거 −1.14, 조달 발주 원가 조정 실익 판단 −2.21이었다. 각 수치는 해당 기준의 셀 수와 평균 변화량을 함께 제시한 원자료를 따른다.

사건별 적중은 A 23→23, B 15→15, C 9→10, D 12→17로 변하였다. 최대 출력 토큰을 8,000으로 설정한 검증에서는 회복 2셀, 불변 막힘 2셀, 신규 막힘 1셀 및 재심사 연쇄 Qwen3 235B 구조 실패 4사건이 기록되었다.

심판 계열별 분포는 Claude 125셀·평균 3.80·표준편차 2.84·10점 비율 4%, GPT 95셀·평균 4.62·표준편차 3.49·10점 비율 17%, Gemini 30셀·평균 5.58·표준편차 3.99·10점 비율 37%로 나타났다. 심판 간 점수 차이가 3점 이상인 사례는 165건이었으며, 사건별로 A 32건, B 40건, C 43건, D 50건이었다.

개선된 기준 (셀 수 · 평균 변화)

금액 표기 불일치	7	+2.57
규정 인용	7	+2.36
과잉 지적 억제	15	+2.07
빈 산출근거 특정	6	+1.58
상금 산식 검산	6	+1.33
조치 어조	7	+1.29
요청 항목별 형식·어조	21	+1.29
참고 수준 어조 조절	8	+1.12
사실 창작 방지	28	+0.66
수의계약 적용요건	8	+0.19
문서 간 거리 대조	6	+0.08

악화된 기준

핵심 초점	7	−0.21
사실 정확성	22	−1.00
확인된 일치사항 보존	6	−1.08
직접경비 산출근거	7	−1.14

조달 발주 원가 조정 실익 판단	7	−2.21

사건별 적중 (28셀)

A 플랫폼 구축	23 → 23
B 서버 구매	15 → 15
C 개발 도구 구매	9 → 10
D 스카이런	12 → 17

실행 설정(최대 출력 토큰 8,000)

- 회복 2셀 · 불변 막힘 2셀(B·D×gpt-oss 높음) · 신규 막힘 1셀(A×Qwen3 235B 끔) · 재심사 연쇄 Qwen3 235B 구조 실패 4사건

심판 계열별 분포

계열	셀	점수 수	평균	표준편차	10점
Claude	125	750	3.80	2.84	4%
GPT	95	570	4.62	3.49	17%
Gemini	30	180	5.58	3.99	37%

- 점수차 3점 이상 165건: A 32·B 40·C 43·D 50. Claude−GPT 106, Claude−Gemini 59.
- 두 번째 심판이 더 높은 경우 GPT 90건, Gemini 57건. 기준별 창작 방지 55·형식 어조 26·사실 정확성 19.

출처: 결과/도구비교/_취합/개선안/검증결과_v5.md, 결과/도구비교/_취합/불일치.md, 결과/도구비교/_취합/비교표.md.

부록 D · 서버 성능별 모델 추천

GPU 메모리별 모델 적합도와 메모리 추정 계산식을 제시하며, 발주 전 실환경 시험을 필수 절차로 설정하였다.

4비트 양자화 기준으로 8GB에는 Qwen3 8B, 16GB에는 Gemma 3 12B·14B급, 24GB에는 Qwen 3.8·3.6 27B, 48GB에는 Llama 3.3 70B 또는 27B 두 개, 96GB에는 gpt-oss-120b, 96GB 두 장에는 Qwen3 235B-A22B를 배치할 수 있는 것으로 정리하였다. 96GB 네 장 구성에서는 작성·심사·심판 계열을 세 역할로 분리하는 구성을 제시하였다.

가중치 추정은 가중치(GB) ≈ 총 파라미터(B) × 0.59로 계산하며, 실측 범위는 0.575~0.61이다. 권장 메모리는 가중치 × 1.1 + 2로 산정한다. MoE 모델은 활성 파라미터가 아니라 총 파라미터를 기준으로 계산하며, gpt-oss-120b는 추론 시 활성 파라미터가 5.1B이지만 61GB를 전부 적재하는 것으로 기록하였다.

실험에서는 gpt-oss-120b의 높은 추론 강도에서 8,000토큰 출력도 절단되었고, Qwen 3.6 27B는 구조화 출력 강제 역할에 부적합하였다. Qwen3 235B-A22B는 추론을 끄면 형식이 붕괴하였으며, Llama 3.3 70B는 사실 창작 성향으로 검토 용도에서 제외하였다. 심판은 피평가 모델과 다른 계열을 2개 이상 사용하고, Gemini의 10점 비율 37%를 보정 대상으로 기록하였다.

GPU 메모리 (4비트)	돌릴 수 있는 모델	권장 구성
8GB	Qwen3 8B (7.2GB)	소형 작성·분류 입문용
16GB	+ Gemma 3 12B (9.8GB)·14B급	작성, 27B는 캐시 자리 없어 비권장
24GB	+ Qwen 3.8·3.6 27B (19.5GB)	작성 주력 티어
48GB	+ Llama 3.3 70B (47.4GB) 또는 27B × 2	27B 둘이 70B 하나보다 낫다(실측)
96GB	+ gpt-oss-120b (69.1GB, MoE)	작성 27B + 심사 120B 낮은 추론 = 지침 4판 본실험 최고 조합
96GB×2	+ Qwen3 235B-A22B (154.6GB, MoE)	대형 심사, 추론 켬
96GB×4	위 전부 동시 서빙	작성·심사·심판 계열 분리 3역할

계산식

```
가중치(GB) ≈ 총 파라미터(B) × 0.59 (실측 0.575~0.61)
권장 메모리(GB) ≈ 가중치 × 1.1 + 2
```

MoE는 활성 파라미터가 아닌 총 파라미터를 기준으로 계산한다. gpt-oss-120b는 추론 시 5.1B만 활성화하지만 61GB의 가중치를 전부 적재한다. 장비 자동 감지, 모델·목표 사용자로부터 필요 GPU 수를 계산하는 역방향 산정, S~F 적합 등급을 포함한다.

실험에서 확인한 제약 5건

- gpt-oss-120b 높은 추론 강도: 8,000토큰에서도 잘림 → 낮음 고정
- Qwen 3.6 27B: 구조화 출력 강제 역할에 부적합 → 단일 프롬프트에만
- Qwen3 235B-A22B 추론 끔: 형식 붕괴
- Llama 3.3 70B: 사실 창작 성향 → 검토 용도 제외
- 심판은 피평가 모델과 다른 계열 2개 이상, Gemini 관대화 37% 보정

출처: 발표자료/하네스형 검토도구/모델추천.md, 발표자료/하네스형 검토도구/모델추천.json, 발표자료/하네스형 검토도구/harness/용량산정.py, 발표자료/하네스형 검토도구/gpus.yaml.

부록 E · 선행연구와 설계 결정 대응표

본 연구는 선행연구의 관찰을 설계 결정과 대응시키고, 각 결정을 실험 절차에 적용하였다.

표 5는 설계 결정, 관련 선행연구, 핵심 근거 및 본 연구의 적용을 대응시킨다.

선행연구는 고정 절차와 외부 검증, 근거 식별자와 인용 검증, 구조화 출력과 내용 품질의 분리, 민감도에 따른 원문 보유 위치, 장문 압축의 손실, 참조답안과 블라인드 평가, 심판 계열 분리, 사람 확정 게이트의 필요성을 각각 제시하였다. 본 연구는 이에 대응하여 검토→검산→재심사 순서를 고정하고, 수치·조문 검증을 별도 단계로 분리하며, 폐쇄망에서 원문을 보유하고 외부 채점 심판과 구분하였다. 또한 골든 기준을 1~10점으로 채점하고, 모델명을 제거하며, 점수차가 3점 이상인 경우 사람 재검토 대상으로 분리하였다.

설계 결정	선행연구	핵심 근거	본 연구 적용
자율 협의 배제, 고정 순서와 전용 검증기	Cemri et al. 2025 MAST (arXiv:2503.13657) · Hong et al. 2023 MetaGPT (arXiv:2308.00352) · Zhang et al. 2024 AFlow (arXiv:2410.10762)	실패 14종을 설계 결함·비정렬·검증 실패로 분류	검토→검산→재심사 순서를 코드로 고정
자기 수정 대신 외부 검증기(강등 전용)	Huang et al. 2023 (arXiv:2310.01798) · Multi-Agent Verification 2025	외부 피드백 없는 자기 수정은 악화	수치 실재 대조를 코드로, 실패 시 강등
근거 ID 강제와 인용 실존 검증	Dahl et al. 2024 (arXiv:2401.01301) · Magesh et al. 2024 (arXiv:2405.20362)	법률 환각 58~88%, 상용 RAG 17~33%	조문 실존 검증, 창작 방지 기준
구조화 출력과 내용 품질 분리 보고	Willard & Louf 2023 Outlines · Dong et al. 2024 XGrammar · Tam et al. 2024	포맷 강제가 내용 품질을 낮출 수 있음	기계 점수와 심판 점수를 다른 열로
민감도 라우팅: 로컬이 원문 보유	Li et al. 2024 PAPILLON · Narayan et al. 2025 Minions · Ong et al. 2024 RouteLLM	외부에 요약·질의만 보내도 품질 85~98%	폐쇄망 실행, 외부는 채점 심판만
장문 압축과 손실	Jiang et al. 2023 LLMLingua · Pan et al. 2024 LLMLingua-2 · Li et al. 2024 SnapKV · SCBench	멀티턴 반복 검토에서 급락	요약 압축 불채택
참조답안·블라인드·쌍대비교 배제	Kim et al. Prometheus · Zheng et al. 2023 MT-Bench (arXiv:2306.05685) · Chiang et al. 2024 Chatbot Arena	참조답안이 인간 상관의 핵심	골든 기준 1~10점, 모델명 제거
다른 계열 심판 패널·계열 분리·불일치	Verga et al. 2024 PoLL · Panickssery et al. 2024 · Thakur et al. 2024	패널이 단일 심판보다 낫고 자기 생성문 선호, 최상위 심판도 5점 편차	Claude+GPT(+Gemini), 점수차 ≥3 사람 재검토
감사 도메인 사람 게이트	Wilson, Tayebi et al. 2026 IntelliAudit (arXiv:2608.07688)	사람이 27건 중 15건에서 관대한 AI 판정 교정	개선안 사용자 확정 게이트
국내 선행·공백	임경태 2025 (감사연구원) · Lee et al. 2025 KoBLEX (arXiv:2509.01324) · Pereira et al. 2025 INACIA	종결 사례 질의응답·사후 분석 중심	사전검토(일상감사) 실사건 평가

출처: AI_Workspace/docs/research/논문흐름지도.md, AI_Workspace/docs/research/연구계획서.md, AI_Workspace/docs/research/프로젝트_경과보고.md, 도구/실험계획/평가파이프라인.md

0절.

본 부록은 수치·판정·실행 기록을 확인할 수 있는 원자료 경로와 재현 순서를 제시한다.

연구 질문·해석·한계는 docs/연구결과서_초안.md, 사건×구성별 적중과 가중평균은 결과/도구비교/_취합/비교표.md, 호출·토큰·비용·시간·막힘은 결과/도구비교/_취합/비용.md에서 확인한다. 심판 점수차 사람 재검토 대기열은 결과/도구비교/_취합/불일치.md, 실패 패턴은 결과/도구비교/_취합/약점목록.md, 지침 5판 전후 변화는 결과/도구비교/_취합/개선안/검증결과_v5.md에서 확인한다. 실험 설계·평가 방법·논문 매핑은 도구/실험계획/모델실험계획서.md와 도구/실험계획/평가파이프라인.md에 기록하였다.

재현을 위해 비교표, 비용표, 불일치·약점목록, 지침 5판 검증의 순서로 원자료를 확인한다.

실행·모아보기·설정·결과보고서 화면은 기록된 화면 자료를 통해 확인한다. 화면 자료는 실행 결과의 해석을 대체하지 않으며, 원자료 경로와 함께 검토한다.

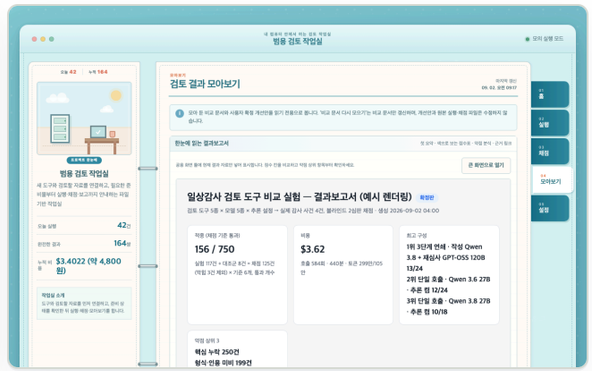
출처: 발표자료/집필/장표계획서.md, 발표자료/집필/1_배경_목적_선행연구_방법.md, 발표자료/집필/2_결과_논의_결론.md, 발표자료/검토작업실_발표자료_전체판.html.

확인하려는 내용	재현 자료
연구 질문·전체 해석·한계	docs/연구결과서_초안.md
사건×구성별 적중과 가중평균	결과/도구비교/_취합/비교표.md
호출·토큰·비용·시간·막힘	결과/도구비교/_취합/비용.md
심판 점수차 재검토 대기열	결과/도구비교/_취합/불일치.md
실패 패턴과 세부 기준	결과/도구비교/_취합/약점목록.md
지침 5판 전후 변화	결과/도구비교/_취합/개선안/검증결과_v5.md
실험 설계·평가 방법·논문 매핑	도구/실험계획/모델실험계획서.md · 평가파이프라인.md
산출물·녹화·협업 기록	발표자료/하네스형 검토도구/ · gui형 검토도구/ · 녹화/ · HANDOFF_도구통합.md · 협업로그/
장표 계획과 원고 · 전체판(25장)	발표자료/집필/장표계획서.md · 1_·2_ 원고 · 검토작업실_발표자료_전체판.html

읽는 순서: 비교표 → 비용표 → 불일치·약점목록 → 지침 5판 검증.



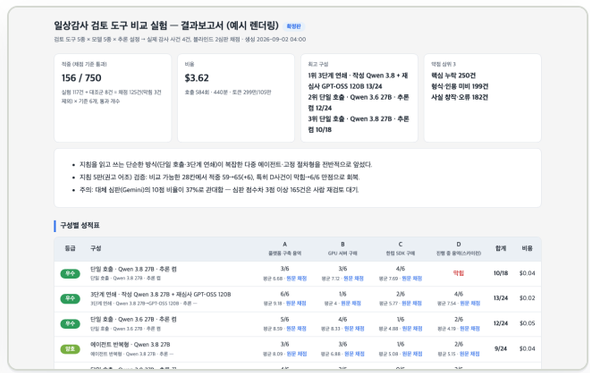
실행 화면



모아보기 화면



설정 화면



결과보고서 가독화 예시

다음 실험을 데이터가 제안한다: 채점 결과는 18개 조합의 재실행 중단과 7개 후보의 추가 검증을 제안하였다.

목적. 본 제안서는 기존 실험의 채점 결과를 이용하여 재실행 우선순위가 낮은 조합과 아직 탐색하지 않은 후보를 구분하는 것을 목적으로 한다.

방법. 채점된 구성 32개와 총 125건의 채점 결과를 입력으로 사용하였다. 적중률 25% 미만을 가지치기 기준으로 적용하였으며, 같은 도구에 비교 가능한 결과가 있는 경우 도구 내 최고 구성과의 격차를 함께 검토하였다. 미탐색 후보의 기대 적중률은 모델과 도구 등 구성요소별 실측 평균에서 추정하였다. 제안서는 python3 harness/eval/탐색제안.py로 재생성한다.

결과. 재실행 중단 후보 18개와 추가 실험 후보 7개를 도출하였다. 기존 구성요소를 교차한 후보 5개의 기대 적중률은 25~26%였으며, 신규 모델 축 2개는 실측값이 없어 기대 적중률을 산정하지 않았다.

고찰. 기대 적중률은 실측 성능이 아니라 구성요소별 평균에 근거한 추정치이다. 사용자가 후보를 승인한 뒤 동일 사건·동일 평가 규칙으로 실행·채점하고 취합 결과를 비교한다.

다음 실험 후보 7개

제안 구성	기대 적중률	예상 비용 (4사건)
재심사 연쇄 · Qwen3 235B-A22B → gpt-oss-120b	26%	$0.008
재심사 연쇄 · Qwen 3.6 27B → gpt-oss-120b	26%	$0.058
재심사 연쇄 · Qwen 3.6 27B → Qwen3 235B-A22B	26%	$0.058
도구 호출형 · Qwen3 235B-A22B · 지침 4판	25%	$0.005
도구 호출형 · Qwen 3.6 27B · 지침 4판	25%	$0.036
단일 프롬프트 · Qwen3 8B · 추론 켬	실측 없음	$0.020
단일 프롬프트 · EXAONE 4.0 32B · 추론 켬	실측 없음	$0.020

가지치기 기준과 결과

항목	값
채점된 구성	32개
채점 결과	125건
가지치기 기준	적중률 25% 미만
재실행 중단 후보	18개
중단 후보 적중 범위	1/24~5/24
중단 후보 실측 비용 범위	$0.002~$1.750

사용자 승인 관문

1. 사용자가 추가 실험 후보를 선택한다.
2. 실행 담당을 배정한다.
3. 동일 사건·동일 평가 규칙으로 실행·채점한다.
4. 결과를 취합하여 기존 구성과 비교한다.

제안서일 뿐 실행하지 않습니다. 하네스 헌법 7에 따라 중단·추가 권고는 사용자가 승인한 뒤에만 다음 실험 계획에 반영한다.

출처: 결과/도구비교/_취합/탐색제안.md. 재현: python3 harness/eval/탐색제안.py.