



공공부문 AI기반 의사결정을 위한 신뢰 기반 거버넌스 설계 방안

김성부 · 이종한 · 홍승헌 · 황하 · 임희선 · 이종훈 · 정원준



한국행정연구원

참여연구진

연구책임자

김성부 연구위원, 이종한 전문연구위원

공동연구자

홍승헌 연구위원, 황하 연구위원, 임희선 부연구위원, 이종훈 교수(KAIST),
정원준 수석연구위원(법무법인 광장)

연구참여자

임현철 전문연구위원

출처를 밝히지 않고 이 보고서를 무단전제 또는 복제하는 것을 금합니다.
본 보고서의 내용은 연구책임자의 개인적 의견이며, 연구원의 공식적인 의견은 아님을 밝힙니다.

본 연구보고서를 인용하실 때는 다음과 같은 사항을 기재해주십시오.
김성부 외. (2025). 공공부문 AI기반 의사결정을 위한 신뢰 기반 거버넌스 설계 방안. 한국행정연구원
연구개발적립금 자체연구보고서

제1장 서론 1

제1절 연구의 배경 및 목적 | 이종한·김성부 2

1. 연구의 배경 2

2. 연구의 목적 3

제2절 연구의 내용 및 방법 | 김성부·이종한 4

1. 연구의 내용 4

2. 연구의 방법 4

제2장 이론적 논의 5

제1절 ADM 체계의 이론적 검토 | 김성부·정원준 6

1. 주요 개념 정의 및 특성 6

2. 선행연구 동향 13

제2절 신뢰가능한 AI 거버넌스 원칙 | 임희선 18

1. 투명성 및 설명가능성 21

2. 편향 최소화 및 공정성 22

3. 책임성 및 감사가능성 24

4. 인간 중심성 26

5. 국제협력 및 상호운용성 27

제3절 숙의민주주의와 시민참여 문제 | 홍승헌 29

1. 공공의사결정에서 AI의 위험성 29

2. 공공의사결정에서 숙의민주주의의 필요성 30

제4절 ADM 거버넌스 신뢰성 분석틀 | 김성부·이종한 34

제3장 ADM 거버넌스 신뢰성 분석 37

제1절 설문조사 개요 | 김성부·이종한 38

1. 조사 목적 및 대상 38
2. 설문조사의 주요 내용 39

제2절 설문조사 결과 | 김성부 42

1. 일반현황 42
2. AI 시스템 신뢰도 결정요인 (생애주기 공통 및 단계별) 47
3. AI 시스템 종합평가, 진단 및 개선계획 68

제3절 순서형 로짓 회귀분석 | 김성부 75

제4절 소결 | 김성부 79

제4장 ADM 거버넌스 사례분석 83

제1절 대한민국 공공부문 ADM 현황 | 이종한 84

1. 최근의 AI관련 환경변화 84
2. 인공지능기본법 체계와 공공기관의 법적 책무 85
3. 행정안전부·과학기술정보통신부 사례 89
4. ADM 거버넌스 신뢰성 확보를 위한 시사점 94

제2절 네덜란드 아동수당 부정수급 탐지 알고리즘 | 이종훈 95

1. 도입 배경과 시스템의 작동 메커니즘 95
2. 시스템의 기술적 메커니즘: 블랙박스 차별 알고리즘 97
3. 실제 운영 방식과 피해 규모 100
4. 프레임워크 기반 신뢰성 진단 101
5. 소결 112

제5장 결론	115
제1절 ADM 거버넌스 설계 및 구축의 중요성 이종한	116
1. 인공지능기본법 시행과 고영향 인공지능 규제체계	117
2. 공공 AI데이터 거버넌스의 진화 및 필요성	118
제2절 ADM 거버넌스의 법적·제도적 개선전략 이종한	121
1. 인공지능 및 데이터 기반 행정 활성화에 관한 법률 개정	121
2. 공공기관의 인공지능 기반 의사결정 거버넌스 규율 강화	125
제3절 ADM 거버넌스의 조직적·문화적 개선전략 이종한	127
1. 인공지능기본법의 국가 AI 거버넌스 체계	127
2. 인적 역량강화 및 조직문화 혁신 전략	133
3. 참여적 거버넌스 구축 전략: 데이터 스튜어드십과 트러스트	137
참고문헌	143

표차례

〈표 2-1〉 AI 기반 의사결정 시스템에 관한 선행연구	13
〈표 2-2〉 주요 국가의 AI 법·제도적 프레임워크 비교	19
〈표 2-3〉 신뢰가능한 AI 거버넌스의 핵심 원칙	20
〈표 2-4〉 AI 시스템 생애주기 (OECD, 2019)	34
〈표 2-5〉 AI 시스템 생애주기 단계별 신뢰도 결정요인	35
〈표 3-1〉 설문조사 개요	38
〈표 3-2〉 설문조사의 주요 내용	40
〈표 3-3〉 AI 시스템 신뢰도 결정요인 및 지표 : 전 단계 공통	48
〈표 3-4〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통	51
〈표 3-5〉 AI 시스템 신뢰도 결정요인 및 지표 : 1단계	52
〈표 3-6〉 AI 시스템 신뢰도 결정요인 : 1단계	55
〈표 3-7〉 AI 시스템 신뢰도 결정요인 및 지표 : 2단계	56
〈표 3-8〉 AI 시스템 신뢰도 결정요인 : 2단계	59
〈표 3-9〉 AI 시스템 신뢰도 결정요인 및 지표 : 3단계	60
〈표 3-10〉 AI 시스템 신뢰도 결정요인 : 3단계	63
〈표 3-11〉 AI 시스템 신뢰도 결정요인 및 지표 : 4단계	64
〈표 3-12〉 AI 시스템 신뢰도 결정요인 : 4단계	67
〈표 3-13〉 AI 시스템 종합평가 항목 및 지표	68
〈표 3-14〉 AI 시스템 종합평가	71
〈표 3-15〉 순서형 로짓 회귀분석 모형의 주요 변수	75
〈표 3-16〉 순서형 로짓 회귀분석 모형	76
〈표 3-17〉 순서형 로짓 회귀분석 결과	77
〈표 5-1〉 고영향 인공지능 판단기준	118
〈표 5-2〉 인공지능 시대를 규정하는 핵심 용어	122
〈표 5-3〉 행정안전부의 AI교육과정 공공 AI역량 트랙	134
〈표 5-4〉 AI기반 행정의 인간개입 유형에 따른 책임성 확보 메커니즘	135

그림차례

〈그림 2-1〉 AI 시스템 생애주기	35
〈그림 2-2〉 AI 시스템 생애주기별 주요 결정요인	36
〈그림 3-1〉 시스템 특성 : 기관 유형 및 도입 단계	43
〈그림 3-2〉 시스템 특성 : 영향 범위 및 의사결정 자율성	43
〈그림 3-3〉 시스템 특성 : 위험도	44
〈그림 3-4〉 응답자 특성 : 성별 및 연령대	45
〈그림 3-5〉 응답자 특성 : 관련 경력 및 정보시스템 업무 여부	46
〈그림 3-6〉 응답자 특성 : 담당 업무	47
〈그림 3-7〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통	49
〈그림 3-8〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통 (도입 단계별)	50
〈그림 3-9〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통 (영향 범위별)	50
〈그림 3-10〉 AI 시스템 신뢰도 결정요인 : 1단계	53
〈그림 3-11〉 AI 시스템 신뢰도 결정요인 : 1단계 (도입 단계별)	54
〈그림 3-12〉 AI 시스템 신뢰도 결정요인 : 1단계 (영향 범위별)	54
〈그림 3-13〉 AI 시스템 신뢰도 결정요인 : 2단계	57
〈그림 3-14〉 AI 시스템 신뢰도 결정요인 : 2단계 (도입 단계별)	58
〈그림 3-15〉 AI 시스템 신뢰도 결정요인 : 2단계 (영향 범위별)	58
〈그림 3-16〉 AI 시스템 신뢰도 결정요인 : 3단계	61
〈그림 3-17〉 AI 시스템 신뢰도 결정요인 : 3단계 (도입 단계별)	61
〈그림 3-18〉 AI 시스템 신뢰도 결정요인 : 3단계 (영향 범위별)	62
〈그림 3-19〉 AI 시스템 신뢰도 결정요인 : 4단계	65
〈그림 3-20〉 AI 시스템 신뢰도 결정요인 : 4단계 (도입 단계별)	65
〈그림 3-21〉 AI 시스템 신뢰도 결정요인 : 4단계 (영향 범위별)	66
〈그림 3-22〉 AI 시스템 종합평가	69
〈그림 3-23〉 AI 시스템 종합평가 (도입 단계별)	70
〈그림 3-24〉 AI 시스템 종합평가 (영향 범위별)	70
〈그림 3-25〉 AI 시스템 신뢰도 결정요인 중 가장 미흡한 영역	72
〈그림 3-26〉 AI 시스템 신뢰성 확보 장애요인	73

〈그림 3-27〉 AI 시스템 개선계획	74
〈그림 3-28〉 AI 시스템 신뢰도 결정요인 (공통 및 단계별)	80
〈그림 4-1〉 고영향 인공지능 활용 영역	86
〈그림 4-2〉 고영향 인공지능 확인 절차	87
〈그림 4-3〉 인공지능기본법의 인적 적용 범위	88
〈그림 4-4〉 범정부 AI 공통기반과 지능형 업무관리 플랫폼 비교	91
〈그림 4-5〉 기존 망 분리 정책과 국가 망 보안체계 비교	92
〈그림 4-6〉 업무정보에 대한 S/S/O 분류기준	93
〈그림 5-1〉 AI기본법과 공공AI법에 따른 국가 AI거버넌스 구조	130

1. 연구목적 및 필요성

○ 연구의 배경 및 필요성

- 디지털플랫폼정부 구현의 핵심으로 AI 기술과 RPA 등 업무 자동화 도입이 체계적으로 확산 중
- 기존의 규칙 기반 RPA를 넘어 스스로 데이터를 분석하고 학습하는 AI 기반 알고리즘 의사결정(ADM) 시스템으로 급격히 전환될 전망
- 복지급여 심사, 사기 적발 등에서 효율성 증진이 기대되나, 투명성 결여, 알고리즘 편향, 책임소재 불분명으로 인한 사회적 신뢰 훼손 우려도 공존
- 네덜란드, 영국 등의 실패 사례는 ADM 사용이 사회적 혼란을 초래할 수 있음을 보여주며, 기술적 성능만큼이나 사회적 수용성과 정당성 확보가 중요한 정책 이슈로 부상
- 기술적 성능을 넘어선 정당성 및 수용성 확보: 신뢰가 확보되지 않은 기술 도입은 사회적·경제적 비용을 막대하게 증가시키며, 시민사회와 정부 간의 관계를 악화

○ 연구의 목적

- AI 기반 의사결정 시스템에 관한 선행연구 및 국내외 사례를 분석하고, 시스템 신뢰성에 영향을 미치는 결정요인을 실증적으로 분석
- 데이터 수집부터 산출까지 전 과정에서 인간의 책임과 개입(HITL)을 반영한 신뢰 기반 ADM 거버넌스를 제시

○ 연구의 내용

- 이론적 논의: ADM 시스템의 개념 및 특징 검토를 통해 신뢰성 측정 및 개선을 위한 분석틀 도출
- 신뢰성 분석: 공공부문 종사자를 대상으로 ADM 시스템의 신뢰도와 결정요인에 대한 주관적 평가를 실증 분석

- 사례 분석: 국내 ADM 현황 및 사례를 살펴보고, 도출된 분석틀을 국외 ADM 도입 사례에 접목하여 심층적으로 고찰
- 거버넌스 설계: 연구 내용을 바탕으로 ADM 신뢰 제고를 위한 거버넌스 구축 방안 제시

2. 연구 방법 및 주요 연구 결과

○ 연구 방법

- 문헌 연구: 국내외 연구 논문, 정부 간행물, 정책 보고서 등에 대한 고찰을 수행
- 실증 연구: 공공부문 AI 시스템 담당자 및 사용자를 대상으로 설문조사를 실시하고, 순서형 로짓 회귀분석을 통해 신뢰도와 결정요인 간 관계를 분석
- 질적 연구: 심층 사례분석을 통해 정량적 연구 결과를 보완

○ 이론적 논의

- 개념 및 특성: ADM은 알고리즘이 데이터를 학습하여 물리적·가상 환경에 영향을 미치는 결정을 내리는 체계로, 자기 학습 및 진화, 확률적 추론, 본질적 불투명성, 데이터 의존성, 사회·기술적 복잡성 등의 특성 보유
- 신뢰가능한 AI 거버넌스 원칙: 신뢰가능한 AI를 위해 투명성·설명 가능성, 편향 최소화·공정성, 책임성·감사 가능성, 인간 중심성, 국제협력·상호운용성의 원칙 도출
- 속의민주주의: AI는 대규모 참여 데이터를 처리하여 지식 격차를 줄이는 등 속의민주주의를 확장할 가능성이 있지만, 알고리즘의 편향과 불투명성을 제어하기 위한 민주적 통제 메커니즘이 필수적
- AI 시스템 생애주기 (OECD 4단계): 설계·데이터·모델링, 검증·확인, 배포, 운영·모니터링
- ADM 거버넌스 신뢰도 결정요인: Agbabiaka et al.(2025)의 18개 요구사항을 생애주기 단계별(17개) 및 전 단계 공통(8개) 요인으로 매핑하여 총 25개의 분석 지표 도출

○ 설문조사 개요

- 조사 목적: 공공부문 AI 기반 의사결정 시스템의 신뢰성을 진단하고, 이용자 신뢰 확보 및 시스템 개선을 위한 실질적인 방안 도출
- 조사 대상: 전국 중앙행정기관, 지자체, 공공기관 종사자 중 AI 시스템 담당자 및 사용자 총 198명
- 조사 내용: 시스템 특성(위험도, 자율성 등), 생애주기별 신뢰도 결정요인(25개), 종합평가 및 개선계획

○ 설문조사 결과: 응답자 현황

- 활용 범위: 내부 업무 지원(62.6%)이 가장 많으며, 시민 대상 서비스(27.3%), 정책 의사결정 지원(10.1%)은 비교적 적음
- 자율성 수준: AI가 정보를 추천하고 인간이 최종적으로 결정하는 ‘의사결정 지원(HITL)’ 방식이 82.3%로 압도적 다수
- 위험도: 영향이 경미한 저위험 시스템(71.7%)이 고위험 시스템(28.3%)보다 2배 이상 많은 것으로 확인

○ 설문조사 결과: 신뢰도 결정요인 평가(5점 만점)

- 전 단계 공통: 이해관계자 참여(3.40점)와 인간의 감독(3.37점) 평가가 높은 반면, 투명성(3.23점)과 책임성(3.24점)은 상대적으로 낮음
- 단계별 특징: 설계·검증 등 초기 단계(1~2단계)보다 배포·운영 등 후기 단계(3~4단계)의 결정요인 점수가 더 높게 나타남
- 특성별 차이: 의사결정 자율성이 높은 시스템, 고위험 시스템, 그리고 정보시스템 업무 담당자일수록 신뢰도를 더 높게 평가

○ 설문조사 결과: 진단 및 개선 방향

- 미흡한 영역: 기술적 견고성(50명), 데이터 프라이버시 및 보안(43명), 데이터 관리(41명) 순으로 보완이 시급하다고 지목
- 신뢰 확보 장애요인: 전문 인력 부족(84명)과 예산 부족(83명)이 가장 큰 걸림돌로 나타남

- 향후 개선계획: 담당자 AI 교육 강화(71명), 보안 및 프라이버시 강화(59명), 데이터 품질 관리 강화(56명)를 우선 추진할 예정이라고 응답

○ 신뢰도 결정요인 회귀분석 결과

- 신뢰도 향상 핵심 요인: '이해관계자 참여'와 '정치적 정당성 및 민주주의' 변수가 AI 시스템의 신뢰도 향상에 통계적으로 유의미한 정(+)의 영향을 미침
- 공정성 강조: 시스템의 공정성 및 비차별 요건이 충족될수록 이용자가 느끼는 종합적인 신뢰도가 높아지는 경향을 보임

○ 설문조사 소결 및 의의

- 설문데이터 분석 결과, 공공부문 AI 시스템의 신뢰도는 전반적으로 '약간 충분한 수준'이나, 기술적 견고성과 데이터 관리에 대한 체감도는 여전히 낮음
- 신뢰받는 ADM 시스템 구축을 위해서는 생애주기 전 과정에서의 이해관계자 참여 확대와 민주적 정당성 확보, 그리고 실질적인 책임성 기제 마련이 필수적

○ 대한민국 공공부문 ADM 사례: 최근의 환경변화 및 제도적 기반

- 인공지능기본법 시행(2026년): AI를 국가 행정 의사결정 체계에 공식 편입하고 법적 책임과 신뢰성 확보를 명문화
- 고영향 인공지능 규제: 국민의 생명·안전·기본권에 직결된 분야(복지 수혜 자격 심사 등)를 '고영향 AI'로 규정하여 엄격한 거버넌스 체계 구축을 강제
- 공공기관의 3대 법적 책무: 투명성 확보(사전 고지), 안전성 확보 및 위험 관리, 설명 의무(결정 근거 제공)

○ 대한민국 공공부문 ADM 사례: 정부 주도의 AI 인프라 구축

- 범정부 AI 공통기반 서비스: 보안이 확보된 정부 내부망에서 민간 초거대 AI 모델을 공동 활용하는 국가 표준 인프라
- 지능형 업무관리 플랫폼(행정 AI 비서): 공무원의 단순 반복 업무를 줄이고 맥락 기반 질의응답 및 업무 자동화를 지원하는 서비스
- 국가 망 보안체계(N2SF): 데이터 등급(기밀/민감/공개)에 따른 차등적 보안 통제로 데이터 공유와 보안성 확보를 병행

○ 네덜란드 아동수당 부정수급 탐지 알고리즘 사례: 개요

- 조세청의 사기 탐지 알고리즘이 이중국적 및 외국인 국적을 위험 지표로 사용해 26,000가구를 부정수급자로 오분류
- 수만 유로의 강제 환수 조치로 가정이 파산하고 2,000명 이상의 아동이 부모와 분리되는 등 '전례 없는 불의'를 초래하여 네덜란드 정부가 총사퇴

○ 네덜란드 사례의 실패 원인에 대한 생애주기별 신뢰성 진단

- 설계 단계: 사기 예방이라는 공식 목표 대신 외국인 혐오적 포퓰리즘에 따른 '정치적 단속'이 실제 목표로 변질. 이해관계자 참여가 배제된 채 위법하게 국적 데이터를 수집
- 검증 단계: 기술적 견고성 테스트 부재로 유죄 판결율이 1% 미만인 저성능 알고리즘이 배포. 결정 근거를 알 수 없는 '블랙박스'로 설계
- 배포 및 운영 단계: 차별적 피드백 루프로 인해 시간이 갈수록 차별이 증폭되었으나 성능 모니터링이 없었음. 내부 고발자와 옴부즈맨의 경고 등 피드백을 무시
- 전 단계 공통: 투명성이 완전히 억압되었고, '알고리즘의 결정'이라는 핑계 뒤에 책임 구조가 붕괴되었으며, 인간의 감독은 형식적으로만 존재

○ 사례분석 소결 및 의의

- 기술의 비중립성 인식: 편향된 데이터로 학습된 알고리즘은 과거의 차별을 자동화하고 규모화하므로, 기술적 효율성보다 윤리적 정당성과 민주적 책임성이 우선되어야 함
- 다차원적 통제 메커니즘: 배포 전 알고리즘 영향평가(AIA)를 의무화하고, 고위험 결정에는 반드시 인간이 개입(HITL)하는 구조를 설계해야 함
- 이의제기권 보장: 블랙박스 시스템은 민주주의와 양립할 수 없으므로, 시민의 알 권리를 보장하고 실질적인 구제 절차를 마련하는 것이 필수적

3. 정책제언 및 법령 개정사항

○ ADM 거버넌스 설계 및 구축의 중요성

- 소버린 AI(Sovereign AI) 경쟁: AI 기술이 국가 안보와 경제의 핵심 자산이 됨에 따라, 자국의 법과 가치에 따라 AI를 통제하는 능력 확보가 필수적
- 행정의 AI 전환 가속화: 2026년 ‘인공지능기본법’ 시행과 함께 공공부문 AI 도입이 가속화되고 있으나, 데이터 품질 저하 및 책임 소재 불분명 등 도전과제가 산재
- 신뢰 확보의 필요성: 고위험 영역의 ADM은 국민의 기본권에 직결되므로, 기술적 효율성을 넘어 법적·윤리적 책임성을 담보하는 거버넌스 설계가 요구됨

○ 법적·제도적 개선 전략

- 공공AI법 전면 개정 (2026년 2월): 기존 데이터 기반 행정을 ‘인공지능 기반 행정’으로 확대하고 ‘학습용 데이터’ 관리를 법제화
- 책임성과 투명성 원칙 확립: AI가 의사결정에 활용되더라도 최종 권한과 책임은 반드시 공공기관에 있음을 명시하여 ‘책임 공백’을 차단
- 공공분야 인공지능 영향평가 도입: AI 도입 전 기본권에 미치는 영향을 사전에 평가하고 결과를 공개하는 제도를 마련
- 권리 구제 절차 강화: AI 기반 처분에 대한 시민의 ‘설명 요구권’과 ‘재결정 요구권’을 행정절차법 등에 명문화할 필요

○ 조직적·문화적 개선 전략

- 다층적 거버넌스 체계 구축: 전략 계층(국가인공지능전략위원회를 통한 정책 방향 설정), 조정 계층(인공지능책임관협의회를 통한 부처 간 정책 정렬), 실행 계층(각 기관의 AI·데이터 행정책임관을 통한 실질적 도입 및 위험 관리)
- 인간 개입(Human-in-the-loop)의 유형화: 위험도에 따라 HITL(실질적 재검토), HOTL(예외적 수정), HOOTL(정기적 감사)로 인간 개입 수준을 차등 설계

- 인적 역량 강화: 공무원 AI 리터러시 강화를 위해 4단계 ‘공공 AI 역량 트랙’과 ‘AI 챔피언 인증제’를 운영
- 견제와 균형: 내부 AI-CDO의 실행력과 독립적인 AI윤리위원회의 규범적 통제를 유기적으로 결합

○ 참여적 거버넌스 및 데이터 신뢰 모델

- 데이터 스튜어드십(Data Stewardship): 데이터 주체인 국민의 권익을 대변하는 신뢰 기반의 수탁자 모델로 전환하여 ‘윤리 워싱’ 문제를 해결
- 데이터 트러스트(Data Trust) 도입: 독립적인 제3의 기구에 데이터 관리 권한을 위탁하고 ‘신의성실의무’를 부과하여 공익 중심의 데이터 활용을 도모
- 사회적 합의 중심의 거버넌스: 단순한 ‘고지 및 동의’를 넘어, 이해관계자가 참여하는 독립 패널이 데이터 활용의 공익성과 윤리성을 심의하는 구조로 진화 촉진

제1장 서론

제1절 연구의 배경 및 목적

제2절 연구의 내용 및 방법

제1장 서론

제1절 연구의 배경 및 목적

1. 연구의 배경

정부가 추진하고 있는 디지털플랫폼정부 구현의 핵심기술은 AI 기술과 RPA와 같은 업무자동화(조세현 외, 2023) 기술로 공공부문의 AI활용은 세계적으로 확산되는 추세이며 성공적인 도입과 활용을 위한 정책을 추진하고 있다. 생성형 AI 등장으로 공공부문 의사결정 과정은 기존의 규칙기반 RPA(Robotic Process Automation)의 한계에서 벗어나 스스로 데이터를 분석하고 패턴을 학습해 결정을 내리는 AI 기반 알고리즘 의사결정(Algorithmic Decision-Making, Automated Decision-Making) 시스템으로 급속히 전환될 것으로 예상된다. 예를 들어 복지급여 심사, 세금 사기 적발, 범죄 위험 예측 등의 분야에 ADM이 활용되어 큰 효과를 낼 것으로 기대된다(Lahusen et al., 2024).

이처럼 공공부문의 인공지능(AI)과 알고리즘 기반 자동화 의사결정(ADM) 확산은 행정 효율성, 비용 절감, 서비스 일관성을 증진시키는 동시에, 투명성 결여, 편향된 결과, 책임소재 불분명 등으로 인해 사회적 신뢰(trust)를 훼손할 우려도 있다. 한국에서도 최근 공공기관의 AI를 활용한 인재채용 시스템을 운영하고 있으나 AI채용시스템의 의사결정 과정에 대한 투명성, 공정성, 형평성과 관련한 우려가 제기되고 있다(이환성 외, 2023). 해외에서도 네덜란드의 복지혜택 부정수급 알고리즘(SyRI) 실패나 영국의 시험 성적 자동산정 시스템 실패 사례에서 보듯이, 잘못 설계된 ADM 사용은 투명성 부족, 예측하기 어려운 알고리즘 편향, 책임회피 등의 결과를 초래하여 사회적 혼란과 공공기관의 AI활용에 대한 우려를 증폭시킬 수 있다(Steen et al., 2021; Lahusen et al., 2024).

공공부문의 ADM 사용은 사회적 수용성과 정당성 확보가 기술적 성능 못지않게 중요함을 관련 연구문헌에서 지적하고 있으며, 이런 측면에서 공공부문의 AI 기반 의사

결정 시스템에 대한 사회적 신뢰(trust) 확보는 중요한 정책 이슈이자 시민사회와 정부 간 관계의 기반이며, 기술 활용에 대한 수용성의 전제조건으로 볼 수 있는 것이다. 그럼에도 불구하고 현재의 AI 거버넌스 담론에서는 이런 제도적 신뢰 문제에 대한 다학제적 논의가 부족하며, 특히 ADM 맥락에서 시스템의 신뢰성(trustworthiness)을 어떻게 확보할지에 대한 연구가 미진한 실정이다. 따라서 사회적 신뢰를 고려한 ADM 도입을 위해서는 투명하고 설명가능한 인간-기계 혼합 거버넌스 설계 필요성이 제기되는 것이다.

2. 연구의 목적

본 연구는 AI 기반 의사결정 시스템에 관한 선행연구를 검토하고, AI 기반 의사결정 시스템의 신뢰성 및 결정요인을 실증적으로 분석하고, 해외 ADM 도입 사례를 분석하는 데에 있다. 특히 AI 기반 의사결정 시스템 사용자를 포함하는 사회적 신뢰 형성을 위해 데이터 수집부터 산출에 이르는 전 과정에서 인간 의사결정자의 책임과 개입을 반영한 ADM 거버넌스를 제시하고자 한다.

제2절 연구의 내용 및 방법

1. 연구의 내용

연구의 내용은 크게 AI 기반 의사결정(ADM) 시스템의 이론적 논의, ADM 시스템의 신뢰성 분석, ADM 거버넌스 해외사례 분석, 그리고 ADM 거버넌스 설계 및 구축 방안으로 구분된다. 첫 번째, AI 기반 의사결정 시스템의 개념과 특징, 공공부문 적용에 관한 이론 기반의 선행연구를 바탕으로 AI 기반 의사결정 시스템의 신뢰성을 측정하고 개선할 수 있는 분석틀을 도출하였다. 두 번째, AI 기반 의사결정 시스템의 신뢰성 분석틀을 토대로 실증적으로 ADM 시스템의 신뢰성 및 신뢰도에 영향을 미치는 결정요인에 대한 주관적인 평가 결과를 수집·분석하였다. 세 번째, ADM 신뢰성 분석틀을 해외사례와 접목하여 ADM 거버넌스를 심층적으로 살펴보았다. 마지막으로 일련의 연구 내용을 바탕으로 ADM 신뢰 제고를 위한 거버넌스 설계 및 구축 방안을 제시하였다.

2. 연구의 방법

연구의 목적 달성을 위해 본 연구에서는 문헌 연구 방법과 실증적 연구 방법을 동시에 활용하였다. 구체적으로 문헌 연구는 주로 국내·외 연구논문, 연구 및 정책보고서, 정부 간행물 등에 대한 고찰을 중심으로 하였다. 본 연구에서 활용된 실증적 연구 방법으로 설문조사가 있는데, 공공부문에 종사하는 AI 의사결정 시스템 담당자 및 사용자를 대상으로 소속 기관에서 도입 예정이거나 운영 중인 AI 시스템에 대한 신뢰도 평가 및 신뢰도 결정요인에 대한 의견을 수렴하였다. 수집한 데이터를 분석하여 AI 시스템 및 응답자 특성 별로 신뢰도와 결정요인 평가가 어떻게 나타나는지 확인하고, 순서형 로짓 회귀분석을 이용하여 AI 시스템의 종합 신뢰도와 결정요인 간 관계를 살펴보았다. 마지막으로 심층 사례분석을 통해 설문조사에 기반한 정량적 연구를 보완하는 질적 연구를 수행함으로써 ADM 거버넌스에 대한 연구를 마무리하였다.

제2장 이론적 논의

제1절 ADM 체계의 이론적 검토

제2절 신뢰가능한 AI 거버넌스 원칙

제3절 숙의민주주의와 시민참여 문제

제4절 ADM 거버넌스 신뢰성 분석틀

제2장 이론적 논의

제1절 ADM 체계의 이론적 검토

1. 주요 개념 정의 및 특성

1.1 AI 기반 의사결정 개념의 정의

1) AI 기반 의사결정

인공지능은 인간의 지능과 관련된 인지 활동이나 기능을 시뮬레이션할 수 있는 변혁적인 기술 세트로 정의(Agbabiaka et al., 2025:1)되는 반면에, AI 기반 의사결정(AI-enabled Automated Decision-Making, ADM)은 알고리즘이 데이터를 수집, 처리, 모델링하여 결정을 내리고, 그 결정의 피드백을 활용하여 스스로 성능을 개선해 나가는 체계를 의미한다(Agbabiaka et al., 2025:2). 이는 공공 행정에서 전통적으로 공무원의 재량에 의해 이루어지던 의사결정 방식이 인공지능에 의해 주도되는 방식으로 변화하고 있음을 보여준다(Agbabiaka et al., 2025:1).

이와 마찬가지로 OECD는 인공지능(AI) 시스템을 명시적 또는 암시적인 목적을 위해 수신한 입력을 바탕으로 물리적 또는 가상 환경에 영향을 미칠 수 있는 예측, 콘텐츠, 권고 또는 의사결정과 같은 결과물을 생성하는 방식을 추론하는 기계 기반 시스템으로 정의하고 있다(OECD, 2024e:4). 따라서 AI 기반 의사결정이란 AI 시스템이 생성한 이러한 결과물을 활용하여 정책 설계, 내부 운영 효율화, 서비스 제공 방식을 현대화하고 혁신하는 일련의 과정을 의미한다(OECD, 2025c:22). AI 모델은 프로세스, 객체, 아이디어, 사람 또는 특정 맥락에서의 상호작용 등 연관된 환경의 전부 또는 일부를 실행가능한 형태로 표현하며, 이를 통해 실제 또는 가상 환경과 상호작용하며 의사결정을 지원하게 된다(OECD, 2025b:15).

AI 기반 의사결정은 또한 자동화된 의사결정(Automated Decision-Making, ADM) 시스템으로도 정의되는데, 이는 데이터와 계산 기법을 활용하여 행정적 판단과

집행을 지원하거나 대체하는 체계를 의미한다. 정부의 결정, 판단, 정책 집행을 돕거나 대체하기 위해 계산(Computation)을 사용하는 모든 시스템, 소프트웨어 또는 프로세스를 의미한다. 이러한 시스템은 예측, 분류, 최적화, 식별 및 권고 기능을 수행하며, 시민의 권리, 자유, 안전에 직접적인 영향을 미칠 수 있다(Richardson, 2022:795).

AI 기반 의사결정 시스템은 인간의 개입 정도에 따라 보조적 역할부터 완전 자동화까지 다양한 수준의 자동화가 가능하데(이유봉, 2022:364-365; Agbabiaka et al., 2025:1), 모든 결정을 기계에 위임하기보다, 인간이 AI와 협력하여 의사결정을 보조받는 구조가 바람직하다는 의견도 있다(OECD, 2025c:20). 이를 통해 공무원이나 전문가의 반복적인 작업에서 벗어나 더 복잡하고 가치 있는 판단이 필요한 핵심 업무에 집중할 수 있다는 것이다(OECD, 2025c:24-25).

2) 공공부문의 AI 의사결정 시스템

공공부문의 AI 의사결정(ADM) 시스템은 정부의 판단이나 정책 집행을 보조하거나 대체하기 위해 계산 기법을 사용하는 소프트웨어 및 프로세스를 포함한다. 이는 특히 시민이나 기업에 중대한 영향을 미칠 수 있는 ‘학습’ 형태를 포함하는 것이 특징이라고 할 수 있다(Harrison & Luna-Reyes, 2020:496). 이 외에도 공공부문의 AI 의사결정 시스템은 다음과 같은 효과를 기대할 수 있다:

- 다양한 과업 수행 능력: 인식(recognition), 이벤트 감지, 예측, 개인화, 상호작용 지원, 목표 중심 최적화, 지식 구조를 활용한 추론 등 광범위한 과업을 수행할 수 있다(OECD, 2024f:10).
- 의사결정 지원: 복잡하고 비정형화된 대규모 데이터를 요약하거나 분석하여 전문가가 더 정교하고 맞춤형된 개입을 할 수 있도록 지원한다(OECD, 2025a:7-8).
- 자동화: 반복적이고 규칙 기반인 업무를 자동화하여 행정적 부담을 줄이고 효율성을 높인다(OECD, 2025a:12).
- 예측 분석 (Predictive Analytics): AI는 미래의 수요나 충격을 예측하는 데 강

점이 있다. 예를 들어, 홍수를 예측하거나 산업 재해 발생 가능성이 높은 기업을 식별하여 자원을 우선 배정하는 데 활용될 수 있다(OECD, 2025a:13-14).

특히 공공부문의 AI 의사결정 시스템은 AI가 인간을 완전히 대체하고 전적으로 결정을 내리기보다 결과의 신뢰성을 보장하기 위해 인간이 최종적으로 검토하고 책임을 지는 구조, 즉 공무원이 AI의 제안을 수락, 수정 또는 거부할 수 있도록 ‘인간의 개입(human-in-the-loop)’을 보장하는 구조가 강조된다(이환성 외, 2023:45-46; OECD, 2025d:17). 예컨대 보건의료 분야에서는 방대한 컴퓨팅 파워와 자기지도학습(self-supervised learning)을 결합하여 질병 진단 및 치료 계획을 수립하는 등의 핵심적인 역할을 수행할 것으로 기대된다(Bartlett, 2025:1).

나아가 AI 의사결정은 그 영향력에 따라 위험 수준(수용 불가능, 고위험, 제한적 위험 등)이 분류되며, 특히 EU에서는 대부분의 사회보장이나 공공 서비스 접근과 관련된 결정은 고위험 영역으로 간주되어 엄격한 규제를 받게 될 가능성이 높다(OECD & UNESCO, 2024:32). 이미 공공부문에서는 공공 서비스의 접근성, 품질, 효율성, 정부 신뢰도 등을 향상하기 위해 교육, 의료, 사회복지 등 다양한 고위험 맥락(high-stakes contexts)에서 자동화된 결정을 내리는 데 사용되고 있다(Agbabiaka et al., 2025:1).

이처럼 AI 기반 의사결정은 공공 서비스의 효율성을 높이고 불평등을 개선할 가능성이 있는 반면, 개인정보 보호, 권력 불균형, 편향 및 차별과 같은 심각한 사회·윤리적 문제를 야기할 수 있는 민감한 특성을 지닌다(Agbabiaka et al., 2025:1-2). 특히 공공기관과 시민 사이의 힘의 불균형을 심화시키거나 기존의 편향을 강화할 위험이 있다는 점도 주요한 특징으로 지목된다(Agbabiaka et al., 2025:2).

1.2 AI 기반 의사결정 시스템의 주요 특성

1) 자기 학습 및 성능 개선

전통적인 소프트웨어와 달리, AI는 피드백 루프와 알고리즘을 통해 새로운 데이터를 학습하며 시간이 지남에 따라 스스로 성능을 향상시키고 개선하는 능력이 있다(Harrison & Luna-Reyes, 2020:501; OECD, 2024a:23). AI 시스템은 배포된 후에

도 인간의 개입 정도에 따라 다양한 수준의 자율성을 가지며, 새로운 데이터와 상황에 맞게 스스로 반응을 조정하는 적응력을 보인다(OECD, 2024e:4). AI 시스템은 인간으로부터 권한과 프로세스 자동화를 위임받은 후, 인간의 개입 없이 스스로 학습하거나 행동할 수 있는 정도를 나타내는 자율성을 가진다. 인간의 감독은 설계, 데이터 수집, 배포, 모니터링 등 시스템 수명 주기의 모든 단계에서 발생할 수 있지만, 시스템 자체는 명시적인 지침 없이도 출력을 생성할 수 있다(OECD, 2024e:6).

알고리즘이 데이터를 모델링할 뿐만 아니라, 내려진 결정의 피드백을 통해 스스로를 지속적으로 발전시키는 동적인 특성을 가진다(Agbabiaka et al., 2025:2). 이처럼 AI 솔루션은 고정된 상태로 머물지 않고 시간이 지남에 따라 학습하며 진화하므로, 이전에는 예측하지 못했던 새로운 시스템 속성이 갑자기 나타날 수 있는 창발적(emergent) 특성도 지니고 있다(OECD, 2024d:21). 하지만 이러한 ‘가변성(plasticity)’ 때문에 동일한 입력에 대해서도 사례나 시간에 따라 결정 결과가 달라질 수 있어 일관된 행동을 추적하기 어렵게 만든다는 어려움도 있다(Harrison & Luna-Reyes, 2020:503-504).

2) 반복적 생애주기

AI 의사결정 체계는 설계, 데이터 수집 및 처리, 모델 구축 및 조율, 테스트, 평가 및 검증, 배포, 운영 및 모니터링, 그리고 폐기에 이르기까지 반복적이고 비순차적인 생애주기를 통해 관리된다(Agbabiaka et al., 2025:4; OECD, 2024b:18). 다양한 관점에 따라 생애주기 단계는 보다 세분화되거나 단순화되기도 하는데, 예컨대 AI 의사결정은 단발적인 사건이 아니라 ‘계획 및 설계 → 데이터 수집 및 처리 → 모델 구축 및 검증 → 배포 및 모니터링 → 책임성 확보’의 5단계를 반복하며 진화하는 과정을 거친다는 연구도 확인된다(GPAI, 2024:16-17).

3) 사회·기술적 복잡성

AI 의사결정 시스템은 단순한 기술적 도구를 넘어 윤리, 법, 정치, 제도적 신뢰와 긴밀하게 연결된 복합적인 시스템(Agbabiaka et al., 2025:17)인 관계로, 그 기술적 복잡성으로 인해 데이터 주체(시민)가 자신의 데이터가 누구에 의해, 어떤 목적으로 수

집되고 처리되는지 이해하기 어려울 수 있다(GPAI, 2024:2). 즉, AI 의사결정 시스템은 기술적으로 매우 복잡하며 빠르게 발전하며 혁신을 가져오지만, 동시에 역공학(Reverse-engineering)을 통한 기밀 추출 등과 같은 고유한 위험을 수반하기도 한다(OECD, 2025f:18). 또한 대규모 데이터와 복잡한 알고리즘을 사용하기 때문에 데이터의 출처나 결정의 근거를 완벽하게 기록하고 관리하는 데 큰 기술적 어려움이 따르는 등 추적 가능성의 한계가 존재한다(OECD, 2024b:37).

4) 본질적 불투명성

AI 의사결정 시스템은 과정과 그 이면의 논리를 투명하게 공개하거나 이해하기 어렵다는 ‘블랙박스’의 특성이 존재한다(Agbabiaka et al., 2025:2). 특히 신경망(neural networks), 딥러닝과 같은 기계 학습 알고리즘과 고도화된 모델은 내부의 논리적 결정 과정이 매우 복잡하여 인간이 결정 과정과 결과가 도출된 정확한 이유를 이해하거나 설명하기 어렵다(Bartlett, 2025:4; OECD, 2024a:73).

이로 인해 AI가 왜 그런 결정을 내렸는지 설명할 수 있어야 한다는 ‘설명 가능성(Explicability)’이 거버넌스의 핵심 원칙으로 대두되고 있으며(Bartlett, 2025:4; OECD, 2024f:6), 투명성은 단순히 있고 없음의 이분법적인 개념이 아니라, 공개되는 정보의 양과 질에 따라 다양한 단계(Gradations)가 존재하는 가변적 특성을 지니게 된다(GPAI, 2024:2).

5) 데이터 의존성

전문가의 이론이나 지식에 기반하여 모델을 구축하는 전통적인 방식과 달리, AI는 데이터 주도형(Data-driven) 접근 방식을 채택하고 가용한 데이터 내의 예측 요인을 찾아내어 결정 규칙을 도출하는 데 집중한다(Harrison & Luna-Reyes, 2020:500). 또한 AI 시스템은 방대한 양의 과거 데이터를 분석하여 특정 사건이 발생할 확률을 계산하거나 미래 트렌드를 예측하는 등 데이터 주도적 예측에 탁월한 능력을 갖추고 있다(OECD, 2024a:25).

나아가 거대언어모델(LLM) 등 AI 시스템은 텍스트, 이미지, 오디오와 같은 방대하고

복잡한 비정형 데이터를 실시간으로 요약하거나 분석하여 의사결정자가 실행가능한 권고안을 도출할 수 있게 지원한다(OECD, 2025c:25). 자연어 처리(NLP) 기술을 통해 이력서의 텍스트나 사용자의 웹사이트 클릭 패턴 같은 복잡하고 구조화되지 않은 빅데이터 정보에서도 유의미한 패턴을 추출할 수 있다(OECD, 2024a:24).

따라서 AI 의사결정의 정확도와 신뢰성은 학습에 사용되는 데이터의 양, 품질, 적합성, 최신성 및 수집 과정의 적절성에 전적으로 좌우된다(Agbabiaka et al., 2025:11; Bartlett, 2025:2). 데이터 세트 구축 및 접근성은 AI 혁신의 병목 현상이 되기도 하므로, 데이터 공유 과정에서 공공의 신뢰를 확보하는 것이 매우 중요하다(Bartlett, 2025:2).

다만 AI의 성능은 학습된 환경과 실제 운영 환경이 다를 경우 설정된 맥락에 따라 그 효과가 크게 달라질 수 있으며(OECD, 2024d:21), 입력 데이터가 원래의 학습 데이터와 달라질 경우 시간이 지나면서 AI 모델의 성능이 저하되거나 결과의 질이 떨어지는 모델의 퇴화 위험(모델 드리프트)이 상존한다(OECD, 2024a:30). 또한 자율 학습 모델은 피드백 루프 과정에서 데이터가 변질될 경우, 사실이 아니거나 왜곡된 정보를 생성하는 오류 및 환각 현상을 일으킬 위험도 존재하므로 이러한 예상 가능한 문제에 대응하기 위한 모니터링 및 평가 체계가 필요하다(OECD, 2024b:21).

6) 편향성 및 차별의 위험

AI 시스템은 학습 데이터에 포함된 기존의 편향을 그대로 학습하거나 증폭할 위험이 있다(Bartlett, 2025:6). AI 의사결정 시스템은 데이터 벡터 내의 숨겨진 상관관계를 통해 성별이나 인종 같은 잠재적 편향을 학습하거나 증폭할 수 있으며, 특정 입력을 제한하는 것만으로는 이러한 차별을 완전히 해결하기 어렵다(Harrison & Luna-Reyes, 2020:503). 예를 들어, 보건의료 분야의 경우 소수 민족이나 여성, 장애인이 데이터에서 과소대표될 경우 이들에 대한 오진이나 자원 배당 차별과 같은 불공정한 의사결정이 발생할 수 있다(Bartlett, 2025:6). 시스템 배포 시 취약 계층에 대한 차별이나 불평등한 대우를 초래할 가능성이 내재되어 있으므로, 이를 방지하기 위한 위험 관리 관행이 필연적으로 요구된다(GPAI, 2024:44, 50).

7) 확률적 추론과 오류 가능성

AI는 확률적 추론(probabilistic inference), 즉 인과관계에 대한 명확한 이해보다는 데이터 노출(학습)을 통해 찾은 패턴을 바탕으로 확률적인 추측을 통해 결과를 도출한다는 특성을 지니고 있다(OECD, 2024b:18). 이처럼 AI는 확정적인 논리가 아닌 패턴 인식과 확률에 기반하여 추론하다 보니 훈련 데이터에 과도하게 맞춤화(overfitting)될 경우 새로운 데이터에 대해 잘못된 예측을 내놓을 위험이 있다(Harrison & Luna-Reyes, 2020:501). 또한 의료 분야 등에서 심각한 고위험(high-stake) 결정을 내릴 때 오류, 정확도 부족, 혹은 예상치 못한 부작용이 발생할 수 있는 기술적 한계를 내재하고 있다(Bartlett, 2025:6). 실제로 미시간주의 실업 보험 사기 탐지 시스템이 93%의 오판율을 기록한 사례처럼 심각한 오류가 발생할 수 있다(Harrison & Luna-Reyes, 2020:497).

8) 사회적 책임 및 윤리적 공백

AI 의사결정은 복지 시스템, 재범 예측, 예측 치안 등 사회 전반에 걸쳐 중대한 영향을 미치지만, 기존의 추상적인 ‘AI 윤리’ 지침만으로는 실질적인 책임성(Accountability)을 담보하기 어렵다는 한계가 있다(Bartlett, 2025:5-6). 따라서 시스템의 자동화 수준과 관계없이, 결정 과정의 어느 단계에서 인간이 개입하고 감독하는지를 정의하는 인적 감독 메커니즘(human oversight mechanism)이 시스템 설계의 중요한 일부가 된다(GPAI, 2024:50). 또한 데이터 관리자(data steward)가 수혜자를 대신해 책임을 지는 구조와 같은 법적·제도적 장치도 요구된다(Bartlett, 2025:4).

2. 선행연구 동향

2.1 AI 기반 의사결정 선행연구 유형

본 연구와 관련된 AI 기반 의사결정 선행연구를 다음과 같이 확인하였다.

〈표 2-1〉 AI 기반 의사결정 시스템에 관한 선행연구

번호	자료	내용
1	Agbabiaka et al. (2025)	• 공공부문에서 신뢰할 수 있는 AI 기반 자동화된 의사결정(ADM)의 18가지 핵심 요구사항을 도출하고 이를 OECD AI 시스템 생애주기에 매핑하여 제시
2	Bartlett (2025)	• 의료 분야의 책임성 있고 신뢰할 수 있는 AI 활용을 위해 데이터 거버넌스와 데이터 스튜어드십의 역할을 강조하며 윤리적 가이드라인을 제안
3	de Fine Licht (2025)	• 공공 AI 거버넌스에서 발생하는 가치 갈등을 해결하기 위해 절차적 정의 프레임워크를 제안하고, 의사결정 근거의 문서화와 이익제기 절차의 중요성을 강조
4	de Fine Licht & Folland (2025)	• 공공 의사결정 내 AI 활용에 따른 위험과 편익을 평가하는 프레임워크를 제시하며, 네덜란드 육아보조금 스캔들 사례를 통해 책임 있는 ADM 거버넌스의 필요성을 설명
5	GPAI (2024)	• 공공부문 알고리즘 등록부 등 투명성 도구를 분석하여 시민의 감시를 가능하게 하고 책임성 및 설명 가능성 원칙을 실현하는 방안을 제시
6	Harrison & Luna-Reyes (2020)	• 디지털 정부 내 신뢰할 수 있는 AI 배포를 위해 기업 데이터 거버넌스와 직원의 데이터 리터러시 함양을 필수 조건으로 제시
7	OECD (2019c)	• AI 시스템을 정의하고 신뢰성을 위한 5가지 가치 기반 원칙을 제시 • 설계부터 운영 및 모니터링에 이르는 AI 생애주기 전반에 걸쳐 위험 관리 접근법 적용 및 이해관계자의 책임성 확보 강조
8	OECD (2024a)	• 공공 고용 서비스(PES) 분야에서 AI와 ADM의 영향을 분석하며, 결과에 대한 책임성 확보를 위해 생애주기 전반의 거버넌스 체계 구축을 강조
9	OECD (2024b)	• 개인정보 보호와 AI 책임성 간의 시너지를 탐색하며, 복합적인 시스템 운영 시 위험 관리 원칙이 효과적으로 작동할 수 있도록 하는 거버넌스 프레임워크를 논의
10	OECD (2024c)	• 고위험 AI 시스템의 훈련 및 배포를 위한 투명한 위험 평가와 완화 절차를 제안하며, 수용 불가능한 위험에 대한 금지선(red lines) 설정을 강조
11	OECD (2024d)	• 보건·의료 분야의 책임 있는 AI 활용을 위해 실제 데이터 기반의 증거 중심 의사결정과 정책 입안자의 디지털 기술 이해도 향상 촉구
12	OECD (2024e)	• AI 시스템의 정의를 명시적 또는 암시적 목표를 위해 예측이나 결정을 생성하는 기계 기반 시스템으로 업데이트하고, 배포 후의 자율성과 적응성을 강조
13	OECD (2024f)	• OECD 국가들의 공공부문 AI 활용 실태를 조사하여 조세, 복지, 사회 서비스 등 핵심 정부 기능에서의 ADM 적용 사례와 정책적 시사점 제공

번호	자료	내용
14	OECD (2025a)	• 사회 보장 제도의 미래를 위해 AI를 활용한 행정 업무 자동화(back-office)와 부정수급 탐지 등 효율성 제고 및 비용 절감 방안 검토
15	OECD (2025b)	• 오픈 소스 파운데이션 모델의 기회와 위험을 분석하며, 정책 입안자들이 개방 성과 위험 관리 사이에서 균형을 잡기 위해 고려해야 할 사항 제시
16	OECD (2025c)	• 정부가 AI 개발자 및 사용자로서 가속화된 디지털 전환을 이끄는 역할을 조망하며, 의사결정 최적화 및 이상 징후 탐지를 위한 AI 활용 트렌드를 분석
17	OECD (2025d)	• 독일의 ADEST 사례 등 사회 보장 분야의 AI 활용 사례를 통해 업무 효율성 개선 효과와 인간 감독(Human-in-the-loop) 설계의 중요성 설명
18	OECD (2025e)	• 히로시마 AI 프로세스에 따라 AI 개발자들이 위험 관리, 투명성 보고, 조직 거버넌스를 어떻게 실행하고 있는지에 대한 초기 결과 보고
19	OECD (2025f)	• 프라이버시 강화 기술(PETs)을 활용하여 질병 예측 및 건강 정책 분석을 위한 신뢰할 수 있는 AI 모델을 안전하게 공유하는 방안 모색
20	OECD (2025g)	• AI 사건 및 위험 패턴을 파악하기 위해 정책 입안자와 이해관계자들이 공유할 수 있는 공통 사건 보고 프레임워크 구축 제안
21	OECD & UNESCO (2024)	• G7 국가들의 공공부문 AI 활용을 지원하기 위해 알고리즘 영향 평가와 데이터 품질 관리 프레임워크를 포함한 구체적인 툴킷 제공
22	김윤권·최순영 (2022)	• 지능형 정부 서비스의 지향 가치를 분석하고, 알고리즘 행정 운영 시 일관성과 공정성을 확보하기 위한 원칙과 정확한 데이터 확보의 필요성을 강조
23	라기원·이유봉·윤길준 (2024)	• AI 활용에 따른 입법적 대응을 위해 국가 전략과 가이드라인을 조사하고, 행정 분야의 안전한 기술 도입을 위한 법적 과제를 분석
24	이유봉 (2022)	• AI 기반 행정의 입법 방안으로서 자동적 처분의 법적 근거 마련과 국민 신뢰 확보를 위한 투명성 및 책임성 원칙의 제도화 논의
25	이유봉 (2024)	• 고위험 AI 관리 체계와 NIST AI RMF 등을 분석하여 AI 영향평가의 구체적인 절차와 법적 의무화 방안에 관한 입법 연구 수행
26	이유봉 외 (2023a)	• 이해충돌방지법의 실효적 운영을 위해 빅데이터와 AI 기술을 활용하여 사전 이해관계를 자동으로 추론하고 모니터링하는 플랫폼 모델 제안
27	이유봉 외 (2023b)	• 청탁금지법 유권해석 업무를 지원하기 위해 생성형 AI 기술을 적용한 자동 질의 응답(QA) 시스템 모델 개발과 데이터 구축 전략 제시
28	이종한 외 (2022)	• 기술 변화에 기민하게 대응하는 애자일 거버넌스 구축과 원칙 중심 규제로의 패러다임 전환을 제안하며 규제기관 거버넌스 개선방안 제시
29	이환성 외 (2023)	• 공공기관 인재 채용 과정에 AI를 도입할 때 공정성과 투명성을 높이기 위한 가이드라인과 인사 데이터의 공공 데이터베이스 구축 방안 제시
30	임성근 외 (2024)	• 생성형 AI 기술로 언론 및 SNS 데이터를 분석하여 자동으로 공공 갈등 사례 DB를 구축하고 상세 정보를 분석하는 시스템 "LISTEN" 연구
31	조세현 외 (2023)	• 디지털플랫폼정부 구현을 위한 RPA 및 AI 기술 활용 실태를 분석하고, 기술 수용성을 저해하는 보안 및 책임성 이슈 해소를 위한 법·제도 개선안 제시

번호	자료	내용
32	한국행정연구원 (2024a)	• 'AI와 함께 일하는 정부' 구현을 위한 정책 의제로서 AI 사례뱅크 구축, 위험성 수준 평가, 그리고 공공부문 AI 조달 지침 마련을 제안
33	한국행정연구원 (2024b)	• 공공부문 AI 활용 거버넌스 분석을 통해 행정안전부의 컨트롤타워 기능 강화와 AI 친화적 공공데이터 생성 및 품질 관리의 중요성을 진단
34	한국행정연구원 (2025a)	• AI 기반 행정의 민주성을 보장하기 위해 시민의 알고리즘 이해권 법제화와 대통령 직속 독립 감독 기구인 AI 옴부즈만 신설 제안
35	한국행정연구원 (2025b)	• 에스토니아의 X-Road 인프라와 Kratt AI 등 주요국의 원스톱 서비스 사례를 비교 분석하여 데이터 공유 및 상호운용성 강화의 시사점 도출
36	한국행정연구원 (2025c)	• 미국 바이든 행정부의 AI 행정명령 M-24-10과 트럼프 행정부의 정책 변화를 분석하여 한국 정부의 AI 전략 추진 및 규제 방향 시사점 제시
37	한국행정연구원 & 행정안전부 (2024)	• 공공부문 AI 도입을 통한 행정 효율성 제고와 증거 기반의 과학적 의사결정 구현 방안을 다루며, 미국과 영국의 최신 도입 사례와 거버넌스 체계 분석
38	홍성민 외 (2024)	• AI 기술의 사회적 영향에 관한 인식 조사를 토대로 고위험 AI의 법적 관리 범위 지정, 딥페이크 규제 및 저작권 인정 여부 등에 관한 입법 정책 연구

출처: 저자 작성

AI 기반 의사결정 시스템에 관한 선행연구를 살펴본 결과, 주제에 따라 다음과 같이 6가지 유형으로 분류하였다.

1) 신뢰할 수 있는 ADM 요구사항 및 윤리 프레임워크

첫 번째 선행연구 유형은 ADM 시스템이 공공부문에 도입될 때 갖추어야 할 윤리적 원칙과 신뢰성 요구사항을 다루고 있다. 예컨대, 대표적으로 공공부문 ADM의 신뢰성을 위해 문제 및 목표의 명확성, 설명 가능성, 책임성, 인간의 감독 등 18가지 핵심 요구사항을 제시하고 이를 OECD AI 생애주기에 매핑하는 연구가 이에 해당된다(Agbabiaka et al., 2025). 또한 ADM 거버넌스에서 발생하는 가치 충돌을 해결하기 위한 절차적 정의 프레임워크와 이해-편익 분석 프레임워크를 제안하는 연구도 있으며(de Fine Licht, 2025; de Fine Licht & Folland, 2025), 의료 분야에서의 책임 있는 데이터 스튜어드십과 윤리 가이드라인을 강조하는 등 분야별 윤리에 관한 내용을 다루고 있다(Bartlett, 2025; OECD, 2024d).

2) 투명성, 책임성 및 영향평가 메커니즘

두 번째 선행연구 유형은 ADM의 블랙박스 문제를 해결하기 위한 도구와 제도적 장치에 초점을 맞추고 있다. 특히 알고리즘 투명성과 관련하여 알고리즘 등록부(Registers)와 같은 투명성 도구의 국가별 운영 실태와 정보 공개 범위를 분석한 연구(GPAI, 2024), 영향평가 제도와 관련하여 캐나다의 알고리즘 영향평가(AIA)와 EU의 기본권 영향평가 표준규칙 등 도입 전 위험을 사전 진단하는 절차를 다루는 연구(이유봉, 2022; 이유봉, 2024), 그리고 책임성 확보를 위해 AI 사고 모니터링 및 사후 감사(Audit) 체계 구축의 중요성을 강조하는 연구 등이 이에 해당된다(한국행정연구원, 2025a).

3) 민주적 가치와 시민의 권리 보호

세 번째 선행연구 유형은 ADM 시스템이 민주주의와 시민의 기본권에 미치는 영향 및 대응 방안을 다루는 연구들로, 알고리즘 이해권, 인식적 민주주의, 이의제기 및 구제를 위한 입법 정책 등을 다루고 있다. 예컨대, 시민이 ADM의 결정 근거를 이해하고 이의를 제기할 수 있는 ‘알고리즘 설명요구권’과 ‘AI 옴부즈만’ 도입을 제언하고, AI 기술이 정보 불평등을 심화시키지 않고 집단지성에 기여할 수 있도록 하는 민주적 거버넌스 모델을 살펴보고, 국민 인식 조사를 바탕으로 고위험 AI 규제 및 권리 구제 절차 마련을 위한 입법 방향을 제시하는 연구들이 이에 해당된다(한국행정연구원, 2025a; 홍성민 외, 2024).

4) 거버넌스 및 리스크 관리 체계

네 번째 선행연구 유형은 ADM 시스템의 안전한 운영을 위한 조직적 구조와 위험 관리 프로세스를 다루는 연구들을 포함한다. 이 가운데 대표적인 연구로 (1) 위험 기반 접근법을 중심으로 AI 시스템을 위험 수준(수용 불가능, 고위험 등)에 따라 분류하고 차등적 규제를 적용하는 방안을 제시하는 연구(OECD, 2024f; OECD, 2025c), (2) NIST의 AI 위험 관리 프레임워크(RMF), G7의 공공부문 AI 톨킷, OECD의 사고 보고 프레임워크 등 글로벌 가이드라인에 관한 연구(OECD, 2025e; OECD, 2025g;

OECD & UNESCO, 2024; 이유봉, 2024), 그리고 (3) 최고 AI 책임자(CAIO) 지정 및 부처 간 협업 구조 등 공공부문 AI 거버넌스 강화 전략을 제안하는 연구 등이 있다(한국행정연구원, 2024a; 한국행정연구원, 2024b; 한국행정연구원, 2025c).

5) 기술적 구현 및 데이터 인프라

다섯 번째 선행연구 유형은 ADM 시스템을 지탱하는 핵심 기술과 데이터 관리 방식에 관한 유형으로 업무 자동화(RPA), 데이터 기술, 지능형 알고리즘 등을 대상으로 한 연구들을 포함한다. 예컨대, 단순 반복 업무의 자동화 도입 현황과 효과, 그리고 봇(Bot)에 대한 신원증명 체계 마련 방안에 관한 연구, 프라이버시 강화 기술(PETs)을 활용한 모델 공유, 메타데이터 관리 고도화, AI 친화적 데이터 축적 플랫폼 설계 등에 관한 연구 등이 있다(조세현 외, 2023; OECD, 2025f; 한국행정연구원, 2024a).

6) 분야별 ADM 적용 사례 및 실태 분석

마지막으로 여섯 번째 선행연구 유형은 정부 기능별로 ADM이 어떻게 활용되고 있는지에 대한 구체적인 사례와 현황을 포함하고 있다. 대표적인 예로 사회 서비스 및 고용 분야가 있는데, 공공 고용 서비스(PES)의 일자리 매칭, 사회 보장 제도의 부담 수급 탐지 및 행정 자동화 사례를 다루는 연구들이 있다(OECD, 2024a; OECD, 2025a; OECD, 2025d). 또한 공공 갈등 및 채용 등과 관련하여 AI 기반 갈등 관리 DB(Listen) 구축과 공공기관 인재 채용 과정에서의 AI 활용 실태를 분석하는 연구들도 확인된다(이환성 외, 2023; 임성근 외, 2024). 이 외에도 법 집행 및 규제에 관한 연구, 즉 미국의 범죄 리스크 예측 프로그램, 증권거래위원회의 불공정거래 감시 시스템, 한국의 이해충돌방지 및 청탁금지법 지원 모델 등의 사례를 포함한 연구들이 이 유형에 해당된다(이유봉 외, 2023a; 이유봉 외, 2023b).

제2절 신뢰가능한 AI 거버넌스 원칙

인공지능(AI)의 급속한 발전은 행정부터 산업 전반에 이르기까지 혁신을 가져오지만, 동시에 기술에 대한 신뢰 확보라는 새로운 도전을 제기한다. AI의 의사결정 과정이 불투명하거나 결과가 불공정하다는 인식이 확산될 경우, 사회 구성원들의 신뢰는 약화되고 그에 따른 사회·경제적 비용이 막대해질 수 있다. 이러한 문제의식 속에서 본 연구는 신뢰가능한 AI 거버넌스를 단순한 윤리적 선언이 아니라 AI 시스템이 사회적으로 정당하고 수용 가능한 방식으로 작동하도록 설계·운영되도록 보장하는 제도적 관리체계로 개념화하고자 한다. 다시 말해, 신뢰는 AI 시스템에 외부적으로 부여되는 추상적 가치가 아니라, 위험 관리와 책임 구조가 제도적으로 내재화된 운영 과정 속에서 축적·형성되는 결과로 이해할 수 있다.

국제 사회와 학계 역시 이와 같은 문제의식을 바탕으로 AI의 신뢰가능성(trustworthiness) 구현을 위한 핵심 원칙들을 비교적 일관되게 제시해왔다. 예를 들어 OECD는 AI가 인간의 가치와 민주적 원칙을 존중하면서 투명하고 책임 있게 활용되어야 함을 강조하며, 신뢰가능성을 AI 정책의 핵심 기준으로 설정하였다(OECD, 2019b). 유럽연합(EU)은 세계 최초의 포괄적 AI 규제안인 AI Act를 통해 위험 기반 접근법을 도입하면서, 특히 고위험(high-risk) AI 시스템에 대해 투명성, 데이터 거버넌스, 인간 개입, 책임성 등의 요건을 법적 의무로 규정하였다(European Union, 2024). 영국 정부 또한 AI 규제 백서에서 혁신 친화적 접근을 유지하되, 안전성, 투명성, 공정성, 책임성, 거버넌스를 핵심 원칙으로 제시하였다(UK Government, 2023). 한국의 경우 2025년 제정된 「인공지능기본법」에서 인간 중심성, 공정성과 투명성, 안전성과 신뢰성, 책임성 확보, 지속가능성을 AI 거버넌스의 기본 원칙으로 명시하였다(대한민국 정부, 2025).

주요 국가들은 AI를 규율하는 법·제도적 경로와 운영 방식에서는 차이를 보이지만, 인간 중심성, 투명성, 공정성, 책임성, 안전성 등 신뢰가능성의 핵심 요소에 대해서는 공통된 문제의식을 공유하고 있다(〈표 2-2〉 참조). 이는 신뢰가능한 AI 거버넌스가 특정 국가의 규제 모델에 한정된 개념이 아니라, 다양한 제도적 맥락 속에서도 반복적으로 확인되는 공통 원칙들의 결합임을 시사한다. 이에 본 연구는 국제적 논의와 제도적 공통분모를 토대로, 신뢰가능한 AI 거버넌스를 구성하는 핵심 원칙으로 투명성, 공정성, 책임성, 인간 중심성, 국제협력의 다섯 가지를 도출하였다. 특히 국제협력은 AI 기

술과 데이터의 활용이 본질적으로 국경을 넘어 이루어진다는 점에서, 개별 국가 차원의 규율만으로는 신뢰가능성을 충분히 확보하기 어렵다는 한계를 보완하는 필수적 요소로 이해된다. 결국 신뢰가능한 AI 거버넌스는 이러한 원칙들을 선언적 가치가 아니라, 실제 정책과 행정 현장에서 작동 가능한 제도적 설계로 구체화할 때 비로소 실질적 의미를 갖는다.

나아가 신뢰가능한 AI 거버넌스의 핵심 과제는 “무엇을 해야 하는가”라는 원칙 차원의 논의를 넘어, 이러한 원칙들을 구체적인 제도 설계와 운영 방식 속에서 “어떻게 구현할 것인가”의 문제로 전환된다. <표 2-3>은 앞서 도출한 다섯 가지 원칙을 중심으로 각 원칙의 개념과 구현 방향을 정리하고, 이를 실제 정책과 행정 현장에서 적용한 대표 사례들을 요약한 것이다. 이하에서는 이들 다섯 가지 원칙을 축으로, 신뢰가능한 AI 거버넌스를 제도적으로 구현하기 위한 주요 정책적 수단과 국가별 사례를 검토하고자 한다.

〈표 2-2〉 주요 국가의 AI 법·제도적 프레임워크 비교

구분	한국	미국	영국	유럽연합
법적 근거	인공지능기본법 (2024.12 통과, 2025.1 공포, 2026.1 시행)	AI 권리장전 (Blueprint for an AI Bill of Rights, 2022) ¹⁾	AI 규제 백서 (AI White Paper, 2023)	AI Act (Regulation (EU) 2024/1689)
핵심 원칙	• 인간 중심 원칙 • 공정성과 투명성 • 안전성과 신뢰성 • 책임성 확보 • 지속가능성	• 안전하고 효과적인 시스템 • 알고리즘에 의한 차별로부터의 보호 • 데이터 보호 • 공지와 설명 • 인간 대체, 고려사항, 대비책	• 안전성 • 투명성 • 공정성 • 책임성과 거버넌스 • 이익제기·구제	• 금지 • 고위험 • 한정적 위험 • 최소위험
운영 방식	국가 차원의 기본법 제정을 통해 AI 개발·활용 전 주기 규율, 세부 시행령 및 가이드라인 마련 예정	연방법 차원의 포괄 입법은 없으며, 행정명령·지침·가이드라인 중심 운영. 민간 자율 규제와 기술표준 활용을 중시	중앙정부가 방향성을 제시하고, 규제기관이 기존 법체계 내에서 부문별로 적용·조정하는 분권적 모델	AI Act 중심의 위험기반 입법 모델. 법적 구속력 있는 규제체계 확립

출처: 저자 작성

1) AI 권리장전은 2022년 10월 백악관 과학기술정책국(OSTP)이 「AI 권리장전을 위한 청사진: 미국인을 위한 자동화된 시스템 만들기」라는 제목의 문서를 통해 발표한 것임.

<https://bidenwhitehouse.archives.gov/ostp/news-updates/2022/10/04/blueprint-for-an-ai-bill-of-rights-a-vision-for-protecting-our-civil-rights-in-the-algorithmic-age/>

(접속일: 2026년 1월 12일)

〈표 2-3〉 신뢰가능한 AI 거버넌스의 핵심 원칙

원칙	개념	구현 방식	대표 정책 및 사례
투명성·설명 가능성	AI 판단의 근거 이해	어떤 데이터와 기준 으로 판단했는지 설 명 제공, 블랙박스 완화	- 프랑스 Parcoursup 대학입학배정 사례 (배정 기준·결과의 공개 및 설명 강화) - 독일 연방노동청 사례 (실업급여 결정에 AI 설명기법 적용, 주요 판단근거 제시) - 한국 AI 신용평가 설명권 도입 (금융분야 AI 판단에 대한 고객 설명요구권 보장) - 캐나다 알고리즘 영향평가(AIA) 도구 (공공부문 AI 도입 시 사전 위험평가 체계)
공정성	차별과 편향 예방 및 정당성 확보	편향 데이터·알고 리즘 점검 및 보정, 공정성 기준 선택 과정 공개	- 미국 COMPAS 사례 (형사사법 AI의 인종 편향 논란으로 공정성 기준 논쟁) - 영국 NHS 피부암 진단 AI 사례 (훈련 데이터 대표성 부족으로 인한 의료 AI 성능의 집단 간 격차) - 암스테르담 알고리즘 등록제 (공공 알고리즘의 목적·데이터·책임 공개로 사회적 감사 가능성 확보)
책임성·감사 가능성	문제 발생 시 책임 주체와 검증 가능성 확보	책임 주체 사전 지 정, 상시적 감사·모 니터링 체계 구축	- 일본 AI 책임자 지정제 (조직 내 AI 시스템별 책임 담당자 지정 및 관리) - 에스토니아 Kratt 통합체계 (공공 AI 서비스 중앙 관리 및 실시간 모니터링) - EU AI Act (고위험 AI에 적합성 평가 의무 부과 및 위반 시 강력 제재 규정) - 중국 알고리즘 추천 관리규정 사례(영향력 큰 알고리즘에 등록·보안 평가 의무화)
인간 중심성	자동화와 인간 개입의 균형	고위험 결정에 대한 인간의 개입 보장, 인간-AI 협업 설계	- 호주 Robodebt 사례 (복지채무 자동산정 실패로 인간 검증의 중요성 부각) - 핀란드 OmaStadi 참여예산 (AI 분석을 보조수단으로 활용하고 최종 결정은 시민 속의로 진행) - 미국 Watson for Oncology 사례(AI가 치료 옵션을 제시하고 최종 결정은 의료진이 담당하는 협업 모델)
국제협력· 상호운용성	국경을 넘는 AI 공통 규범 확보	데이터 이전 및 활 용에 관한 국제 규 범 수립, 글로벌 표 준·다자 협력	- EU-미국 데이터 프레임워크 (개인정보 이전에 대한 공동 기준 마련으로 법적 불확실성 해소) - ISO/IEC AI 국제표준 (AI 책임성과 위험관리에 대한 공통 운영 기준 제공) - IEEE AI 가이드라인 (설계·운영 전반에서 책임성과 통제 가능성에 대한 국제 준거 제시)

출처: 저자 작성

1. 투명성 및 설명가능성

투명성은 단일 차원의 개념이 아니라 여러 층위로 구성된 다차원적 개념이다. Diakopoulos(2016)는 알고리즘 투명성을 다섯 가지 층위(데이터 투명성, 모델 투명성, 추론 투명성, 알고리즘 존재 투명성, 인터페이스 투명성)로 구분하면서, 투명성이 내부 검증과 외부 소통의 측면 모두를 포함한다고 지적하였다. 즉, 데이터·모델·추론의 투명성은 주로 전문가와 규제기관이 알고리즘을 들여다보고 책임성을 확보하는 차원인 반면, 알고리즘 존재 투명성과 인터페이스 투명성은 일반 시민이 해당 알고리즘의 존재와 작동 방식을 인지하도록 돕는 대외적 설명의 차원에 가깝다(Diakopoulos, 2016).

프랑스의 대학 입학배정 시스템 Parcoursup 사례는 투명성의 다층적 접근 필요성을 잘 보여준다. Parcoursup 도입 초기에는 알고리즘 작동 방식에 대한 설명이 부족하여, 학생과 학부모들이 자신이 받은 대학 배정 결과의 근거를 이해하기 어렵다는 비판이 제기되었다. 이에 프랑스 정부는 알고리즘이 어떤 기준으로 작동하는지 정보를 단계적으로 더 공개하고, 지원자들이 배정 결과를 이해할 수 있도록 안내를 강화하는 방향으로 제도를 보완해왔다. 특히 2024년 Parcoursup 절차 종료 후 실시된 공식 설문조사에서 응답자의 약 78%가 자신이 받은 입학 제안에 만족한다고 밝혔는데²⁾, 이는 여전히 입시 배정 절차 자체가 스트레스 요인으로 인식됨에도 불구하고 제도 운영의 투명성과 정보 제공 측면에서는 일정 수준 신뢰를 확보하고 있음을 시사한다.

설명가능성은 AI의 판단 결과를 인간이 이해할 수 있는 형태로 제공하는 것을 의미하며, 단순한 정보 공개를 넘어 행정 의사결정의 정당성과 수용성을 확보하는 핵심 요소로 꼽힌다(Diakopoulos, 2016). 딥러닝과 같은 복잡한 기계학습 모델 내부를 완전히 설명하는 것은 한계가 있으므로, 실제 공공부문에서는 부분적 설명 방식이 활용되고 있다. 예를 들어 독일 연방노동청은 실업급여 지급 여부를 판단하는 알고리즘에 대해, SHAP(SHapley Additive exPlanations) 등 설명가능 인공지능(XAI) 기법을 적용하였다. 이를 통해 개별 결정에 영향을 미친 주요 변수와 그 영향력을 시각화하여 제시함으로써, 알고리즘의 전체 소스 코드를 공개하지 않고도 현장 담당자와 시민이 판단

2) Le Monde (2024). Sur Parcoursup, moins de propositions ont été faites aux candidats en 2024. https://www.lemonde.fr/campus/article/2024/10/07/sur-parcoursup-moins-de-propositions-ont-ete-faites-aux-candidats-en-2024_6346096_4401467.html (접속일: 2026년 1월 6일)

근거를 이해하고 검토할 수 있도록 지원하였다(Bauer et al., 2025). 이러한 설명 정보는 자동결정 결과를 맹목적으로 정당화하기 위한 것이 아니라, 담당 공무원이나 당사자가 결과를 검증하고 이의제기할 수 있도록 돕는 보조 수단으로 기능한다.

국내에서도 금융 분야를 중심으로 AI 판단에 대한 설명가능성 확보를 제도화하고 있다. 금융위원회·금융감독원 등이 공동 발간한 「금융분야 AI 개발·활용 안내서」는 신용 평가나 여신심사와 같은 고위험 금융서비스의 경우 AI 개발 단계부터 설명가능성을 충분히 고려하고, 적절한 XAI 기법 또는 준하는 대안을 마련하도록 권고하고 있다. 아울러 AI 기반 의사결정 결과에 대해 고객의 설명 요구권과 이의제기권을 보장할 것을 명시함으로써, 금융소비자가 AI 판단의 근거를 이해하고 필요 시 이의를 제기할 수 있는 기본권을 부여하고 있다(금융위원회 외, 2022). 이는 민간 영역에서도 투명성과 설명가능성 원칙을 규범화하여 신뢰 기반을 마련하려는 움직임이라 할 수 있다.

한편, 캐나다 정부는 공공부문 AI 시스템의 사전 위험 평가를 위해 알고리즘 영향평가(AIA: Algorithmic Impact Assessment) 도구를 운영 중이다. 이 평가체계는 자동화된 의사결정 시스템의 설계 목적, 활용 데이터, 잠재적 영향 등을 사전에 점검하여 위험 수준을 단계별로 산출하고, 위험 수준에 따라 추가로 필요한 투명성 요건이나 대응 조치를 결정하도록 설계되어 있다. AIA는 캐나다의 「자동화 의사결정 지침(Automated Decision-Making Directive)」 이행을 지원하는 도구로서, 위험이 높은 시스템일수록 보다 상세한 설명과 검토 절차를 거치도록 유도한다(Government of Canada, 2025). 이처럼 투명성과 설명가능성 확보는 사전적 점검부터 사후적 설명까지 아우르는 다각도의 접근을 필요로 하며, 이는 신뢰가능한 AI 거버넌스 구축의 출발점이라 할 수 있다.

2. 편향 최소화 및 공정성

공정성 원칙은 AI의 결정이 특정 개인이나 집단에 부당한 편향(bias)이나 차별을 초래하지 않도록 보장하는 것을 의미한다. 그러나 공정성은 단일한 척도로 정의될 수 있는 개념이 아니며, 서로 다른 통계적·규범적 기준들로 구성된 다면적 개념이다. 실제로 알고리즘 기반 위험 예측 모델을 분석한 Kleinberg et al.(2017)은 보정(calibration),

집단 간 오류 균형(balance), 예측 동등성(predictive parity)과 같은 대표적 공정성 기준들이 일반적인 조건하에서는 동시에 충족될 수 없음을 수학적으로 입증하였다. 이는 하나의 알고리즘이라 하더라도 어떤 공정성 기준을 채택하느냐에 따라 상반된 평가가 가능함을 의미하며, 공정성 문제를 단순한 기술적 최적화의 문제로 환원할 수 없다는 점을 시사한다.

이러한 공정성 기준 간의 구조적 충돌은 미국 형사사법 분야에서 활용된 재범 위험 예측 시스템 COMPAS 사례를 통해 보다 분명하게 드러난다. COMPAS 알고리즘은 흑인 피고인에게 불리한 편향이 존재한다는 비판을 받았는데, 이를 둘러싸고 한편에서는 재범 위험 점수가 인종 집단별로 실제 재범 확률과 일관되게 대응되도록 보정되어야 한다는 주장이 제기되었고, 다른 한편에서는 특정 인종 집단에 대해 과도한 고위험 판정이 이루어지지 않도록 집단 간 오분류 비율이 동일해야 한다는 입장이 맞섰다. 그러나 Berk et al.(2018)은 이러한 두 기준이 구조적으로 양립할 수 없음을 분석하며, 하나의 기준을 충족시키는 선택이 다른 기준을 포기하는 결과로 이어질 수밖에 없음을 지적하였다. 이 사례는 알고리즘의 정확도나 성능을 단순히 개선하는 것만으로는 공정성 논란을 해소할 수 없으며, 어떤 공정성 기준을 우선할 것인지, 그리고 그 선택이 어떤 사회적 가치 판단에 기반하는지를 명시적으로 설명하고 정당화하는 문제가 거버넌스의 핵심 과제로 부상하고 있음을 보여준다. 따라서 공공부문에서 알고리즘을 설계·도입할 때에는 채택한 공정성 정의와 그에 따른 한계를 투명하게 공개하고, 이에 대한 사회적 합의를 모색하는 절차가 필수적이다.

한편 공정성 확보는 이러한 규범적 선택의 문제에 그치지 않고, 기술적 설계 단계에서도 중요한 과제로 부각되고 있다. 최근에는 편향을 사후적으로 발견·조정하는 접근을 넘어, AI 개발 초기 단계에서부터 편향을 예방·완화하려는 기술적 시도가 확산되고 있다. Bellamy et al.(2019)은 IBM의 AI Fairness 360 오픈소스 툴킷을 통해 데이터 편향을 측정하는 다양한 지표와 함께 훈련 데이터 재구성, 가중치 조정, 적대적 재훈련 등 여러 편향 완화 기법을 제시하였다. 이러한 도구의 활용은 공정성을 단순한 결과 평가 지표가 아니라, 데이터 구성과 학습 과정 전반에서 지속적으로 관리해야 할 대상으로 확장시켰다는 점에서 의미를 갖는다. 예를 들어 Norori et al.(2021)은 피부 병변 이미지 분류와 같은 의료 AI 응용에서 훈련 데이터에 소수 인종 집단의 대표성이 부족할 경우, 해당 집단에 대한 진단 성능이 지속적으로 낮게 나타난다는 점을 지적하

며, 합성 데이터 생성이나 클래스 불균형 보정과 같은 학습 단계의 개입이 필수적임을 강조하였다. 이는 의료 분야에서 AI의 공정성 확보가 알고리즘 출력의 사후 개선 문제가 아니라, 데이터 수집과 학습 설계 자체를 재검토하는 문제임을 보여준다.

더 나아가 공정성 문제는 단일 속성에 국한되지 않고, 인종·성별·연령과 같은 여러 사회적 속성이 결합될 때 더욱 복합적으로 나타난다. 딥러닝 기반 의료영상 진단 모델의 경우, 데이터 편향으로 인해 특정 인종과 성별의 조합에 해당하는 환자 집단에서 오진률이 체계적으로 높아지는 사례들이 보고되어 왔다(Seyyed-Kalantari et al., 2021; Yang et al., 2024). 이는 공정성을 하나의 지표로 단순 평가하는 접근의 한계를 보여주며, 교차분석(intersectional analysis)을 통해 다양한 사회적 속성이 AI 성능과 판단에 미치는 영향을 함께 점검할 필요성을 시사한다.

이러한 문제의식 속에서 일부 국가와 도시는 알고리즘 사용의 공정성과 책임성을 제도적으로 점검하기 위한 거버넌스 장치를 도입하고 있다. 대표적으로 네덜란드 암스테르담은 공공서비스에 활용되는 알고리즘의 목적, 사용 데이터, 의사결정 논리, 담당 부서 등을 공개하는 알고리즘 등록부(algorithm register)를 운영하고 있다. 이를 통해 시민들이 행정 알고리즘의 존재와 작동 방식을 인지하고, 그 공정성과 사회적 영향을 감시할 수 있는 투명성 인프라를 구축하였다(Ada Lovelace Institute, 2021). 암스테르담의 사례는 공정성 문제를 사후적 논쟁에 맡기기보다, 설계와 운영 단계에서부터 투명성과 감사 가능성을 제도화함으로써 신뢰성을 제고하려는 선제적 정책 실험으로 평가할 수 있다.

3. 책임성 및 감사가능성

AI가 잘못된 판단을 내렸을 때 누가, 어떤 방식으로 책임을 질 것인지를 명확히 하는 것은 신뢰가능한 AI 거버넌스의 핵심 이슈다. AI 시스템에는 데이터 제공자, 알고리즘 개발자, 서비스를 운영하는 기관, 이를 감독하는 규제당국 등 여러 주체가 관여하기 때문에, 문제가 발생했을 때 피해자가 누구를 상대로 책임을 물어야 하는지 불분명한 경우가 많다. 이러한 책임 공백을 해소하려면 사전에 책임 주체를 명확히 규정하고, 사후에도 검증과 제재가 가능한 체계를 구축해야 한다.

일본은 단일 AI 기본법 제정보다는 행정지침을 중심으로 유연한 거버넌스 접근을 취하고 있는데, 2024년 12월 개정된 「AI 비즈니스 활용 가이드라인」을 통해 공공부문을 포함한 AI 개발·제공·이용 주체들에게 위험 기반 접근(risk-based approach) 하에 투명성과 책임성을 강화할 것을 요구하고 있다. 특히 이 가이드라인은 AI 시스템의 개발·운영 전 과정에서 책임 주체를 명확히 하기 위해, 각 조직 내에 해당 AI 시스템의 책임 담당자를 지정하고 그 역할과 책임을 문서화하여 공유할 것을 권고한다(Government of Japan, 2024). 이는 AI 의사결정 과정에서 발생할 수 있는 오류나 부작용에 대해 조직 차원에서 설명 책임(accountability)을 지도록 함으로써, 책임성 공백을 줄이려는 조치로 평가된다.

전통적인 사후 감사만으로는 공공부문에 확산되는 AI 시스템의 복잡성과 속도를 따라가기 어렵다는 인식도 확산되고 있다. 이에 따라 에스토니아는 행정 서비스에 AI를 광범위하게 활용하면서도 중앙 집중형 통제를 가능케 하는 플랫폼인 Kratt를 운영하고 있다. Kratt은 모든 공공 AI 서비스를 한데 모아 관리하는 통합체계로, AI 도입 현황을 중앙에서 모니터링하고 위험 수준에 따라 인간 검토와 통제를 적용할 수 있도록 설계되었다. 에스토니아 국가 AI 전략은 자동화된 행정 의사결정 시스템에 대해 법적·조직적·기술적 통제 장치를 결합하여 위험을 관리해야 한다고 명시하고 있는데, 이는 AI 사용으로 인한 잠재적 오류나 부작용을 사전에 완화하기 위한 제도적 기반으로 평가된다(Estonian Government, 2021). 이러한 접근은 문제가 발생한 후 처벌하는 방식에서 나아가, 문제가 발생하지 않도록 미리 감시·예방하는 거버넌스 모델을 제시한다는 데 의미가 있다.

물론 명확한 법적 근거에 기반한 강력한 책임 부과 역시 필수적이다. EU의 AI Act는 고위험 AI 시스템에 대해 사전 적합성 평가(conformity assessment)와 위험 관리 의무를 부과하고, 이를 위반할 시 전 세계 매출의 일정 비율에 해당하는 과징금을 부과할 수 있도록 해 강력한 집행력을 담보하고 있다. 중국 역시 2022년 시행된 「인터넷 정보서비스 알고리즘 추천 관리규정」을 통해 영향력이 큰 알고리즘 서비스 제공자를 국가에 등록하고 보안 평가를 받도록 의무화하였다. 이에 따라 주요 플랫폼 기업들은 자사 알고리즘의 이용 목적, 기본 원리, 잠재적 위험 및 대응조치 등을 정부에 제출하고 감독을 받게 되었다. 이는 알고리즘 안전성에 문제가 생긴 후 제재하는 데 그치는 것이 아니라, 사전에 정보를 투명하게 드러내고 정부의 검증을 받는 구조를 통해 책임

성과 안전성을 높이려는 접근이다(Xu, 2024). 이처럼 각국은 법·제도 장치를 통해 AI 활용에 내재한 위험을 제도적으로 통제하고 책임 귀속을 명확히 함으로써, 신뢰가능성의 기반을 강화하고자 노력하고 있다.

4. 인간 중심성

AI는 업무 효율을 높일 수 있지만, 어느 범위까지 의사결정을 자동화하고 어디에 인간의 개입을 유지할 것인지에 대한 판단이 중요하다. 인간이 일일이 개입하면 AI를 쓰는 효과가 반감되지만, 반대로 AI 판단에 전적으로 의존하면 예기치 못한 위험이 커질 수 있다. 따라서 자동화의 장점과 인간 판단의 가치를 조화시키는 균형점을 찾는 것이 인간 중심성 원칙의 핵심 과제가 된다.

Human-in-the-Loop(HITL)는 자동화된 의사결정 과정에 인간 검토자나 결정권자를 개입시켜, 전면 자동화의 위험을 줄이고 최종 결과에 인간의 가치 판단을 반영하는 접근이다(Clarke et al., 2024). 호주의 Robodebt 사례는 인간 중심 개입의 중요성을 잘 보여준다. Robodebt는 복지 수급자의 소득 신고액과 세무 자료를 자동 비교하여 과지급된 복지급여를 부채로 환수하는 시스템이었는데, 전면 자동화로 운영된 결과 수많은 오류와 논란을 빚었다. 2015~2019년 약 43만 3천 명에게 총 17억 호주달러 규모의 잘못된 부채가 청구되었고, 부당 청구로 인한 심각한 심리적 피해 사례까지 보고되었다(Australian Government, 2024). 2022년 발표된 Robodebt 사태 조사보고서는 복잡한 개인별 사정을 고려해야 하는 복지 행정에서는 일률적 자동 산정이 부적절하며, 향후 유사 시스템 도입 시 사례가 복잡하면 자동 프로세스에서 이탈(fall-out)시킨 후 인간이 검토하도록 설계해야 한다고 권고하였다.

핀란드 헬싱키는 AI 기술을 활용하면서도 궁극적인 결정은 인간이 내리는 구조를 실험하고 있다. 2018년부터 시행 중인 참여예산제(OmaStadi)는 매년 시 예산 약 440만 유로를 시민들이 제안한 사업에 배정하는데, 이 과정에서 자연어 처리 등 AI 기술을 시민 제안의 분류·분석에 보조적으로 활용한다. 다만 최종적인 예산배정 대상은 행정 전문가의 검토와 시민 투표를 거쳐 결정되며, AI는 어디까지나 정보를 구조화하고 시나리오를 제시하는 역할에 그친다. 많은 선정 사업들이 실제 집행되어 성과를 거두었

으며, 이러한 헬싱키의 시도는 AI를 의사결정 전 과정에 투입하되 인간의 숙의와 결정을 중심에 놓는 거버넌스의 성공 사례로 평가된다(Tuominen & Rask, 2022).

인간 중심적(Human-centric) AI 거버넌스에서 중요한 점은, AI와 인간이 각자의 강점을 살려 상호보완적으로 협업하도록 설계하는 것이다. AI는 방대한 데이터 처리와 패턴 인식에 뛰어난 반면, 최종적인 가치 판단과 책임은 인간이 지는 것이 적절한 영역이 많기 때문이다. 예를 들어 미국 메모리얼 슬론 케터링 암센터와 IBM이 협업하여 개발한 Watson for Oncology는 수천 건의 임상 가이드라인과 최신 의학 논문 데이터를 학습해 암 치료 옵션을 제시하는 임상 의사결정 지원 시스템이지만, 최종 치료 결정은 항상 다학제 의료진(MDT)의 합의에 맡기는 구조로 운영되었다. 2021년 발표된 메타분석 연구에 따르면 WFO가 제시한 권고안과 의료진의 실제 결정을 비교한 결과 암종·병기에 따라 편차는 있으나 전반적으로 높은 일치도를 보였으며, 연구진은 “AI는 의사를 대체하는 도구가 아니라 의사결정을 보완하는 도구”로 활용되어야 한다고 강조했다(Jie et al., 2021). 이러한 사례는 복잡한 전문 분야일수록 AI 단독 판단보다 전문가의 판단을 보조하는 방식(HITL)이 현실적이고 바람직한 방향임을 시사한다.

5. 국제협력 및 상호운용성

AI 기술과 데이터는 국경을 넘나들어 활용되는 반면, 이를 규율하는 법·제도는 국가별로 상이하여 규제 충돌과 불확실성을 초래한다. 각국이 데이터 주권과 자국민 보호를 강조하는 상황에서도, AI의 혁신 촉진과 위험 대응을 위해서는 국제적 협력이 불가피하다는 인식이 확산되고 있다. 이러한 긴장 관계 속에서 핵심 과제는 국가별 규율을 전면적으로 통일하는 것이 아니라, 상호 신뢰를 기반으로 한 최소한의 공통 규범과 상호운용성을 어떻게 확보할 것인가에 있다.

EU와 미국 간 개인정보 이전을 둘러싼 사례는 이러한 문제를 잘 보여준다. 2020년 유럽사법재판소는 미국의 정보 접근 제도가 EU의 개인정보 보호 기준에 부합하지 않는다는 이유로 기존의 EU-미국 프라이버시 실드 체계를 무효화하였다. 이로 인해 많은 기업이 법적 불확실성에 직면했지만, 2023년 양측은 새로운 EU-U.S. 데이터 프라이버시 프레임워크를 마련하였다. 이 제도는 미국 정보기관의 데이터 접근을 제한하고

독립적인 규제 절차를 도입함으로써, EU가 요구한 보호 기준을 제도적으로 보완한 것이다(European Commission, 2023).

국가별 규제가 계속 다른 상황에서, 기술적 차원에서는 국제표준이 중요한 역할을 한다. 국제표준화기구(ISO)와 국제전기표준회의(IEC)가 공동으로 마련한 AI 국제표준은 AI 시스템을 어떻게 관리하고 통제할 것인지에 대한 공통 기준을 제공한다. 특히 ISO/IEC 42001은 조직이 AI를 책임 있게 운영하기 위해 갖추어야 할 관리체계를 제시함으로써, 위험 관리와 책임성을 체계적으로 구현할 수 있도록 돕는다(ISO/IEC, 2023). 이러한 표준은 법처럼 강제되지는 않지만, 기업과 공공기관이 국가별 규제 차이 속에서도 공통된 기준에 따라 AI를 운영하도록 유도하는 실질적인 기준점으로 기능하고 있다(ISO, 2023).

이와 함께 국제기구와 다자 협력을 통한 논의도 중요해지고 있다. IEEE의 가이드라인은 AI 시스템의 설계와 운영 전 과정에서 책임성과 통제 가능성을 고려하도록 요구하며, 빠르게 변화하는 기술 환경에 유연하게 대응할 수 있는 기준을 제시한다(IEEE, 2021). 또한 아시아-태평양 지역의 디지털경제파트너십협정(DEPA)이나 G7 히로시마 AI 프로세스와 같은 다자간 논의는 법적 구속력보다는 원칙 공유와 정책 조율을 통해 국가 간 협력의 기반을 넓히는 역할을 한다.

결국 국제협력과 상호운용성 확보는 개별 국가의 규제를 약화시키기 위한 선택이 아니라, AI가 가진 초국경적 특성 속에서 신뢰가능성을 유지하기 위한 필수 조건으로 이해할 수 있다.

제3절 속의민주주의와 시민참여 문제

생성형 AI와 알고리즘적 의사결정(ADM)이 행정 현장에 빠르게 확산되면서, 공공부문은 효율성·정확성 제고라는 약속과 함께 편향, 불투명성, 책임소재 불분명 등 새로운 위험을 동시에 마주하고 있다. EU와 각국 정부는 위험기반(risk-based) 규제·관리 프레임워크를 도입하고 있으나, ‘무엇을 위하여, 그리고 누구의 관점에서’ 위험을 정의하고 통제할 것인가의 민주적 정당성은 여전히 핵심 과제로 제시되고 있다. 따라서 공공 의사결정에서 AI가 야기하는 주요 위험을 확인하고, 이러한 위험에 대응하는 사회적 해결책으로서 속의민주주의(시민의회, 속의형 여론조사 등)의 이론·실증 근거를 고찰할 필요성이 제기된다.

1. 공공의사결정에서 AI의 위험성

1.1 차별·편향과 분배적 불평등

AI는 학습자료와 설계 선택의 편향을 증폭하거나 새로운 차별을 낳을 수 있다. 이러한 가능성은 데이터·모델 편향 검증과 외부적 견제(external checks and balances)를 제도화할 필요를 시사한다. 네덜란드 아동수당 사건에서 자동화된 위험평가가 이민자·저소득층을 과도하게 표적화하며 대규모 피해를 초래한 사례는 규제 부재와 비례성 심사의 실패가 결합할 때의 파급을 보여준다.³⁾ 이와 마찬가지로 호주 복지당국의 자동화된 부채 환수시스템이 복지혜택수급자들에게 잘못된 환수통지를 하여 대규모 피해를 야기한 사례는 인간의 개입이 결여된 자동화된 의사결정의 폐해를 보여준다.⁴⁾ 또한 최근 영국 지방자치단체에서 사용된 요약·평가용 LLM이 동일 사례를 남성/여성으로만 바꾸었을 때 여성의 건강 이슈를 덜 심각하게 기술하는 경향을 보였다는 실증도 보고된 바 있다.⁵⁾

3) https://www.amnesty.org/en/latest/news/2021/10/xenophobic-machines-dutch-child-benefit-scandal/?utm_source=chatgpt.com

4) 홍승헌 & 황하. (2024). 누구를 위한 디지털 전환인가? 자동화된 복지행정의 위험성. 정부학연구, 30(2), 61-84.

5) <https://www.theguardian.com/technology/2025/aug/11/ai-tools-used-by-english-councils-downplay-womens-health-issues-study-finds?>

1.2 불투명성과 설명가능성의 한계

인공지능 특유의 ‘블랙박스’ 모델은 결정사유의 제시, 절차적 정당성, 사후불복·구제권 보장에 장애로 작용할 수 있다. 복잡한 딥러닝 모델은 입력과 출력 사이의 의사결정 과정을 투명하게 설명하기 어려우며, 이는 행정절차법상 요구되는 ‘처분 이유 제시 의무’와 충돌할 수 있다. EU AI Act는 복지·이민·사법 등 권리영향이 큰 분야의 시스템을 ‘고위험’으로 분류하고 데이터 거버넌스, 로그·문서화, 투명성·인간감독 등을 요구하고 있다. 또한 캐나다는 연방 행정에 ‘알고리즘 영향평가(AIA)’를 의무화하여 위험수준에 따른 통제요건과 결과 공개를 규정했고, 뉴질랜드는 ‘알고리즘 차터’로 정부의 알고리즘 투명성·책무성을 자발적이지만 포괄적으로 약속하도록 의무화하고 있다.

1.3 자동화 편향과 인간감독의 취약성

형식적인 인간 검토(ritual human review)만으로는 편향과 오류를 걸러내기 어렵고, 설계 단계부터 인간과 기계 간 상호작용을 고려한 통제와 훈련체계가 필요하다.⁶⁾ 기존 연구에 의하면, 공무원과 시민 모두가 경고 신호를 인지하더라도 알고리즘 권고를 과신(automation bias)하거나, 반대로 초기실패 경험 등으로 인해 전면 불신(algorithmic aversion)하는 양극적 반응을 보이는 것이 관찰되었다.

2. 공공의사결정에서 숙의민주주의의 필요성

2.1 숙의민주주의의 효과와 한계

숙의민주주의는 단순한 투표와 선호집계를 넘어서, 이성에 기반한 진정한 숙의(authentic deliberation)를 통한 민주적 정당성을 추구하고 있다. 시민사회와 국가

6) Alon-Barkat, S., & Busuioc, M. (2023). Human-AI interactions in public sector decision making: “automation bias” and “selective adherence” to algorithmic advice. *Journal of Public Administration Research and Theory*, 33(1), 153-169; Ruschemeier, H., & Hondrich, L. J. (2024). Automation bias in public administration—an interdisciplinary perspective from law and psychology. *Government Information Quarterly*, 41(3), 101953; Kazim, T., & Tomlinson, J. (2023). Automation bias and the principles of judicial review. *Judicial Review*, 28(1), 9-16.

사이의 정치적 의사소통 공간으로 기능하는 공론장(public sphere)에서 공정한 절차와 의사소통을 통해 정당한 시민 결정을 만들어낼 수 있다는 Habermas,⁷⁾ 시민이 공공이슈에 관해 숙의할 때 공정한 정치사회 구조를 정당화할 수 있다는 Rawls⁸⁾ 등이 숙의민주주의의 철학적 기초를 제공하고 있다. 숙의민주주의는 당파성 감소와 반대 의견에 대한 공감 증가, 증거기반 추론에 대한 존중, 의사결정에 대한 참여자들의 헌신, 사회적 응집력을 촉진하는 광범위한 합의가능성 증대 등을 효과를 낼 수 있을 것으로 기대된다.

한편, 숙의민주주의가 현실에서 구현되기 위해서는 넘어야 할 한계 또한 명백하다. 먼저, 규모의 문제가 있는데, Chambers,⁹⁾ Landemore¹⁰⁾ 등은 대규모 참여와 심도 있는 숙의 간의 근본적 긴장을 지적하였다. 바로 실제의 숙의과정에는 소수의 선별된 시민만이 참여가능하고, 전체 인구를 포괄하는 동시적 숙의는 현실적으로 불가능하다는 지적이다. 덧붙여서 사회적 불평등의 재생산의 문제가 있다. Karpowitz & Mendelberg,¹¹⁾ Sanders,¹²⁾ Young¹³⁾ 의 연구에 따르면 사회적 불평등은 숙의 공간에 그대로 재현되어 공정한 숙의가 이뤄지기 어렵다. 성별, 인종, 계급과 같은 특성은 체계적으로 불평등한 참여를 초래하며, 정치적 문해력(political literacy)과 정보 비대칭이 의사소통의 불평등을 야기한다. 의미있는 숙의를 위해서는 상당한 시간과 자원의 투자가 필요한데, 개인의 경제적 제약, 업무, 가사책임 등이 평등한 책임을 방해할 수 있는 것이다.

7) Habermas, J. (1996). *Between Facts and Norms: Contributions to a Discourse Theory of Law and Democracy*. Cambridge, MA: MIT Press.

8) Rawls, J. (1993). *Political Liberalism*. New York: Columbia University Press; Rawls, J. (1997). "The Idea of Public Reason Revisited." *University of Chicago Law Review*, 64(3): 765-807.

9) Chambers, S. (2009). "Rhetoric and the Public Sphere: Has Deliberative Democracy Abandoned Mass Democracy?" *Political Theory*, 37(3): 323-350.

10) Landemore, H. (2020). "Can AI Bring Deliberative Democracy to the Masses?" Working paper, Yale University.

11) Karpowitz, C. F., & Mendelberg, T. (2014). "Gender Inequality in Deliberation: Unpacking the Black Box of Interaction." *Perspectives on Politics*, 12(1): 18-44.

12) Sanders, L. (1997). "Against Deliberation." *Political Theory*, 25(3): 347-376.

13) Young, I. M. (1996). "Communication and the Other: Beyond Deliberative Democracy." In S. Benhabib (ed.), *Democracy and Difference*. Princeton: Princeton University Press, pp. 120-135; Young, I. M. (2001). "Activist Challenges to Deliberative Democracy." *Political Theory*, 29(5): 670-690.

2.2 인공지능의 가능성

1) 대규모의 참여데이터 처리를 통한 규모확장

수백만 개 이상의 온라인 의견을 자동화된 텍스트 분석을 통해 처리함으로써 전통적인 방법으로는 소수의 인용문으로 축소되었을 정보에 대한 포괄적인 분석이 가능해진다.¹⁴⁾

2) 정보 비대칭과 지식 격차의 완화

AI가 보조자(AI Advisers)로 사용될 때, 시민들이 복잡한 정책 이슈를 이해하도록 맞춤형 정보를 제공하고, 인식론적 장벽을 극복하여 더 효과적인 참여를 가능케 하고, 전문지식과 일반시민의 판단력 간 격차를 축소시켜줄 수 있다. 또한 인공지능 기반 대화형 플랫폼에서 생성형 인공지능이 토론을 촉진시킬 수 있다.

3) 의사소통 불평등 감소

Tessler et al.의 연구¹⁵⁾에 따르면 숙의 참여자들은 인공지능이 생성한 진술문이 인간 중재자가 작성한 것보다 더 유익하고, 명확하며, 편향되지 않고, 논리적이라고 평가하였다. 또한 지배적 발언자의 영향력이 제한되며 소수 의견이 공정하게 반영되었다고 하였다. 텍스트 임베딩 분석결과 인공지능이 생성한 그룹 진술문은 다수의 입장을 존중하면서도 반대의견을 통합하였고, 비판 처리 단계에서는 오히려 소수 의견에 가중치를 부여함으로써 소수를 보호하고자 한 것이다. 인공지능의 중재 이후 참여자들은 자신의 견해를 업데이트할 수 있었고, 공유된 관점으로 의견수렴이 일어났으며, 숙의 전보다 이슈에 대해 덜 분열되는 결과를 보여주었다. 이는 합리적 이해조율이 이뤄지기보다 감정과 자기이해에 추동되는 참여한 이해관계 대립상황에서의 숙의가 인공지능의 도움을 통해 보다 원활히 이뤄질 수 있는 가능성을 제시하는 것이다.

14) Carnegie Endowment for International Peace (2025). "How AI Can Unlock Public Wisdom and Revitalize Democratic Governance." <https://carnegieendowment.org/posts/2025/07/how-ai-can-unlock-public-wisdom-and-revitalize-democratic-governance>

15) Tessler, M. H., Bakker, M. A., et al. (2024). "AI Can Help Humans Find Common Ground in Democratic Deliberation." *Science*, 385(6714): 1252-1257.

4) 확장성과 효율성, 포용성

인공지능의 중재 방식은 시간 효율적이며, 가상 시민의회 환경에서도 잘 작동하여 민주적 숙의에 있어 광범위한 적용 가능성을 시사한다. 온라인 플랫폼을 통해 시간과 장소의 제약을 극복할 수 있고, 언어적 다양성을 포괄할 수 있고, 문해력이 낮은 참여자를 위한 대안적 인터페이스를 제공할 수 있어 포용성이 높다. 무작위 추출된 시민패널(mini public)의 순환(rotation)을 인공지능으로 지원할 수 있으며, 제한된 참여자들의 숙의 결과를 광범위한 공중과 연결가능하다. 또한, 수백만 명이 인공지능 증강 플랫폼에서 논의를 진행하는 온라인 군중숙의(mass online deliberation) 또한 가능할 것으로 기대된다.

이처럼 인공지능은 숙의민주주의의 전통적 한계(규모, 비용, 불평등)를 극복할 도구를 제공하지만, 동시에 ADM이 야기하는 새로운 민주적 도전(블랙박스, 책임성, 편향)은 숙의민주주의의 규범적 원칙을 통해서만 해결 가능하다. 중요한 것은 인공지능은 숙의의 규모와 효율성을 증폭시키는 도구이며, 인공지능의 방향과 한계를 설정할 때 숙의민주주의가 민주적 통제 메커니즘으로 작동해야 한다는 점이다.

제4절 ADM 거버넌스 신뢰성 분석틀

앞서 살펴보았듯이 일반적인 시스템 개발과 구별되는 AI 시스템의 대표적인 특징으로 데이터 의존성과 시간이 지남에 따라 반복하고 진화하는 자율적인 능력 등을 확인하였는데, 다수의 선행연구에서는 공공부문의 ADM 시스템의 안정적 운영을 위해서는 신뢰가능한 거버넌스(trustworthy governance) 구축의 중요성을 지적하고 있으며, 이런 맥락에서 신뢰가능한 AI 거버넌스 원칙을 제시하고 있다. 나아가 ADM 거버넌스에 시민참여를 제도화함으로써 알고리즘 설계·운영에 대한 감시와 정당성 확보가 가능하며, 이를 통해 ADM의 절차적 정당성을 제고함으로써 공공신뢰 형성에 긍정적으로 작용하게 된다.

OECD(2019c:13)는 AI 시스템 생애주기(AI system life-cycle)를 설계, 데이터 및 모델링(design, data and models), 검증 및 확인(verification and validation), 배포(deployment), 그리고 운영 및 모니터링(operation and monitoring)으로 이어지는 4단계로 구분하여 제시하였는데, 각 단계는 다음과 같이 구성된다.

〈표 2-4〉 AI 시스템 생애주기 (OECD, 2019)

순서	단계	내용
1단계	설계, 데이터 및 모델링	- 여러 관련 활동을 포함하며, AI 시스템에 따라 그 순서가 달라질 수 있음 - 기획 및 설계: 시스템의 개념과 목표, 기본 가정, 맥락 및 요구사항을 명확히 정의하고, 잠재적으로 프로토타입을 제작하는 활동 등을 포함 - 데이터 수집 및 처리: 데이터를 수집하고 정제하며, 데이터의 완전성과 품질에 대한 점검을 수행하고 데이터의 특성을 문서화 (데이터 특성에는 데이터의 생성 방법, 구성, 의도된 용도 및 유지 관리 방식에 대한 정보 등 포함) - 모델 구축 및 해석: 모델 또는 알고리즘을 생성하거나 선택하고, 이를 보정(Calibration) 및 학습(Training)시키며 해석하는 과정
2단계	검증 및 확인	모델을 실행하고 조정(Tuning)하며, 다양한 차원과 고려사항에 걸쳐 성능을 평가하기 위한 테스트를 수행
3단계	배포	실제 운영 환경에 적용하는 단계로, 시범 운영(Piloting), 기존 시스템과의 호환성 확인, 규제 준수 보장, 조직의 변화 관리 및 사용자 경험 평가 등 포함
4단계	운영 및 모니터링	- AI 시스템을 가동하면서 그 권고사항과 영향(의도한 결과 및 의도하지 않은 결과 모두 포함)을 목표와 윤리적 고려사항에 비추어 지속적으로 평가 - 이 단계에서 문제가 식별되면 이전 단계로 되돌아가 조정하거나, 필요한 경우 운영 중인 AI 시스템을 폐기(Retire)하기로 결정

출처: OECD(2019c:13)

〈그림 2-1〉 AI 시스템 생애주기



출처: NotebookLM Infographic 기능을 활용하여 저자 작성

Agbabiaka et al.(2025:9,16)은 AI 기반 의사결정 시스템의 신뢰도에 영향을 미치는 18개 주요 결정요인을 OECD의 AI 시스템 생애주기 4단계와 매핑 및 연결하였는데, 본 연구에서는 이를 참고하여 아래와 같이 단순화하였다. 18개의 신뢰도 결정요인이 모든 단계에 공통으로 적용되거나 또는 각 단계별로 적용되는 경우를 모두 고려하여 총 25개 결정요인(8개 공통 및 17개 단계별 적용)으로 구분하였다.

〈표 2-5〉 AI 시스템 생애주기 단계별 신뢰도 결정요인

단계	신뢰도 결정요인
(1~4 단계) 공통	• 이해관계자 참여(설계-테스트-모니터링) • 투명성 • 책임성 • 인간 행위 주체성 및 감독 • 윤리, 평가 및 지속적 개선 • 공정성 및 비차별 • 정치적 정당성 및 민주주의 • 이의 제기 가능성 및 구제
(1단계) 설계, 데이터 및 모델링	• 문제 및 목표 명확성 • 가치 상충 및 정렬 • 다양성, 참여 및 포괄성 • 데이터 관리 • 맥락 민감성 • 선택 및 자율성

단계	신뢰도 결정요인
(2단계) 검증 및 확인	- 기술적 견고성 - 시스템 안정성 검증 테스트 수행 - 설명 가능성 - 공정성 및 비차별 - 데이터 프라이버시, 보호 및 보안
(3단계) 배포	- 기술적 견고성 - 인간 행위 주체성 및 감독 - AI 리터러시, 교육 및 인식 제고
(4단계) 운영 및 모니터링	- 기술적 견고성 - 윤리, 평가 및 지속적 개선 - 피드백 및 정책 학습

출처: 저자 작성

〈그림 2-2〉 AI 시스템 생애주기별 주요 결정요인



출처: NotebookLM Infographic 기능을 활용하여 저자 작성

이어서 3장에서는 OECD(2019c)의 AI 시스템 생애주기 모형과 Agbabiaka et al.(2025)의 신뢰도 결정요인을 실증적으로 적용하여 측정 및 분석하였다.

제3장 ADM 거버넌스 신뢰성 분석

제1절 설문조사 개요

제2절 설문조사 결과

제3절 순서형 로짓 회귀분석

제4절 소결

제3장 ADM 거버넌스 신뢰성 분석

제1절 설문조사 개요

1. 조사 목적 및 대상

본 연구에서는 공공부문 기관과 단체에서 도입 예정 또는 운영 중인 AI 기반 의사결정 시스템의 신뢰성 진단 및 이용자 신뢰 확보 방안을 알아보기 위한 설문조사를 2026년 1월 2주간 실시하였다.

조사의 목적은 정부 및 공공기관 종사자들의 경험과 의견을 바탕으로 AI 기반 의사결정 시스템의 평가 및 신뢰도 결정요인을 진단하고, 또한 향후 공공부문 의사결정 시스템 개선을 위한 의견을 수렴하여 이를 바탕으로 공공부문 AI 기반 의사결정 시스템의 신뢰성과 정당성을 확보할 수 있는 구체적이고 실질적인 개선 방안을 제시하는 데 있다.

〈표 3-1〉 설문조사 개요

구 분	내 용
설문조사 대상	전국의 중앙행정기관, 지방자치단체, 공공기관 등 공공부문 종사자 중 AI 시스템 담당자 및 사용자
설문조사 방법	구조화된 설문지를 활용한 웹조사 (95% 신뢰수준에서 최대허용 표집오차 $\pm 6.9\%$ Point)
표본 설계	할당 표본 추출(quota sampling)
표본 수	202명 (AI 시스템 담당자 100명, AI 시스템 사용자 102명)
설문조사 기간	2026년 1월 (2주)

출처: 저자 작성

본 설문조사를 위해 목표 모집단을 전국의 중앙행정기관, 지방자치단체, 공공기관 등 공공부문 종사자 중 AI 시스템 담당자 및 사용자로 정의하였다.

설문조사를 실시할 때 초반에 경제활동 여부, 직장 유형(공공, 민간 등), 담당 업무, 정보시스템 사용 여부 및 특성, AI 기반 의사결정 시스템 사용 여부를 묻는 스크리닝 문항(screening question)을 설정하여 공공부문 AI 의사결정 시스템 담당자와 사용자를 선별하였다. 특히 AI 시스템 담당자와 사용자를 구분하고 AI 기반 의사결정 시스템의 특성을 명시함으로써 선별 과정의 정확성과 신뢰도를 높이하고자 하였다. 결과적으로 AI 시스템 담당자 100명 및 AI 시스템 사용자 102명 등 총 202명이 응답하였으나 소속기관의 AI 시스템 도입 단계와 무관하게 개인적인 목적으로 사용한다고 응답한 4명을 제외한 198명을 최종 표본으로 확정하였다.

2. 설문조사의 주요 내용

설문조사의 주된 목적은 공공부문 AI 기반 의사결정 시스템의 평가 및 신뢰도 결정 요인을 진단하고 향후 공공부문 의사결정 시스템 개선을 위한 의견을 수렴하는 데에 있다. 이에 따라 조사 내용은 스크리닝 문항, 일반현황, AI 시스템 신뢰도 결정요인(생애주기 공통 및 단계별), 그리고 AI 시스템 종합평가, 진단 및 개선 방안을 포함하고 있다.

스크리닝 문항으로는 경제활동 여부, 직장 유형(공공, 민간 등), 담당 업무, 정보시스템 사용 여부 및 특성, AI 기반 의사결정 시스템 사용 여부 등을 확인하여 공공부문 AI 시스템 담당자 및 사용자를 식별하였다. 일반현황은 크게 AI 시스템 특성과 응답자 특성으로 구분할 수 있는데, AI 시스템 특성으로는 기관 유형, 도입 단계, 영향 범위, 의사결정 자율성 및 위험도를 조사하였으며, 응답자 특성(성별, 연령대, 관련 경력, 정보시스템 업무 여부, 담당 업무)도 확인하여 응답자 특성별 답변의 차이를 확인하고, 고급 통계분석의 통제 변수로 활용하였다.

AI 시스템 신뢰도 결정요인은 생애주기 공통 및 단계별로 구분하여 조사하였으며, AI 시스템 생애주기는 1단계 설계·데이터 및 모델링, 2단계 검증 및 확인, 3단계 배포, 그리고 4단계 운영 및 모니터링으로 구분하였다.

〈표 3-2〉 설문조사의 주요 내용

영역	구분	항목 및 문항	
스크리닝 문항	-	- 경제활동 여부 - 직장 유형(공공, 민간 등) - 담당 업무	- 정보시스템 사용 여부 및 특성 - AI 시스템 사용 여부
일반현황	AI 시스템 특성	- 기관 유형 - 도입 단계 - 영향 범위	- 의사결정 자율성 - 위험도
	응답자 특성	- 성별 - 연령대 - 관련 경력	- 정보시스템 업무 여부 - 담당 업무
AI 시스템 신뢰도 결정요인 (생애주기 공통 및 단계별)	전 단계 공통	- 이해관계자 참여 - 투명성 - 책임성 - 인간 행위 주체성 및 감독	- 윤리, 평가 및 지속적 개선 - 공정성 및 비차별 - 정치적 정당성 및 민주주의 - 이의 제기 가능성 및 구제
	설계, 데이터 및 모델링	- 문제 및 목표 명확성 - 가치 상충 및 정렬 - 다양성, 참여 및 포괄성	- 데이터 관리 - 맥락 민감성 - 선택 및 자율성
	검증 및 확인	- 기술적 견고성 - 시스템 안정성 검증 테스트 - 설명 가능성	- 공정성 및 비차별 - 데이터 프라이버시, 보호 및 보안
	배포	- 기술적 견고성 - 인간 행위 주체성 및 감독	AI 리터러시, 교육 및 인식 제고
	운영 및 모니터링	- 기술적 견고성 - 윤리, 평가 및 지속적 개선	피드백 및 정책 학습
AI 시스템 종합평가, 진단 및 개선계획	신뢰도	- AI 시스템 신뢰도 (응답자) - AI 시스템 신뢰도 (시민/이용자)	
	준비 수준	1단계 준비 수준 2단계 준비 수준	3단계 준비 수준 4단계 준비 수준
	진단 및 개선계획	- AI 시스템 신뢰도 결정요인 중 가장 미흡한 영역 - AI 시스템 신뢰성 확보 장애요인 - AI 시스템 개선계획	

출처: 저자 작성

1~4단계에 공통으로 적용되는 신뢰도 결정요인으로 이해관계자 참여, 투명성, 책임성 등 8개 결정요인과 이를 측정하기 위한 22개 지표를 구성하였다. 이 외에도 생애주기 단계별로 관련된 결정요인과 지표를 구성하였는데, 1단계(설계, 데이터 및 모델링)에 대한 문제 및 목표 명확성, 가치 상충 및 정렬 등 6개 결정요인 및 16개 지표, 2단계(검증 및 확인)에 대한 기술적 견고성, 시스템 안정성 테스트 등 5개 결정요인 13개 지표, 3단계(배포)에 대한 기술적 견고성, 인간 행위 주체성 및 감독 등 3개 결정요인 7개 지표, 그리고 4단계(운영 및 모니터링)에 대한 기술적 견고성, 윤리·평가 및 지속적인 개선 등 3개 결정요인 8개 지표를 조사하였다.

AI 시스템 종합평가에 대한 문항으로는 응답자 및 시민/사용자 관점에서의 AI 시스템의 신뢰도와 소속 기관의 AI 시스템 생애주기 단계별 준비 수준에 대한 6개 평가항목(모두 단일지표로 구성)으로 구성하였다. 마지막으로 AI 시스템 진단 및 개선계획으로 신뢰도 결정요인 중 가장 미흡한 영역, 신뢰성 확보 장애요인 및 개선계획에 대한 문항을 조사에 포함하였다.

제2절 설문조사 결과

1. 일반현황

1.1 AI 시스템 특성

본 설문조사에서 확인한 AI 시스템의 특성으로 기관 유형, 도입 단계, 영향 범위, 의사결정 자율성 및 위험도가 있으며 다음과 같은 특성을 확인하였다. 설문조사에 응한 공공부문 AI 시스템 담당자 및 사용자는 주로 공공기관에 종사하고 있으며, 소속 기관들의 AI 시스템 도입 수준은 4개의 도입 단계에 비교적 골고루 분포되어 있으며, 과반 이상의 AI 시스템이 내부 업무 지원 목적 및 의사결정 지원 용도로 활용되고 저위험 시스템으로 분류되는 것으로 나타났다.


1) 기관 유형

공공부문 AI 시스템 담당자 및 사용자 198명에게 현재 근무하고 있는 기관의 유형을 물어본 결과 공공기관(공기업, 준정부기관, 기타 공공기관 등)이 123명(62.1%)으로 가장 많았으며, 정부 부처 및 산하 기관(중앙부처, 국립기관 등)과 지방자치단체 및 산하 기관(시·도청, 시·군·구청, 지방공기업 등)이 각각 37명(18.7%)과 38명(19.2%)으로 비슷한 것으로 나타났다.

2) 도입 단계

조사기관들의 AI 시스템 도입 단계는 시범 운영(59명, 29.8%)과 정식 운영(57명, 28.8%)이 가장 많은 것으로 나타나 AI 시스템 도입을 고려하거나 진행하고 있는 공공부문의 기관들의 과반 이상이 적극적으로 도입·운영하고 있음을 확인하였다(2026년 1월 기준). 아직 운영하고 있지 않은 기관들의 경우 도입을 검토(47명, 23.7%)하는 기관이 개발 중(35명, 17.7%)인 기관보다 많은 것으로 나타났다.

〈그림 3-1〉 시스템 특성 : 기관 유형 및 도입 단계




출처: 저자 작성

3) 영향 범위

공공부문 AI 시스템의 주된 영향(활용) 범위는 내부 업무 지원이 124명(62.6%)으로 가장 많았으며, 시민 대상 서비스(54명, 27.3%), 정책 의사결정 지원(20명, 10.1%) 순으로 많은 것으로 나타났다.

〈그림 3-2〉 시스템 특성 : 영향 범위 및 의사결정 자율성



출처: 저자 작성


4) 의사결정 자율성

공공부문 AI 시스템의 의사결정 자율성 수준을 인간 개입 여부에 따라 2가지 유형으로 분류할 경우, AI 시스템이 정보를 추천·분석하고 최종 결정은 인간(담당자)이 하는 ‘의사결정 지원(Human-in-the-loop)’과 (인간의 개입이 거의 없거나) AI가 직접 최종 결정을 내리고 실행하는 ‘의사결정 자동화(Human-out-of-the-loop)’로 구분할 수 있다. 조사기관들의 AI 시스템의 경우 ‘의사결정 지원’에 해당한다고 응답한 비율이 82.3%(163명)로 ‘의사결정 자동화’ 비율(35명, 17.7%)보다 월등하게 많은 것으로 나타나 AI 시스템에게 인간 의사결정을 보조하는 역할을 부여하고 있음을 확인하였다.

5) 위험도

공공부문 AI 시스템은 의사결정이 미치는 위험도 수준에 따라 고위험(high-risk)과 저위험(low-risk)으로 구분할 수 있는데, 국민의 기본권, 안전, 재정 상태에 직접적이고 중대한 영향을 주는 경우(예: 복지 수급 탈락, 채용 불합격, 법적 제재)를 고위험으로 분류한 반면 영향이 경미하거나 오류 발생 시 쉽게 수정이 가능한 경우(예: 내부 문서 분류, 단순 챗봇 안내)는 저위험으로 분류하여 조사하였다. 조사기관들의 AI 시스템의 경우 ‘저위험’에 해당한다고 응답한 비율이 71.7%(142명)로 ‘고위험’ 비율(56명, 28.3%)보다 2배 이상 많은 것으로 나타나 AI 시스템이 영향이 경미한 용도에 더 많이 활용되고 있음을 확인하였다.

〈그림 3-3〉 시스템 특성 : 위험도



출처: 저자 작성


1.2 응답자 특성

본 설문조사에 응답한 공공부문 AI 시스템 담당자 및 사용자의 특성으로 성별, 연령대, 관련 경력, 정보시스템 업무 여부 및 담당 업무가 있으며 다음과 같은 특성을 확인하였다. 설문조사에 응한 공공부문 AI 시스템 담당자 및 사용자는 주로 남성이 많았으며, 대부분이 30대, 40대 및 50대인 것으로 나타났다. 응답자들의 2/3가 AI 관련 업무 경력이 3년 미만으로 적은 편이었으나 응답자들의 1/6은 관련 경력이 5년 이상으로 고르게 분포되어 있었으며, AI 시스템 담당자와 사용자가 비슷한 비율로 조사되었다.

1) 성별

공공부문 AI 시스템 담당자 및 사용자 198명 중 남성은 143명(72.2%)으로 여성(55명, 27.8%)보다 많은 것으로 나타났다.

〈그림 3-4〉 응답자 특성 : 성별 및 연령대



출처: 저자 작성


2) 연령대

설문조사에 응한 공공부문 AI 시스템 담당자 및 사용자는 40대가 73명(36.9%)으로 가장 많았으며, 30대(49명, 24.7%)와 50대(53명, 26.8%)가 비슷한 비율을 보인 반면에 20대 이하(7명, 3.5%)와 60대(16명, 8.1%)는 적은 편이었으며 70대 이상은 없었다.

3) 관련 경력

설문조사에 응한 공공부문 종사자들은 AI 관련 업무 경력이 1년 이상~3년 미만이 68명(34.3%)으로 가장 많았으며, 1년 미만(59명, 29.8%), 3년 이상~5년 미만(38명, 19.2%), 5년 이상(33명, 16.7%) 순으로 많은 것으로 나타났다.

〈그림 3-5〉 응답자 특성 : 관련 경력 및 정보시스템 업무 여부



출처: 저자 작성


4) 정보시스템 업무 여부

표본 설계 시 AI 시스템 담당자 및 사용자를 동일한 비율로 할당하여 조사를 수행한 결과 99명이 AI 시스템 담당자로 정보시스템 기획·개발·운영·관리 업무를 담당하고 있는 것을 확인하였다. 99명의 AI 시스템 사용자의 경우 정책 기획·조정, 예산·회계, 인사·조직, 대민 서비스·민원 등 정보시스템 기획·개발·운영·관리 외 다른 업무를 담당한다고 응답하였다(중복 선택 가능).

5) 담당 업무

설문조사에 응한 공공부문 종사자들에게 담당 업무를 기획, 개발, 운영, 관리, 감독 등으로 유형화하여 조사한 결과 운영이 114명(57.6%)으로 가장 많았으며, 관리(93명, 47.0%), 기획(61명, 30.8%), 개발(50명, 25.3%) 순으로 높게 나타났다(중복 선택 가능).

〈그림 3-6〉 응답자 특성 : 담당 업무



출처: 저자 작성

2. AI 시스템 신뢰도 결정요인 (생애주기 공통 및 단계별)

AI 시스템 신뢰도 결정요인은 생애주기 공통 및 단계별로 구분하여 조사하였는데, AI 시스템 생애주기는 1단계 설계·데이터 및 모델링, 2단계 검증 및 확인, 3단계 배포, 그리고 4단계 운영 및 모니터링으로 구분하였다.

2.1 전 단계 공통

AI 시스템 생애주기 1~4단계에 공통으로 적용되는 신뢰도 결정요인으로 ‘이해관계자 참여’, ‘투명성’, ‘책임성’ 등 8가지 요인을 선정하고 이를 측정하기 위한 22개 지표

를 조사하였다. 리커트(Likert) 5점 척도를 이용하여 22개 지표에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하고, 신뢰도 결정요인 별로 지표들의 산술평균을 구하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 생애주기 전 단계에 적용되는 신뢰도 결정요인을 비교·분석하였다.

〈표 3-3〉 AI 시스템 신뢰도 결정요인 및 지표 : 전 단계 공통

번호	결정요인	지표
[S1]	이해관계자 참여	AI 시스템의 전 생애주기에 걸쳐 이해관계자 참여(설계-테스트-모니터링)가 지속되고 있습니까?
[S2]	투명성	- AI 시스템의 운영 프로세스(개요, 절차)가 투명하게 공개되어 있습니까? - 알고리즘 및 모델에 대한 정보(종류, 주요 변수 등)가 적절한 수준으로 공개되어 있습니까? - 이해관계자별(시민, 전문가)로 필요한 수준의 투명성이 제공되고 있습니까? - AI 시스템 관련 정보에 대한 접근성(정보 공개 청구 등)이 보장되어 있습니까?
[S3]	책임성	- AI 시스템 운영에 대한 책임(시스템/데이터/의사결정 책임자)이 명확히 정의되고 할당되어 있습니까? - 다양한 이해관계자(내부, 시민, 감독기관)에 대한 책임 체계가 수립되어 있습니까? - 헌법적 가치(기본권 보호, 공공 이익)와 공공 책임성이 확보되어 있습니까? - 책임 이행 여부를 검증할 수 있는 메커니즘(감사, 성과 평가 등)이 있습니까?
[S4]	인간 행위 주체성 및 감독	- 전체 AI 라이프사이클에 걸쳐 인간의 통제와 감독이 유지되고 있습니까? - 중요한 결정(고위험 결정)에 대해 인간의 최종 판단이 보장됩니까?
[S5]	윤리, 평가 및 지속적 개선	- 윤리적 원칙과 가이드라인(AI 윤리 헌장 등)이 전 단계에서 준수되고 있습니까? - 지속적인 품질 보증 활동(단계별 품질 게이트 등)이 전 단계에서 수행되고 있습니까?
[S6]	공정성 및 차별	- 시스템의 전체 수명 주기 동안 공정성이 지속적으로 평가되고 있습니까? - 차별 방지를 위한 정기적인 점검(편향 탐지, 집단별 결과 분석)이 이루어지고 있습니까?
[S7]	정치적 정당성 및 민주주의	- AI 시스템이 민주적 가치와 정치적 정당성(입법적 근거 등)을 확보하고 있습니까? - 기본권 보호(평등권, 인격권 등)가 충분히 고려되고 있습니까? - AI 시스템이 기관의 신뢰와 조직 평판에 긍정적으로 기여하고 있습니까?
[S8]	이의제기 가능성 및 구제	- AI 결정에 대해 이의를 제기할 수 있는 메커니즘이 명확히 마련되어 있습니까? - 피해 구제를 위한 명확한 절차(재검토, 구제 조치)가 수립되어 있습니까? - 이의 제기 및 구제 절차가 이용자에게 사전에 안내되고 있습니까? - 이의 제기에 대한 처리가 신속하고 공정하게(예: 7일 내 재검토) 이루어지고 있습니까?

출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

AI 시스템의 모든 생애주기에 공통으로 적용되는 신뢰도 결정요인 8개의 평균값은 3.23~3.40점으로 약간 충분한 수준으로 나타났으며 결정요인 간 차이가 비교적 큰 것으로 나타났다.¹⁶⁾ 전체 응답자 답변을 살펴보면 평균적으로 8개 결정요인 중 [S1] 이해관계자 참여(3.40점), [S4] 인간 행위 주체성 및 감독(3.37점), 그리고 [S5] 윤리, 평가 및 지속적 개선(3.37점)에 대한 평가가 가장 높게 나타난 반면, [S2] 투명성(3.23점), [S3] 책임성(3.24점), 그리고 [S8] 이의제기 가능성 및 구제(3.24점)에 대한 평가가 비교적 낮은 것으로 나타났다.

〈그림 3-7〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통




출처: 저자 작성

전 단계 공통으로 적용되는 신뢰도 결정요인을 도입 단계별로 살펴보면 ‘도입 검토 단계’인 AI 시스템에 대한 평가가 2.72~2.95점으로 가장 낮았으며, ‘정식 운영 단계’인 AI 시스템에 대한 평가가 3.54~3.72점으로 가장 높게 나타났다.

16) 평균값이 가장 큰 결정요인 [S1]과 가장 작은 결정요인 [S2] 간 t-검정 결과 통계적으로 유의한 차이를 확인하였다($\alpha=0.01$).


〈그림 3-8〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통 (도입 단계별)



출처: 저자 작성

반면에 전 단계 공통으로 적용되는 신뢰도 결정요인을 영향 범위별로 살펴보면 ‘내부 업무 지원(3.19~3.39점)’, ‘시민 대상 서비스(3.25~3.44점)’ 그리고 ‘정책 의사결정 지원(3.23~3.48점)’이 대체로 유사한 수준인 것으로 나타났다.

〈그림 3-9〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.33~3.60점)’ 시스템이 ‘의사결정 지원(3.20~3.38점)’ 시스템보다 결정요인 평균값이 대체로 높게 나타났으며, ‘고위험(3.26~3.54점)’ 시스템이 ‘저위험(3.20~3.35점)’ 시스템보다 결정요인 평균값이 대체로 높은 것으로 나타났다. 또한 정보시스템 업무 담당자(3.33~3.51점)가 정보시스템 이외 업무 담당자(3.14~3.29점)보다 결정요인 평균값이 높게 나타난 반면, 기관 유형 간 차이는 확인되지 않았다.

〈표 3-4〉 AI 시스템 신뢰도 결정요인 : 전 단계 공통

		[S1]	[S2]	[S3]	[S4]	[S5]	[S6]	[S7]	[S8]
전체		3.40	3.23	3.24	3.37	3.37	3.27	3.29	3.24
기관 유형	중앙정부 및 산하 기관	3.49	3.22	3.21	3.46	3.49	3.43	3.38	3.28
	지방정부 및 산하 기관	3.34	3.22	3.27	3.36	3.39	3.21	3.27	3.37
	공공기관	3.39	3.24	3.25	3.35	3.33	3.24	3.26	3.19
도입 단계	도입 검토 단계	2.87	2.73	2.72	2.95	2.84	2.82	2.84	2.72
	개발 단계	3.51	3.33	3.32	3.36	3.56	3.27	3.37	3.31
	시범 운영 단계	3.44	3.28	3.31	3.41	3.36	3.24	3.32	3.29
	정식 운영 단계	3.72	3.54	3.56	3.70	3.70	3.68	3.57	3.57
영향 범위	내부 업무 지원	3.39	3.22	3.23	3.38	3.36	3.26	3.28	3.19
	시민 대상 서비스	3.44	3.25	3.28	3.33	3.38	3.29	3.31	3.34
	정책 의사결정 지원	3.35	3.28	3.24	3.48	3.40	3.30	3.23	3.30
의사결정 자율성	의사결정 자동화	3.60	3.36	3.41	3.36	3.46	3.33	3.46	3.42
	의사결정 지원	3.36	3.21	3.21	3.38	3.35	3.26	3.25	3.20
위험도	고위험	3.54	3.26	3.27	3.49	3.49	3.32	3.42	3.35
	저위험	3.35	3.23	3.23	3.33	3.32	3.25	3.23	3.20
정보시스템 업무 여부	정보시스템 업무	3.51	3.33	3.34	3.50	3.49	3.38	3.40	3.33
	기타 업무	3.29	3.14	3.15	3.25	3.24	3.16	3.17	3.15
표본 수		198	198	198	198	198	198	198	198

출처: 저자 작성

주: 결정요인 별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

2.2 1단계: 설계, 데이터 및 모델링

AI 시스템 생애주기 단계 중 1단계(설계, 데이터 및 모델링)에 대한 신뢰도 결정요인으로 ‘문제 및 목표 명확성’, ‘가치 상충 및 정렬’ 등 6가지 요인을 선정하고 이를 측정하기 위한 16개 지표를 조사하였다. 리커트 5점 척도를 이용하여 16개 지표에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하고, 신뢰도 결정요인 별로 지표들의 산술평균을 구하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 생애주기 1단계에 적용되는 신뢰도 결정요인을 비교·분석하였다.

〈표 3-5〉 AI 시스템 신뢰도 결정요인 및 지표 : 1단계

번호	결정요인	지표
[1-1]	문제 및 목표 명확성	- AI 시스템 도입 목적과 해결하고자 하는 문제가 명확하게 정의되어 문서화되어 있습니까? - AI 시스템의 목표가 기관의 공공 가치 및 정책 목표와 일치합니까? - AI 시스템이 달성해야 할 구체적인 성과 지표(KPI)가 설정되어 있습니까?
[1-2]	가치 상충 및 정렬	- AI 시스템 설계 시 발생할 수 있는 가치 간 상충(예: 효율성 vs 공정성)을 식별하고 논의했습니까? - 가치 상충 발생 시 우선순위 결정 기준이 명확히 수립되어 있습니까? - AI 시스템의 가치 정렬이 시민의 이익 및 공공선과 부합하는지 검토했습니까?
[1-3]	다양성, 참여 및 포괄성	- AI 시스템 설계 과정에 다양한 이해관계자(시민, 전문가 등)가 참여했습니까? - 소외 계층 및 취약 집단의 관점(접근성, 형평성)이 설계에 반영되었습니까?
[1-4]	데이터 관리	- 학습 데이터의 품질(정확성, 완전성, 일관성)이 체계적으로 검증되었습니까? - 데이터 수집 과정이 문서화되어 있으며, 데이터 출처와 수집 시점이 명확합니까? - 데이터의 대표성(특정 집단 과소/과대 표집 여부)이 분석되었습니까? - 데이터 수집, 저장, 활용에 대한 정기적인 감사 체계가 마련되어 있습니까?
[1-5]	맥락 민감성	- AI 시스템이 적용될 구체적인 행정 맥락과 상황이 충분히 고려되었습니까? - 알고리즘이 맥락(예: 긴급 vs 일반)에 따라 유연하게 작동하도록 설계되었습니까?
[1-6]	선택 및 자율성 ^가	- 시민이 자신의 데이터 사용에 동의하거나 거부할 수 있는 기능이 제공됩니까? - AI 시스템 이용 여부 또는 인간 담당자 처리를 선택할 권리가 보장됩니까?

출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

^가 시스템의 주된 영향 범위가 시민 대상 서비스 및 정책 의사결정 지원인 경우만 조사

AI 시스템 생애주기 1단계에 적용되는 신뢰도 결정요인 6개의 평균값은 3.22~3.32점으로 약간 충분한 수준으로 나타났으며 결정요인 간 차이가 있는 것으로 나타났다.¹⁷⁾ 전체 응답자 답변을 살펴보면 평균적으로 6개 결정요인 중 [1-1] 문제 및 목표 명확성(3.32점)과 [1-5] 맥락 민감성(3.32점)에 대한 평가가 가장 높게 나타난 반면, [1-3] 다양성, 참여 및 포괄성(3.22점)과 [1-6] 선택 및 자율성(3.27점)에 대한 평가가 비교적 낮은 것으로 나타났다.

〈그림 3-10〉 AI 시스템 신뢰도 결정요인 : 1단계




출처: 저자 작성

1단계에 적용되는 신뢰도 결정요인을 도입 단계별로 살펴보면 ‘도입 검토 단계’인 AI 시스템에 대한 평가가 2.69~2.91점으로 가장 낮았으며, ‘정식 운영 단계’인 AI 시스템에 대한 평가가 3.36~3.70점으로 가장 높게 나타났다.

17) 평균값이 가장 큰 결정요인 [1-1]과 가장 작은 결정요인 [1-3] 간 t-검정 결과 통계적으로 유의한 차이를 확인하였다($\alpha=0.05$).


〈그림 3-11〉 AI 시스템 신뢰도 결정요인 : 1단계 (도입 단계별)



출처: 저자 작성

1단계에 적용되는 신뢰도 결정요인을 영향 범위별로 살펴보면 대체로 유사한 수준이지만 ‘정책 의사결정 지원(3.33~3.50점)’이 ‘내부 업무 지원(3.20~3.31점)’과 ‘시민 대상 서비스(3.19~3.44점)’보다 약간 높은 것으로 나타났다.

〈그림 3-12〉 AI 시스템 신뢰도 결정요인 : 1단계 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.08~3.54점)’ 시스템이 ‘의사결정 지원(3.20~3.34점)’ 시스템보다 결정요인 평균값이 대체로 높게 나타났으며, ‘고위험(3.32~3.39점)’ 시스템이 ‘저위험(3.18~3.31점)’ 시스템보다 결정요인 평균값이 대체로 높은 것으로 나타났다. 또한 정보시스템 업무 담당자(3.29~3.46점)가 정보시스템 이외 업무 담당자(3.14~3.25점)보다 결정요인 평균값이 높게 나타난 반면, 기관 유형 간 차이는 확인되지 않았다.

〈표 3-6〉 AI 시스템 신뢰도 결정요인 : 1단계

		[1-1]	[1-2]	[1-3]	[1-4]	[1-5]	[1-6] ^a
전체		3.32	3.30	3.22	3.31	3.32	3.27
기관 유형	중앙정부 및 산하 기관	3.40	3.34	3.24	3.42	3.39	3.40
	지방정부 및 산하 기관	3.31	3.25	3.32	3.28	3.34	3.39
	공공기관	3.31	3.31	3.18	3.29	3.29	3.21
도입 단계	도입 검토 단계	2.90	2.86	2.79	2.91	2.84	2.69
	개발 단계	3.37	3.30	3.26	3.24	3.36	3.29
	시범 운영 단계	3.31	3.43	3.28	3.29	3.36	3.36
	정식 운영 단계	3.65	3.54	3.49	3.70	3.66	3.36
영향 범위	내부 업무 지원	3.31	3.28	3.20	3.30	3.25	
	시민 대상 서비스	3.32	3.31	3.23	3.27	3.44	3.19
	정책 의사결정 지원	3.38	3.45	3.33	3.50	3.45	3.48
의사결정 자율성	의사결정 자동화	3.43	3.44	3.31	3.45	3.54	3.08
	의사결정 지원	3.30	3.28	3.20	3.28	3.27	3.34
위험도	고위험	3.37	3.39	3.32	3.33	3.38	3.39
	저위험	3.31	3.27	3.18	3.30	3.30	3.20
정보시스템 업무 여부	정보시스템 업무	3.45	3.44	3.30	3.46	3.42	3.29
	기타 업무	3.20	3.17	3.14	3.16	3.22	3.25
표본 수		198	198	198	198	198	74

출처: 저자 작성

주: 결정요인 별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

^a 시스템의 주된 영향 범위가 시민 대상 서비스 및 정책 의사결정 지원인 경우만 조사

2.3 2단계: 검증 및 확인

AI 시스템 생애주기 단계 중 2단계(검증 및 확인)에 대한 신뢰도 결정요인으로 ‘기술적 견고성’, ‘시스템 안정성 테스트’ 등 5가지 요인을 선정하고 이를 측정하기 위한 13개 지표를 조사하였다. 리커트 5점 척도를 이용하여 ‘시스템 안정성 테스트’에 관한 지표 1개¹⁸⁾를 제외한 12개 지표에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하고, 신뢰도 결정요인 별로 지표들의 산술평균을 구하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 생애주기 2단계에 적용되는 신뢰도 결정요인을 비교·분석하였다.

〈표 3-7〉 AI 시스템 신뢰도 결정요인 및 지표 : 2단계

번호	결정요인	지표
[2-1]	기술적 견고성	- AI 모델의 정확성과 성능(예: Accuracy, F1-score)이 객관적 지표로 평가되었습니까? - 적대적 입력이나 데이터 변화(Concept Drift)에 대한 견고성이 검증되었습니까? - 시스템의 사용자 친화성(UI/UX)이 실제 사용자를 대상으로 평가되었습니까?
[2-2]	시스템 안정성 테스트	다양한 시나리오(예: 예외 케이스)에서 시스템의 안정성을 검증하는 테스트가 수행되었습니까? [예, 아니오, 기타(모름, 진행 중)]
[2-3]	설명 가능성	- AI의 개별 결정이 사람이 이해할 수 있는 방식(예: 거부 사유 명시)으로 설명될 수 있습니까? - AI 의사결정 프로세스(변수 중요도, 로직)가 투명하게 문서화되어 있습니까? - 이해관계자별(시민용, 담당자용)로 적절한 수준의 설명이 제공될 수 있습니까?
[2-4]	공정성 및 차별	- AI 시스템의 공정성이 정량적 지표(예: 인구통계적 형평성)로 측정되고 평가되었습니까? - 특정 집단(성별, 연령, 지역 등)에 대한 차별이나 편향이 없는지 검증되었습니까? - 공정성 지표가 정의되고 지속적 모니터링 체계가 수립되어 있습니까?
[2-5]	데이터 프라이버시, 보호 및 보안	- 개인정보 보호법 등 관련 법규 준수 여부(예: PIA(개인정보영향평가) 수행)가 검증되었습니까? - 데이터 암호화, 접근 권한 관리 등 보안 조치가 적절히 구현되어 있습니까? - 데이터 유출이나 보안 침해에 대응하는 절차가 마련되어 있습니까?


출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

18) ‘시스템 안정성 테스트’에 관한 1개 지표는 ‘예’ 또는 ‘아니오/기타’ 값을 취하는 이진 변수(binary variable)로 변환하여 분석에 활용하였다.

AI 시스템 생애주기 2단계에 적용되는 신뢰도 결정요인 4개¹⁹⁾의 평균값은 3.20~3.36 점으로 약간 충분한 수준으로 나타났으며 결정요인 간 차이가 있는 것으로 나타났다.²⁰⁾ 전체 응답자 답변을 살펴보면 평균적으로 4개 결정요인 중 [2-5] 데이터 프라이버시, 보호 및 보안(3.36점)과 [2-3] 설명 가능성(3.32점)에 대한 평가가 높게 나타난 반면, [2-1] 기술적 견고성(3.20점)과 [2-4] 공정성 및 비차별(3.22점)에 대한 평가가 비교적 낮은 것으로 나타났다. 또한 전체 응답자 중 60%가 시스템 안정성 검증 테스트를 수행했다고 답변하였다.

〈그림 3-13〉 AI 시스템 신뢰도 결정요인 : 2단계



출처: 저자 작성


2단계에 적용되는 신뢰도 결정요인을 도입 단계별로 살펴보면 ‘도입 검토 단계’인 AI 시스템에 대한 평가가 2.70~2.94점으로 가장 낮았으며, ‘정식 운영 단계’인 AI 시스템에 대한 평가가 3.53~3.65점으로 가장 높게 나타났다. 시스템 안정성 검증 테스트를 수행한 비율은 ‘정식 운영 단계(74%)’가 가장 높았으며 ‘도입 검토 단계(30%)’가 가장 낮았다.

19) 2단계의 5개 결정요인 중 이진 변수로 변환한 ‘[2-2] 시스템 안정성 테스트’ 미포함

20) 평균값이 가장 큰 결정요인 [2-5]와 가장 작은 결정요인 [2-1] 간 t-검정 결과 통계적으로 유의한 차이를 확인하였다($\alpha=0.05$).


영향 범위별로 신뢰도 결정요인을 살펴보면 ‘정책 의사결정 지원(3.25~3.63점)’이 ‘내부 업무 지원(3.15~3.37점)’과 ‘시민 대상 서비스(3.21~3.33점)’보다 약간 높은 것으로 나타났다. 시스템 안정성 검증 테스트를 수행한 비율은 ‘시민 대상 서비스(69%)’, ‘정책 의사결정 지원(60%)’, ‘내부 업무 지원(56%)’ 순으로 높게 나타났다.

〈그림 3-14〉 AI 시스템 신뢰도 결정요인 : 2단계 (도입 단계별)



출처: 저자 작성

〈그림 3-15〉 AI 시스템 신뢰도 결정요인 : 2단계 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.34~3.47점)’ 시스템이 ‘의사결정 지원(3.15~3.37점)’ 시스템보다 결정요인 평균값이 대체로 높게 나타났으며, ‘고위험(3.24~3.48점)’ 시스템이 ‘저위험(3.18~3.36점)’ 시스템보다 결정요인 평균값이 대체로 높은 것으로 나타났다. 또한 정보시스템 업무 담당자(3.30~3.54점)가 정보시스템 이외 업무 담당자(3.09~3.19점)보다 결정요인 평균값이 높게 나타난 반면, 기관 유형 간 일관된 차이는 확인되지 않았다. 시스템 안정성 검증 테스트를 수행한 비율은 ‘의사결정 자동화(66%)’ 시스템, ‘고위험(71%)’ 시스템, 그리고 정보시스템 업무 담당자(72%)가 높은 것으로 나타났다.

〈표 3-8〉 AI 시스템 신뢰도 결정요인 : 2단계

		[2-1]	[2-2]	[2-3]	[2-4]	[2-5]
전체		3.20	60%	3.32	3.22	3.36
기관 유형	중앙정부 및 산하 기관	3.26	51%	3.44	3.27	3.43
	지방정부 및 산하 기관	3.16	71%	3.29	3.32	3.42
	공공기관	3.19	59%	3.30	3.18	3.32
도입 단계	도입 검토 단계	2.70	30%	2.92	2.84	2.94
	개발 단계	3.40	66%	3.31	3.21	3.45
	시범 운영 단계	3.15	66%	3.37	3.20	3.37
	정식 운영 단계	3.53	74%	3.61	3.57	3.65
영향 범위	내부 업무 지원	3.18	56%	3.27	3.15	3.37
	시민 대상 서비스	3.21	69%	3.33	3.31	3.33
	정책 의사결정 지원	3.25	60%	3.63	3.43	3.42
의사결정 자율성	의사결정 자동화	3.39	66%	3.47	3.41	3.34
	의사결정 지원	3.15	58%	3.29	3.18	3.37
위험도	고위험	3.24	71%	3.48	3.32	3.36
	저위험	3.18	55%	3.26	3.19	3.36
정보시스템 업무 여부	정보시스템 업무	3.30	72%	3.45	3.33	3.54
	기타 업무	3.09	47%	3.19	3.12	3.19
표본 수		198	198	198	198	198

출처: 저자 작성

주: 결정요인 별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

2.4 3단계: 배포

AI 시스템 생애주기 단계 중 3단계(배포)에 대한 신뢰도 결정요인으로 ‘기술적 견고성’, ‘인간 행위 주체성 및 감독’ 등 3가지 요인을 선정하고 이를 측정하기 위한 7개 지표를 조사하였다. 리커트 5점 척도를 이용하여 7개 지표에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하고, 신뢰도 결정요인 별로 지표들의 산술평균을 구하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 생애주기 3단계에 적용되는 신뢰도 결정요인을 비교·분석하였다.

〈표 3-9〉 AI 시스템 신뢰도 결정요인 및 지표 : 3단계

번호	결정요인	지표
[3-1]	기술적 견고성	• 실제 운영 환경(실제 데이터)에서의 시스템 성능이 검증되었습니까? • 배포 전 충분한 기간의 시범 운영(파일럿 테스트)이 수행되었습니까?
[3-2]	인간 행위 주체성 및 감독	• AI 결정 전 인간의 검토와 승인 절차(AI 추천→인간 검토)가 있습니까? • AI 결정에 대한 인간의 개입 및 재량권(판단 반복 권한)이 명확히 규정되어 있습니까? • 시스템 운영에 대한 인간 감독 체계(주기적 샘플 검토 등)가 구축되어 있습니까?
[3-3]	AI 리터러시, 교육 및 인식 제고	• 시스템 운영 담당자를 대상으로 AI 원리, 한계점, 오류 대응 방법 등 교육이 실시되었습니까? • 시민을 대상으로 AI 시스템에 대한 정보 제공(안내 자료, 설명회 등) 및 인식 제고 활동이 이루어졌습니까? ^a

출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분). 시범 및 정식 운영 단계 시스템만 조사


^a 시스템의 주된 영향 범위가 시민 대상 서비스 및 정책 의사결정 지원인 경우만 조사

AI 시스템 생애주기 3단계에 적용되는 결정요인 3개의 평균값은 3.48~3.55점으로 어느 정도 충분한 수준으로 나타났으며 결정요인 간 차이는 없는 것으로 나타났다.²¹⁾ 전체 응답자 답변을 살펴보면 평균적으로 3개 결정요인 중 [3-1] 기술적 견고성(3.55 점)에 대한 평가가 가장 높게 나타난 반면, [3-3] AI 리터러시, 교육 및 인식 제고(3.48 점)에 대한 평가가 비교적 낮은 것으로 나타났다.

21) 평균값이 가장 큰 결정요인 [3-1]과 가장 작은 결정요인 [3-3] 간 t-검정 결과 통계적으로 유의한 차이를 확인하지 못하였다($\alpha=0.10$).


3단계에 적용되는 신뢰도 결정요인을 도입 단계별로 살펴보면 ‘시범 운영 단계’인 AI 시스템에 대한 평가가 3.32~3.36점으로 비교적 낮은 반면, ‘정식 운영 단계’인 AI 시스템에 대한 평가는 3.61~3.75점으로 높게 나타났다.

〈그림 3-16〉 AI 시스템 신뢰도 결정요인 : 3단계



출처: 저자 작성

〈그림 3-17〉 AI 시스템 신뢰도 결정요인 : 3단계 (도입 단계별)




출처: 저자 작성

주: 시범 운영 및 정식 운영 단계 시스템만 3단계 결정요인 조사 대상에 포함

영향 범위별로 신뢰도 결정요인을 살펴보면 ‘정책 의사결정 지원(3.69~3.85점)’, ‘시민 대상 서비스(3.54~3.54점)’, ‘내부 업무 지원(3.39~3.52점)’ 순으로 높게 나타났다.

〈그림 3-18〉 AI 시스템 신뢰도 결정요인 : 3단계 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.63~3.71점)’ 시스템이 ‘의사결정 지원(3.44~3.51점)’ 시스템보다 결정요인 평균값이 대체로 높게 나타났으며, ‘고위험(3.68~3.81점)’ 시스템이 ‘저위험(3.41~3.46점)’ 시스템보다 결정요인 평균값이 대체로 높은 것으로 나타났다. 또한 정보시스템 업무 담당자(3.53~3.67점)가 정보시스템 이외 업무 담당자(3.37~3.43점)보다 결정요인 평균값이 높게 나타났으며, 중앙정부 및 산하 기관(3.63~3.82점)과 지방정부 및 산하 기관(3.61~3.68점)이 공공기관(3.39~3.43점)보다 높게 나타났다.

〈표 3-10〉 AI 시스템 신뢰도 결정요인 : 3단계

		[3-1]	[3-2]	[3-3]
전체		3.55	3.52	3.48
기관 유형	중앙정부 및 산하 기관	3.82	3.77	3.63
	지방정부 및 산하 기관	3.68	3.61	3.62
	공공기관	3.43	3.42	3.39
도입 단계	도입 검토 단계	-	-	-
	개발 단계	-	-	-
	시범 운영 단계	3.36	3.32	3.36
	정식 운영 단계	3.75	3.73	3.61
영향 범위	내부 업무 지원	3.52	3.43	3.39
	시민 대상 서비스	3.54	3.57	3.57
	정책 의사결정 지원	3.69	3.85	3.69
의사결정 자율성	의사결정 자동화	3.70	3.71	3.63
	의사결정 지원	3.51	3.47	3.44
위험도	고위험	3.80	3.81	3.68
	저위험	3.46	3.42	3.41
정보시스템 업무 여부	정보시스템 업무	3.67	3.67	3.53
	기타 업무	3.42	3.37	3.43
표본 수		116	116	116

출처: 저자 작성

주: 결정요인 별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분). 시범 및 정식 운영 단계 시스템만 조사

2.5 4단계: 운영 및 모니터링

AI 시스템 생애주기 단계 중 4단계(운영 및 모니터링)에 대한 신뢰도 결정요인으로 ‘기술적 견고성’, ‘윤리·평가 및 지속적 개선’ 등 3가지 요인을 선정하고 이를 측정하기 위한 8개 지표를 조사하였다. 리커트 5점 척도를 이용하여 8개 지표에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하고, 신뢰도 결정요인 별로 지표들의 산술평균을 구하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 생애주기 4단계에 적용되는 신뢰도 결정요인을 비교·분석하였다.

〈표 3-11〉 AI 시스템 신뢰도 결정요인 및 지표 : 4단계

번호	결정요인	지표
[4-1]	기술적 견고성	• 시스템이 실제 운영에서 지속적으로 목표한 정확성과 성능을 유지하고 있습니까? • 시스템 오류나 이상 작동 발생 시 신속한 대응 체계(장애 대응 매뉴얼 등)가 마련되어 있습니까?
[4-2]	윤리, 평가 및 지속적 개선	• AI 시스템에 대한 정기적인 모니터링과 감사(성능, 공정성 등)가 수행되고 있습니까? • 시스템의 사회적 영향 및 위험에 대한 평가(알고리즘 영향평가 등)가 주기적으로 실시되고 있습니까? • 평가 결과를 바탕으로 지속적인 품질 개선(PDCA 사이클)이 이루어지고 있습니까?
[4-3]	피드백 및 정책 학습 ^a	• 시민이나 이용자로부터 피드백(만족도, 민원 등)을 수집하는 공식적인 메커니즘이 운영되고 있습니까? • 수집된 피드백이 시스템 개선 및 정책 수립에 실제로 반영되고 있습니까? • 피드백 반영 결과가 이용자에게 공유되고 있습니까?

출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분). 시범 및 정식 운영 단계 시스템만 조사


^a 시스템의 주된 영향 범위가 시민 대상 서비스 및 정책 의사결정 지원인 경우만 조사

AI 시스템 생애주기 4단계에 적용되는 결정요인 3개의 평균값은 3.46~3.53점으로 어느 정도 충분한 수준으로 나타났으며 결정요인 간 차이는 없는 것으로 나타났다.²²⁾ 전체 응답자 답변을 살펴보면 평균적으로 3개 결정요인 중 [4-1] 기술적 견고성(3.51점)과 [4-3] 피드백 및 정책 학습(3.53점)에 대한 평가가 가장 높게 나타난 반면, [4-2] 윤리, 평가 및 지속적 개선(3.46점)에 대한 평가가 비교적 낮은 것으로 나타났다.

4단계에 적용되는 신뢰도 결정요인을 도입 단계별로 살펴보면 ‘시범 운영 단계’인 AI 시스템에 대한 평가가 3.31~3.41점으로 비교적 낮은 반면, ‘정식 운영 단계’인 AI 시스템에 대한 평가는 3.62~3.71점으로 높게 나타났다.


22) 평균값이 가장 큰 결정요인 [4-2]와 가장 작은 결정요인 [4-3] 간 t-검정 결과 통계적으로 유의한 차이를 확인하지 못하였다($\alpha=0.10$).

〈그림 3-19〉 AI 시스템 신뢰도 결정요인 : 4단계



출처: 저자 작성

〈그림 3-20〉 AI 시스템 신뢰도 결정요인 : 4단계 (도입 단계별)




출처: 저자 작성

주: 시범 운영 및 정식 운영 단계 시스템만 4단계 결정요인 조사 대상에 포함

영향 범위별로 신뢰도 결정요인을 살펴보면 ‘정책 의사결정 지원(3.69~3.82점)’, ‘시민 대상 서비스(3.43~3.51점)’, ‘내부 업무 지원(3.38~3.48점)’ 순으로 높게 나타났다.

〈그림 3-21〉 AI 시스템 신뢰도 결정요인 : 4단계 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.62~3.68점)’ 시스템이 ‘의사결정 지원(3.41~3.50점)’ 시스템보다 결정요인 평균값이 대체로 높게 나타났으며, ‘고위험(3.74~3.77점)’ 시스템이 ‘저위험(3.36~3.43점)’ 시스템보다 결정요인 평균값이 대체로 높은 것으로 나타났다. 다만 정보시스템 업무 담당자(3.43~3.59점)와 정보시스템 이외 업무 담당자(3.37~3.70점) 간 결정요인 평균값이 비슷한 수준으로 나타났으며, 중앙정부 및 산하 기관(3.56~4.07점), 지방정부 및 산하 기관(3.43~3.59점), 공공기관(3.39~3.51점) 순으로 높게 나타났다.

〈표 3-12〉 AI 시스템 신뢰도 결정요인 : 4단계

		[4-1]	[4-2]	[4-3] ^a
전체		3.51	3.46	3.53
기관 유형	중앙정부 및 산하 기관	3.58	3.56	4.07
	지방정부 및 산하 기관	3.48	3.59	3.43
	공공기관	3.51	3.39	3.48
도입 단계	도입 검토 단계	-	-	-
	개발 단계	-	-	-
	시범 운영 단계	3.32	3.31	3.41
	정식 운영 단계	3.71	3.62	3.62
영향 범위	내부 업무 지원	3.48	3.38	
	시민 대상 서비스	3.51	3.51	3.43
	정책 의사결정 지원	3.69	3.74	3.82
의사결정 자율성	의사결정 자동화	3.65	3.68	3.62
	의사결정 지원	3.48	3.41	3.50
위험도	고위험	3.75	3.77	3.74
	저위험	3.43	3.36	3.40
정보시스템 업무 여부	정보시스템 업무	3.62	3.55	3.43
	기타 업무	3.40	3.37	3.70
표본 수		116	116	49

출처: 저자 작성

주: 결정요인 별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분). 시범 및 정식 운영 단계 시스템만 조사

^a 시스템의 주된 영향 범위가 시민 대상 서비스 및 정책 의사결정 지원인 경우만 조사

3. AI 시스템 종합평가, 진단 및 개선계획

마지막으로 AI 시스템 종합평가와 관련하여 ‘AI 시스템의 신뢰도’와 ‘AI 시스템 생애주기 단계별 준비 수준’에 대한 6개 평가 문항을 조사하였다. 또한 AI 시스템 진단 및 개선계획을 확인하기 위해 ‘신뢰도 결정요인 중 가장 미흡한 영역’, ‘신뢰성 확보 장애요인’, 그리고 ‘AI 시스템 개선계획’에 대한 의견을 조사하였다.

3.1 AI 시스템 종합평가

AI 시스템 종합평가 항목으로 ‘응답자의 AI 시스템 신뢰도’, ‘시민/이용자의 AI 시스템 신뢰도’, ‘소속 기관의 1~4단계 별 준비 수준’ 등 6가지 항목을 선정하고 이를 측정하기 위한 6개 단일지표를 조사하였다. 리커트 5점 척도를 이용하여 6개 종합평가 항목에 대한 공공부문 AI 시스템 담당자·사용자들의 주관적 의견을 정량화하여 분석에 활용하였다. 이를 통해 각 기관에서 도입 예정이거나 도입·운영 중인 AI 의사결정 시스템의 종합평가 항목들을 비교·분석하였다.

〈표 3-13〉 AI 시스템 종합평가 항목 및 지표


번호	항목	지표
[T1]	AI 시스템 신뢰도 (응답자)	• 귀 기관의 AI 시스템이 전반적으로 신뢰할 수 있는 수준이라고 생각하십니까?
[T2]	AI 시스템 신뢰도 (시민/이용자)	• 시민/이용자가 귀 기관의 AI 시스템을 신뢰한다고 생각하십니까?
[R1]	1단계 준비 수준	• 각 단계별로 귀 기관의 준비 수준을 평가해 주세요: 1단계 설계, 데이터 및 모델링
[R2]	2단계 준비 수준	• 각 단계별로 귀 기관의 준비 수준을 평가해 주세요: 2단계 검증 및 확인
[R3]	3단계 준비 수준	• 각 단계별로 귀 기관의 준비 수준을 평가해 주세요: 3단계 배포
[R4]	4단계 준비 수준	• 각 단계별로 귀 기관의 준비 수준을 평가해 주세요: 4단계 운영 및 모니터링

출처: 저자 작성

주: 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)

AI 시스템 종합평가 항목들의 평균값은 3.26~3.49점으로 약간 충분하거나 약간 신뢰하는 수준으로 나타났으며 항목 간 평균값 차이가 비교적 큰 것으로 나타났다.²³⁾ 전체 응답자 답변을 살펴보면 [T1] AI 시스템 신뢰도(응답자, 3.49점), [R1] 1단계(설계, 데이터 및 모델링) 준비 수준(3.37점), [T2] AI 시스템 신뢰도 (시민/이용자, 3.36점) 순으로 신뢰도가 높게 나타났으며, [R3] 3단계(배포) 준비 수준(3.26점)과 [R4] 4단계(운영 및 모니터링) 준비 수준(3.27점)에 대한 신뢰도는 비교적 낮게 나타났다. 즉, AI 시스템 전반에 대한 신뢰도나 초기 단계 준비 수준에 비해 배포, 운영 및 모니터링 단계의 준비 수준이 낮다고 평가하고 있음을 확인하였다.

〈그림 3-22〉 AI 시스템 종합평가




출처: 저자 작성

AI 시스템 종합평가 항목들을 도입 단계별로 살펴보면 ‘도입 검토 단계’인 AI 시스템에 대한 평가가 2.72~3.09점으로 가장 낮았으며, ‘정식 운영 단계’인 AI 시스템에 대한 평가가 3.56~3.79점으로 가장 높게 나타났다.

23) 평균값이 가장 큰 [T1]과 가장 작은 [R3] 간 t-검정 결과 통계적으로 유의한 차이를 확인하였다($\alpha=0.01$).


〈그림 3-23〉 AI 시스템 종합평가 (도입 단계별)



출처: 저자 작성

영향 범위별로 AI 시스템 종합평가 항목들을 살펴보면 ‘시민 대상 서비스(3.30~3.65 점)’가 가장 높게 나타났으며 ‘내부 업무 지원(3.19~3.45점)’과 ‘정책 의사결정 지원(3.15~3.50점)’은 비슷한 수준으로 나타났다.

〈그림 3-24〉 AI 시스템 종합평가 (영향 범위별)



출처: 저자 작성

이 외에도 AI 기반 의사결정 자율성이 높은 ‘의사결정 자동화(3.34~3.69점)’ 시스템이 ‘의사결정 지원(3.21~3.45점)’ 시스템보다 종합평가 항목들의 평균값이 대체로 높게 나타났으며, ‘고위험(3.23~3.70점)’ 시스템이 ‘저위험(3.25~3.42점)’ 시스템보다 종합평가 평균값이 높거나 비슷한 수준인 것으로 나타났다. 정보시스템 업무 담당자(3.30~3.56점) 또한 정보시스템 이외 업무 담당자(3.17~3.43점)보다 평가 항목의 평균값이 높게 나타난 반면, 기관 유형 간 일관된 차이는 확인되지 않았다.

〈표 3-14〉 AI 시스템 종합평가

		[T1]	[T2]	[R1]	[R2]	[R3]	[R4]
전체		3.49	3.36	3.37	3.32	3.26	3.27
기관 유형	중앙정부 및 산하 기관	3.51	3.27	3.57	3.38	3.22	3.32
	지방정부 및 산하 기관	3.50	3.47	3.39	3.24	3.24	3.32
	공공기관	3.49	3.36	3.31	3.33	3.28	3.24
도입 단계	도입 검토 단계	3.09	3.02	2.96	2.74	2.72	2.74
	개발 단계	3.66	3.40	3.34	3.29	3.14	3.31
	시범 운영 단계	3.44	3.42	3.44	3.46	3.31	3.29
	정식 운영 단계	3.79	3.56	3.67	3.67	3.74	3.67
영향 범위	내부 업무 지원	3.45	3.31	3.40	3.26	3.19	3.23
	시민 대상 서비스	3.65	3.44	3.30	3.52	3.35	3.35
	정책 의사결정 지원	3.35	3.45	3.40	3.15	3.50	3.30
의사결정 자율성	의사결정 자동화	3.69	3.43	3.34	3.40	3.37	3.54
	의사결정 지원	3.45	3.35	3.38	3.30	3.24	3.21
위험도	고위험	3.70	3.50	3.46	3.32	3.23	3.34
	저위험	3.42	3.31	3.34	3.32	3.27	3.25
정보시스템 업무 여부	정보시스템 업무	3.56	3.44	3.43	3.40	3.30	3.37
	기타 업무	3.43	3.28	3.31	3.23	3.22	3.17
표본 수		198	198	198	198	198	198

출처: 저자 작성

주: 종합평가 항목별 지표들의 산술평균. 지표는 5점 척도 기준으로 측정(1점 = 매우 미흡, ..., 5점 = 매우 충분)


3.2 AI 시스템 진단 및 개선계획

AI 시스템 진단 및 개선계획으로 ‘AI 시스템 신뢰도 결정요인 중 가장 미흡한 영역’, ‘AI 시스템 신뢰성 확보 장애요인’ 및 ‘AI 시스템 개선계획’에 대한 문항을 조사하였다.

1) AI 시스템 신뢰도 결정요인 중 가장 미흡한 영역

첫 번째, 공공부문 AI 시스템 담당자 및 사용자 198명이 18개의 신뢰도 결정요인 중 가장 미흡하다고 생각하는 3개 요인을 조사한 결과, 기술적 견고성(50명), 데이터 프라이버시, 보호 및 보안(43명), 데이터 관리(41명), 책임성(40명), 피드백 및 정책 학습(40명) 순으로 가장 많이 지목되었다.

〈그림 3-25〉 AI 시스템 신뢰도 결정요인 중 가장 미흡한 영역



출처: 저자 작성


주: 응답자별로 3개 영역 선택

반면에 설명 가능성(20명), 투명성(23명), 선택 및 자율성(23명), 다양성, 참여 및 포괄성(25명), 그리고 정치적 정당성 및 민주주의(25명)는 가장 적은 응답자로부터 미흡한 영역이라고 지목되었으며, 미흡한 영역이 없다고 응답한 사람도 7명이나 확인되었다. 이는 응답자들이 대체로 이론적이거나 포괄적인 개념보다는 즉각적인 AI 시스템 적용 및 활용과 관련되고 직접적으로 체감되는 영역을 보완할 필요성을 느끼고 있음을 확인하였다.

2) AI 시스템 신뢰성 확보 장애요인

두 번째, 공공부문 AI 시스템 담당자 및 사용자가 소속된 기관의 AI 시스템 신뢰성 확보에 있어 주요한 장애요인은 무엇인지 조사하기 위해서 11가지 장애요인 중에서 복수 선택하도록 물어본 결과, 전문 인력 부족(84명), 예산 부족(83명), 데이터 부족 또는 품질 문제(74명), 관련 법규 및 가이드라인 부재/모호(70명), 조직 문화 및 AI에 대한 인식 부족(68명), 기술적 한계(66명), 기술 역량 및 전문 지식 부족(59명), 부서 간 협력 부족(44명), 이해관계자 간 의견 차이(43명), 시간 부족(34명), 최고 경영진의 관심 및 지원 부족(39명) 등이 가장 큰 장애요인으로 지목되었다.

〈그림 3-26〉 AI 시스템 신뢰성 확보 장애요인



출처: 저자 작성


주: 응답자별로 복수 선택 가능

반면에 시간 부족(34명), 최고 경영진의 관심 및 지원 부족(39명), 이해관계자 간 의견 차이(43명), 그리고 부서 간 협력 부족(44명)이 장애요인이라고 응답한 사람은 비교적 적은 것으로 확인되었다.

3) AI 시스템 개선계획

세 번째, 공공부문 AI 시스템 담당자 및 사용자가 소속된 기관에서 향후 6개월 내에 우선적으로 개선할 계획이 있는 영역을 조사한 결과, 담당자 AI 교육 강화(71명), 보안 및 프라이버시 강화(59명), 데이터 품질 관리 강화(56명), 위험 평가 및 모니터링 체계 구축(54명) 순으로 많은 것으로 나타났다(14개 보기 중 복수 선택 가능). 즉, 공공부문 AI 시스템 도입 및 운영 시 근본적이고 직접적인 AI 시스템의 적용 및 활용과 관련되고 개선 효과가 즉각적으로 체감되는 계획을 우선적으로 수립하고 있음을 확인하였다.

〈그림 3-27〉 AI 시스템 개선계획



출처: 저자 작성

주: 응답자별로 복수 선택 가능

제3절 순서형 로짓 회귀분석

앞서 설문조사 결과의 기술통계 분석을 통해 공공부문 AI 시스템의 신뢰도 및 결정 요인에 대한 평가 결과를 확인하였다. 이를 바탕으로 본 절에서는 순서형 로짓 회귀분석 모형(ordinal logistic regression model)을 이용하여 AI 시스템의 신뢰성 평가와 AI 시스템의 신뢰도 결정요인 간 관계를 살펴보았다. 순서형 로짓 모형에 사용한 종속 변수, 독립변수 및 통제 변수는 다음과 같다.

〈표 3-15〉 순서형 로짓 회귀분석 모형의 주요 변수

구분	변수		
종속변수	• AI 시스템 신뢰도 (응답자)		
독립변수 (신뢰도 결정요인)	공통	• 이해관계자 참여 • 투명성 • 책임성 • 인간 행위 주체성 및 감독	• 윤리, 평가 및 지속적 개선 • 공정성 및 비차별 • 정치적 정당성 및 민주주의 • 이의 제기 가능성 및 구제
	1단계	• 문제 및 목표 명확성 • 가치 상충 및 정렬 • 다양성, 참여 및 포괄성	• 데이터 관리 • 맥락 민감성 •
	2단계	• 기술적 견고성 • 시스템 안정성 검증 테스트 • 설명 가능성	• 공정성 및 비차별 • 데이터 프라이버시, 보호 및 보안
	3단계	• 기술적 견고성 • 인간 행위 주체성 및 감독	• AI 리터러시, 교육 및 인식 제고
	4단계	• 기술적 견고성	• 윤리, 평가 및 지속적 개선
통제 변수	AI 시스템 특성	• 기관 유형 • 도입 단계 • 영향 범위	• 의사결정 자율성 • 위험도 •
	응답자 특성	• 성별 • 연령대 • 관련 경력	• 정보시스템 업무 여부 • 담당 업무 •

출처: 저자 작성

순서형 로짓 모형은 3~4단계에 적용된 신뢰도 결정요인들의 독립변수 추가 여부와 통제 변수의 유무에 따라 4가지 모형으로 구분하여 추정하였다. 4가지 모형의 종속 변수는 AI 시스템 신뢰도(응답자)로 동일하고, AI 시스템 생애주기 전 단계(공통) 및 1~2 단계에 적용된 신뢰도 결정요인들은 4가지 모형에 독립변수로 포함하였다.

〈표 3-16〉 순서형 로짓 회귀분석 모형

모형 번호	종속변수	독립변수 (신뢰도 결정요인)			통제 변수
	AI 시스템 신뢰도	공통	1~2단계	3~4단계	AI 시스템 및 응답자 특성
(1)	○	○	○	X	X
(2)	○	○	○	X	○
(3)	○	○	○	○	X
(4)	○	○	○	○	○

출처: 저자 작성

순서형 로짓 회귀분석 모형을 이용하여 분석한 결과 ‘[S1] 이해관계자 참여’와 ‘[S7] 정치적 정당성 및 민주주의’ 변수가 대체로 유의미한 정(+)의 효과를 보이고 있음을 확인하였다. 표본 및 변수의 한계로 표준오차가 커서 통계적으로 유의미하지 않은 결과도 일부 모형에서 확인되기도 불구하고 계수값(coefficient)은 일관되게 나타난다는 점에서 (다른 모든 조건이 동일하다면) AI 시스템 도입·운영 시 이해관계자 참여와 정치적 정당성 및 민주주의가 개선될수록 AI 의사결정 시스템의 신뢰도 향상에 기여할 것으로 예상된다.

모형(4)의 경우 ‘[2-2] 시스템 안정성 테스트’ 변수가 유의미한 부(-)의 효과를 보이고 있는데 이는 신뢰할 만한 AI 시스템을 도입·운영할 경우 안정성 테스트를 실시하지 않아도 되는 경우를 반영한 결과로 보인다. 이와 더불어 모형(4) 결과에서 ‘[2-4] 공정성 및 비차별’ 변수는 유의미한 정(+)의 효과를 보이는 것으로 보아 AI 시스템의 공정성이 확보될수록 AI 시스템에 대한 신뢰도가 높아질 것으로 기대된다.

〈표 3-17〉 순서형 로짓 회귀분석 결과

		(1)	(2)	(3)	(4)
공통	[S1] 이해관계자 참여	1.719*** (0.412)	1.993*** (0.482)	1.520** (0.705)	1.029 (1.117)
	[S2] 투명성	-0.090 (0.550)	-0.234 (0.645)	0.213 (0.922)	1.669 (1.886)
	[S3] 책임성	0.920 (0.700)	1.897** (0.865)	-0.161 (1.145)	0.456 (2.170)
	[S4] 인간 행위 주체성 및 감독	0.450 (0.456)	0.515 (0.548)	0.490 (0.766)	2.118 (1.570)
	[S5] 윤리, 평가 및 지속적 개선	-0.221 (0.556)	-0.810 (0.682)	-0.201 (0.952)	-2.626 (2.066)
	[S6] 공정성 및 비차별	0.262 (0.538)	0.372 (0.651)	-0.546 (0.870)	-3.675* (1.894)
	[S7] 정치적 정당성 및 민주주의	1.144** (0.561)	1.358** (0.683)	1.089 (0.931)	5.299** (2.450)
	[S8] 이의 제기 가능성 및 구제	0.097 (0.502)	-0.351 (0.604)	1.310 (0.905)	1.081 (1.609)
1단계	[1-1] 문제 및 목표 명확성	-0.042 (0.396)	-0.196 (0.387)	0.039 (0.562)	0.855 (1.169)
	[1-2] 가치 상충 및 정렬	0.010 (0.485)	0.132 (0.561)	0.743 (0.910)	0.485 (1.741)
	[1-3] 다양성, 참여 및 포괄성	0.234 (0.438)	-0.310 (0.531)	1.628** (0.804)	1.616 (1.546)
	[1-4] 데이터 관리	-0.564 (0.519)	-0.603 (0.623)	-0.450 (0.978)	-0.077 (1.729)
	[1-5] 맥락 민감성	0.825 (0.517)	1.515** (0.660)	-1.526 (1.127)	-1.130 (1.889)

		(1)	(2)	(3)	(4)
2단계	[2-1] 기술적 견고성	0.542 (0.511)	0.704 (0.610)	0.414 (0.907)	-1.487 (1.699)
	[2-2] 시스템 안정성 테스트	-0.147 (0.410)	-0.347 (0.505)	-0.495 (0.634)	-2.447* (1.397)
	[2-3] 설명 가능성	-0.436 (0.560)	-0.781 (0.702)	-0.374 (0.959)	-0.781 (1.995)
	[2-4] 공정성 및 비차별	0.248 (0.513)	0.390 (0.645)	0.984 (0.878)	5.078** (2.481)
	[2-5] 데이터 프라이버시, 보호 및 보안	-0.752* (0.451)	-0.557 (0.528)	-0.146 (0.820)	1.898 (1.846)
3단계	[3-1] 기술적 견고성			0.932 (0.813)	1.985 (1.460)
	[3-2] 인간 행위 주체성 및 감독			-0.631 (0.715)	-0.223 (1.315)
	[3-3] AI 리터러시, 교육 및 인식 제고			0.563 (0.817)	1.512 (1.522)
4단계	[4-1] 기술적 견고성			1.526* (0.896)	1.810 (1.926)
	[4-2] 윤리, 평가 및 지속적 개선			-1.640 (1.058)	-2.622 (1.751)
통제 변수 : AI 시스템 특성 ^a		-	○	-	○
통제 변수 : 응답자 특성 ^b		-	○	-	○
표본 수		198	198	116	116

출처: 저자 작성

주: 표준오차는 괄호 안에 표기. *** p<0.01, ** p<0.05, * p<0.1

^a AI 시스템 특성(기관 유형, 도입 단계, 영향 범위, 의사결정 자율성, 위험도)

^b 응답자 특성(성별, 연령대, 관련 경력, 정보시스템 업무 여부, 담당 업무)

제4절 소결


3장에서는 공공부문 기관과 단체에서 도입 예정 또는 운영 중인 AI 기반 의사결정 시스템의 신뢰성을 진단하고 이용자 신뢰 확보 방안을 알아보기 위해 공공부문 AI 시스템 담당자 및 사용자 198명을 대상으로 실시한 설문조사 결과를 살펴보았다.

AI 시스템 생애주기를 1단계 설계·데이터 및 모델링, 2단계 검증 및 확인, 3단계 배포, 그리고 4단계 운영 및 모니터링으로 구분하여 각 단계별로 관련된 결정요인을 선별하여 조사하였는데, 응답자들은 소속 기관의 AI 시스템 신뢰도 결정요인이 모두 약간 충분한 수준(5점 척도 기준 3점 초·중반대)인 것으로 평가하였다. 특히 AI 시스템의 모든 생애주기에 공통으로 적용되는 신뢰도 결정요인 8개의 평균값은 3.23~3.40점으로 '[S1] 이해관계자 참여', '[S4] 인간 행위 주체성 및 감독', 그리고 '[S5] 윤리, 평가 및 지속적 개선'에 대한 평가가 가장 높게 나타났다.

각 단계별로 관련된 결정요인들에 대한 평가의 경우, 1~2단계(설계·데이터 및 모델링, 검증 및 확인)의 결정요인들보다는 3~4단계(배포, 운영 및 모니터링)의 결정요인에 대한 평가가 높게 나타났다. 더불어 모든 결정요인 평가 결과는 AI 기반 의사결정 자율성이 높은 의사결정 자동화 시스템, 고위험 시스템, 그리고 정보시스템 업무 담당자가 의사결정 지원 시스템, 저위험 시스템, 그리고 정보시스템 외 업무 담당자보다 높게 나타났는데, 이는 AI 시스템의 특성이 AI 시스템의 신뢰성 평가와 정(+)의 상관관계가 있음을 시사한다.

이는 곧 AI 시스템 도입을 설계하고 준비하는 초기 단계보다는 배포·운영하는 단계의 AI 시스템이 완성도가 높을 가능성이 크며, 의사결정 자율성이 높은 의사결정 자동화 시스템이나 고위험 시스템을 도입·운영하는 경우 더욱 완성도 높은 AI 시스템을 구축할 가능성이 크다는 점을 반영하는 것이다. 이와 마찬가지로 정보시스템 업무 담당자가 정보시스템 이외 업무 담당자보다 평가 점수가 높게 나타나는 결과는 AI 시스템에 대한 이해도가 높을수록 신뢰도가 높아진다는 의미로 해석된다.

〈그림 3-28〉 AI 시스템 신뢰도 결정요인 (공통 및 단계별)



출처: 저자 작성

설문에서 AI 시스템 진단 및 개선계획을 조사한 결과 기술적 견고성, 데이터 프라이버시, 보호 및 보안, 데이터 관리, 책임성, 피드백 및 정책 학습 등 즉각적인 AI 시스템 적용 및 활용과 관련되고 직접적으로 체감되는 영역이 미흡하다는 다수 의견을 확인하였다. 또한 향후 우선적으로 개선할 계획이 있는 영역으로 담당자 AI 교육 강화, 보안 및 프라이버시 강화, 데이터 품질 관리 강화, 위험 평가 및 모니터링 체계 구축 등이 가장 많이 언급되었는데 이는 공공부문 AI 시스템 도입·운영 시 근본적이고 직접적인 AI 시스템의 적용 및 활용과 관련되고 개선 효과가 즉각적으로 체감되는 영역에 대한 개선계획을 우선적으로 수립하고 있음을 보여주었다.

한편 순서형 로짓 회귀분석 모형 분석결과는 ‘[S1] 이해관계자 참여’와 ‘[S7] 정치적 정당성 및 민주주의’ 변수가 AI 시스템의 신뢰도와 대체로 유의미한 정(+)의 효과를 보이고 있음을 보여주었다. 일부 모형 결과에서는 ‘[2-4] 공정성 및 비차별’ 변수도 유의미한 정(+)의 효과를 보이는 것으로 확인되었는데, 이러한 결과는 AI 시스템 생애주기 전 단계에 걸쳐서 이해관계자 참여, 정당성 및 공정성이 확보될수록 AI 시스템에 대한 이용자의 신뢰도도 높아질 것을 의미한다.

제4장 ADM 거버넌스 사례분석

제1절 대한민국 공공부문 ADM 현황

제2절 네덜란드 아동수당 부정수급 탐지 알고리즘

제4장 ADM 거버넌스 사례분석

제1절 대한민국 공공부문 ADM 현황

1. 최근의 AI관련 환경변화

정부는 2026년 1월 22일 예정대로 ‘인공지능 발전과 신뢰기반 조성 등에 관한 기본법(인공지능기본법)’을 시행함으로써 민간은 물론이고 정부의 행정시스템도 거대한 AI 전환기를 맞이하게 되었다. 인공지능기본법 시행은 단순히 AI 신기술을 도입한다는 차원을 넘어, 국가 행정의 근간을 이루는 의사결정 체계에 인공지능을 공식적으로 편입시키고 이에 대한 법적 책임과 신뢰성 확보를 명문화했다는 점에서 역사적 의의를 가진다. 민간에서는 이미 ADM 활용사례가 늘어나고 있지만 이제 공공기관에서도 AI 기반의 자동화된 의사결정이 공식 의사결정 시스템에 편입될 수 있는 제도적 기반이 충분하지는 않지만 의사결정에 활용을 위한 필요조건은 갖추어졌다고 볼 수 있다. 특히 공공기관의 ADM은 국민의 권리와 의무에 직결되는 만큼 기술적 효율성도 중요하지만 윤리적 정당성도 갖추어야 하는 보다 균형된 관점이 요구된다.

그동안 정부의 디지털 전환 정책은 주로 정보의 전산화와 온라인 서비스 확대에 초점을 맞추어 왔으나 이제는 인공지능이 방대한 행정 데이터를 학습하고 이를 바탕으로 정책적 대안을 제시하거나 직접적인 행정처분 의사결정의 근거를 생성하는 수준으로 발전하였다.²⁴⁾ 이러한 변화의 대표적 사례로 행안부와 과기부 공동으로 추진하는 ‘범정부 초거대 AI 공통기반 구축’ 사업을 들 수 있다. 범정부 AI 공통기반 구축 사업은 기존의 단순 업무지원이나 자동화를 위한 정보화 사업과는 범정부 차원의 AI 인프라를 마련함으로써 빠르게 발전하고 있는 초거대 AI를 의사결정 과정에 통합시켜 행정의 효율성, 과학성, 그리고 지능성을 동시에 달성할 수 있는 중요한 계기가 될 국가사업이다.

24) ‘정부 행정망에서도 AI 챗서비스 사용 가능해진다, 대한민국 정책브리핑, 뉴스, 2025.11.24., 과학기술정보통신부

인공지능기본법은 이러한 기술적 도약이 초래할 수 있는 잠재적 위험을 관리하기 위해 ‘고영향 인공지능’ 개념을 도입하고, 인공지능의 공정성, 투명성, 책임성, 안전성, 접근성을 신뢰 기반 조성을 위한 핵심 가치로 규정하고 있다. 특히 공공서비스에 대한 수혜 자격 확인이나 심사 등 국민에게 직접적인 영향을 미칠 수 있는 의사결정 과정에 AI를 활용할 경우 고영향 인공지능으로 규정²⁵⁾하고 이에 대한 엄격한 거버넌스 체계를 구축하도록 강제하고 있다(법 제4장).

2. 인공지능기본법 체계와 공공기관의 법적 책무

2.1 인공지능기본법의 제정 배경과 입법취지

한국의 인공지능기본법은 EU의 강력한 제재중심의 AI Act와 미국, 영국, 일본의 혁신 우선주의보다 유연한 접근법 사이에서 한국의 특수성을 반영한 독자적 모델로 평가할 수 있다.²⁶⁾ 법 제1조는 인공지능의 건전한 발전과 신뢰기반 조성, 국민의 권익과 존엄성 보호, 국민의 삶의 질 향상을 위해 인공지능이 개발·이용되어야 함을 분명히 하고 인공지능 산업의 진흥과 규제의 균형있는 접근을 도모하고 있다. 또한 국가 인공지능 정책의 최고지휘부로 ‘국가인공지능전략위원회’를 대통령 소속으로 설치하고, 이를 지원하기 위한 인공지능정책센터와 인공지능안전연구소를 신설하여 정책개발과 안전성 평가를 전담하게 하였다. 정부와 공공기관은 이러한 AI 기본법에 따른 국가적 거버넌스 체계 내에서 AI 도입 계획을 수립하고 기본법상의 AI의 안전성과 투명성을 보장하기 위한 윤리 및 신뢰성 확보 규정을 준수해야 한다.

25) 법 제2조(정의) 제4호 자목에 따르면 ‘공공서비스 제공에 필요한 자격 확인 및 결정 또는 비용징수 등 국민에게 영향을 미치는 국가, 지방자치단체, ‘공공기관의운영에관한법률’ 제4조에 따른 공공기관 등의 의사결정에 사용하는 인공지능시스템은 고영향 인공지능으로 규정

26) 조선일보 (2025.10.02.) AI 규제… 한국, EU보다 자율적이고 美보다 엄격,
https://www.chosun.com/economy/tech_it/2025/10/02/WVG12WDUXVCOZJVHDKXDHEYVKE/ (검색일:26.01.15)

2.2 고영향 인공지능의 정의와 범위

법 제2조 제4호에서 정의한 ‘고영향 인공지능’이란 ‘사람의 생명, 신체의 안전 및 기본권에 중대한 영향을 미치거나 위험을 초래할 우려가 있는 인공지능시스템으로서 다음 각 목의 어느 하나의 영역에서 활용되는 것’으로 규정하고 있다. 먼저 활용 영역에 대한 판단, 이어서 영향 및 위험 수준에 관한 판단의 두 단계 판단을 통해 고영향 인공지능 여부를 판단하게 된다.

〈그림 4-1〉 고영향 인공지능 활용 영역

구분	사용되는 영역
에너지	가. 「에너지법」 제2조제1호에 따른 에너지의 공급
먹는물	나. 「먹는물관리법」 제3조제1호에 따른 먹는물의 생산 공정
보건의료	다. 「보건의료기본법」 제3조제1호에 따른 보건의료의 제공 및 이용체계의 구축·운영
의료기기	라. 「의료기기법」 제2조제1항에 따른 의료기기 및 「디지털의료제품법」 제2조제2호에 따른 디지털의료기기의 개발 및 이용
원자력	마. 「원자력시설 등의 방호 및 방사능 방재 대책법」 제2조제1항제1호에 따른 핵물질과 같은 항 제2호에 따른 핵물질과 원자력시설의 안전한 관리 및 운영
범죄 수사·체포	바. 범죄 수사나 체포 업무를 위한 생체인식정보(얼굴·지문·홍채 및 손바닥 정맥 등 개인을 식별할 수 있는 신체적·생리적·행동적 특징에 관한 개인정보를 말한다)의 분석·활용
채용, 대출 심사 등	사. 채용, 대출 심사 등 개인의 권리·의무 관계에 중대한 영향을 미치는 판단 또는 평가
교통	아. 「교통안전법」 제2조제1호부터 제3호까지에 따른 교통수단, 교통시설, 교통체계의 주요한 작동 및 운영
공공서비스	자. 공공서비스 제공에 필요한 자격 확인, 결정 또는 비용징수 등 국민에게 영향을 미치는 국가, 지방자치단체, 「공공기관의 운영에 관한 법률」 제4조에 따른 공공기관 등(이하 “국가기관등”이라 한다)의 의사결정
교육	차. 「교육기본법」 제9조제1항에 따른 유아교육·초등교육 및 중등교육에서의 학생 평가

출처: 고영향 인공지능 판단 가이드라인(2026.1), 과학기술정보통신부·한국지능정보사회진흥원, p.20

법 제25조(고영향 인공지능의 확인 절차 등) 제2항에 따르면 먼저 AI 시스템이 위의 10가지 영역에서 활용되는지 여부를 판단하고, 다음으로 사람의 생명, 신체의 안전 및 기본권에 초래할 수 있는 위험의 영향, 중대성, 빈도 및 활용 영역별 특수성을 검토하여 고영향 AI 여부를 판단한다. 고영향 인공지능 판단 가이드라인에 따르면 ‘생명, 신체의 안전 및 기본권에 대한 위험성을 판단함에 있어서는 인공지능시스템의 의도된 목적, 기능, 활용 맥락을 다양한 관점에서 종합적으로 고려해야 한다’고 기술하고 있으나 이러한 위험의 수준을 판단하는 객관적 기준을 제시하기는 어렵기 때문에 ‘위험의 중

대성을 판단하기 위하여 가능한 경우 적절한 위험 측정 방법 및 지표를 이용하는 것이 바람직하지만 이러한 방법이나 지표를 이용할 수 없는 경우에는 인공지능시스템의 목적 및 기능과 활용되는 상황의 맥락(활용에 따른 긍정적·부정적 영향, 위험에 대한 사회적 수용성 등)을 고려하여 판단²⁷⁾한다고 기술하고 있다.

시행령의 고영향 인공지능 확인 절차는 다음과 같다.

〈그림 4-2〉 고영향 인공지능 확인 절차

판단시 고려요소	- 활용영역(법 제2조 제4호) - 사람의 생명, 신체의 안전 및 기본권에 초래할 수 있는 위험의 영향, 중대성, 빈도 및 활용영역별 특수성 - 인공지능사업자의 사전검토결과 - 전문위원회 자문결과 - 기타 과기정통부장관이 고시하는 사항
판단결과 회신절차	- 요청받은 날로부터 30일 이내에 회신 - 30일의 범위에서 한 차례 연장 가능, 이 때 연장사유와 기간을 문서로 통지
회신에 대한 이의절차	- 회신받은 날로부터 10일 이내 문서로 요청 - 과기정통부장관은 전문위원회 자문을 받아 30일 이내 회신

출처: Issue Report, 고영향 AI판단 가이드라인 발표(2025.09), 이상봉 외, 대륙아주

공공부문의 인공지능 활용은 이처럼 인공지능기본법에서 규정하고 10가지 활용 영역에 해당할 가능성이 높고 대부분 공공서비스와 관련된 활용임을 감안한다면 고영향 인공지능으로 판단될 가능성이 크다고 하겠다. 고영향 인공지능으로 판단되면 해당 인공지능사업자는 위험관리 정책과 조직체계를 포함한 위험관리방안, 인공지능이 도출한 최종결과, 결과도출에 활용된 주요 기준, 인공지능 개발활용에 사용된 학습용데이터 등에 대한 설명, 이용자보호 방안, 사람의 관리감독, 안전성·신뢰성 확보를 위한 조치 등에 관한 계획과 방안을 수립·시행해야 한다(법 제34조, 시행령 제27조). 즉 고영향 인공지능을 활용하는 공공기관은 이러한 내용을 충족시킬 수 있는 AI 거버넌스를 구축해야 한다.

27) 고영향 인공지능 판단 가이드라인, p.21

2.3 인공지능사업자로서의 공공기관의 3대 책무

인공지능기본법에서는 공공기관이 AI 서비스를 직접 개발하거나 외부 서비스를 도입하여 운영할 때 ‘인공지능사업자’로서의 책무를 부여한다. 위반 시 최대 3천만원의 과태료가 부과될 수 있다.

- 투명성 확보 의무(법 제31조, 시행령 제23조) : 고영향 AI나 생성형 AI를 활용할 경우, 해당 서비스가 AI기반으로 운용된다는 사실을 이용자에게 사전에 명확히 고지해야 한다.
- 안전성 확보 및 위험관리 의무(법 제32조, 제34조, 시행령 제27조) : 시스템 생애주기 전반에 걸친 위험 식별 및 완화 방안을 수립해야 한다. 고영향 AI 사업자는 위험관리방안 수립, 사람의 관리감독 체계 마련, 안전성 확보조치 이행 결과의 문서화 및 5년간 보관해야 한다.
- 설명 의무(법 제34조) : 인공지능이 도출한 최종 결과, 결과도출에 사용된 주요 기준, 학습용 데이터의 개요 등에 대해 이용자가 요청할 경우 의미있는 설명을 제공할 수 있는 방안을 갖추어야 한다.

〈그림 4-3〉 인공지능기본법의 인적 적용 범위

	인공지능사업자		이용자	영향받는자
	인공지능개발사업자	인공지능이용사업자		
개념	인공지능서비스에 사용되는 인공지능을 개발하여 제공하는 자	¹⁾인공지능개발사업자로부터 인공지능을 제공받거나 ²⁾자신이 개발한 인공지능을 기반으로 인공지능제품 또는 인공지능서비스를 제공하는 사업자	인공지능제품이나 인공지능서비스를 제공 받아 직접 이용하는 자	인공지능제품 또는 인공지능서비스에 의하여 자신의 생명, 신체의 안전 및 기본권에 중대한 영향을 받는 자
특징	인공지능제품과 인공지능서비스에 사용되는 인공지능 모두 포함		인공지능에 대한 제어 권한이 없거나 매우 제한적	
비고	- 자기가 개발한 인공지능을 이용하여 서비스를 제공하는 경우 개발사업자와 이용사업자 중복 지위를 가지며 책무를 모두 부담 - 공공 및 민간 모두 적용 대상			

출처: 고영향 인공지능 판단 가이드라인, p.15

3. 행정안전부·과학기술정보통신부 사례

3.1 범정부 AI 공통기반 서비스

그간 정부는 국내외 민간의 인공지능 서비스는 내부 행정 데이터 유출 위험으로 인해 기관 내부망에서는 사용하지 못하고 인터넷망에서만 사용할 수 있어 정부 업무 전반에 활용하는데 커다란 제약이 있었다. ‘범정부 AI 공통기반 서비스’는 중앙부처와 지방자치단체가 보안이 확보된 정부 내부망 환경에서 민간의 최신 초거대 AI모델과 고성능 인프라를 공동으로 활용할 수 있도록 지원하는 국가 표준 인프라 사업이다. 이 사업은 약 90억원 규모의 예산이 투입되었으며, 삼성SDS 컨소시엄(네이버클라우드 등 포함)이 구축을 담당하였다.

범정부 AI 공통기반은 각 부처가 개별적으로 시스템을 구축하지 않고 공통으로 활용할 수 있도록 데이터·AI모델·인프라·표준을 통합 관리하는 체계라 할 수 있으며, 주요 기술적 구성요소를 살펴보면 다음과 같다.

- 공공데이터 플랫폼: 각 부처의 데이터를 표준화된 형식으로 수집·저장·관리하며, 공개된 행정문서(법령, 지침, 민원상담 내역 등)를 AI 모델과 연계
- AI모델 라이브러리(멀티 LLM): 삼성SDS(Brity Copilot기반)와 네이버클라우드(HyperCLOVA-X)가 제공하는 민간 초거대 AI모델 2종을 내부망 환경에서 지원하며, 2026년 정부가 추진하고 있는 독자 AI파운데이션 모델이 개발되면 ‘범정부 AI 공통기반 서비스’에 연동하여 민간활용과 공공 특화 모델을 동시에 활용하여 공무원 업무를 보조하는 ‘질의응답형 비서’로 활용 가능
- 클라우드 인프라 공유(GPU) : 고성능 컴퓨팅 자원을 중앙 및 지방정부가 공동 활용할 수 있도록 지원하며, 2026년까지 약 26만장 규모의 GPU 확보를 추진 중인 ‘AI 고속도로’ 인프라와 연계
- 표준·가이드 및 통합개발 환경: 공공기관이 신속하게 AI서비스를 개발할 수 있도록 표준 가이드와 도구, 통합개발환경 제공
- 망 보안 체계 : 차세대 국가 망 보안체계(National Network Security Framework: N2SF) 가이드라인 1.0을 적용하여 데이터 등급(기밀/민감/공개)에 따른 차등적 보안 통제 실시

AI 공통기반 서비스를 통해 중앙과 지방정부는 “중복개발·투자없이 내부 행정업무부터 공공서비스까지 다양한 인공지능 기술을 업무 전반에 적용할 수 있게 되어 본격적인 AI 행정시대가 열릴 것”으로 기대된다. 공통기반은 공개된 행정문서·데이터를 인공지능 AI 모델과 연계하여 내부망에서도 활용 가능한 인공지능 챗서비스 2종을 제공하게 된다. 정부는 “2026년 ‘독자 AI 파운데이션 모델 프로젝트’를 통해 선정되는 인공지능 모델도 ‘범정부 AI 공통기반’에서 활용할 수 있도록 추가 도입할 예정”으로 향후 지속적으로 민간의 우수한 AI 모델을 행정업무에 적용하여 효율성과 정확성을 개선해 나갈 계획이다.

3.2 지능형 업무관리 플랫폼

지능형 업무관리 플랫폼은 앞서 설명한 범정부 AI 공통기반 서비스 위에서 실제 공무원이 사용하는 일종의 AI 행정비서 서비스이다. 구축된 엔진을 활용하여 구체적인 행정업무 효율화를 구현하는 상부 서비스 계층에 해당한다. 인공지능을 활용하여 소통·협업 도구(메일, 메신저, 영상회의 등)를 유기적으로 연계하여 단순·반복적인 업무를 생략해 업무에 집중할 수 있는 환경을 제공한다.

행정 AI 비서의 주요 기능과 워크플로우는 다음과 같다.

- 맥락 기반의 지능형 질의응답 : 공통 행정데이터뿐만 아니라 해당 공무원이 담당하는 기관 내부의 비공개 문서와 개인 데이터를 실시간으로 참조(RAG)하여 외부 범용 AI보다 훨씬 정교하고 맥락에 맞는 답변을 생성
- 업무 자동화 시나리오 : 예컨대 1시간 분량의 회의 음성을 5분 만에 요약하여 회의록을 작성하거나, 과거 유사 정책자료를 찾아 보도자료 초안을 작성하고, 주고받은 메일 내용을 분석하여 오늘의 할 일을 제안
- 부처별 특화 서비스 연계 : 행정안전부, 과학기술정보통신부, 식품의약품안전처 3개 기관이 시범 운영 대상이며, 각 기관의 특수 데이터(예: 식약처의 의약품 심사자료)를 결합하여 맞춤형 전문 서비스를 제공

〈그림 4-4〉 범정부 AI 공통기반과 지능형 업무관리 플랫폼 비교

구분	범정부 AI 공통기반	지능형 업무관리 플랫폼
사용처	전체 중앙·지방정부	3개 중앙행정기관 시범 시행 ※ 행안부, 과기정통부, 식약처
활용데이터	법령, 보도자료 등 공통데이터	개인·기관별 문서·데이터(+공통데이터)
UI/UX (사용자경험)	AI 서비스 개발 환경 및 대화창(프롬프트)	문서 편집, 소통, 협업 등 AI 기반의 업무 환경
시범서비스 일정	'25.11월 말 ~ '26.2월 말	'25.11월 말 ~ '26.2월 말 ※ '26년부터 단계적 확대 추진

출처: 민간 최신 AI, 행정망에서 보안 걱정없이 활용해 'AI 행정시대' 활짝 연다(2025.11.24.), 관계부처 합동 보도자료


3.3 데이터 거버넌스와 N2SF 보안 아키텍처의 통합 적용

범정부 AI 공통기반 서비스와 지능형 업무관리 플랫폼은 국가 사이버보안의 새로운 패러다임인 '차세대 국가망 보안체계(N2SF)'를 통해 신뢰성을 확보한다. N2SF는 기존의 획일적인 망 분리 방식을 넘어 국가 망 보안체계 기반의 보안정책으로 패러다임을 전환하여 보다 유연하고 효율적인 보안 환경을 조성하고, AI·클라우드 등 신기술을 융합해 정보유통을 강화함으로써 언제 어디서나 업무를 수행할 수 있는 스마트 업무환경을 실현할 수 있다.

국가 망 보안체계는 국가·공공기관의 업무정보와 정보시스템에 대해서, 업무 중요도에 따라 기밀(Classified), 민감(Sensitive), 공개(Open) 등 3개 등급으로 분류하고, 등급별로 차등적인 보안통제를 적용하여 보안성 확보와 원활한 데이터 공유의 두 가지 목적을 동시에 달성하고자 한다.²⁸⁾

28) 국가망 보안체계 보안가이드라인(Draft)(2025.01). 국가정보원/NSR, p.12

〈그림 4-5〉 기존 망 분리 정책과 국가 망 보안체계 비교



출처: 국가망 보안체계 보안가이드(2025), p.12

보안가이드에 따르면 업무정보의 등급 분류, 즉 기밀정보(C등급), 민감정보(S등급)는 정보공개법, 공공데이터법, 보안업무규정에 따라 각급기관이 지정한 비공개 정보가 해당한다. 가령 기밀정보는 비밀, 안보·국방·외교·수사 등 기밀정보 및 국민생활·생명안전과 직결된 정보로 정보공개법 제9조(비공개 대상 정보)의 제1호부터 제4호까지를 포함한다. 민감정보(S), 공개정보(O) 분류도 위의 그림에 표시된 것처럼 정보공개법, 공공데이터법 등의 규정에 따라 차등 분류된다. 또한 N2SF는 권한, 인증, 분리·격리 등 6개 영역의 280여개 보안통제 항목을 제시한다. 특히 AI모델에 질문을 입력하는 시점에 민감정보 포함여부를 실시간으로 감시하는 CDS(정보통제기술)와 생성된 결과물의 무단 유출을 막는 DRM기술이 내재화되어 있다.

〈그림 4-6〉 업무정보에 대한 S/S/O 분류기준

비공개 대상 정보 정보공개법, 공공데이터법 등에 따라 각급 기관이 지정	기밀 정보 (C)	비밀, 안보·국방·외교·수사 등 기밀정보 및 국민 생활·생명·안전과 직결된 정보	- 제1호 : 법률상 비밀·비공개로 규정 - 제2호 : 안보·국방·통일·외교 관련 공개 시 국익 침해 - 제3호 : 공개 시 국민 생명·신체·재산보호에 현저한 지장 초래 - 제4호 : 진행중 재판 및 범죄예방·수사·공소형 집행교정 관련 정보로 공개 시 현저한 직무수행 곤란 및 피고인 재판권 침해
	민감 정보 (S)	비공개 정보로 개인·국가 이익 침해가 가능한 정보	- 제5호 : 감사·감독·검사·시험·입찰·계약·기술개발·인사관리 및 의사결정내부검토 관련 정보로, 공개 시 공정한 업무수행, 연구개발 등에 현저한 지장 - 제6호 : 성명·주민번호 등 개인정보로, 공개 시 사생활 침해 - 제7호 : 법안·단체·개인의 경영·상업·영업상 비밀로, 공개 시 이익 침해 - 제8호 : 공개 시 부동산·투기, 매점·매석으로 특정인에게 이익·불이익 - 기 타 : 로그 및 임시백업 등
	공개 정보 (O)	기밀·민감정보 이외 모든 정보 및 별도의 조치를 적용한 비공개 정보	- 공공데이터법(제2조)에 따른 공공데이터로 기밀(C)·민감(S) 정보 이외 모든 정보 - 관련 법령 등에서 규정하는 요건을 조차한 행정·민감 정보 - 기간의 경과 등으로 비공개 필요성 소멸 시 공개한 정보

출처: 국가망 보안체계 보안가이드(2025), p.21

3.4 시범운영의 성과 및 시사점

‘범정부 AI 공통기반’ 서비스의 본격적인 운영 및 확산에 앞서 사용자 의견수렴, AI 서비스 기능 검증 및 품질개선을 위한 서비스 시범운영은 2025년 11월 말부터 2026년 2월 말까지 예정되어 있다. 3월부터는 전체 중앙·지방정부가 서비스를 이용할 수 있도록 단계적으로 서비스 대상을 확대할 계획이라고 한다.²⁹⁾ 따라서 아직 시범운영의 성과에 대해 평가하기는 어려우나 부처별 또는 기관별로 AI 시스템을 구축할 필요없이 공통기반을 활용함으로써 AI 도입 비용을 절감하고, 행정 AI 비서를 통해 단순 반복 업무 시간의 감축을 예견할 수 있다.

그러나 관계부처 보도자료에서 언급되고 있지 않는 ADM 거버넌스 측면에서도 점검해야 할 과제가 있다. 먼저 공통기반의 데이터 품질관리가 답변의 신뢰성을 결정짓는다는 점이다. 학습데이터의 오류나 편향은 곧바로 행정 결정의 오류로 이어질 위험이 크다. 다음으로 고영향 AI로 분류될 수 있는 복지 심사나 인허가 업무에 AI 비서를 도입할 경우, AI기본법이 요구하는 의사결정 과정의 투명성, 결과에 대한 설명가능성, ‘인간에 의한 최종 검토(Human-in-the-loop)’ 체계를 어떻게 기술적으로 구현할 것인지에 대한 거버넌스 설계에 대한 검토가 요구된다.

29) Ibid. p.3

4. ADM 거버넌스 신뢰성 확보를 위한 시사점

4.1 다학제적 AI 거버넌스 기구 상설화

ADM의 신뢰성은 기술적 완결성만으로 확보되기 어렵다. 공공기관은 내부적으로 기술, 법률, 윤리 전문가가 참여하는 다학제적 AI 거버넌스 위원회를 상설 운영할 필요가 있다. 이 기구를 통해 AI 시스템 도입 초기단계부터 인공지능영향평가를 실시하고, 해당 시스템이 고영향 AI에 해당하는지, 시스템 이용자의 생명안전에 어떤 위험을 유발하거나 기본권에 부정적 영향을 줄 가능성이 있는지 등을 주기적으로 검토해야 한다. 또한 시스템 오류 발생시 즉각적인 서비스 중단과 복구가 가능한 ‘Kill Switch’ 또는 비상대응 프로토콜을 마련하고 기관의 AI 활용한 업무 특성을 고려한 인공지능 윤리원칙도 검토해야 할 것이다.

4.2 설명가능한 AI 기술 고도화 및 인간개입 보장

인공지능기본법이 요구하는 설명의무를 충족하기 위해서는 AI 의사결정, 결과물에 대한 설명가능성이 상시 제공되어야 한다. AI가 단순히 답변을 제공하는 것에 그치지 않고, 어떤 데이터를 참조했는지, 결정의 근거는 무엇인지를 설명할 수 있어야 한다. 또한 ADM의 수준을 위험도에 따라 구분하고 인간개입의 수준을 차등화해야 한다. 중대한 영향을 미치는 사안에 대해서는 반드시 인간이 최종 결정권을 행사하는 Human-in-the-loop 방식을 적용해야 하며, AI는 단지 비교가능한 대안을 제시하는 조력자(assistant) 역할에 머물러야 한다.

4.3 투명성 강화를 위한 이용자 소통채널 구축

신뢰관계는 일방적 선언이 아니라 상호관계, 소통 과정을 통해 형성된다. AI를 활용한 행정서비스의 목록을 공개하고, 알고리즘 작동 원리를 이용자가 이해하기 쉬운 언어로 설명하는 ‘AI 알 권리’를 보장해야 한다.³⁰⁾

30) 이준일(2024), 인공지능과 기본권, 월간복지동향 2024-02-01, 참여연대

제2절 네덜란드 아동수당 부정수급 탐지 알고리즘 31)

2013년부터 2020년까지 네덜란드 조세청(Belastingdienst)이 운영한 아동수당 사기탐지 알고리즘(Risicoclassificatiemodel)은 이중국적과 외국인 국적을 주요 위험 지표로 사용하여 네덜란드 하원 의회조사위원회 추정 약 26,000여 가구를 부정수급자로 잘못 분류했다(College voor de Rechten van de Mens, 2022; Parliamentary Inquiry Committee Childcare Benefits, 2021; Hummel et al., 2025). 이 시스템은 수만 유로의 전액 환수를 명령하며 가정을 파탄시켰고, 2,000명 이상의 아동이 부모로부터 강제로 분리되었다(Amnesty International, 2021). 2020년 12월 의회조사위원회는 이를 “전례 없는 불의(Ongekende Onrecht/Unprecedented Injustice)”로 규정하며 법치주의의 근본 원칙이 위반되었다고 결론지었고, 2021년 1월 정부 전체가 사임했다. 이는 알고리즘적 위험분류가 제도적 실패를 증폭·가속하여 결국 정부 총사임으로 이어진 사례이자, 기술이 제도적 인종차별을 규모화한 대표적 사례로 기록되었다.

이 절에서는 이 시스템의 도입 배경과 목적, 기술적 메커니즘, 실제 운영 방식을 먼저 살펴본 뒤, 상술한 실무 중심 프레임워크(Practice-focused Framework)를 활용해 체계적으로 평가한다. 이를 통해 시스템이 AI 라이프사이클의 어느 지점에서 어떤 신뢰성 요건을 위반했는지를 단계별로 규명하고, 궁극적으로 이 참사가 기술적 실패가 아닌 제도적·윤리적·정치적 실패의 복합적 산물임을 보여준다.

1. 도입 배경과 시스템의 작동 메커니즘

1.1 도입 배경과 목적: 복지 사기 단속의 정치화

1) 아동수당 제도의 시작과 법적 결함

2004년 네덜란드 의회는 아동보육법(Wet kinderopvang)을 채택하여 아동수당(kinderopvangtoeslag) 제도를 도입했다. 이 제도는 일하거나 공부하는 부모가 보육비용의 최대 96%(저소득층 기준)까지 국가 지원을 받을 수 있도록 설계되었다. 연간

31) 본고를 작성하며 참고한 문헌 중 영문 버전이 제공되지 않는 일부 네덜란드어 원문 문헌의 경우, 원문 내용 파악을 위해 기계번역의 도움을 받았음을 밝힌다.

100만 명 이상의 아동이 평균 5,000유로를 지원받았으며, 제도 운영은 사회고용부가 주관했지만 실제 집행, 지급, 사기 방지는 재무부 산하 조세청이 담당했다(Statistics Netherlands, 2022).

2005년 도입된 소득연동급여에 관한 일반법(AWIR)은 치명적 결함을 내포했다. 법에는 사정변경조항(hardship clause)이 없어 규정 적용이 부당한 경우에도 예외를 인정하거나 구제할 수 없었다. 2009년 조세청 급여부(Toeslagen) 관리층은 의도적으로 가장 엄격한 해석을 선택하여 “전부 아니면 전무(all-or-nothing)” 접근법을 채택했다. 이는 탐지된 부정 수급 사례 중 서명 누락이나 소액 미납 같은 사소한 실수가 원인이 되는 건에 대해서도 수년간 받은 수당 전액(종종 수만 유로)을 즉시 일괄 상환하도록 강제하는 근거가 되었다. 행정기관이 상황에 따라 유연하게 판단할 수 있는 재량권이나 사정변경조항이 결여되어 있었기 때문이다. 네덜란드 최고행정법원인 국사원(Raad van State)은 2019년 10월까지 이러한 가혹한 접근을 수백 건의 판결을 통해 반복적으로 지지했다(Parliamentary Inquiry Committee Childcare Benefits, 2021).

2) 정치적 전환점: 불가리아 사기 사건

2013년 4월, RTL Nieuws는 불가리아 범죄 조직이 2007~2013년 사이 네덜란드 주소에 단기 등록 후 의료보험 및 주택수당을 소급 신청해 약 400만 유로를 부정수급한 사실을 폭로했다. 805명 이상의 불가리아인이 연루된 이 사건은 엄청난 정치적 파장을 일으켰다. 재무부 국무장관 Frans Weekers(VVD)는 조세청과 재정정보조사국(FIOD)이 1년 전부터 알고 있었던 사실을 전혀 인지하지 못했음이 조사를 통해 드러났다. CDA 의원 Pieter Omtzigt가 제출한 불신임안은 연립정당의 지지로 부결되었지만, 의회는 극단적으로 강경한 사기 단속을 요구했다(Berends, 2021에서 재인용).

이 사건은 이미 형성되어 있던 외국인 혐오적 정치 담론을 증폭시켰다. 극우 자유당(PVV) 대표 Geert Wilders는 2008년 “누가 청구서를 지불하는가? 열심히 일하고 제대로 세금을 내는 네덜란드 국민이다. 평범한 네덜란드인 Henk와 Ingrid는 공짜를 받지 못한다. 그들이 Mohammed와 Fatima의 비용을 대고 있다.”라고 발언하며 소수민족과 복지 사기의 연결고리를 정치적으로 정당화했다(Jacobin, 2021). 첫 번째 Rutte 내각의 연정 협약은 사기 단속 강화 조항을 포함했고, 2013년 6월 Mark Rutte 총리는 각료급 위원회에 사기 척결을 지시했다.

3) 제도화된 단속 체계의 구축

2013년 5월 조세청과 재무부 고위 공무원들로 구성된 사기관리팀(Management Team Fraude)이 설립되었다. 2013년 후반에는 협력 촉진자 단속팀(CAF, Combiteam Aanpak Facilitators)이 창설되어 사기 신청을 돕는다고 의심받는 보육 대행사, 센터와 중개 기관을 적극적으로 수색했다. CAF는 의심사례 중 “80%는 사기, 20%는 무죄”라는 근거 없는 가정 하에 조직적 사기가 의심되는 600여 개 기관을 조사하여 약 2,200 가구를 대상으로 수당지급 중지 및 환수 조치를 시행하였다(Amnesty International, 2021).

2013년 이 시점에서 핵심 기술인 위험분류모델(Risk Classification Model)이 도입되었다. 공식 목표는 사기 방지, 효율성 향상, 비용 통제, 정치적 압력 대응이었다. 그러나 실제 동기는 외국인 혐오적 포퓰리즘, 신자유주의적 거버넌스, 식민주의 시대로부터 이어진 인종차별적 가정—Gloria Wekker가 말한 식민지 문화적 아카이브—이었다(Arts & van den Berg, 2025). 조세청은 알고리즘 비용을 정당화하기 위해 충분한 자금을 압류해야 하는 왜곡된 재정 인센티브를 갖고 있었다.

2. 시스템의 기술적 메커니즘: 블랙박스 차별 알고리즘

2.1 자가학습 위험 점수 시스템

핵심 알고리즘은 위험분류모델(Risicoclassificatiemodel/Risk Classification Model)이었으며, 보조시스템으로 FSV(Fraude Signalering Voorziening, 사기신호설비)가 있었다. 2013년부터 2020년까지 운영된 알고리즘의 핵심 작동 방식은 다음과 같다.

첫째, 자가학습 메커니즘이다. 시스템은 역사적으로 정확한 신청과 부정확한 신청 사례를 비교하여 패턴을 학습했다. 시간이 지나면서 명시적인 인간 프로그래밍 없이도 독자적으로 적응했다.

둘째, 위험 점수 산정이다. 각 신청서는 여러 위험 요소에 대해 테스트되었다. 위험 요소 기준을 충족하면 해당 요소의 가중치에 위험 점수가 가산되었다. 점수는 누적되어 총 위험 점수를 형성했으며, 높은 점수는 높은 사기 위험을 나타냈다.

셋째, 자동화된 의사결정 경로가 구축되었다. 저위험 신청은 인간 검토 없이 자동 승인되었고, 고위험 신청은 공무원의 수동 조사 대상으로 선정되며 수당 지급이 즉시 중단되었다. 공무원은 신청자에게 추가 증거를 요구했지만, 무엇이 잘못되었는지 설명을 거부했다.

2.2 차별적 위험 지표

네덜란드 데이터보호청(Dutch Data Protection Authority) 조사와 의회 보고서는 다음과 같은 위험 지표를 확인했다(Autoriteit Persoonsgegevens, 2020; Parliamentary Inquiry Committee Childcare Benefits, 2021). 식별된 주요 차별 지표는 다음과 같다:

- 네덜란드 국적 여부: 비네덜란드 국적자는 자동으로 더 높은 위험 점수를 받았다.
- 이중국적: 명시적으로 고위험 플래그로 사용되었다.
- 특정국적: 터키계와 모로코계가 표적이 되었으며, 120~150명의 가나인에 대한 의심이 발생하자 당국은 가나 국적을 가진 전체 6,047명의 신청자를 조회하고 조사했다.

추가 위험 요소로는 저소득 수준(저소득 가정은 높은 수당을 받아 환수액이 많았음), 행정 오류(아동보육 서비스 계약서의 서명 누락, 의무적 개인 분담금의 지연 또는 불완전 지급, 사소한 서류 실수), 외국인처럼 들리는 이름, 출신배경, 여러 자녀를 둔 경우, 문제 지역 거주, 가족 관계와 생활 조건(조직적 사기 탐지를 위해 동질적 인구 식별에 사용)이 포함되었다. 네덜란드 인권연구소는 외국 출신자가 카테고리과 연도에 따라 여타 인구집단보다 적게는 1.19배에서 많게는 16배 가량 조사 대상이 될 가능성이 높았다고 밝혔다(College voor de Rechten van de Mens, 2022).

2.3 자동 라벨링과 가혹한 처벌

시스템은 연간 수당이 €10,000 이상인 경우, 또는 환수해야 할 금액이 €3,000 이상인 경우에 해당하는 사람들에게 자동으로 고의 또는 중과실 라벨을 부여했다. 이 자동 분류에는 실제 고의성 여부를 검증하는 어떤 절차도 수반하지 않았다. 2016년 내부 메모는 €3,000 이상의 부채가 있는 모든 사람에게 이 라벨을 자동으로 부여하도록

권장했다. 뿐만 아니라, 조세청은 근거 없이 80/20 파레토 원칙을 적용하여 조사된 부모의 80%가 유죄이고 20%가 무죄라고 가정했다. 실제로는 2,200가구 피해자 중 단 15건의 유죄 판결과 8건의 합의만이 있었을 뿐이었다(Hadwick, 2024).

2.4 시스템 아키텍처와 블랙박스 특성

FSV는 2012년부터 2020년까지 8년간 수당 신청의 이상 징후를 플래그(flag)하기 위해 사용되었다. 이 시스템은 잠재적 사기 신호를 등록하고 플래그가 지정된 개인들의 데이터를 추적했으며, 이를 다른 정부 기관과 공유하는 중앙 허브 역할을 수행했다. GDPR 위반으로 2020년 2월 27일 폐쇄되었으며, 당시 데이터베이스에는 60,000명의 개인정보가 포함되어 있었다.

이 시스템을 구동한 위험분류모델(RKM)은 고도의 알고리즘 아키텍처를 특징으로 했다. 알고리즘은 명시적인 인간의 프로그래밍 없이도 과거의 경험과 데이터를 통해 독립적으로 학습하고 작동 방식을 스스로 변경하는 자기학습 및 자율적 적응 능력을 갖추었다. 이 시스템은 ‘정확’하거나 ‘부정확’하다고 이미 분류된 과거 신청서들을 분석하며 과거 데이터로 훈련되었고, 추적된 패턴을 사용하여 미래의 사기 가능성을 예측하는 예측 분석을 수행했다. 이 과정에서 시스템은 자동으로 데이터베이스를 조회하여 국적 데이터를 위험 요소로 검색하는 자동 쿼리 체계를 갖추고 있었다.

차별적 피드백 루프는 시스템 실패를 가속화했다. 시스템 초기에 설정된 ‘이중 국적’이나 ‘이민 배경’에 대한 편향은 소수민족에 대한 조사 빈도를 높였고, 이렇게 집중된 조사는 다시 편향된 훈련 데이터를 생성했다. 결과적으로 알고리즘은 소수민족을 사기 위험군으로 고착화하여 학습하게 되었으며, 이는 다시 해당 집단에 대한 조사를 더욱 증가시키는 악순환을 만들었다. 국제 앰네스티는 이를 두고 알고리즘이 기존의 제도적 인종차별을 기계적으로 학습하고 증폭시킨 결과라고 평가했다(Amnesty International, 2021).

시스템 내부의 의사결정 과정은 다층적인 불투명성에 가려져 있었다. 기술적 차원에서는 입력값과 복잡한 계산 과정이 사용자에게 보이지 않았고, 사례를 검토하는 공무원들은 위험 점수만 받고 그 산정 근거를 알 수 없었다. 자기학습의 특성상 설계자와 개발자조차 특정 결정이 왜 내려졌는지 완전히 이해하지 못하는 블랙박스 현상이 발생했

다. 정보 비대칭 또한 심각했는데, 조세청 내부에서도 실무 공무원은 점수만 전달받을 뿐이었고, 신청자인 시민들은 알고리즘의 존재 자체를 인지하지 못했다. 감사 추적이 없어 특정 결정의 이유를 사후에 재구성하는 것은 불가능에 가까웠다.

GDPR의 역설은 문제를 더욱 복잡하게 만들었다. GDPR이 규정하는 ‘자동화된 의사결정에 대해 의미 있는 정보를 제공받을 권리’는 완전히 자동화된 결정에만 적용되었다. 따라서 시스템에 의해 ‘저위험’으로 분류되어 자동으로 수당이 승인된 사람들은 피해가 없음에도 설명받을 권리가 있었으나, 정작 ‘고위험’으로 분류되어 공무원의 형식적인 검토를 거쳐 수당이 중단된 사람들은 ‘인간의 개입’이 있었다는 이유로 설명받을 권리에서 제외되었다. 제도의 맹점이 가장 큰 차별을 받은 사람들을 구제 절차 밖으로 밀어낸 것이다.

3. 실제 운영 방식과 피해 규모

3.1 책임 기관과 집단 처벌 메커니즘

주요 책임 기관은 재무부 소속의 조세청/급여부(Belastingdienst/Toeslagen)로, 수당의 실행, 지급, 사기 방지를 총괄했다. 이 기관의 운영 방식을 극명하게 보여주는 사례가 2011년부터 2014년 사이 진행된 CAF 11 하와이 사건이다. 조세청은 아인트호번의 탁아기관 Dadim을 조사했으나, 2012년 판결에서 사기가 발견되지 않았고 2013년 11월 16개 보육사에 대한 현장 방문에서도 어떠한 증거도 발견되지 않았다. 그럼에도 불구하고 2014년 4월, 조세청은 317명의 고객을 사기꾼으로 라벨링했는데, 이들은 거의 모두 이중국적 보유자였다(Nationale ombudsman, 2017).

시스템의 작동 방식은 집단 처벌의 특성을 띠었다. 국적, 가족 관계, 생활 조건 등을 사용하여 조직적 사기 혐의로 조사할 동질적 인구집단을 식별했고, 식별된 대상에게는 즉각적이며 중대한 재정적 조치가 부과되었다. 사기꾼으로 라벨링된 부모나 보육사는 받은 모든 아동수당을 전액 상환하도록 강제되었으며, 그 금액은 종종 수만 유로에 달했다. 즉시 일괄 상환을 요구받았고 분할 납부는 불가능했다. €27의 사소한 오류가 €27,242에 달하는 전체 수당 상환 요구로 이어질 수 있었다.

3.2 피해의 규모와 특성

피해 규모는 재앙적이었다. 약 26,000~35,000 가정이 2005~2019년 사이 잘못 고소되었으며, 70,000명 이상의 아동이 영향을 받았다. 특히 CAF를 통해 집중적으로 표적이 된 가정은 약 2,200가구에 달했다(Parliamentary Inquiry Committee Childcare Benefits, 2021).

재정적 영향은 심각했다. 가구당 평균 부채는 €27,500~€30,000에 이르렀으며, 수천 가정이 심각한 부채와 빈곤에 빠졌다. 채무를 진 가정들은 주택 매각을 강요받았고, 파산과 실업이 발생했다. 가족 구조 자체가 파괴되었다. 이혼과 가정 붕괴가 속출했고, 다수의 아동이 국가 보호나 위탁 보호로 이관되었다. 파산, 장기 빈곤, 법적 구제 실패가 수년간 지속됨에 따라 많은 가정이 회복 불가능한 파탄에 이르렀다.

인간적 피해 또한 측정하기 어려울 정도로 컸다. 피해자들은 정신 건강 문제와 스트레스 관련 질병에 시달렸으며, 여러 차례의 자살 시도가 발생했다. 심각한 심리적 트라우마와 함께 사기꾼으로 낙인찍히는 사회적 수치심도 감내해야 했다.

피해는 특정 집단에 불균형적으로 집중되었다. 인정된 피해자의 약 50%가 해외에서 태어났으며, 70%가 이민 배경을 보유했고, 50%가 한부모 가구의 어머니였다. 특히 카리브해/수리남 계열, 터키계, 가나 국적자가 차별적 영향을 받았다.

4. 프레임워크 기반 신뢰성 진단

이 절에서는 앞서 규명한 시스템의 도입 배경과 작동 메커니즘에 대한 논의를 토대로, 시스템 실패와 그 원인을 체계적으로 진단한다. 논의에는 2장에서 다룬 프레임워크를 활용한다. 프레임워크에 따라 OECD AI 시스템 라이프사이클(OECD, 2019a)의 4단계에 Agbabiaka et al.(2025)의 연구에 근거한 18가지 신뢰성 총괄 요건을 매핑하여, 각 단계에서 시스템이 어떤 요건을 위반했는지를 규명한다.

4.1 설계, 데이터 및 모델링 단계의 신뢰성 실패

설계 단계는 AI 시스템의 방향을 결정하는 가장 중요한 시점이다. 이 단계에서의 결

함은 이후 모든 단계로 전파되어 회복 불가능한 피해를 초래한다. 네덜란드 시스템은 설계 초기부터 근본적인 신뢰성 조건들을 위반했다.

1) 문제 및 목표 명확성의 근본적 왜곡 (R1)

Agbabiaka et al.(2025)의 논의에서 R1(문제 및 목표 명확성)은 설계 단계에서 AI 프로젝트의 목표와 방향을 명확히 설정하는 것을 요구한다. 진단 질문은 “AI 프로젝트의 목표와 목적이 명확하게 정의되었는가?”, “초기 단계에서 문제 정의 및 공식화에 이해관계자가 참여했는가?”이다.

앞서 확인했듯이, 시스템의 공식 목표는 사기 방지 및 효율성 향상이었지만 실제 동기는 전혀 달랐다. 2013년 불가리아 사기 사건 이후 형성된 외국인 혐오적 포퓰리즘과 사기 척결 정치 압력에 대응하는 것이 진짜 목표였다. Mark Rutte 총리가 각료급 위원회 사기 척결을 설치하고 의회가 극단적으로 강경한 단속을 요구한 정치적 맥락 속에서, 시스템의 실제 목표는 사기 예방이 아니라 가시적인 단속 성과 창출과 정치적 정당성 확보로 변질되었다.

더욱 심각한 것은 조세청이 알고리즘 비용을 정당화하기 위해 충분한 자금을 압류해야 하는 왜곡된 재정 인센티브를 갖고 있었다는 점이다. 문제 정의 과정에서 이해관계자 특히 수당 수급 가정의 참여는 전혀 이루어지지 않았으며, 목표 설정이 정치적 편의성과 조직적 이해관계에 의해 좌우되었다. 이는 R1의 핵심 원칙인 문제 정의 및 공식화와 목표 정의 및 설정을 모두 위반한 것이다.

2) 가치 상충의 은폐와 가치 정렬의 부재 (R2)

R2(가치 상충 및 정렬)는 설계 단계에서 가치를 내재화하고 시민들의 이익과 정렬해야 함을 요구한다. 프레임워크의 진단 초점은 가치 상충 인식, 가치 정렬, 우선순위 지정이다. 앞서 살펴본 바와 같이 네덜란드 시스템은 효율성과 비용 절감이라는 행정적 가치를 공정성, 비차별, 적법절차라는 헌법적 가치보다 우선시했다. 다시 말해 행정적 편의와 개인의 권리 보호라는 가치가 상충하는 상황에서 전자를 선택한 것이며, 이러한 근본적 가치 선택에 대한 민주적 숙의나 투명한 논의는 전혀 없었다.

시스템 설계자들은 서명 누락이나 소액 미납 같은 사소한 서류 오류를 수만 유로의 전액 환수 사유로 자동 전환하는 알고리즘을 개발하면서, 이것이 저소득 가정에 미칠 파괴적 영향을 전혀 고려하지 않았다. 사소한 재정적 오류가 전체 수당 상환 요구로 이어질 수 있었다는 사실은 가치 정렬의 완전한 부재를 보여주며, 가치 정렬은커녕 시민의 기본권과 정면으로 충돌하는 설계가 의도적으로 선택되었다.

3) 다양성, 참여 및 포괄성의 전면적 배제 (R3)

R3(다양성, 참여 및 포괄성)는 참여형 설계와 공동 창작을 강조한다. 프레임워크는 이 요건이 전체 라이프사이클에 걸쳐 적용되지만 특히 설계 단계에서 중요함을 명시한다. 앞서 확인했듯이 시스템 설계 과정에서 영향을 받을 수당 수급자, 이민자 커뮤니티, 시민사회단체, 독립적 인권 전문가의 참여는 전혀 없었다.

2013년 후반 설립된 CAF는 혐의자 중 “80%는 사기, 20%는 무죄”라는 근거 없는 가정 하에 운영되었는데, 이러한 편향적 전제에 대한 외부 검증이나 다양한 관점의 검토는 배제되었다. 더욱 문제인 것은 시스템이 명시적으로 다양성을 배제하는 방향으로 설계되었다는 점이다.

앞서 상세히 분석한 차별적 위험 지표(네덜란드 국적 여부, 이중국적자 여부, 특정 국적 여부)는 다양성에 대한 적극적 차별이었다. 일부 가나인의 혐의를 근거로 가나 국적자 전체를 조사한 사례는 참여와 포괄성의 원칙을 근본적으로 위반한 집단 처벌의 전형이다. 전체 피해자의 70%가 이민 배경을 가지고 있던 것은 우연이 아니라 설계상 차별의 직접적 결과였다.

4) 데이터 관리의 구조적 결함 (R4)

R4(데이터 관리)는 데이터 품질 및 맥락, 데이터 감사, 데이터 수집 프로세스를 하위 요건으로 제시하며, 전체 수명 주기에 걸쳐 중요하지만 특히 설계 및 모델링 단계에서 결정적이다. 진단 질문은 “훈련 데이터셋이 정확하고 완전하며 맥락과 관련이 있는가?”, 그리고 “배포 전후에 데이터셋에 대한 감사가 수행되는가?”이다.

앞서의 기술적 메커니즘 분석에서 밝혔듯이 시스템은 모든 측면에서 실패했다. 첫

째, 시스템은 역사적으로 정확한 신청과 부정확한 신청으로 분류된 과거 데이터로 훈련되었는데, 이 훈련 데이터 자체가 이미 편향된 인간 판단의 산물이었다. 외국 출신자나 이중국적자를 더 많이 조사했던 과거 관행이 데이터에 반영되어, 알고리즘은 “소수 민족 = 사기 위험”이라는 차별적 패턴을 학습했다. 이는 차별적 피드백 루프의 시작점이었다.

둘째, 국적 데이터의 수집과 보유 자체가 위법이었다. 앞서 확인했듯이 네덜란드 개인정보보호법에 따라 2014년 1월 이중국적자 정보를 삭제했어야 했지만, 2018년 5월 기준 140만 명의 이중국적자 정보가 여전히 등록되어 있었다. 이는 데이터 수집 프로세스의 합법성 결여를 보여준다.

셋째, 데이터 품질에 대한 체계적 감사가 없었다. 어떤 데이터가 위험 점수 산정에 사용되는지, 데이터의 정확성과 대표성은 어떠한지, 시간 경과에 따른 데이터 품질 저하는 없는지에 대한 지속적 검증 메커니즘이 부재했다.

5) 맥락 민감성의 완전한 상실 (R10)

R10(맥락 민감성)은 설계 단계에서 AI가 적용될 맥락에 대한 명확성이 신뢰 기반을 강화한다고 명시한다. 진단 질문은 “AI가 적용될 맥락에 대한 명확성이 신뢰 기반을 강화하는가?”이다. 앞서 확인했듯이 아동수당은 연간 100만 명 이상의 아동이 평균 €5,000를 지원받는 대규모 사회안전망이었다. 이러한 제도의 사회적 중요성과 수혜자의 취약성을 고려하면, 사소한 행정 오류에 대한 가혹한 처벌은 명백히 맥락에 부적합했다. 시스템은 서명 누락이나 의무적 개인 분담금의 지연 같은 사소한 실수를 수년간 받은 수당 전액(종종 수만 유로)의 즉시 일괄 상환 사유로 자동 전환했다.

또한 시스템은 저소득 가정이 더 많은 수당을 받기 때문에 환수액이 크다는 구조적 현실을 악용했다. 연간 수당 €10,000 이상 또는 환수액 €3,000 이상인 경우 자동으로 고의 또는 중과실 라벨을 부여한 것은, 취약계층에 대한 불균형적 처벌을 알고리즘적으로 제도화한 것이다. 맥락에 민감한 알고리즘은 설계 단계부터 완전히 무시되었다.

6) 선택 및 자율성의 박탈 (R18)

R18(선택 및 자율성)은 설계 단계에서 사용자가 데이터 사용에 동의하거나 거부할 수 있는 기능을 설계해야 함을 요구한다. 그러나 앞서의 불투명성 분석에서 밝혔듯이 네덜란드 시스템에서 시민들은 자신의 데이터가 알고리즘적 위험 프로파일링에 사용 되는지조차 알지 못했다. 시스템 도입 후 7년이 지난 시점인 2020년까지 일반 대중은 이러한 알고리즘의 존재 자체를 몰랐으며, 따라서 동의나 거부의 선택권은 애초에 존재하지 않았다.

더욱이 일단 고위험으로 분류되면 시민들은 아무런 선택권이 없었다. 수당 지급은 즉시 중단되었고, 추가 증거를 제출하라는 요구를 받았지만 무엇이 잘못되어 수당 지급이 중단되었는지에 대한 설명은 거부되었다. 알고리즘 결정에 대한 이의 제기 과정도 실질적으로 불가능했다. 시민들은 블랙박스 시스템의 일방적 판단에 따라 재정적 파멸로 내몰렸으며, 자율성과 선택권은 완전히 박탈되었다.

4.2 검증 및 확인 단계의 신뢰성 실패

검증 및 확인 단계는 설계된 시스템이 의도대로 작동하는지, 예상치 못한 편향이나 오류는 없는지를 확인하는 중요한 관문이다. 이 단계에서 발견된 문제는 배포 전에 시정될 수 있으므로, 적절한 검증은 대규모 피해를 예방하는 마지막 기회다. 네덜란드 시스템은 이 단계에서도 결정적으로 실패했다.

1) 기술적 견고성 검증의 부재 (R8)

R8(기술적 견고성)은 검증 단계에서 모델 평가를 통해 성능을 확인하고 시스템 정확성을 보장해야 함을 요구한다. 진단 질문은 “모델 성능 측정 지표가 설정 및 보고되고 있는가? 시스템이 정확하고 견고함을 유지하는가?”이다.

살펴본 바와 같이 네덜란드 시스템은 배포 전 독립적인 기술적 검증을 거치지 않았다. 모델 성능 측정 지표가 설정되거나 공개적으로 보고되지 않았으며, 정확도(precision), 재현율(recall), 위양성률(false positive rate) 같은 기본적인 성능 지표조차 평가되지 않았다. 자가학습 알고리즘의 특성상 시간이 지나면서 시스템이 어떻게 진화하는지에

대한 지속적 모니터링이 필수적이었으나, 이러한 메커니즘도 없었다.

실제로 CAF가 조사한 2,200가구 중 단 15건의 유죄 판결과 8건의 합의만 있었다는 사실은 시스템의 정확도가 극도로 낮았음을 보여준다. 파레토 원칙을 오용하여 조사된 부모의 80%가 유죄라고 가정했지만, 실제 결과는 1% 미만의 유죄율을 보였다. 만약 적절한 검증이 이루어졌다면 이러한 심각한 성능 결함은 배포 전에 발견되었을 것이다. 부정확한 예측이나 권고로 인한 오류를 방지하기 위한 백업 전략도 전혀 마련되지 않았다.

2) 설명 가능성 검증의 실패 (R6)

R6(설명 가능성)은 모델 구축 및 해석 단계에서 특히 중요하다. 진단 질문은 “모델 구축 및 해석 단계에서 설명 가능성이 확보되는가?”이다. 검증 단계에서는 알고리즘이 내린 결정을 이해관계자가 이해할 수 있는 방식으로 설명할 수 있는지를 확인해야 한다.

네덜란드 시스템은 설명 가능성이 전혀 없는 블랙박스로 설계되었다. 신청서가 높은 위험 점수를 받은 이유를 공무원도 이해할 수 없었고, 어떤 요소가 플래그를 트리거했는지 접근할 수도 없었다. 입력과 계산이 사용자에게 보이지 않았고, 사례를 검토하는 공무원은 위험 점수만 받고 설명은 받지 못했다. 특정 신청서가 높은 점수를 받은 이유를 이해하는 것이 불가능했다.

더욱 심각한 것은 자가학습의 불투명성이다. 앞서 밝혔듯 알고리즘의 자기 진화 과정에서 설계자, 개발자, 사용자, 감독 기관을 포함한 어떤 인간도 특정 결정이 어떻게 내려졌는지 완전히 이해하지 못하게 되었다. 검증 단계에서 이러한 설명 불가능성이 식별되고 해결되었어야 했지만, 오히려 이것이 시스템의 특성으로 받아들여졌다. 감사 추적이 없어 특정 결정이 내려진 이유를 사후적으로 재구성하는 것도 불가능했다.

4.3 배포 단계의 신뢰성 실패

배포 단계는 검증된 시스템을 실제 환경에 투입하는 단계로, 이론적 성능과 실제 성능 간의 격차가 드러날 수 있다. 따라서 이 단계에서도 지속적인 모니터링과 조정이 필요하다.

1) 기술적 견고성 유지의 실패 (R8)

R8은 배포 단계에서도 시스템이 정확하고 견고함을 유지해야 함을 요구한다. 진단 질문은 “시스템이 배포 후에도 정확하고 견고함을 유지하는가?”이다. 앞서 확인했듯이 2013년 배포 후 2020년 폐쇄까지 7년간 시스템의 성능 저하나 오작동에 대한 체계적 모니터링이 없었다. 부정확한 예측이나 권고로 인한 오류를 방지하기 위한 백업 전략도 부재했다.

시스템은 한번 배포되면 자동으로 작동했고, 그 결과로 앞서 분석한 대로 수만 가정이 파괴되는 동안에도 기술적 견고성에 대한 재평가는 이루어지지 않았다. 특히 자가 학습 메커니즘으로 인해 시스템이 원래 설계 파라미터를 넘어 진화했음에도, 이러한 변화가 의도한 목표와 일치하는지, 새로운 편향을 생성하지는 않는지에 대한 검증이 없었다. 차별적 피드백 루프(초기 편향 → 소수민족 조사 증가 → 편향된 훈련 데이터 → 알고리즘이 소수민족=사기 위험으로 학습 → 소수민족 조사 추가 증가)가 작동하면서 시스템의 차별성이 시간에 따라 증폭되었지만, 이를 감지하고 중단할 메커니즘은 전혀 마련되지 않았던 것이다.

4.4 운영 및 모니터링 단계의 신뢰성 실패

운영 및 모니터링 단계는 시스템이 실제 환경에서 장기간 작동하는 단계로, 피드백을 수집하고 지속적으로 개선하는 것이 핵심이다. 이 단계에서의 실패는 초기 설계 결함을 시정할 마지막 기회마저 놓치는 것을 의미한다.

1) 피드백 및 정책 학습의 부재 (R17)

R17(피드백 및 정책 학습)은 운영 단계에서 시민 피드백이 시스템 개선 및 정책 방향 설정을 위해 중요함을 강조한다. 진단 질문은 “운영 단계에서 시민 피드백은 시스템 개선 및 정책 방향 설정을 위해 중요한가?”이다.

네덜란드 조세청은 2014년부터 이의 제기를 처리하는 직원들로부터 부모들이 근거 없이 부당하게 대우받고 있다는 보고를 받았음에도, 주요 관리자들은 아무런 조치도 취하지 않았다. 2017년 사내 법률자문 Sandra Palmen이 위법 행위를 보고했을 때에도

정책 변경은 없었다. 2017년 8월 국가 옴부즈맨이 CAF 11 하와이 사건의 232가구에 대한 가혹한 접근을 비판하는 보고서를 발표했지만 권고사항은 무시되었다(Nationale ombudsman, 2017).

이는 피드백 메커니즘이 기술적으로 존재했음에도 제도적으로 작동하지 않았음을 보여준다. 내부고발자, 옴부즈맨, 담당 공무원의 경고를 체계적으로 무시한 것은 정책 학습 의지의 부재를 넘어 의도적인 은폐였다. 2019년 8월 사회당이 280건의 불만을 담은 블랙북을 제출한 후에야 제한적인 대응이 시작되었으나, 이미 앞서 확인한 대로 수만 가정이 파괴된 이후였다. 시스템은 피드백으로부터 학습하는 대신 문제를 은폐하는 방향으로 운영되었다.

4.5 전체 라이프사이클에 걸친 신뢰성 실패

Agbabiaka et al.(2025)의 프레임워크는 일부 요건이 특정 단계에 집중되지만, 많은 핵심 요건들은 전체 라이프사이클에 걸쳐 지속적으로 평가되고 다루어져야 함을 명시한다. 네덜란드 시스템은 이러한 전방위적 요건들에서도 체계적으로 실패했다.

1) 투명성의 전면적 부재 (R11)

R11(투명성)은 AI 라이프사이클 전체에 걸쳐 지속적으로 평가되고 다루어져야 한다. Agbabiaka et al.의 프레임워크는 프로세스 투명성, 알고리즘/모델 투명성, 이해관계자 기반 투명성, 접근성, 공적 공개를 하위 요건으로 제시한다. 진단 질문은 “AI/ADM 결정에 도달하는 프로세스(변수, 가중치, 계산 등)가 투명한가? AI 사용에 대한 정보(AI register)가 대중에게 공개되고 있는가?”이다.

살펴본 바와 같이 네덜란드 시스템은 이 모든 측면에서 완전히 불투명했다. 첫째, 프로세스 투명성의 부재로 AI/ADM 결정에 도달하는 프로세스(변수, 가중치, 계산 등)가 내부 공무원에게도 투명하게 공개되지 않았다. 사례를 검토하는 공무원은 위험 점수만 받을 뿐 그 근거는 알 수 없었다. 둘째, 알고리즘/모델 투명성의 부재로 시스템이 어떤 요소를 어떻게 가중하는지, 자가학습을 통해 어떻게 진화하는지에 대한 문서화나 정보 공개가 없었다. 셋째, 공적 공개의 부재로 시스템 도입 7년 후인 2020년까지 일

반 대중은 알고리즘의 존재조차 몰랐다. AI 사용에 대한 정보가 공개 등록부(AI register)에 등재되지 않았으며, 의회조차 시스템의 작동 방식에 대해 정확히 알지 못했다. 조세청은 감독 기관을 지속적으로 오도하거나 정보 제공을 거부했으며, 내각은 수년간 문제를 알고 있었음에도 의회로부터 정보를 은폐했다(Parliamentary Inquiry Committee Childcare Benefits, 2021). 투명성은 책임성의 전제조건임에도, 네덜란드 시스템은 투명성을 체계적으로 억압함으로써 책임 회피를 제도화했다.

2) 책임성 구조의 붕괴 (R12)

R12(책임성)는 공적 책임성, 책임 정의 및 할당, 다중 포럼 책임성, 헌법적 책임성을 포함하며 전체 AI 라이프사이클에 걸쳐 요구된다. 진단 질문은 “책임 소재를 명확히 하고 거버넌스를 개선하는가?”이다. 앞서의 폭로와 조사 과정 분석에서 밝혔듯이 네덜란드 사례는 책임성 구조의 완전한 붕괴를 보여준다.

첫째, 책임 정의 및 할당의 실패다. 알고리즘 결정에 대한 책임이 시스템 설계자, 운영 공무원, 관리층, 정치적 지도부 중 누구에게, 얼마만큼 부여되는지가 명확히 정의되지 않았다. 이러한 책임 소재의 모호성은 “알고리즘이 결정했다.”라는 변명을 가능하게 했다.

둘째, 공적 책임성의 부재다. 앞서 확인했듯이 2021년 1월 15일 제3차 Rutte 내각 전체가 사임했지만, 같은 총리와 정당들이 권력을 유지했다. Rutte는 2021년 선거에서 승리했고 동일한 연정이 계속되었다. 형식적 책임은 인정되었지만 실질적 책임은 회피되었다.

셋째, 헌법적 책임성의 실패다. 2021년 1월 7일 검찰이 조세청의 주권 면제를 이유로 형사 조사를 거부했으며, 어떤 공무원도 기소되지 않았다. 의회조사위원회는 법치주의의 근본 원칙이 위반되었다고 결론지었지만, 법적 책임은 추궁되지 않았다. 책임성 요구사항이 AI 라이프사이클 전반에 걸쳐 지속적으로 요구되었어야 했지만, 모든 단계에서 책임 회피가 제도화되었다.

3) 인간 행위 주체성 및 감독의 형해화 (R14)

R14(인간 행위 주체성 및 감독)는 전 라이프사이클에 걸쳐 인간의 통제와 감독이 필요함을 명시한다. 진단 질문은 “시스템의 전 영역에 걸쳐 인간의 통제(Human control)와 감독(oversight)이 적절하게 이루어지고 있는가?”, “공무원이 시스템의 권고를 재량으로 개입하고 판단할 여지가 있는가?” 등이 된다.

네덜란드 시스템에서 인간의 역할은 알고리즘이 표시한 고위험 사례를 단순히 집행하는 것으로 축소되었다. 공무원들은 왜 특정 신청이 선별(flagging)되었는지 알지 못했기 때문에 의미 있는 재량 판단을 할 수 없었다. 위험 점수만 받고 그 근거는 알 수 없었으므로, 공무원은 시스템의 권고를 재량으로 개입하고 판단할 여지가 사실상 없었다.

더욱이 앞서 언급한 GDPR의 역설적 결함이 인간 감독을 무력화했다. GDPR의 의미 있는 정보에 대한 권리는 완전히 자동화된 결정에만 적용되어, 공무원 검토가 있는 고위험 사례(가장 차별받은 사람들)는 설명 권리를 보장받지 못했고, 자동 승인된 저위험 사례는 설명 권리가 있지만 피해가 없었다. 명목상의 인간 개입이 오히려 권리 보호를 약화시킨 것이다.

앞서 확인했듯이 감독 기관들 국가 옴부즈맨, 네덜란드 데이터보호청, 네덜란드 인권연구소, 중앙정부 감사국의 경고와 권고는 체계적으로 무시되었다. 인간 감독은 형식적으로만 존재했고 실질적 권한은 없었다. 전체 스펙트럼에 걸쳐 인간의 통제와 감독이 필요했지만, 모든 단계에서 형해화되었다.

4) 윤리, 평가 및 지속적 개선의 부재 (R13)

R13(윤리, 평가 및 지속적 개선)은 윤리적 고려사항, 위험 및 영향 평가, 감사/모니터링 및 지속적 품질 개선을 전 단계에서 요구한다. 진단을 위해 “배포 전 의무적인 알고리즘 영향 평가(AIA)가 수행되는가?”, “윤리적 우려를 다루기 위한 거버넌스 구조(예: 윤리 위원회)가 마련되었는가?”, “시스템에 대한 지속적인 감사 및 모니터링 조치(품질 보증)가 있는가?” 등의 질문을 던져볼 수 있다.

앞서의 도입 배경 분석에서 확인했듯이 네덜란드 시스템은 배포 전 의무적인 알고리즘 영향 평가(AIA)를 전혀 수행하지 않았다. 시스템이 인권, 평등, 프라이버시에 미칠 영향에 대한 사전 평가가 없었고, 윤리적 우려를 다루기 위한 거버넌스 구조(예: 윤리

위원회)도 마련되지 않았다.

배포 후에도 시스템에 대한 지속적인 감사 및 모니터링 조치가 없었다. 2020년 7월 네덜란드 데이터보호청이 조사를 시작하기 전까지 독립적 감사는 전무했다. 품질 보증 메커니즘의 부재로 시스템은 7년간 오작동하면서 앞서 분석한 대로 수만 가정을 파괴했지만, 지속적 개선은 커녕 문제 인식조차 되지 않았다.

2020년 12월 의회조사위원회는 법치주의의 근본 원칙이 위반되었다고 결론지었지만, 이는 사후적 평가일 뿐 예방적 윤리 검토가 아니었다. 윤리적 관행 및 지속적인 품질 보증 조치(감사 등)는 전 단계에서 중요했지만, 모든 단계에서 완전히 부재했다.

5) 공정성 및 비차별의 체계적 위반 (R9)

R9(공정성 및 비차별)는 시스템의 전체 수명 주기 동안 지속적으로 평가되어야 한다. 이는 “시스템의 전체 수명 주기 동안 공정성이 지속적으로 평가되는가?”라는 질문을 통해 진단해볼 수 있다. 주지하듯 네덜란드 시스템은 설계 단계부터 의도적으로 차별적이었고, 운영 중에도 이러한 차별이 시정되지 않았다.

네덜란드 국적 여부를 핵심 위험 지표로 사용한 것은 국적 기반 차별의 명백한 사례다. 외국 출신자는 카테고리화 연도에 따라 훨씬 더 높은 조사 가능성—혐의자로 지목될 가능성—에 노출되었으며, 실제로 인정된 피해자의 약 50%가 해외에서 태어났고, 70%가 이민 배경을 가졌으며, 50%가 한부모 어머니였다는 사실은 시스템이 취약계층에 불균형적 피해를 입혔음을 보여준다. 2021년 10월 앰네스티 인터내셔널은 보고서에서 이를 인종 프로파일링, 설계상 차별, 인권 위반이라고 결론지었다(Amnesty International, 2021).

2022년 5월 25일이 되어서야 네덜란드 정부는 제도적 인종차별이 근본 원인이었음을 공개적으로 인정했다. 공정성 평가는 전 라이프사이클에서 부재했고, 차별은 시스템의 결함이 아닌 특성이었다.

6) 이의 제기 가능성 및 구제의 형식화 (R16)

R16(이의 제기 가능성 및 구제)은 전 라이프사이클에서 시민들이 AI 결정에 대해

이의를 제기할 수 있는 접근 가능한 경로와 부정적인 AI 결과에 대한 시정 조치를 취할 수 있는 메커니즘을 요구한다. 진단 질문으로는 “시민들이 AI 결정에 대해 이의를 제기(Contestability)할 수 있는 접근 가능한 경로가 마련되어 있는가?”와 “부정적인 AI 결과에 대해 시정 조치(Recourse)를 취할 수 있는 채널과 메커니즘이 있는가?” 등을 적용할 수 있다.

앞의 블랙박스 특성과 불투명성 분석에서 밝혔듯이 네덜란드 시스템에서 이의 제기는 사실상 불가능했다. 시민들은 자신이 왜 사기꾼으로 분류되었는지 알 수 없었고, 알고리즘 결정의 근거에 접근할 수 없었으며, 따라서 효과적으로 이의를 제기할 방법이 없었다. 형식적으로는 행정 불복 절차가 존재했지만, 블랙박스 시스템의 특성상 이의 제기의 실질적 기반을 형성하는 결정의 논리와 근거에 대한 설명이 제공되지 않았다.

앞서 확인했듯이 국사원은 2019년 10월까지 수백 건의 판결을 통해 조세청의 가혹한 전부 아니면 전무 접근을 반복적으로 지지함으로써 사법적 구제마저 차단했다. 보상 절차는 2021년 발표되었지만 실행 불가능하고 복잡하다고 비판받았으며, 2025년 말까지 걸릴 수 있다. 앞선 피해 분석에서 밝혔듯이 가정 파괴, 양육권 상실(2,090명 이상의 아동이 부모로부터 분리), 정신적 트라우마, 자살 같은 비가역적 피해는 어떤 보상으로도 복구할 수 없다. 이의 제기와 구제는 형식적으로만 존재했고 실질적 효과는 없었다.

5. 소결

이 절에서는 네덜란드 아동수당 사기 탐지 알고리즘 스캔들을 종합적으로 분석했다. 먼저 시스템의 도입 배경(외국인 혐오적 포퓰리즘, 정치적 압력, 왜곡된 재정 인센티브)과 기술적 메커니즘(자가학습 알고리즘, 차별적 위험 지표, 블랙박스 특성), 실제 운영 방식(집단 처벌, 자동 레이블링, 가혹한 환수)과 그로 인한 참담한 피해 규모(경제적 파산, 가정 파괴, 아동 분리 등)를 상세히 규명했다.

이어서는 2장의 실무 중심 프레임워크를 적용하여 OECD AI 시스템 라이프사이클의 모든 단계에서 이 시스템이 18가지 신뢰성 총괄 요건의 거의 전부를 어떻게 위반했는지를 체계적으로 진단했다. 설계 단계에서 문제 정의는 왜곡되었고(R1), 가치 정렬

은 부재했으며(R2), 참여는 배제되었고(R3), 데이터 관리는 위법했으며(R4), 맥락 민감성은 상실되었고(R10), 선택권은 박탈되었다(R18). 검증 단계에서는 기술적 견고성 확인이 없었고(R8), 설명 가능성은 전무했다(R6). 배포와 운영 단계에서도 성능 모니터링이 부재했고, 피드백은 무시되었다(R17).

전 라이프사이클에 걸쳐 투명성은 억압되었고(R11), 책임성은 붕괴했으며(R12), 인간 감독은 형해화되었고(R14), 윤리적 평가는 부재했으며(R13), 공정성은 체계적으로 위반되었고(R9), 이의 제기는 불가능했다(R16). 이는 단순한 기술적 결함이 아니라 외국인 혐오적 포퓰리즘, 신자유주의적 긴축, 식민주의 시대의 인종차별적 가정, 정치적 편의성이 결합하여 알고리즘이라는 도구를 통해 제도적 불의를 자동화하고 규모화한 체계적 실패였다.

5.1 공공부문 AI ADM 시스템을 위한 핵심 교훈

네덜란드 아동수당 부정수급 탐지 알고리즘의 사례는 공공부문 AI ADM 시스템에 대한 다음과 같은 중요한 교훈을 제공한다.

첫째, 기술적 신뢰성(R8)만으로는 절대 불충분하며, 가치 정렬(R2), 공정성(R9), 투명성(R11), 책임성(R12)이 동시에 확보되어야 한다. 네덜란드 시스템은 정확도가 1% 미만이었음에도 7년간 작동했는데, 이는 기술적 성능 평가조차 부재했음을 의미한다.

둘째, 자가학습 알고리즘은 고위험 공공 의사결정에서 특히 위험하며, 강력한 인간 감독(R14)과 지속적 모니터링(R13)이 필수적이다. 시스템이 원래 설계 파라미터를 넘어 진화하면서 차별을 증폭시켰지만, 이를 감지하고 중단할 메커니즘이 없었다.

셋째, 알고리즘 영향 평가(AIA)는 배포 전 의무화되어야 하며, 단순한 기술 평가를 넘어 윤리적·법적·정치적·문화적 차원의 다차원적 평가여야 한다. 네덜란드는 어떠한 사전 영향 평가도 수행하지 않았고, 그 결과는 재앙이었다.

넷째, 이해관계자 참여(R3)는 설계 단계부터 필수적이며, 특히 영향받는 취약계층의 목소리가 반영되어야 한다. 피해자의 70%가 이민 배경을 가진 것은 우연이 아니라 설계 단계에서 이들의 참여가 배제된 직접적인 결과였다.

다섯째, 투명성(R11)과 설명 가능성(R6)은 책임성(R12)의 전제조건이며, 블랙박스 시스템은 민주적 거버넌스와 양립할 수 없다. 다층적 불투명성은 책임 회피를 제도화

했고, 결국 알고리즘이 결정했다는 변명을 가능하게 했다.

여섯째, 피드백 메커니즘(R17)은 기술적으로 존재하는 것을 넘어 제도적으로 작동해야 하며, 내부고발자와 감독 기관의 경고를 무시하는 문화는 참사를 초래한다. 2014년부터 2019년까지 수많은 경고가 있었지만 모두 무시되었다.

일곱째, 이의 제기 가능성(R16)과 실질적 구제 메커니즘은 형식이 아닌 실질적으로 보장되어야 한다. 행정 불복 절차가 존재했지만 블랙박스 시스템의 특성상 효과적인 이의 제기가 불가능했다.

5.2 마치며: 기술은 중립적이지 않다

알고리즘 시스템은 편향된 역사적 데이터로 훈련될 때 과거의 차별을 인코딩하고 미래를 향해 투사한다. 기술은 중립적이지 않으며, 외국인 혐오, 인종차별, 계급 차별 같은 사회적 편견이 코드로 번역되어 규모화되고 자동화될 때, 그 피해는 기하급수적으로 증폭된다. 내각이 사퇴하고, 정부가 제도적 인종차별을 공식 인정했다 한들, 파괴된 가정과 분리된 아동들은 돌아오지 않는다.

네덜란드 아동수당 스캔들은 알고리즘이 법치주의의 근본 원칙을 어떻게 위반할 수 있는지, 그리고 신뢰할 수 있는 공공 AI 시스템을 구축하기 위해서는 신뢰성 요건의 포괄적이고 지속적인 준수가 얼마나 중요한지를 역사적으로 입증한 사례로 남을 것이다. 이 프레임워크를 통한 체계적 진단은 유사한 참사를 예방하고, OECD AI 라이프사이클의 모든 단계에서 신뢰성을 확보하는 실무적 로드맵을 제공한다.

공공기관은 AI 시스템을 도입하기 전에 반드시 이러한 포괄적 진단을 수행해야 하며, 기술적 효율성만큼이나 윤리적 정당성과 민주적 책임성을 중시해야 한다. 그렇지 않으면 우리는 네덜란드의 비극을 반복하게 될 것이다.

제5장 결 론

제1절 ADM 거버넌스 설계 및 구축의 중요성

제2절 ADM 거버넌스의 법적·제도적 개선전략

제3절 ADM 거버넌스의 조직적·문화적 개선전략

제5장 결론

제1절 ADM 거버넌스 설계 및 구축의 중요성

인공지능 기술이 단순한 행정보조 수단을 넘어 국가의 안보, 경제적 성과, 그리고 문화적 정체성을 결정짓는 핵심 전략 자산으로 급부상함에 따라 세계 각국은 자국만의 독자적인 인공지능 생태계를 구축하기 위한 소버린 AI(Sovereign AI) 경쟁에 돌입하였다.³²⁾ 소버린 AI란 국가가 자국의 영토 내에서 인공지능 기술의 개발, 배치, 거버넌스를 자국의 법과 가치, 그리고 이익에 따라 통제하고 대외적 영향으로부터 자율성을 유지하려는 능력을 의미한다.³³⁾

우리나라 정부 역시 이러한 글로벌 흐름에 발맞추어 글로벌 AI 3대 강국(G3) 도약을 국가적 비전으로 설정하고, 데이터와 연산 인프라, 모델 개발은 물론 보안 체계와 규범에 이르기까지 인공지능 전주기 역량을 내재화하기 위한 전방위적 정책을 추진하고 있다.³⁴⁾ 특히 2026년 인공지능기본법의 본격적인 시행과 함께 국가 인공지능 예산이 10.1조 원 규모로 집중 투자되는 원년으로서, 공공부문의 디지털 전환이 가속화되는 중대한 전환점이 될 것으로 전망된다.³⁵⁾ 이러한 배경에서 공공기관은 소버린 AI 기술을 행정 의사결정에 실질적으로 적용하고 대국민 서비스 품질을 혁신해야 하는 주체로서의 역할을 요구받고 있다. 2023년 기준 한국의 전체 공공기관 중 약 60.6%가 이미 다양한 수준의 인공지능 시스템을 도입하여 운영 중이며³⁶⁾, 이는 단순한 초기 도입 단계를 지나 생성형 AI와 검색 증강 생성(RAG) 기술을 결합한 정교한 의사결정 보조시스템으로 진화하고 있음을 보여준다. 그러나 이러한 기술적 양적 팽창 이면에는 데이

32) 윤정현(2025), 한국형 소버린 AI 국가전략의 모색, INSS 전략보고, 국가안보전략연구원

33) 디지털 거버넌스의 새로운 패러다임으로서 소버린 AI에 관한 연구, 경제규제와 법, DBpia, accessed on March 10, 2026

34) 대한민국정부, 이재명정부 123대 국정과제, 국정목표 2 세계를 이끄는 혁신경제, 추진전략 1. AI 3대 강국 도약 참조

35) 대통령실 보도자료, '이대통령 "AI 고속도로 구축해 도약과 성장의 미래 열어야"', 2025.11.04., 정책브리핑 www.korea.kr, 정책뉴스

36) 임영모 외(2025), 2024년 공공부문 AI 도입현황 연구, 소프트웨어정책연구소, 연구보고서 RE-188, p.viii

터 품질 저하, 개인정보 침해, 알고리즘의 편향성, 그리고 책임 소재 불분명 등 안전하고 신뢰할 수 있는 인공지능 활용을 저해하는 도전과제들이 산재해 있다.

1. 인공지능기본법 시행과 고영향 인공지능 규제체계

2026년부터 본격적으로 시행되는 ‘인공지능 산업 육성 및 신뢰 기반 조성 등에 관한 법률’(이하 인공지능기본법)은 한국 인공지능 정책의 규범적 틀을 완성하는 상징적 의미를 갖는다.³⁷⁾ 이 법은 인공지능 산업의 진흥을 도모하는 동시에 국민의 생명, 안전, 기본권에 직결된 분야를 고영향 인공지능(High-impact AI)으로 정의하고 이에 대한 엄격한 관리 책무를 부과하고 있다.³⁸⁾ 공공기관이 운영하는 대다수의 의사결정 시스템은 그 파급력으로 인해 고영향 인공지능의 범주에 포함될 가능성이 매우 높으며, 이는 공공 부문의 데이터 거버넌스가 단순한 기술적 관리를 넘어 법적·윤리적 책임성을 담보해야 함을 의미한다.³⁹⁾

인공지능기본법에 따른 고영향 인공지능의 판별은 위험 영역의 해당성, 사람에 대한 중대한 영향/위험 초래 우려라는 두 가지 조건을 종합적으로 고려하여 이루어진다⁴⁰⁾. 공공기관이 공공서비스 제공을 위해 도입한 인공지능을 최종 결정권자가 아닌 의사결정 보조 비서로 설정하고 담당자가 최종 승인하는 절차(Human-in-the-loop)를 마련하는 것이 한편으로 고영향 인공지능 규제에 따른 법적 부담을 완화하면서도 행정의 신뢰도를 유지할 수 있는 방안이 될 수 있다. 고영향 인공지능 사업자로 분류된 공공기관은 이용자의 기본권을 보호하기 위한 위험 관리방안을 수립하고 인공지능 기반 운영 사실을 이용자에게 사전에 명확히 고지하여 투명성을 확보해야 한다.⁴¹⁾ 또한 인공지능이 내린 결정의 근거를 설명할 수 있는 체계(Explainability)를 마련해야 하며, 필요시 인공지능 영향평가를 실시하여 사회적·경제적 파급효과를 분석해야 한다.⁴²⁾ 이러한 의무 위

37) 과학기술정보통신부 보도자료, “인공지능기본법” 22일 시행 ... 생성형 AI 결과물 ‘워터마크’ 표시의무’, 2026.01.21., 정책브리핑 www.korea.kr, 정책뉴스

38) Ibid.

39) 과학기술정보통신부, NIA, (2026). 고영향인공지능 판단 가이드라인. 고영향 인공지능 관련 내용 참조

40) Ibid.

41) Ibid. 고영향 인공지능사업자의 책무 참조

42) 인공지능기본법 제35조(고영향 인공지능 영향평가) 및 시행령 제28조 참조

반에 대해서는 3천만 원 이하의 과태료가 부과될 수 있으며, 공공기관으로서는 무엇보다 행정적 신뢰도에 치명적인 타격을 입을 수 있다는 점에서 유의할 필요가 있다.

아울러 학습에 사용된 누적 연산량이 1026 FLOPs(부동소수점 연산) 이상인 초거대 AI 모델의 경우 수명주기 전반에 걸친 위험 식별 및 완화 조치 등 더욱 강력한 안전성 확보 의무가 부여된다.⁴³⁾

〈표 5-1〉 고영향 인공지능 판단기준

판별단계	주요내용 및 기준	근거
1단계: 위험 영역	에너지의 공급, 먹는물의 생산공정, 보건의료 제공이용 체계 및 의료기기, 원자력시설의 안전한 관리운영, 범죄수사·체포 목적 생체인식정보 분석활용, 채용 및 대출심사, 교통수단·시설체계의 주요한 작동운영, 공공서비스 제공에 필요한 국가기관등의 의사결정, 유아·초·중등 교육에서의 학생평가	법 제2조제4호 가목에서 카목
2단계: 중대한 영향	개인의 생명, 신체의 안전 및 기본권에 초래할 수 있는 위험의 영향, 중대성, 빈도 및 활용영역별 특수성	법 제2조제4호, 시행령 제25조제2항
3단계: 인적 개입 부재	사람의 개입없이 인공지능이 전적으로 판단하고 결정하는지 여부	human-in-the-loop는 법에 규정된 직접적인 판단기준은 아니지만 인간에 미치는 중대한 위험 판단의 보완적 기준

출처: 저자 작성

2. 공공 AI데이터 거버넌스의 진화 및 필요성

공공 부문에서의 AI 데이터 거버넌스는 인공지능의 연료가 되는 데이터를 수집, 저장, 관리하는 전통적인 데이터 거버넌스의 개념을 넘어, 인공지능 모델의 학습부터 추론, 그리고 행정적 결과 도출에 이르는 전 과정에서 투명성, 공정성, 안전성, 책임성을 확보하기 위한 조직적·기술적·제도적 체계를 총칭한다.⁴⁴⁾ 과거의 거버넌스가 데이터

43) 인공지능기본법 제32조(인공지능 안전성 확보의무) 및 시행령 제24조 참조

44) Pahune, Akhtar, Mandapati, and Siddique(2025)은 ‘AI 데이터 거버넌스는 개발 과정부터, end-to-end 테스트 과정, 모델 검증, 안전한 배포 및 운영에 이르는 LLM 활동의 전 생애과정에서 데이터가 적절하게 활용되도록 보장하는 핵심 프레임워크’로 AI 데이터 거버넌스를 정의하고 있음. 기존의 데이터 거버넌스가 AI 생애과정에 포함되면서 데이터가 AI의 학습, 검증, 테스트라는 AI 개발을 위한 기본적인 필수 자원이자 개인정보, 저작권, 환각 현상 등 AI 맥락에서 제기되는 핵심 이슈가 된다는 관점에서 이를 관리하고 모니터링하기 위한 AI 거버넌스로 확대되고 있음. 이런 시각에서 AI 데이터 거버넌스의 중요성을 강조하고자함

의 ‘가용성’과 ‘무결성’에 초점을 맞추었다면, 인공지능 시대의 거버넌스는 데이터가 알고리즘을 통해 편향된 결과를 도출하지 않도록 관리하고, 인공지능이 내린 결정의 근거를 국민에게 설명할 수 있는 ‘설명 가능성(Explainability)’을 확보하는 데 그 본질이 있다. 특히 2026년 2월 전면 개정된 「인공지능 및 데이터 기반 행정 활성화에 관한 법률」은 ‘인공지능기반 행정’이라는 개념을 새롭게 도입하였다.⁴⁵⁾ 이는 공공기관이 인공지능을 활용하는 방법으로 정책 수립 및 의사결정을 효율적이고 과학적으로 수행하는 행정을 의미하며, 이를 뒷받침하는 데이터 거버넌스는 ‘학습용 데이터’의 품질 관리와 신뢰 기반 조성을 핵심 목표로 설정하게 되었다.⁴⁶⁾ 따라서 현대적 공공 AI 거버넌스는 데이터를 단순한 자산으로 보는 관점에서 벗어나, 사회적 가치 창출을 위한 ‘공공재적 공유 자원’으로 인식하고 이를 수탁자적 책임감으로 관리하는 체계로 진화해야 한다.⁴⁷⁾

공공 부문이 인공지능 데이터 거버넌스를 강화해야 하는 이유는 기술적, 법적, 사회적 측면에서 매우 명확하다. 기술적 측면에서 인공지능 모델의 성능은 지식 베이스에 축적된 데이터의 품질에 정비례한다. 행정 문서의 비정형성으로 인한 정보 손실을 방지하고 인공지능의 할루시네이션(환각) 현상을 최소화하기 위해서는 기계 판독이 가능한 형태의 표준화된 고품질 데이터를 안정적으로 축적하는 시스템이 필수적이다. 정교한 데이터 거버넌스 없이 도입된 인공지능은 잘못된 행정 판단을 초래하여 막대한 사회적 비용을 발생시킬 우려가 크다.

법적 측면에서는 2026년부터 시행되는 인공지능기본법에 따라 공공기관이 운영하는 대다수의 의사결정 시스템이 ‘고영향 인공지능(High-impact AI)’으로 분류될 가능성이 매우 높다. 고영향 인공지능으로 분류되면 국민의 기본권 보호를 위한 위험관리 방안 수립, 사전 고지의무, 설명 책임 등 엄격한 법적 책무가 부과되며, 이를 위반할 시 과태료 부과 및 행정적 신뢰도 하락이라는 치명적인 결과를 초래할 수 있다. AI 데이터 거버넌스는 이러한 법적 책무를 실질적으로 이행하기 위한 운영관리의 토대가 된다. 사회적 측면에서는 인공지능의 복잡성과 자율성으로 인해 발생하는 ‘책임 공백(Responsibility Gap)’ 문제를 해결하기 위한 제도적 수단이다. 인공지능이 내린 결정으로 인해 국민이

45) ‘인공지능 및 데이터기반 행정 활성화에 관한 법률 제개정문

46) 행정안전부 보도자료(2026.1.29.) ‘AI민주정부’ 이끈 공공AI 법제도 기반인 ‘공공AI법’ 국회본회의 통과

47) ‘공공AI법 통과와 그 의미’ 법률신문(2026.02.09.), ‘공공AI법 국회 본회의 통과’, 법무법인(유) 화우 (2026.02.03.)

피해를 입었을 때, 그 결정의 경로를 추적하고 책임 소재를 명확히 할 수 있는 거버넌스 체계가 부재하다면 공공행정의 민주적 정당성은 훼손될 수밖에 없을 것이다. 따라서 투명한 데이터 계보(Data Lineage) 관리와 인간 개입(Human-in-the-loop)을 보장하는 거버넌스 설계는 공공 AI 도입의 전제조건이다.

제2절 ADM 거버넌스의 법적·제도적 개선전략

1. 인공지능 및 데이터 기반 행정 활성화에 관한 법률 개정

1.1 법률개정 배경

2026년 2월 27일 국회 본회의를 통과한 「인공지능 및 데이터 기반 행정 활성화에 관한 법률」(이하 공공 AI법)의 일부개정안은 한국 공공 부문의 AI 도입을 위한 결정적 법적 토대를 마련하였다. 본 법률의 개정은 인공지능 기술의 폭발적인 발전과 확산에 따라, 인공지능을 활용한 공공행정 서비스가 확대되는 시대적 흐름을 제도적으로 수용하기 위해 추진되었다. 기존의 「데이터기반행정 활성화에 관한 법률」이 데이터의 수집과 분석을 통한 과학적 행정에 초점을 맞추었다면, 개정법은 인공지능 기술의 도입·활용을 위한 구체적인 법적 근거를 마련함으로써 ‘AI 민주정부’ 구현과 대국민 서비스 혁신을 도모하려는 확고한 의지를 담고 있다.⁴⁸⁾

개정의 주요 사유는 크게 세 가지로 요약된다. 첫째, 공공 부문에 인공지능을 도입하고 활용할 수 있는 명확한 법적 지위를 부여하여 행정의 효율성을 제고하는 것이다. 둘째, 개별 공공기관이 인공지능을 도입할 때 발생할 수 있는 중복 투자를 방지하고, 범정부 차원에서 공동으로 이용할 수 있는 기술적 기반을 구축하여 예산 집행의 효율성을 확보하는 것이다. 셋째, 인공지능 활용과정에서 발생할 수 있는 편향성, 불투명성, 기본권 침해 등의 부작용을 관리하기 위한 제도적 안전장치를 마련하여 국민의 신뢰를 확보하는 것이다.

1.2 핵심 정의 규정 신설

이번 개정에서 가장 상징적인 변화는 법률 제명의 변경이다. 기존의 명칭에 ‘인공지능’을 추가하여 「인공지능 및 데이터 기반 행정 활성화에 관한 법률」로 개칭함으로써, 데이터와 인공지능이 공공행정의 양대 핵심 축임을 명확히 하였다. 제1조(목적) 역시 기존의 ‘객관적이고 과학적 행정’에 ‘효율적’ 행정이라는 가치를 더하고, 인공지능의

48) 법률 제개정 사유

안전한 활용에 필요한 ‘신뢰 기반 조성’을 법의 목적으로 명시하여 규범적 지향점을 확장하였다.

또한 인공지능 시대를 규정하는 핵심 용어들에 대한 정의 규정이 새롭게 마련되었다. 제2조에 신설된 주요 정의는 다음과 같다.

〈표 5-2〉 인공지능 시대를 규정하는 핵심 용어

용어	정의 및 법적 의미	근거조항
인공지능	‘인공지능 발전과 신뢰기반 조성에 관한 기본법’ 제2조제1호에 따른 인공지능을 의미하며, 지적 능력을 전자적 방법으로 구현한 기술을 포괄	법 제2조제1호
인공지능기반 행정	공공기관이 인공지능을 활용하는 방법으로 정책수립 및 의사결정을 효율적이고 과학적으로 수행하는 행정	법 제2조제3호
학습용 데이터	인공지능의 개발·활용 등에 사용되는 데이터로서, 기관간 공유 및 활용의 핵심 자산	법제2조제6호

출처: 저자 작성

이러한 정의의 신설은 인공지능을 단순히 기술적 도구로 취급하던 과거의 관점에서 벗어나, 행정체계 전반을 혁신하는 주체적 요소로 격상시켰음을 의미한다. 특히 ‘학습용 데이터’를 법적으로 규정한 것은 공공데이터를 인공지능이 읽을 수 있는 형태로 가공하고 관리해야 하는 기관의 의무를 실질화하는 근거가 된다.

1.3 행정의 책임성과 투명성 원칙 확립

인공지능의 자율성이 증대됨에 따라 행정 주체인 공무원이나 기관의 책임이 모호해질 수 있다는 우려에 대응하여, 제3조에서는 인공지능 활용 시 지켜야 할 기본 원칙을 대폭 강화하였다. 신설된 제3조제5항은 공공기관이 인공지능을 정책 수립 및 의사결정에 활용하는 경우라도, 그 결정에 대한 최종적인 권한과 책임이 반드시 해당 공공기관에 있음을 명확히 하도록 규정하고 있다. 이는 “인공지능이 그렇게 판단했다”는 이유로 행정의 책임을 회피하는 것을 원천적으로 차단하며, 인간의 개입(Human-in-the-loop)을 보장하는 ‘켄타우로스 모델⁴⁹⁾’의 법적 근거가 된다. 또한 제3조제7항에서는

49) 수리적·반복적 업무는 인공지능이 담당하고 최종적 가치판단과 복합적 의사결정은 인간 공무원이 수행함으로써 신속한 의사결정으로 시너지를 극대화려는 의사결정 방식

인공지능기반 행정 수행 과정에서 데이터의 편향성 및 의사결정의 투명성을 고려해야 한다는 원칙을 세워, 기술적 불투명성으로 인해 발생할 수 있는 국민 권익 침해를 예방하고자 하였다.

1.4 조직체계의 정비: 인공지능 및 데이터기반 행정책임관 도입

기존의 ‘데이터기반행정 책임관(CDO)’은 이제 명칭부터 역할까지 ‘인공지능 및 데이터 기반 행정 책임관(AI-CDO)’으로 확대 개편되었다. 이는 공공기관 내에서 데이터 관리와 인공지능 도입을 분리된 업무가 아닌 하나의 통합된 거버넌스 체계로 운영해야 함을 시사한다.

신설된 AI-CDO의 구체적 업무 범위는 다음과 같다 :

- ① 정책 총괄: 인공지능 및 데이터 기반 행정 활성화에 관한 정책의 총괄 조정 및 지원
- ② 데이터 연계 및 활용: 인공지능 학습을 위한 데이터의 연계, 제공 및 기관 간 공동 활용 지원
- ③ 학습용 데이터 관리: 제29조에 따른 학습용 데이터의 체계적인 구축 및 품질 관리
- ④ 신뢰성 및 위험관리: 인공지능 도입 시 신뢰성 확보와 잠재적 위험관리에 관한 업무 총괄
- ⑤ 협의회 참여: 행정안전부 장관이 구성하는 ‘책임관 협의회’를 통해 부처 간 데이터를 연계하고 정책적 합의를 도출하는 컨트롤 타워 역할 수행

특히 위험관리 업무가 AI-CDO의 핵심 책무로 명시된 것은 공공 부문의 거버넌스가 단순한 기술 진흥을 넘어 법적·윤리적 책임성을 담보해야 한다는 시대적 요구를 반영한 결과이다.

1.5 범정부 AI공통기반 플랫폼 구축

공공기관마다 각자 인공지능 모델을 개발하거나 서버를 구축할 경우 발생하는 막대한 예산 낭비와 기술적 파편화를 막기 위해, 법 제27조에서는 AI활용 ‘공통기반’의 구축 및 운영 의무를 신설하였다. 행정안전부 장관과 과학기술정보통신부 장관은 공공기관이 중복 투자 없이 신속하고 안전하게 인공지능을 도입할 수 있도록 범정부 차원의 AI 공유 인프라를 마련해야 한다.

이 공통기반은 보안성이 확보된 환경에서 민간의 초거대 AI 모델을 활용할 수 있도록 지원하고, 공공기관장은 인공지능 도입 시 이 공통기반을 우선적으로 이용하도록 노력해야 한다는 ‘우선 이용 노력 의무’를 지게된다(법 제27조제2항). 이를 통해 정부는 보안 등급이 혼재된 행정 데이터가 인공지능에 의해 부적절하게 결합되어 유출되지 않도록 망 분리 체계와 고성능 클라우드 자원을 안전하게 연계하는 기술적 보안 대책을 선행적으로 제공할 수 있게 된다.

1.6 공공분야 인공지능 영향평가제도 도입

개정법에서 가장 강력한 규제이자 보호 장치로 평가받는 조항은 제32조에 신설된 ‘공공분야 인공지능 영향평가’이다. 이는 공공기관이 인공지능을 도입하기 전에 사전에 인공지능이 국민의 기본권에 미치는 영향을 평가하고 그 결과를 공개하도록 하는 제도이다. 인공지능 영향평가는 다음과 같은 세부 운영 원칙을 준수해야 한다 :

- ① 평가 의무 및 공개: 도입 전 사전 평가를 실시하고 결과를 공표해야 하며, 이는 행정의 투명성을 확보하는 핵심 기제로 작동
- ② 면제 사유의 엄격성: 국가안보, 국방 등 기밀 보호가 필요한 경우나 단순 반복적인 업무로서 파급효과가 적은 경우, 그리고 인공지능기본법에 따라 이미 고영향 인공지능 영향평가를 마친 경우에만 행정안전부 장관과 협의하여 면제할 수 있다
- ③ 위험관리 방안 수립: 평가 과정에서 식별된 오류나 위험에 대처하기 위해 공공기관장은 반드시 실효성 있는 위험관리 방안을 수립하고 시행해야 한다
- ④ 전문성 확보: 평가는 전문기관에 의뢰할 수 있으며, 정부는 이에 필요한 행정적·기술적·재정적 지원을 제공해야 한다

이 제도는 인공지능의 ‘블랙박스’ 문제로 인해 국민이 자신이 왜 그러한 행정 처분을 받았는지 알 수 없는 상황을 방지하고, 인공지능기반 행정에 대한 사법적 통제가 가능하도록 데이터셋의 공정성과 알고리즘의 논리를 사전에 검증하는 데 그 의의가 있다.⁵⁰⁾ 특히 고영향 인공지능에 대해서는 설명 가능성(Explainability) 확보가 필수적이며, 이는 국민의 알 권리와 기본권 보호를 위한 최소한의 안전장치가 될 수 있다.

1.7 학습용 데이터 품질관리 및 서비스 현황 관리

인공지능의 성능을 보장하고 기관 간 데이터의 재사용성을 높이기 위해, 개정법은 ‘데이터 자산화’에 대한 법적 책무를 신설하였다. 제29조에 따라 공공기관장은 학습용 데이터의 적정한 품질 수준을 확보하기 위한 조치를 취해야 하며, 이는 데이터 프로파일링, 정제 공정, 메타데이터 관리 등을 포괄하는 기술적 활동의 근거가 된다. 또한 제30조에 따라 공공기관이 제공하는 인공지능 서비스의 유형, 목적, 활용 데이터 등의 현황을 관리하고 행정안전부 장관에게 제출해야 한다. 행정안전부는 이를 목록화하여 매년 공표함으로써 범정부 차원의 AI 서비스 지도를 구축하고, 중복 개발을 방지하며 우수한 서비스를 타 기관으로 확산하는 선순환 체계를 마련하게 된다.⁵¹⁾

2. 공공기관의 인공지능 기반 의사결정 거버넌스 규율 강화

이번 공공 AI법 개정은 2026년부터 시행되는 「인공지능 산업 육성 및 신뢰 기반 조성 등에 관한 법률」(인공지능기본법)과 유기적으로 연계되어 있다. 인공지능기본법이 인공지능 산업 전반의 진흥과 ‘고영향 인공지능’에 대한 범국가적 규제 틀을 제시한다면, 공공 AI법은 이를 공공행정이라는 특수 영역에 구체화하여 적용하는 특별법적 성격을 갖는다. 특히 인공지능기본법에 따른 고영향 인공지능의 판별 기준은 공공기관의 AI 시스템 운영에 직접적인 영향을 미친다. 공공기관은 자사의 시스템이 고영향 인공

50) 허성욱(2024) 인공지능에 근거한 행정처분에 대한 사법심사이론 연구, 사법정책연구원 연구총서 2024-16

51) 행정안전부(2026.1.19.) ‘AI 민주정부’ 이끌 공공 AI 법제도 기반인 ‘공공AI법’ 국회 본회의 통과, 보도자료, 2026.1.29

지능에 해당하는지 사전에 진단해야 하며, 만약 해당한다면 인공지능기본법상의 의무(투명성 고지, 위험 관리 등)와 공공 AI법상의 의무(영향평가, 윤리 준수 등)를 동시에 충족해야 한다. 특히 고영향 인공지능 사업자로 분류될 경우 설명 책임 제도가 의무화되며, 이는 국민이 자신의 기본권에 영향을 미치는 행정 결정의 근거를 알 수 있도록 보장하는 행정 절차법적 정당성을 확보하는 핵심 장치가 된다.

인공지능의 자율성으로 인해 발생하는 ‘책임 공백’을 메우기 위한 국가배상법 및 관련 판례에 대한 선제적 정비가 논의되고 있다. 판례상 자동화 시스템의 오류는 공공 영조물의 안전성 결여에 따른 영조물 책임(국가배상법 제5조)으로 인정될 가능성이 높다. 따라서 인공지능 시스템의 결함으로 인한 손해가 발생했을 때, 공무원의 구체적인 과실을 입증하기 어려운 경우라도 시스템 자체의 ‘안전성 결여’를 근거로 국가가 신속하게 배상 책임을 지는 수준의 전향적인 권리 구제 절차를 마련해야 한다. 또한 인공지능에 의한 행정 작용에 대하여 국민이 이의를 제기하고 구제받을 수 있도록 행정심판법 및 행정기본법을 개정하여 ‘설명 요구권’과 ‘재결정 요구권’을 명문화해야 한다는 요구가 제기되고 있다.⁵²⁾ 이미 행정안전부는 인공지능 기반 행정처분에 대한 설명요구권을 담은 행정절차법 개정안을 발의한 바 있다.⁵³⁾ 이는 기술의 불투명성이 법치국가의 원칙을 훼손하지 않도록 하는 규범적 방어선이 될 수 있다.

결론적으로, 2026년 개정된 공공 AI법 체계는 인공지능을 단순한 기술적 혁신의 도구로 보는 데서 나아가, 이를 엄격한 법적 책임과 윤리적 기준 아래 관리해야 하는 행정의 핵심 요소로 규정하고 있다. 공공기관은 이러한 제도적·법적 요소들을 유기적으로 결합하여, 기술적 종속을 넘어선 규범적 주권을 확립하고 국민이 체감할 수 있는 안전하고 신뢰할 수 있는 인공지능 행정을 실현할 수 있다.

52) 김찬희(2023)는 인공지능 기반 자동화된 행정행위가 가능하려면 인공지능의 자율성과 불투명성이 행정적 의사결정의 민주적 정당성과 법치국가 원리, 적법절차 원칙에 따라 규율될 수 있도록 법적 규율체계 보완이 필요하다고 주장하였다. 특히 절차적 정당성 확보를 위해 인공지능 알고리즘과 그에 입력되는 데이터의 적정성에 대한 감독, 인공지능 기반 행정행위의 영향을 받는 이해관계자의 입력데이터 등에 대한 설명 요구권, 부적절한 데이터 입력 등 자동화 행정행위가 부당하다고 판단될 경우 이의제기권 보장이 필요하다고 보았다(pp.60-61)

53) 행정절차법 일부개정법률안(2025.12), 의안번호 14816

제3절 ADM 거버넌스의 조직적·문화적 개선전략

1. 인공지능기본법의 국가 AI 거버넌스 체계

1.1 국가AI전략위원회

국가인공지능위원회는 인공지능기본법에 따라 '인공지능 발전과 신뢰 기반 조성'을 위한 주요 정책을 심의·의결하기 위하여 대통령 소속으로 설치된 위원회 조직이다. 위원회는 위원장 1명과 부위원장 1명을 포함한 60명 이내의 위원으로 구성되며, 대통령이 위원장을 맡아 정책의 실행력을 극대화한다. 위원의 과반수는 민간 전문가로 구성되어 기술적 전문성과 사회적 수용성을 동시에 확보하며, 특정 성별로만 위원회를 구성할 수 없도록 규정하여 인적 구성의 균형을 도모한다. 위원회는 정부가 3년마다 수립하는 AI기본계획안에 대한 점검·분석, AI 관련 국가비전 및 중장기 전략수립, AI 정책 및 사업 수립·조정, 연구개발 전략 수립, 투자 방향 결정, AI 발전을 저해하는 규제·의 발굴 및 개선 등 국가전략 전반에 걸친 강력한 권한을 행사한다. 국가기관의 장 및 인공지능 사업자에 대하여 AI의 올바른 사용과 윤리 실천, 안전성 및 신뢰성 확보에 관한 권고 또는 의견을 표명할 수 있어, 공공기관의 AI 도입 방향에 실질적인 영향을 미칠 수 있다.

특히 위원회의 중요한 업무로는 고영향 인공지능 규율에 관한 사항인데, 고영향 인공지능 사업자로 분류되는 공공기관은 다음과 같은 단계적 의무를 지게 된다:

1. 사전 검토 및 고지: 인공지능 사업자는 사용하려는 시스템이 고영향 AI에 해당하는지 사전에 스스로 검토해야 하며, 필요한 경우 과기부장관에게 확인 요청(법 제33조)할 수 있다. 또한 고영향 인공지능을 이용한 서비스를 제공하는 경우 인공지능이용사업자는 해당 서비스가 인공지능에 기반하여 운용된다는 사실을 이용자에게 사전 고지해야 함(법 제31조제1항)
2. 안전성·신뢰성 확보조치 이행: 고영향 인공지능 또는 이를 이용한 제품/서비스를 제공하는 경우 사업자는 일정한 안전성·신뢰성 확보조치 이행의무가 부과됨(제34조). 여기에는 위험관리방안의 수립·운영, 인공지능이 도출한 최종결과, 최종결과 도출에 활용된 주요기준, 사용된 학습용 데이터 개요 등에 대한 설명

- 방안 수립·시행, 이용자보호방안의 수립·운영, 고영향인공지능에 대한 사람의 관리감독, 안전성·신뢰성 확보 조치에 관한 문서 작성 및 보관 등이 포함됨
3. 고영향 AI 안전·신뢰 검·인증: 인공지능사업자가 고영향 AI를 제공하는 경우 사전에 안전성·신뢰성에 대한 자율적인 검인증을 받도록 노력해야 함(제30조제3항)
 4. 기본권에 미치는 영향평가: AI사업자는 고영향 AI를 이용할 경우 사람의 기본권에 미치는 영향을 평가하기 위해 노력해야 함(제35조제1항)

이처럼 고영향 인공지능을 사용할 경우 공공기관을 비롯한 AI사업자의 준수 의무를 비롯하여 AI 안전성과 투명성 확보를 위한 위험관리 및 AI 데이터 거버넌스 구축을 위한 규제체계를 어떻게 가져갈 것인가는 아직 불확실하며, AI국가전략위원회는 신속하게 정책 방향을 제시하고 공공을 비롯한 민간 사업자의 구현가능한 거버넌스 모델을 제시해야 한다.

1.2 공공기관의 AI거버넌스 조직

공공AI법 개정으로 기존의 '데이터기반 행정 책임관(CDO)'은 이제 '인공지능 및 데이터기반 행정책임관(AI-CDO)'로 역할이 강화되었다. 이는 공공기관 내에서 데이터 관리와 인공지능 도입을 서로 분리된 업무가 아닌 하나의 통합된 거버넌스 체계로 운영해야 함을 법적으로 명시한 것이다. AI-CDO는 기관 내 AI 전략 수립 및 이행 점검의 최종 책임자로서 다음과 같은 책무를 수행한다:


1. 정책 및 전략 총괄: 소관 기관의 인공지능 및 데이터 기반 행정 활성화에 관한 정책의 총괄·조정 및 부서 간 업무 연계 지원
2. 학습용 데이터 자산화: 인공지능 모델의 성능을 결정짓는 '학습용 데이터'의 체계적인 구축과 품질관리를 전담하며, 기관 간 공유 및 활용을 위한 메타데이터 관리를 수행
3. 신뢰성 및 위험관리: AI 도입 시 신뢰성 확보와 잠재적 위험관리에 관한 업무를 총괄하며, 특히 공공분야 인공지능영향평가(제32조)의 수행을 담당

4. 범정부 컨트롤 타워 협력: 행정안전부 장관이 구성하는 ‘책임관 협의회’에 참여하여 부처 간 AI·데이터 규제 이슈를 공유하고 범부처 사업을 발굴

특히 AI-CDO는 기관의 AI 도입이 단순한 기술적 실험에 그치지 않고, 행정의 효율성과 신뢰성을 동시에 확보할 수 있도록 ‘거버넌스 설계자’로서의 역할을 부여받고 있다. 이는 과거 IT 부서장이 수행하던 기술 지원 업무와는 질적으로 다른, 규범적·전략적 의사결정 권한을 수반한다. 특히 공공AI법 제32조의 ‘공공분야 인공지능 영향평가’는 AI-CDO가 수행해야 하는 중요한 임무로, 공공기관이 인공지능을 도입하기 전, 사전에 인공지능이 국민의 기본권에 미치는 영향을 평가하고 그 결과를 공개하도록 공공기관의 장에게 의무를 부과하고 있다. 이와 관련한 AI-CDO의 역할은 기관에서 도입하려는 인공지능이 평가대상인지 판단 및 전문기관에 의뢰하여 도입예정인 AI의 목적, 활용데이터, 파급효과 등을 분석한다. 또한 평가과정의 데이터를 제공하고 기술적 검증을 지원해야 한다. 이를 통해 데이터 편향성, 알고리즘 투명성, 기본권 침해가능성 등을 검토해야 한다. 여기서 도출된 오류나 위험에 대한 실효성있는 대책을 마련하고 위험관리방안의 최종 승인 및 시행 감독을 책임진다. 최종적으로 평가보고서 작성 및 공표를 통해 AI기반 행정의 투명성을 확보하고 국민의 알 권리를 충족시키는 일련의 과정을 총괄한다. 따라서 AI-CDO는 이런 과정을 총괄 집행하고 책임질 수 있는 기술적 전문성이 요구되고 이를 바탕으로 AI행정의 정당성을 방어하는 역할을 수행하게 된다.

기관과 국가 차원의 AI 거버넌스 관계를 살펴보면, 인공지능기본법의 국가인공지능전략위원회를 정점으로 한 거버넌스 조직은 국가차원의 AI정책 전략·조정을 위한 거버넌스라 할 수 있고 공공AI법의 거버넌스는 위원회 차원에서 조정된 AI관련 정책을 공공기관에서 적용·집행에 필요한 거버넌스 조직에 해당한다.

〈그림 5-1〉 AI기본법과 공공AI법에 따른 국가 AI거버넌스 구조



출처: ChatGPT로 생성(2026.3.17.)

인공지능기본법은 국가차원의 AI정책을 총괄하는 전략적 조정체계를 규정하고 있어 국가인공지능전략위원회를 중심으로 각 분과위원회, 특별위원회, 그리고 부처 차관급, 시도의 부지사급으로 구성되는 인공지능책임관 협의회를 포함하는 그 자체로 다층적 거버넌스를 규정하고 있다. 이런 거버넌스 구조는 부처 간 정책을 협의·조정하고 국가 정책과 전략의 일관성을 유지하기 위한 것으로 보인다. 반면 공공AI법은 각 공공기관 내부에서 AI 정책을 실제 집행하기 위한 운영체계의 골간을 규정하고 있다. 공공기관의 장은 AI 및 데이터 기반 행정에 대한 총괄 책임을 지며, 이를 보조하기 위해 AI-CDO를 임명하도록 하였다. 따라서 AI기본법과 공공AI법에 따른 AI거버넌스는 위의 그림처럼 구조와 기능을 세 가지 계층으로 구분할 수 있다.

첫째, 전략계층은 국가인공지능전략위원회로 구성되며, 국가 AI 정책의 방향설정과 주요 의사결정을 담당한다. 이 계층은 정책 목표와 우선순위를 정의하는 역할을 담당하게 된다.

둘째, 조정계층은 분과위원회, 특별위원회, 그리고 인공지능책임관협의회로 구성되며, 전략 계층에서 설정된 정책방향을 부처간 정렬하고 정책간 충돌을 조정하는 기능을 담당한다. 이 계층이 AI정책의 일관성을 유지하는 핵심 메커니즘으로 보이며 협의회에서 얼마나 정책조정 과정이 효율적이고 효과적으로 이루어지느냐에 따라 정책의 성과에 결정적 영향을 줄 수 있다.

셋째, 실행계층은 공공기관의 장과 AI-CDO로 구성되며, 정책을 실제 행정서비스와 시스템으로 구현하는 역할을 담당한다. 이 계층은 정책의 실질적 성과를 확정짓는 단계에 해당한다.

이런 구조는 결과적으로 전략-조정-실행으로 이어지는 선형적 정책흐름을 형성하며 기능별로 분리된 계층형 거버넌스로 규정할 수 있다. 이런 기능적 분화가 성공적으로 작동하여 효율적이고 유연한 통제가 이루어질 수 있지만, 동시에 구조적 리스크도 함께 지게 된다.

첫째, 조정기능과 실행기능이 혼용될 경우 책임구조가 불명확해질 우려가 있다. 가령, 책임관협의회가 실행기능까지 수행하게 될 경우 정책실패의 책임이 분산되고 정책 효과성이 떨어질 수 있다. 아직 제도 시행 초기로 선불리 판단하기 어려우나 부처의 인공지능책임관은 위원회의 요청으로 기관의 장이 지명하고 AI-CDO는 각 공공기관의 장이 임명하게 되어 있어 동일한 직책으로 운영이 가능하며, 이럴 경우 정책 조정과 실행의 연계와 피드백이 보다 효율적으로 이루어질 수 있다. 다만 행안부 장관이 소집하는 AI-CDO협의회와 위원회가 운영하는 인공지능책임관협의회가 얼마나 기능적으로 계층적으로 구분된 역할을 할 수 있는지에 따라 정책조정과 집행의 실효성과 책임성이 달라질 수 있다.

둘째, 전략계층과 실행계층 간 연결이 충분히 제도화되지 않을 경우 정책 불일치가 발생할 가능성이 있다. 가령 부처간 정책은 정렬되었지만 기관 단위 실행이 이를 반영하지 못한다면, 또는 기관단위 실행은 충분히 이루어지고 있지만 정작 조정계층에서 이를 충분히 반영하지 못하는 등의 불일치가 발생한다면 정책집행의 성과를 기대하기 어려울 수 있다.

셋째, 협의체 기반 구조는 책임이 분산되는 경향이 있으며, 반대로 단일 책임과 구조는 과도한 책임 집중을 초래할 수 있다. 이런 이중적 리스크를 관리할 수 있도록 거버넌스 설계가 이루어져야 한다.

1.3 인공지능윤리위원회와 AI-CDO의 협력 및 견제

공공분야의 AI거버넌스의 성공적 정착을 위해서는 거시적 윤리원칙을 수립하는 AI 윤리위원회와 기관 차원에서 미시적 실행을 담당하는 AI-CDO간의 유기적 협력관계

가 필수적이다. 이는 공공기관에서 AI기술의 진흥과 AI기반 행정의 신뢰성을 확보하기 위한 일면 상충된 목표를 균형있게 달성하기 위한 것이다.

앞서 살펴본 AI거버넌스는 '부처간 조정 메커니즘'과 '프로그램 집행권한'으로 명확히 구분된다. 인공지능기본법에 따른 책임관협의회는 부처간 정책 중복을 방지하고 전략적 일관성을 확보하는 조정자 역할을 수행한다. 반면 공공AI법에 따른 AI-CDO는 기관 내에서 AI 시스템을 직접 도입하고 운영하는 집행자로서의 권한을 가진다. 인공지능기본법 제28조는 인공지능사업자가 윤리원칙 준수를 위해 '민간자율인공지능윤리위원회'를 설치할 수 있도록 규정하고 있다. 공공기관은 내부 혹은 외부 전문가가 참여하는 윤리위원회를 구성하여 거버넌스의 신뢰성을 보완할 수 있다.

윤리위원회는 실행계층인 AI-CDO를 감시하고 조언하는 '규범적 감독기구'의 성격을 갖는다. 위원회는 기술적 효율성을 중시하는 실행부서와 독립되어 다음과 같은 역할을 수행하게 된다(법 제28조 제2항).

1. 윤리원칙 가이드라인 수립: 기관 특성에 맞는 윤리원칙 수립 및 행동지침 제시
2. 고위험 서비스 심의: 국민의 기본권에 영향을 미치는 '고영향 AI' 도입 시 알고리즘의 편향성과 투명성을 독립적으로 검토
3. 조사 및 감독: AI시스템 운영 결과나 인권침해 여부를 조사하고 개선을 권고함으로써 민주적 통제 기능 수행

AI-CDO와 윤리위원회 관계는 '전략적 집행'과 '규범적 통제'의 상호보완적 관계로 정의할 수 있다. AI-CDO는 위원회가 수립한 윤리원칙을 기술적 규범으로 번역하여 시스템에 내재화하고, 윤리위원회는 AI 도입 과정에서의 '윤리적 맹점'을 견제해야 한다. 특히 공공분야 인공지능 영향평가 수행 시, 위원회는 평가의 객관성을 담보하고 위험관리방안의 적정성을 심의함으로써 행정의 정당성을 확보해야 한다. 이처럼 일견 대립되는 기능과 역할을 담보하는 것처럼 보이지만 두 기구가 서로 정보를 차단하고 회피하는 비협력적 대립관계가 아닌, 정보공유와 소통을 통한 협력을 바탕으로 견제와 균형의 관계를 유지하는 것이 AI기반 행정의 신뢰성 확보를 위해 무엇보다 중요하다.

인공지능기본법과 곧 시행될 공공AI법에 따라 본격화되는 AI거버넌스 체계는 AI전략위원회-AI책임관협의회-AI-CDO로 이어지는 계층 구조를 갖추고 있다. 여기에 AI

윤리위원회가 조직 내 규범적 감독자로 제도적으로 안착한다면 ‘진흥’과 ‘신뢰’가 균형을 이루는 견제와 균형을 통한 안정적 거버넌스 모델로 진화할 수 있을 것이다. 공공기관의 AI-CDO의 실행력과 윤리위원회의 합리적 견제를 유기적으로 결합하여 공익을 증진하는 도구로 AI를 활용할 수 있을 것이다.

2. 인적 역량강화 및 조직문화 혁신 전략

2.1 인공지능 관리자로서의 공무원 역량강화 로드맵

AI-CDO와 인공지능책임관은 국가 AI거버넌스에서 조정과 실행 계층을 연결하는 중요한 역할을 담당한다. AI관련 전문성과 관련 정책분야 조정역량을 갖추어지지 않으면 AI정책의 현장적용과 적용효과에 대한 피드백 반응이 어렵고진흥과 통제의 균형도 갖추기 어려워진다. 공공 AI거버넌스의 최종적 성공은 기술이나 법제도가 아닌, 이를 운용하는 ‘사람’에게 달려있다. 공공AI법에 규정된 공공기관 장의 소속 임직원 인공지능 활용 역량강화 교육훈련 실시의무도 이런 인식에서 출발한다⁵⁴⁾.

행정안전부는 공무원의 AI활용 역량강화를 위해 2024년부터 행정지원 서비스 개발 및 시범운영을 시행하고 있으며, 2026년까지 전 직원을 대상으로 한 상시 교육체계를 구축할 계획이다. 교육의 핵심은 단순히 AI 활용 방법 학습에 그치는 게 아니라 ‘지능형 인공지능 관리자’로서의 소양을 갖추는 데 있다:

- 1) AI 리터러시: 인공지능의 작동원리와 한계(환각, 편향성)를 명확히 인식하는 능력
- 2) 비판적 검토 능력: AI 생성 결과물을 맹목적으로 수용하지 않고, 법적·윤리적 관점에서 비판적으로 검토하고 최종 책임을 지는 자세
- 3) 보안 및 윤리의식: 망분리 환경의 보안수칙을 준수하고, 공공기관의 AI 윤리기준에 따라 업무를 수행하는 도덕적 엄격성

54) 공공AI법 제28조제1항

행정안전부는 보도자료를 통해 공공분야 인공지능 전문가 2만 명을 양성하고 전 직원 AI 활용역량 강화 계획을 발표하였다.⁵⁵⁾ 계획에 따르면 모든 공공기관이 함께 활용할 수 있는 AI 교육 커리큘럼을 마련하고 전 직원의 AI 리터러시 강화와 공직 내부 전문가를 양성하여 2030년까지 AI전문가 2만명 양성할 계획이다. 이를 위해 행정안전부는 4단계 ‘공공 AI역량 트랙’을 마련하여 실무활용 교육 중심의 보편역량 트랙뿐만 아니라 전문인재 트랙까지 운영하여 AI전문인재로 양성한다는 계획이다. 또한 행정·공공기관 직원 대상의 AI기술을 활용한 실무과제 수행을 통해 문제해결 역량을 인증하는 ‘AI챔피언 인증제’도 연계 운영할 계획이다.

〈표 5-3〉 행정안전부의 AI교육과정 공공 AI역량 트랙

① 보편역량	② 전문인재		
(트랙1) AI활용	(트랙2) AI융합	(트랙3) AI개발	(트랙4) AI마스터
전 직원	실무자(비IT 직렬) AI챔피언 그린	IT담당 AI챔피언 블루	IT담당(고급) AI챔피언 블랙(26년 예정)
AI 기본 이해와 행정업무 적용을 위한 활용방법 교육	AI 기술과 노코드 도구를 활용해 AI 서비스 기획·구현	AI 모델 개발과 데이터분석 역량을 키우는 기술 교육	고급AI기술 이해, 기관별 AI혁신을 이끄는 거점리더

출처: 행정안전부 보도자료(2025.9.24.)

AI기반 행정 활성화를 위해서는 담당 부처 공무원의 역량강화가 일차적으로 선행되어야 하겠지만 AI기술발전과 신뢰성 제고를 위해서 이를 이용하는 이용자의 AI리터러시도 중요하다. 또한 AI활용에 있어 디지털 디바이드와 같은 양극화를 방지하고 AI활용을 국민 기본권 차원에서 보장할 필요가 있다. 이런 관점에서 정부는 더 나아가 전국민 AI 활용역량 강화를 표방하고 ‘모두의 AI’ 구현을 위한 ‘전국민 AI 활용 역량강화 및 일상화 방안’을 관계부처 합동으로 제시하였다.⁵⁶⁾

2.2 책임 공백 해소 및 인간개입의 원칙(Human-in-the-loop) 확립

생성형 AI에서 더 나아가 AI에이전트 등장으로 AI에 의한 완전 자율적 의사결정과

55) 행정안전부 보도자료(2025.9.24.). ‘공공분야 인공지능 전문가 2만명 양성하고, 전 직원 AI활용역량 강화한다’.

56) 관계부처합동 보도자료(2026.3.11.). 전국민 AI 활용역량 강화, K-문샷 미션 확정으로 대한민국 AX·전략기술 육성 가속화.

업무수행이 가능해짐에 따라 행정의 책임주체가 누구에게 있는지 명확히 제시할 필요가 있다. 앞서 설명한대로 공공AI법에서는 이러한 AI기반 행정의 ‘책임공백’문제를 해결하기 위해 제3조제5항에서 ‘공공기관은 인공지능을 정책 수립 및 의사결정에 활용하는 경우에는 그 결정에 대한 최종적인 권한과 책임이 해당 공공기관에 있음을 명확히 하여야 한다’고 규정하고 인간이 의사결정 경로의 핵심에 항상 위치하고 AI기반 의사결정의 최종 책임을 지도록 요구하고 있다. 이는 공공기관 의사결정 과정에서 AI는 의사결정의 주체가 아닌 행정 보조수단의 지위를 가지며, 주체는 인공지능을 활용하는 공공기관임을 의미한다. 따라서 기관의 AI기반 행정의 신뢰성 확보와 위험관리 업무를 총괄하는 AI-CDO는 기관 내 모든 AI시스템 설계 시 인간이 최종 의사결정에 개입할 수 있는 안전장치를 반드시 마련할 책무를 진다. 이런 법적 책임을 이행하기 위해 인공지능기반 행정업무의 위험도와 자율성 수준에 따라 인간개입 수준을 유형화하고 이에 따른 의사결정 책임성 확보 기제를 구축할 수 있다.

〈표 5-4〉 AI기반 행정의 인간개입 유형에 따른 책임성 확보 메커니즘

개입유형	개입방식	적용 사례 예시
Human-in-the-loop; HITL	AI권고안에 대해 인간이 실질적 재검토 후 최종 결재	복지급여 중단, 공무원 임용·징계, 고위험 범죄예측 등 권리제한적 처분
Human-over-the-loop; HOTL	AI가 자동 처리하되 인간은 예외적 상황에만 개입하여 수정	지능형 교통관제, 환경오염 실시간 단속, 단순 과태료 부과 등 반복적/빈번한 행정
Human-out-of-the-loop; HOOTL	AI가 전담하되 인간은 정기적 표본감사(audit) 및 이의신청 시 개입	단순 정보제공 챗봇, 시설물 자동제어 등 수해적/기술적 행정

출처: 저자 작성

법 제3조제5항의 최종 책임 구현을 위해서는 개입 유형에 따른 AI기반 행정 책임성 확보 메커니즘을 구축하고 의사결정 사전, 실행, 사후로 단계를 나누어 다음과 같은 거버넌스 체계를 갖추어야 한다.

1) 사전 단계: AI영향평가 및 유형 배정

메커니즘: 새로운 AI 시스템 도입 시 AI-CDO는 해당 업무가 시민의 기본권에 미치는 영향을 평가하여 HITL/HOTL 중 어떤 개입모델을 적용할지 사전에 검토하고 확정

현실 적용 가능성: 개정된 공공AI법 제32조(공공분야 인공지능 영향평가 등)(본 조문은 27년2월28일 시행예정)와 연계하여 운영

2) 실행 단계: 설명가능한 AI(XAI)와 대시보드 구축

메커니즘: 담당 공무원이 AI의 판단근거를 모를 경우 ‘형식적 결재’에 그칠 수 있기 때문에 AI가 왜 그런 판단을 했는지 핵심 변수를 보여주는 인터페이스 제공

현실 적용 가능성: 기술적으로 이미 XAI 기법이 상당한 수준으로 발전하고 있기 때문에 시스템 설계 및 조달 단계에서 이를 요구 사양에 반영하여 운영

3) 사후 단계: 이의제기권 및 책임소재 규명

메커니즘: AI 결정에 불복하는 시민을 위해 ‘인간에 의한 재심사’를 청구할 권리를 명문화

현실 적용 가능성: 이미 법 제3조제5항에 ‘최종 책임은 공공기관’에 있음을 명확히 해야 한다고 규정하였기 때문에 시민이 이의를 제기할 경우 담당 공무원이 AI의 논리를 검증하여 답변해야 할 법적 의무가 발생하는 것으로 보아야 하며, 이를 절차적으로 명확히 적용하기 위한 하위 규정을 만들어야 함

현실적으로 이런 책임성 확보 기제를 충분히 구축하기는 주어진 인력 및 예산 제약으로 어려울 수 있으나 이보다 더 경계해야 할 것은 행정편의주의로 HITL을 적용해야 하지만 실상 HOTL로 운영되거나 이보다 더 형식적인 점검으로 그칠 수 있으므로 이

러한 책임회피가 발생하지 않도록 감시하고 조정하는 것 역시 법 제19조에서 규정하고 있는 AI-CDO의 핵심 임무가 되어야 한다.

2.3 범정부 AI공통기반 및 민관 협력생태계 구축

개별 공공기관이 각자 필요한 AI모델을 개발한다면 막대한 예산 낭비와 기술적 파편화를 초래할 수 있다. 따라서 정부는 범정부 차원의 공통 인프라를 구축하고 민간의 전문 역량을 수용하는 전략을 취하고 있다.

행정안전부와 과학기술정보통신부는 공공기관이 중복 투자없이 신속하고 안전하게 AI를 도입할 수 있도록 ‘범정부 생성형 AI플랫폼’을 구축하고 있다⁵⁷⁾. 이 플랫폼은 보안성이 확보된 환경에서 민간의 초거대 AI모델을 활용할 수 있도록 지원하고 고성능 클라우드 자원을 공유할 수 있는 기반을 제공한다.

AI-CDO는 인공지능 도입 시 이 공통기반 플랫폼을 우선적으로 이용해야 하는 ‘우선 이용노력 의무’를 지게되며, 이를 통해 보안 등급이 혼재된 행정 데이터가 부적절하게 유출되지 않도록 망분리 체계와 안전하게 연계하는 기술적 조치를 선행적으로 제공 받게 된다.

이와 함께 민간의 전문성을 공공부문에 효율적으로 수용하기 위해 ‘공공 인공지능·데이터 협회’ 설립을 추진하고 있다. 협회는 기술표준의 제정, 제도개선 건의, 전문인력 양성 지원 등의 역할을 수행하게 되며, 정부와 민간 사이의 가교 역할을 기대할 수 있다.

3. 참여적 거버넌스 구축 전략: 데이터 스튜어드십과 트러스트

3.1 데이터 스튜어드십

최근 데이터 스튜어드십(data stewardship)에 대한 강조는 선언적 수준의 ‘AI윤리’의 한계에서 벗어나 데이터 주체인 국민의 권익을 실질적으로 대변하고 법적 책임성을 담보하는 능동적 거버넌스 모델을 구축하려는 흐름으로 볼 수 있다. 이러한 흐름은 그

57) 앞 장의 국내외 ADM 도입 사례 참조

간 AI 윤리원칙이 구체적 실천방안이나 법적 강제력이 결여되어 기업들이 AI개발과 활용에 있어 윤리적 책임을 다하는 것처럼 보이게 하면서 실제로는 문제적 관행을 지속하는 ‘윤리 워싱(ethics washing)’의 수단으로 악용되고 있다는 우려와 연결되어 있다. 선언적 AI윤리 원칙을 AI 데이터 거버넌스에 자발적으로 적용할 것을 권고하는 방식의 접근은 AI 거버넌스의 핵심 요소인 책임성, 정당성, 신뢰성을 확보하는데 실패하였고, 이러한 원칙을 집행할 수 있는 구체적 메커니즘 부재와 윤리원칙 적용을 위한 인센티브가 없는 상황에서는 공공부문 AI가 요구하는 높은 수준의 공적 책무를 감당하기에는 부족하고 한계가 있다.

이러한 선언적 윤리의 한계를 극복하기 위한 대안으로 ‘데이터 스튜어드십’ 모델이 부각되고 있다. 데이터스튜어드십은 단순히 데이터를 기술적으로 관리하는 것을 넘어, 데이터 주체의 이익을 대변하는 신뢰할 수 있는 중개자(스튜어드)가 데이터의 보존, 관리활용에 대한 책임을 지는 능동적이고 참여적인 거버넌스 시스템을 의미한다⁵⁸⁾.

데이터스튜어드십 모델의 핵심은 ‘답변가능성/책임성’에 있다. 데이터 스튜어드는 AI개발자나 행정기관의 편이가 아닌, 오직 데이터 주체인 국민의 가치와 권익보호를 최우선 목표로 삼는다. 특정 수혜자와 분리되어 추상적으로 논의되는 AI 윤리원칙과 달리, 데이터 스튜어드십은 ‘수혜자를 위한 국민의 구체적인 책무’를 전제한다는 점에서 근본적 차이가 있다. 기존 모델에서 국민의 데이터는 국가가 공익을 위해 ‘활용’하는 자원으로 취급되었고 국민은 수동적인 데이터 제공자에 머물러 있다. 그러나 데이터 스튜어드십 모델에서 스튜어드는 데이터 권리를 국민을 위해 ‘신탁’받아 관리하는 법적 의무를 지닌 수탁자의 지위를 가지게 된다. 이는 권력의 중심을 국가에서 데이터의 본래 주인인 국민으로 이동시키는 중요한 변화로 국민은 더 이상 단순한 데이터 포인트가 아니라, 법적으로 보호받고 집행 가능한 권리를 가진 수혜자가 된다. 이는 국가의 데이터 활용이 당연한 권리가 아니라, 엄격한 법적 감독하에 위임된 책임이라는 새로운 사회적 계약으로 인식하는 것이다.

3.2 데이터 트러스트와 신의성실의무

데이터 스튜어드십 개념을 현실에서 구현하기 위한 가장 효과적인 법적 메커니즘은

58) Bartlett, B.(2025).

‘데이터 트러스트(Data Trust)’ 모델이다. 데이터 트러스트는 신탁법 원리를 데이터 거버넌스에 적용한 것으로 데이터 수탁자, 즉 데이터 스튜어드가 수혜자(국민)의 이익을 위해 데이터 관련 권리를 보유하고 관리하는 법적 구조를 말한다.

이 모델이 작동할 수 있는 강력한 힘은 수탁자가 수혜자에 대해 부담하는 ‘신의성실의무(fiduciary duty)’에서 나온다. 신의성실의무는 수탁자가 자신의 개인적인 이익이나 제3자의 이익보다 수혜자의 이익을 최우선으로 고려해야 하는 상법상의 가장 강력한 수준의 법적 의무이다. 만약 수탁자가 신탁의 목적을 벗어나 데이터를 부당하게 활용하거나 관리 소홀로 피해를 발생시킬 경우, 수혜자는 법적 절차를 통해 그 책임을 묻고 구제받을 수 있다. 이는 기존 AI 윤리체계에서는 볼 수 없었던 강력한 ‘집행 가능성’을 부여하는 핵심 장치로 거버넌스의 실질적인 집행을 담보할 수 있다.

또한 데이터 트러스트 모델은 공공의 이익과 민간의 혁신사이의 고질적인 이해상충을 해결할 수 있는 제도적 틀을 제공한다. 현재 공공 AI 개발은 구글, 팔란티어와 같은 거대 기술기업과의 직접적인 파트너십에 의존하는 경우가 많아, 이해상충, 투명성 부족, 공공 데이터의 상업적 독점 등의 문제를 야기한다. 데이터 트러스트는 이러한 문제를 해결하기 위해 데이터의 ‘통제’와 AI의 ‘개발’을 분리하는 독립적인 중재자 역할을 수행할 수 있다. 즉 데이터 트러스트가 국민을 대신하여 공공 데이터를 안전하게 관리하고 통제하며, 민간 기업은 이 트러스트와의 투명한 계약을 통해 데이터에 접근하여 AI를 개발하게 된다. 이 과정에서 데이터 트러스트는 신의성실의무에 따라 데이터 활용 범위, 프라이버시 보호, 공익 환원, 지적재산권 등 모든 조건을 수혜자인 국민의 이익을 극대화하는 방향으로 설정하고 감독할 수 있다.

데이터 트러스트 구성은 일반적으로 데이터를 제공하는 ‘데이터 제공자’, 데이터에 접근하여 가치를 창출하는 ‘데이터 이용자’, 데이터 접근 및 이용 관련 의사결정을 총괄하는 ‘수탁자(trustees)’, 그리고 실무 인력으로 이루어진다. 실제 데이터의 물리적 저장·관리보다는 데이터에 관한 ‘권리’를 관리하는 데이터 라이선싱 관리기구로서 역할 하게 된다. 즉 데이터 제공자는 데이터 사용권을 트러스트에 라이선싱하고, 트러스트는 설정된 목적에 따라 제3자의 접근 허용여부를 결정하는 구조이다.

실제로 국가가 이런 데이터 트러스트 모델의 공적 감독기구로서 데이터 수탁자의 역할을 담당하는 사례와 함께 민간이 직접 데이터 트러스트를 구성하여 운영하는 사례도 찾아볼 수 있다. 민간이 자율적인 데이터 트러스트나 협동조합을 구성하여 운영하는 사

례로는 스위스의 MIDATA, 스페인의 Salus, 싱가포르의 MRI 데이터트러스트, 미국의 Driver's Seat, 유럽의 polypoly, 네덜란드의 JoinData, WILDLABS 등이 있다. 국가가 공적 감독기구로 데이터 트러스트 모델을 운영하는 사례로 영국의 INSIGHT 모델을 들 수 있다. 영국의 INSIGHT(안과 및 오쿨로믹스 헬스데이터 연구허브)는 데이터 트러스트 모델의 대표적 사례로 단순히 데이터 저장소 역할을 넘어서 독립적인 제3의 기구가 데이터를 관리하고 활용에 대한 의사결정을 내리는 법적·조직적 구조를 갖추고 있다. 우선 독립적 의사결정구조로 DataTAB(Data Trust Advisory Board)는 환자, 일반시민, 보건의료 전문가 등 다양한 이해관계자로 구성된 독립적인 패널로 연구자들이 INSIGHT의 데이터에 접근 신청하면, 신청이 환자와 대중에게 실질적인 이익이 되는지, '윤리적으로 타당한지'를 독립적으로 심의하고 권고안을 제시한다. 즉 데이터를 보유한 기관(NHS 병원)이 직접 승인 여부를 결정하는 것이 아니라, 수혜자(국민/환자)를 대변하는 독립적 기구에게 데이터 활용 여부에 관한 의사결정을 위탁함으로써 신뢰를 확보하였다. 실제 작동 과정을 보면, 학계나 산업계 등 연구자가 데이터 사용신청을 하면 허브 운영진이 기술적·법적 관점의 실무 사전 검토를 진행한다. 사전검토 완료 후에는 DataTAB의 심의가 이루어지는데, 여기서 신청의 윤리성과 공익적 가치를 평가한다. 이때 중요한 기준이 '이 연구가 환자에게 어떤 도움을 주는가'이다. 이에 따라 DataTAB은 일차적인 데이터 통제기관인 데이터 보유 병원에게 승인 또는 거부 권고를 내리고, 병원은 특별한 사유가 없는 한 이 권고를 따라야 한다. 이런 심의과정과 결정 사항은 회의록으로 작성되어 투명하게 공개하고 대중의 감독을 받게 된다.

이처럼 데이터 트러스트 모델은 데이터를 수집·보유한 기관들(INSIGHT의 경우 병원들)이 독립적인 제3의 기구에 데이터의 접근·관리 및 활용에 관한 의사결정 권한을 위탁하고, 수탁자인 해당 기구가 데이터 제공자/수혜자(환자/일반국민)의 이익을 위해 데이터를 관리하는 거버넌스 체계이다. 이런 데이터 트러스트 적용 사례는 공공부문의 AI 데이터 거버넌스 운영을 위한 합의가 적지 않다. 행정기관의 입장에서는 개인정보가 포함된 데이터 공개는 데이터 활용에 따른 프라이버시 침해 위험과 법적 책임이 따르기 때문에 주저하게 되는데, 데이터 트러스트 모델이 도입된다면 다음과 같은 측면에서 변화를 기대할 수 있을 것이다.

1) 데이터 관리 인식의 전환 : 소유권에서 '공공재 인프라'로

데이터 트러스트는 행정 데이터를 기관의 소유물이 아닌 국민으로부터 위탁받은 '공공 인프라' 혹은 '공유자원'으로 재정의한다. 이러한 인식변화는 데이터가 행정적 부산물이 아니라 도로나 통신망처럼 사회적 가치창출을 위한 핵심 자산이란 정책적 근거를 제공하며, 비공개 사유를 기관이 증빙하는 전면 개방 체계로의 전환을 유도할 수 있다.

2) 의사결정의 독립성과 법적 책임 완화

행정기관의 장이 단독으로 결정하던 데이터 접근 승인을 독립적인 '수탁자'나 '데이터 트러스트 자문위원회'로 이전할 수 있다. 공공AI법에 따르면 AI-CDO가 결정하고 기관장이 최종 결재하는 방식의 의사결정 과정을 거쳐 데이터 사용 승인이 이루어질 것으로 예상되지만, 인공지능기본법에 따른 인공지능윤리위원회 또는 독자적인 DataTAB과 같은 데이터트러스트 자문위원회를 '수탁기구'로 지정하여 데이터 접근 및 활용에 관한 의사결정권을 이전할 수 있다. 이때 '수탁기구'의 독립성과 신의성실의무 부여가 중요하다. 이해관계자가 참여하는 독립 패널이 데이터 활용의 공익성과 윤리성을 직접 검증하는 '독립적 심의'를 통해 기관의 독자적 결정에 따른 정치적 사회적 부담에서 벗어날 수 있다. 또한 수탁자에게 충실의무와 주의의무를 법적으로 부과함으로써, 데이터가 목적 외로 활용되거나 오용될 경우 수탁자가 법적 책임을 지는 구조가 형성되어 기관의 잠재적 리스크가 분산될 수 있다.

3) 기술적 안전장치 도입: 'Data-to-Compute' to 'Compute-to-Data'

개인정보가 포함된 원천 데이터를 외부로 반출하는 대신, 데이터 트러스트 내의 '안전 연구 환경(Trusted Research Environment, TRE) 혹은 '개인정보 안심구역'을 활용하는 방식으로 변화한다. 데이터는 기관의 통제하에 있는 안전한 서버(Safe Haven)에 머물며, 연구자는 승인된 범위 내에서만 분석 결과값을 가져갈 수 있는 폐쇄적 분석 환경을 구축할 수 있다. 재식별 위험을 최소화하기 위해 동형 암호, 차분 프라이버시, 합성 데이터 기술이 거버넌스 체계 내에서 결합되어 데이터의 유용성을 유지하면서도 완벽한 비식별화를 보장할 수 있다.

4) 사회적 신뢰 구축 및 동의체계 효율화

기존의 복잡하고 형식적인 '고지 및 동의(notice-and-consent)' 모델에서 벗어나 트러스트가 데이터 주체의 이익을 대변하는 중개자가 되어 사회적 합의를 도출할 수 있다. 시민들이 트러스트의 의사결정에 참여하는 참여적 거버넌스를 통해 '어떤 목적의 AI 학습에 데이터를 제공할 것인가'를 집단적으로 결정함으로써 개인정보 활용에 대한 정당성을 확보하고 민주적 통제를 실현할 수 있다. 개인정보 안심구역과 같은 모델에서는 강화된 보안을 전제로 가명정보의 장기 보관(예: 5년 이상) 및 제3자 재사용이 허용되어, 시계열 분석 등 지속적인 연구가 가능하다.

개인정보 관련 규제의 유연화가 동반되어야 하지만 핵심은 독립적인 데이터 수탁기구의 구성과 이해관계자 참여를 통한 공익성, 수혜자 이익 중심의 의사결정이 이루어질 수 있도록 노력이 필요하다.

〈참고문헌〉

- 과학기술정보통신부. (2026). '인공지능기본법' 22일 시행 ... 생성형 AI 결과물 '워터마크' 표시의무. 2026.01.21. 보도자료.
- 과학기술정보통신부·NIA. (2026). 고영향인공지능 판단 가이드라인. 2026.01.29.
- 관계부처 합동. (2026). 전국민 AI 활용역량 강화, K-문샷 미션 확정으로 대한민국 AX·전략 기술 육성 가속화. 2026.03.11. 보도자료.
- 금융위원회·금융감독원·한국신용정보원·금융결제원·금융보안원·은행연합회·금융투자협회·생명보험협회·손해보험협회·여신금융협회. (2022). 금융분야 AI 개발·활용 안내서.
- 김윤권·최순영. (2022). 미래예견적 국정관리와 정부운영(III): 지능형 정부서비스의 지향 가치와 전달체계를 중심으로. KIPA 연구보고서 2022-02. 한국행정연구원.
- 대통령실. (2025). '이대통령' AI 고속도로 구축해 도약과 성장의 미래 열어야. 2025.11.04. 보도자료.
- 대통령실. (2025). 이재명정부 123대 국정과제. 정책브리핑. 2025.09.16.
- 대한민국 정부. (2025). 인공지능 발전과 신뢰 기반 조성 등에 관한 기본법. 법률 제 20676호.
- 라기원·이유봉·윤길준. (2024). AI 활용과 대응을 위한 입법분야 조사연구. 세부 과제 24-20-④. 한국법제연구원.
- 우지숙. (2025). 디지털 거버넌스의 새로운 패러다임으로서 소버린 AI에 관한 연구. 경제규제와 법. 18(2) 통권 36호. pp. 32-61.
- 윤정현. (2025). 한국형 소버린 AI 국가전략의 모색, INSS 전략보고. 국가안보전략연구원.
- 이유봉. (2022). AI기반 행정을 위한 입법방안 연구. 연구보고 22-01. 한국법제연구원.
- 이유봉. (2024). AI 영향평가를 위한 입법연구. AI혁신법제 연구 24-20-①. 한국법제연구원.

- 이유봉·장민선·이경희·김명아·배건이·최경호·박가림·손권상·김경재·박호연·김현민·김가연·고의열·문병우·황예인. (2023a). 데이터 기반 이해충돌방지법 운영시스템 마련 연구. 경제·인문사회연구회 협동연구사업 23-04-01. 한국법제연구원.
- 이유봉·장민선·이경희·황지은·김경재·박호연·박가림·손권상·강정아. (2023b). 인공지능 기반 「청탁금지법」 유권해석 자동질의응답시스템 모델 개발 연구. 경제·인문사회연구회 협동연구사업 23-52-01. 한국법제연구원.
- 이종한·원소연·심우현. (2022). 규제기관 거버넌스 개선방안. KIPA 연구보고서 2022-05. 한국행정연구원.
- 이환성·장효진·최돈위·금재덕·박진술·오동진·신계균·하현상·허형조. (2023). Artificial Intelligence(AI)를 활용한 공공부문 인재채용과정에서의 공공가치 증진방안. 경제·인문사회연구회 협동연구사업 23-08-01. 한국행정연구원.
- 임성근·은재호·허준영·조유선·최병윤·서영선·장신재·박외진·김종희·최종명·이수기·김경원·이창용·김민휴·공득조·임현택·신성호. (2024). AI 기반 갈등관리 DB 구축 및 운영방안 연구. 경제·인문사회연구회 협동연구사업 24-04-01. 한국행정연구원.
- 임영모·김리나·안성원. (2025). 2024년 공공부문 AI 도입현황 연구. 연구보고서 RE-188. 소프트웨어정책연구소.
- 조세현·우하린·신승윤·박주원·김재선. (2023). 디지털플랫폼정부 구현을 통한 정부혁신 이행방안 연구: RPA(Robotic Process Automation) 등 업무자동화 및 인공지능 기술 활용을 중심으로. KIPA 연구보고서 2023-02). 한국행정연구원.
- 한국정보통신기술협회·과학기술정보통신부. (2025). 인공지능 투명성 확보 가이드라인. 한국행정연구원. (2024a). AI와 함께 일하는 정부: 제도·거버넌스·체제.
- 한국행정연구원. (2024b). 공공부문 AI 활용 및 디지털화 거버넌스 분석. 정부조직진단보고서.
- 한국행정연구원. (2025a). AI 기반 행정의 민주성: 민주적 거버넌스와 시민의 알고리즘 이해권을 중심으로. KIPA BRIEF 스페셜 이슈 1.
- 한국행정연구원. (2025b). AI·디지털 기술 기반 원스톱 서비스 혁신 트렌드와 사례, KIPA 정부혁신 트렌드, 7,

- 한국행정연구원. (2025c). 최근 미국 행정부의 AI 정책 변화와 시사점. KIPA 정부혁신 트렌드.
- 한국행정연구원·행정안전부. 정부혁신을 위한 공공부문 AI 활용 방안 [포럼 자료집]. 2024년 11월 14일 제6차 정부혁신 미래전략 포럼. 광주.
- 행정안전부. (2025). 공공분야 인공지능 전문가 2만명 양성하고, 전 직원 AI 활용역량 강화한다. 2025.9.24. 보도자료.
- 행정안전부. (2026). ‘AI민주정부’ 이끄는 공공AI 법제도 기반인 ‘공공AI법’ 국회 본회의 통과. 2026.01.29. 보도자료.
- 허성욱. (2024). 인공지능에 근거한 행정처분에 대한 사법심사이론 연구. 연구총서 2024-16. 사법정책연구원.
- 홍성민·이유봉·라기원. (2024). AI 관련 인식조사를 통한 입법정책 연구. AI혁신법제 연구 24-20-③. 한국법제연구원.
- 화우 법무법인. (2025). ‘공공AI법’ 국회 본회의 통과. 2026.02.03.

〈영문자료〉

- Ada Lovelace Institute, AI Now Institute, & Open Government Partnership. (2021). Algorithmic accountability for the public sector: Learning from the first wave of policy implementation. <https://www.opengovpartnership.org/documents/algorithmic-accountability-public-sector/>
- Agbabiaka, O., Ojo, A., & Connolly, N. (2025). Requirements for trustworthy AI-enabled automated decision-making in the public sector: A systematic review. *Technological Forecasting and Social Change*. 215:124076.
- Amnesty International. (2021). Xenophobic machines: Discrimination through unregulated use of algorithms in the Dutch childcare benefits scandal. Amnesty International Netherlands. <https://www.amnesty.org/en/documents/eur35/4686/2021/en/> [최종인출일: 2026.01.20.]

- Arts, J., & van den Berg, M. (2025). What the Dutch benefits scandal and policy's focus on 'fraud' can teach us about the endurance of empire. *Critical Social Policy*. 45(1):177-187.
- Australian Government. (2024). Centralised Code of Conduct Inquiry Taskforce: Final report.
- Autoriteit Persoonsgegevens. (2020). Methods used by Dutch Tax Administration unlawful and discriminatory. Dutch Data Protection Authority.
<https://www.autoriteitpersoonsgegevens.nl/en/current/methods-used-by-dutch-tax-administration-unlawful-and-discriminatory> [최종인출일: 2026.01.20.]
- Bartlett, B. (2025). Towards accountable, legitimate and trustworthy AI in healthcare: Enhancing AI ethics with effective data stewardship. *The New Bioethics*.
- Bauer, B., Mühlbauer, S., Schlögl-Flierl, K., Weber, E., & Ziehmman, P. (2025). Ethical integration in public sector AI: The case of algorithmic systems in the public employment service in Germany. IAB Discussion Paper No. 12/2025. Nuremberg: Institute for Employment Research (IAB).
- Bellamy, R. K. E., Mojsilovic, A., Nagar, S., Ramamurthy, K. N., Richards, J., Saha, D., Sattigeri, P., Singh, M., Varshney, K. R., Zhang, Y., Dey, K., Hind, M., Houde, S., Kannan, K., Lohia, P., Martino, J., Mehta, S., & Hoffman, S. C. (2019). AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias. *IBM Journal of Research and Development*. 63(4-5).
- Berends, S. (2021). Dutch child benefit scandal: origin and latest developments. European Commission.
<https://ec.europa.eu/social/BlobServlet?docId=24723&langId=en> [최종인출일: 2026.01.20.]
- Berk, R., Heidari, H., Jabbari, S., Kearns, M., & Roth, A. (2018). Fairness in Criminal Justice Risk Assessments: The State of the Art. *Sociological*

- Methods & Research. 50(1):3-44.
- Clarke, R., Michael, K., & Abbas, R. (2024). Robodebt: A socio-technical case study of IS failure. *Australasian Journal of Information Systems*. 28.
- College voor de Rechten van de Mens. (2022). Vooronderzoek naar de vermeende discriminerende effecten van de werkwijzen van de Belastingdienst/Toeslagen. [Netherlands Institute for Human Rights. Preliminary investigation into the alleged discriminatory effects of the Tax and Customs Administration/Benefits' working methods] <https://publicaties.mensenrechten.nl/publicatie/a356efac-8752-4843-a86c-665bb0a98667> [최종인출일: 2026.01.20.]
- de Fine Licht, K. (2025). Resolving value conflicts in public AI governance: A procedural justice framework. *Government Information Quarterly*. 42(2):102033.
- de Fine Licht, K., & Folland, A. (2025). AI in public decision-making: A harm-benefit framework. *Public Administration*. 1-15.
- Diakopoulos, N. (2016). Accountability in algorithmic decision making. *Communications of the ACM*. 59(2):56-62.
- Estonian Government. (2021). KrattAI: National artificial intelligence strategy.
- European Commission. (2023). Commission implementing decision (EU) 2023/... of 10 July 2023 pursuant to Regulation (EU) 2016/679 on the adequate level of protection of personal data under the EU-U.S. Data Privacy Framework. *Official Journal of the European Union*.
- European Union. (2024). Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). *Official Journal of the European Union*.
- Global Partnership on Artificial Intelligence [GPAI]. (2020). Data

- Governance Working Group: A Framework Paper for GPAI's work on Data Governance. November 2020. GPAI Montreal Summit.
- Global Partnership on Artificial Intelligence [GPAI]. (2024). Algorithmic transparency in the public sector: A state-of-the-art report of algorithmic transparency instruments.
- Government of Canada. (2025). Algorithmic Impact Assessment (AIA) tool. Ottawa: Government of Canada.
- Government of Japan. (2024). AI guidelines for business (Ver. 1.01).
- Hadwick, D. (2024). Lessons learned from the toeslagenaffaire. International Conference on Taxpayer Rights.
- Harrison, T. M., & Luna-Reyes, L. F. (2020). Cultivating trustworthy-AI in digital government. *Social Science Computer Review*. 40(2):495-511.
- Hummel, B., Yerkes, M. A., & Bal, M. (2025). 'Unprecedented injustice': Digitalisation and the perceived accessibility of childcare benefits. *Journal of Social Policy*. 54(4):1320-1339.
- IEEE Standard for an Age Appropriate Digital Services Framework Based on the 5Rights Principles for Children. (2021). IEEE Std 2089-2021, 1-54.
- International Organization for Standardization [ISO]. (2023). Guidance on the use of artificial intelligence (AI) for ISO committees.
- ISO·IEC. (2023). ISO/IEC 42001:2023 Information Technology - Artificial intelligence — Management system.
- Jacobin. (2021). The Dutch government's benefits scandal is rooted in stigma against welfare recipients.
<https://jacobin.com/2021/01/dutch-welfare-benefits-childcare-scandal> [최종인출일: 2026.01.20.]
- Jie, Z., Li, L., & Zhiying, Z. (2021). A meta-analysis of Watson for Oncology in application. *Scientific Reports*, 11(1).

- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. In 8th Innovations in Theoretical Computer Science Conference (ITCS 2017). Vol. 67. 43:1-23.
- Lahusen, C., Maggetti, M., & Slavkovik, M. (2024). Trust, trustworthiness and AI governance. *Scientific Reports*. 14(1):20752.
- Nationale Ombudsman. (2017). Geen powerplay maar fair play (Rapport nr. 2017/095). [Nationale ombudsman. Fair play or power play?].
- Norori, N., Hu, Q., Aellen, F. M., Faraci, F. D., & Tzovara, A. (2021). Addressing bias in big data and AI for health care: A call for open science. *Patterns*. 2(10).
- Organisation for Economic Co-operation and Development [OECD]. (2019a). Artificial intelligence in society. OECD Publishing.
- Organisation for Economic Co-operation and Development [OECD]. (2019b). Recommendation of the Council on Artificial Intelligence. Paris: Organisation for Economic Co-operation and Development.
- Organisation for Economic Co-operation and Development [OECD]. (2019c). Scoping the OECD AI principles: Deliberations of the Expert Group on Artificial Intelligence at the OECD (AIGO). OECD Digital Economy Papers, No. 291. OECD Publishing.
- Organisation for Economic Co-operation and Development [OECD]. (2024a). A new dawn for public employment services: Service delivery in the age of artificial intelligence. OECD Artificial Intelligence Papers, No. 19. OECD Publishing.
- Organisation for Economic Co-operation and Development [OECD]. (2024b). AI, data governance and privacy: Synergies and areas of international co-operation. OECD Artificial Intelligence Papers.
- Organisation for Economic Co-operation and Development [OECD]. (2024c). Assessing potential future artificial intelligence risks, benefits and

policy imperatives. OECD Artificial Intelligence Papers.

Organisation for Economic Co-operation and Development [OECD]. (2024d). Collective action for responsible AI in health. OECD Artificial Intelligence Papers. No. 10. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2024e). Explanatory memorandum on the updated OECD definition of an AI system. OECD Artificial Intelligence Papers. No. 8.

Organisation for Economic Co-operation and Development [OECD]. (2024f). Governing with artificial intelligence: Are governments ready?. OECD Public Governance Committee.

Organisation for Economic Co-operation and Development [OECD]. (2025a). AI and the future of social protection in OECD countries. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2025b). AI openness: A primer for policymakers. OECD Artificial Intelligence Papers. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2025c). Governing with artificial intelligence: The state of play and way forward in core government functions. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2025d). Harnessing artificial intelligence in social security: Use cases, governance and workforce readiness. OECD Digital Government Studies. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2025e). How are AI developers managing risks?. OECD Artificial Intelligence Papers. OECD Publishing.

Organisation for Economic Co-operation and Development [OECD]. (2025f). Sharing trustworthy AI models with privacy-enhancing technologies.

- OECD Artificial Intelligence Papers. OECD Publishing.
- Organisation for Economic Co-operation and Development [OECD]. (2025g). Towards a common reporting framework for AI incidents. OECD Artificial Intelligence Papers. OECD Publishing.
- Organisation for Economic Co-operation and Development [OECD] & United Nations Educational, Scientific and Cultural Organization [UNESCO]. (2024). G7 toolkit for artificial intelligence in the public sector. OECD Publishing.
- Pahune S., Akhtar Z., Mandapati V., and Kamran Siddique, (2025). The Importance of AI Data Governance in Large Language Models. *Big Data and Cognitive Computing*. 9(6), 147.
- Parliamentary Inquiry Committee Childcare Benefits. (2021). Ongekende onrecht [Unprecedented injustice].
[https://www.coe.int/en/web/venice-commission/-/CDL-REF\(2021\)073-e](https://www.coe.int/en/web/venice-commission/-/CDL-REF(2021)073-e) [최종인출일: 2026.01.20.]
- Richardson, R. (2022). Defining and Demystifying Automated Decision Systems. *Maryland law review*. 81(3):785-840.
- Seyyed-Kalantari, L., Zhang, H., McDermott, M. B. A., Chen, I. Y., & Ghassemi, M. (2021). Underdiagnosis bias of artificial intelligence algorithms applied to chest radiographs in under-served patient populations. *Nature Medicine*. 27(12):2176-2182.
- Statistics Netherlands. (2022). Childcare benefits for over 1 million children. <https://www.cbs.nl/en-gb/news/2022/28/childcare-benefits-for-over-1-million-children> [최종인출일: 2026.01.20.]
- Steen, M., Timan, T., & van de Poel, I. (2021). Responsible innovation, anticipation and responsiveness: case studies of algorithms in decision support in justice and security, and an exploration of potential, unintended, undesirable, higher-order effects. *AI and Ethics*, 1(4):501-515.

- Tuominen, P., & Rask, M. (2022). Participatory budgeting – Case study in Helsinki, Finland. Deliverable D4.2. COLDIGIT Project. University of Helsinki.
- UK Government. (2023). A pro-innovation approach to AI regulation. AI White Paper. Department for Science, Innovation and Technology. London.
- Xu, J. (2024). Opening the ‘black box’ of algorithms: regulation of algorithms in China. *Communication Research and Practice*. 10(3):288-296.
- Yang, Y., Zhang, H., Gichoya, J. W., Katabi, D., & Ghassemi, M. (2024). The limits of fair medical imaging AI in real-world generalization. *Nature Medicine*. 30(10):2838-2848.



공공부문 AI기반 의사결정을 위한 신뢰 기반 거버넌스 설계 방안



한국행정연구원